Aprendizaje Computacional

Mario Graff

Tabla de contenidos

Prefacio **9**
Notación . . . 9
Licencia . . . 10

1 Introducción **11**
Paquetes usados . . . 11
1.1 Aprendizaje Computacional . . . 11
1.2 Predicción e Inferencia Causal . . . 12
1.3 Tipos de Aprendizaje Computacional . . . 14
1.4 Metodología General en Aprendizaje Supervisado y No Supervisado . . . 15
1.5 Aprendizaje No Supervisado . . . 16
1.6 Aprendizaje Supervisado . . . 20
1.7 Definiciones de Aprendizaje Supervisado . . . 25
1.7.1 Estilos de Aprendizaje . . . 27
1.7.2 Sobre-aprendizaje . . . 27
1.7.3 Sub-aprendizaje . . . 27
1.8 Organización del Libro . . . 29

2 Rendimiento **31**
Paquetes usados . . . 31
2.1 Introducción . . . 31
2.2 Conjunto de Entrenamiento y Prueba . . . 32
2.3 Clasificación . . . 32
2.3.1 Error . . . 33
2.3.2 Exactitud (*Accuracy*) . . . 34
2.3.3 Cobertura (*Recall*) . . . 34
2.3.4 Precisión (*Precision*) . . . 35
2.3.5 F_β . . . 35
2.3.6 Medidas Macro . . . 35
2.3.7 Entropía Cruzada . . . 36
2.3.8 Área Bajo la Curva *ROC* . . . 36
2.3.9 Ejemplo . . . 37
2.4 Regresión . . . 42
2.4.1 Ejemplo . . . 43

2.5 Conjunto de Validación y Validación Cruzada . . . 44
2.5.1 k-Iteraciones de Validación Cruzada . . . 47
2.6 Resumen . . . 50

3 Regresión y Regularización **51**
Paquetes usados . . . 51
3.1 Introducción . . . 51
3.2 Datos: Abandono Escolar . . . 52
3.3 Mínimos Cuadrados Ordinarios . . . 53
3.3.1 Ejemplo: Abandono Escolar . . . 55
3.3.2 Modelo Reducido . . . 57
3.4 Sesgo y Varianza . . . 59
3.5 Regresión Ridge . . . 61
3.6 Lasso . . . 62
3.6.1 Elastic Net . . . 66
3.7 Selección de λ por Validación Cruzada . . . 67
3.8 Los Coeficientes no se Interpretan Causalmente . . . 71
3.9 Focalización: un Problema de Política de Predicción . . . 73
3.10 Resumen . . . 76
Actividades . . . 76

4 Selección de Variables **78**
Paquetes usados . . . 78
4.1 Introducción . . . 78
4.2 Basada en Estadísticas . . . 79
4.2.1 Ventajas y Limitaciones . . . 80
4.3 Selección hacia Adelante y hacia Atrás . . . 80
4.3.1 Ventajas y Limitaciones . . . 83
4.4 Selección mediante Modelo . . . 83
4.4.1 Ventajas y Limitaciones . . . 84
4.5 Comparación de los Procedimientos . . . 85
4.6 Resumen . . . 88
Actividades . . . 89

5 Teoría de Decisión Bayesiana **90**
Paquetes usados . . . 90
5.1 Introducción . . . 90
5.2 Probabilidad . . . 91
5.2.1 Ejemplos . . . 91
5.3 Teorema de Bayes . . . 91
5.3.1 Problema Sintético . . . 92
5.3.2 Predicción . . . 94
5.4 Error de Clasificación . . . 97

5.5 Error Bayesiano . . . 99
5.6 Riesgo . . . 100
5.6.1 Acción nula . . . 101
5.7 Seleccionando la acción . . . 102
5.7.1 Ejemplo . . . 102
5.8 Resumen . . . 106

6 Métodos Paramétricos **107**
Paquetes usados . . . 107
6.1 Introducción . . . 107
6.2 Metodología . . . 108
6.3 Estimación de Parámetros . . . 108
6.3.1 Verosimilitud . . . 108
6.3.2 Distribución de Bernoulli . . . 109
6.3.3 Ejemplo: Distribución Gaussiana . . . 109
6.4 Metodología de Clasificación . . . 111
6.5 Clasificador . . . 112
6.5.1 Estimación de Parámetros . . . 112
6.5.2 Predicción . . . 114
6.5.3 Rendimiento . . . 115
6.6 Clasificador Bayesiano Ingenuo . . . 118
6.7 Ejemplo: Breast Cancer Wisconsin . . . 119
6.7.1 Entrenamiento . . . 120
6.7.2 Predicción . . . 120
6.7.3 Rendimiento . . . 120
6.8 Diferencias en Rendimiento . . . 120
6.9 Resumen . . . 125

7 Métodos No Paramétricos **126**
7.1 Paquetes usados . . . 126
7.2 Introducción . . . 126
7.3 Histogramas . . . 127
7.3.1 Selección del tamaño del bin . . . 127
7.4 Estimador de Densidad por Kernel . . . 129
7.4.1 Caso multidimensional . . . 131
7.5 Estimador de Densidad por Vecinos Cercanos . . . 132
7.6 Clasificador de vecinos cercanos . . . 132
7.6.1 Implementación . . . 134
7.7 Regresión . . . 136
7.8 Resumen . . . 137

8 Discriminantes Lineales **138**
8.1 Paquetes usados . . . 138

8.2 Introducción . . . 138
8.3 Función Discriminante . . . 139
8.3.1 Clasificación Binaria . . . 139
8.3.2 Geometría de la Función de Decisión . . . 140
8.3.3 Múltiples Clases . . . 144
8.4 Máquinas de Soporte Vectorial . . . 145
8.4.1 Kernel . . . 151
8.4.2 Regresión . . . 153
8.5 Regresión Logística . . . 153
8.5.1 Optimización . . . 154
8.5.2 Múltiples clases . . . 156
8.6 Comparación . . . 156
8.7 Resumen . . . 158

9 Optimización **159**
9.1 Paquetes usados . . . 159
9.2 Introducción . . . 159
9.3 Descenso por Gradiente . . . 160
9.3.1 Ejemplo - Regresión Lineal . . . 160
9.4 Diferenciación Automática . . . 163
9.4.1 Una Variable . . . 163
9.4.2 Dos Variables . . . 164
9.4.3 Visualización . . . 164
9.4.4 Regresión Lineal . . . 164
9.5 Regresión Logística . . . 166
9.6 Actualización de Parámetros . . . 169
9.7 Resumen . . . 170

10 Árboles de Decisión **171**
10.1 Paquetes usados . . . 171
10.2 Introducción . . . 171
10.3 Clasificación . . . 171
10.3.1 Predicción . . . 174
10.3.2 Entrenamiento . . . 174
10.3.3 Ejemplo: Breast Cancer Wisconsin . . . 177
10.4 Regresión . . . 178
10.4.1 Predicción . . . 178
10.4.2 Entrenamiento . . . 179
10.5 Resumen . . . 182

11 Ensambles **183**
11.1 Paquetes usados . . . 183
11.2 Introducción . . . 183

11.3 Fundamentos . . . 184
11.4 Bagging . . . 186
11.4.1 Ejemplo: Dígitos . . . 186
11.4.2 Ejemplo: Diabetes . . . 189
11.5 Bosques Aleatorios (Random Forest) . . . 192
11.6 Stack Generalization . . . 193
11.6.1 Ejemplo: Diabetes . . . 194
11.7 Resumen . . . 195

12 Redes Neuronales **197**
12.1 Paquetes usados . . . 197
12.2 Introducción . . . 197
12.3 Regresión Logística Multinomial . . . 197
12.3.1 Optimización . . . 199
12.3.2 Optimización Método Adam . . . 200
12.3.3 Comparación entre Optimizadores . . . 201
12.4 Perceptrón . . . 201
12.4.1 Composición de Perceptrones Lineales . . . 203
12.5 Perceptrón Multicapa . . . 203
12.5.1 Desvanecimiento del Gradiente . . . 204
12.6 Ejemplo: Dígitos . . . 205
12.7 Ejemplo: Diabetes . . . 208
12.8 Resumen . . . 215

13 Reducción de Dimensión **217**
Paquetes usados . . . 217
13.1 Introducción . . . 217
13.2 Análisis de Componentes Principales . . . 218
13.2.1 Ejemplo - Visualización . . . 218
13.3 UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction 220
13.4 Resumen . . . 223

14 Agrupamiento **224**
14.1 Paquetes usados . . . 224
14.2 Introducción . . . 224
14.3 K-medias . . . 225
14.3.1 μ_i . . . 225
14.3.2 G_i . . . 225
14.3.3 Algoritmo . . . 227
14.4 Maximización de la Expectativa . . . 229
14.4.1 K-medias como caso particular de EM . . . 231
14.5 Ejemplo: Iris . . . 233
14.6 Rendimiento . . . 234

14.7 Número de Grupos . . . 236
14.8 Resumen . . . 236

15 Comparación de Algoritmos **238**
15.1 Paquetes usados . . . 238
15.2 Introducción . . . 238
15.3 Intervalos de confianza . . . 239
15.3.1 Método: Distribución Normal . . . 239
15.3.2 Ejemplo: Exactitud . . . 239
15.3.3 Método: Bootstrap del error estándar . . . 241
15.3.4 Método: Percentil . . . 242
15.3.5 Ejemplo: macro-recall . . . 243
15.4 Comparación de Algoritmos . . . 244
15.4.1 Método: Distribución t de Student . . . 244
15.4.2 Método: Bootstrap en diferencias . . . 245
15.5 CompStats . . . 246
15.6 Resumen . . . 250

Referencias **251**

Apéndices **255**

A Estadística **255**
Paquetes usados . . . 255
A.1 Error estándar . . . 255
A.1.1 Media . . . 255
A.1.2 Ejemplo: Media . . . 256
A.1.3 Ejemplo: Coeficientes OLS . . . 258
A.2 Bootstrap . . . 258
A.2.1 Ejemplo . . . 259

B Conjunto de Datos **261**
Paquetes usados . . . 261
B.1 Problemas de Política Pública . . . 261
B.1.1 Pobreza . . . 262
B.1.2 Seguridad . . . 263
B.1.3 Salud . . . 265
B.1.4 Educación . . . 266
B.1.5 Territorio . . . 268
B.2 Problemas Sintéticos y Clásicos . . . 270
B.2.1 Problemas Sintéticos . . . 272
B.2.2 Problemas de Clasificación . . . 272

B.2.3 Problemas de Regresión 279

Prefacio

Este curso ha evolucionado de las clases de Aprendizaje Computacional impartidas en la Maestría en Ciencia de Datos e Información (MCDI) de INFOTEC y de Aprendizaje Computacional en la Maestría en Métodos para el Análisis de Políticas Públicas del CIDE.

La versión actual está orientada a la electiva *Machine Learning* de la Maestría en Métodos para el Análisis de Políticas Públicas (METPOL) del CIDE: se asume que quien lee ya cuenta con conocimientos de estadística, econometría, inferencia causal y evaluación de programas, y por ello los ejemplos y el orden de los capítulos buscan conectar el aprendizaje computacional con los problemas de política pública.

En la MCDI compartí el curso con la Dra. Claudia N. Sánchez y parte de este material, en particular algunas figuras, fueron generadas por la Dra. Sánchez.

El curso trata de ser auto-contenido, es decir, no debería de ser necesario leer otras fuentes para poder entenderlo y realizar las actividades. De cualquier manera es importante comentar que el curso está basado en los siguientes libros de texto:

- Introduction to machine learning, Third Edition. Ethem Alpaydin. MIT Press.
- Probabilistic Machine Learning: An Introduction. Kevin Patrick Murphy. MIT Press.
- An Introduction to Statistical Learning with Applications in R. Gareth James, Daniela Witten, Trevor Hastie, and Robert Tibshirani. Springer Texts in Statistics.
- All of Statistics. A Concise Course in Statistical Inference. Larry Wasserman. MIT Press.
- An Introduction to the Bootstrap. Bradley Efron and Robert J. Tibshirani. Monographs on Statistics and Applied Probability 57. Springer-Science+Business Media.
- Understanding Machine Learning: From Theory to Algorithms. Shai Shalev-Shwartz and Shai Ben-David. Cambridge University Press.

Notación

La Tabla 1 muestra la notación que se seguirá en este documento.

Tabla 1: Notación

Símbolo	Significado
x	Variable usada comúnmente como entrada

Símbolo	Significado
y	Variable usada comúnmente como salida
$\mathbb{R}$	Números reales
$\mathbf{x}$	Vector Columna $\mathbf{x} \in \mathbb{R}^d$
$\|\mathbf{x}\|$	Norma Euclidiana
d	Dimensión
$\mathbf{w} \cdot \mathbf{x}$	Producto punto donde $\mathbf{w}$ y $\mathbf{x} \in \mathbb{R}^d$
$W^\top$	Transpuesta de la matriz W
$\mathcal{D}$	Conjunto de datos
$\mathcal{T}$	Conjunto de entrenamiento
$\mathcal{V}$	Conjunto de validación
$\mathcal{G}$	Conjunto de prueba
N	Número de ejemplos
K	Número de clases
$\mathbb{P}(\cdot)$	Probabilidad
$\mathcal{X}, \mathcal{Y}$	Variables aleatorias
$\mathcal{N}(\mu, \sigma^2)$	Distribución Normal con parámetros μ y σ^2
$f_\mathcal{X}$	Función de densidad de probabilidad de $\mathcal{X}$
$\mathbb{1}(e)$	Función para indicar; 1 si e es verdadero
Ω	Espacio de búsqueda
$\mathbb{V}$	Varianza
$\mathbb{E}$	Esperanza

Licencia

Esta obra está bajo una Licencia Creative Commons Atribución-CompartirIgual 4.0 Internacional

1 Introducción

El **objetivo** de la unidad es explicar el área de aprendizaje computacional, los diferentes tipos de aprendizaje que la componen, la metodología general del área y su relación con otras áreas del conocimiento, en particular con el análisis de políticas públicas.

Paquetes usados

```
import numpy as np
import pandas as pd
from matplotlib import pylab as plt
import seaborn as sns
from CompStats.metrics import recall_score
from sklearn.model_selection import train_test_split
from sklearn.datasets import load_iris
from sklearn.datasets import load_breast_cancer
from sklearn.datasets import fetch_openml
from sklearn.preprocessing import Normalizer
from sklearn.pipeline import make_pipeline
from sklearn.cluster import KMeans
from sklearn import decomposition
from sklearn.svm import LinearSVC
from sklearn.naive_bayes import GaussianNB
from sklearn.discriminant_analysis import QuadraticDiscriminantAnalysis as QDA
from sklearn.discriminant_analysis import LinearDiscriminantAnalysis as LDA
from sklearn.ensemble import RandomForestClassifier
from sklearn.neighbors import KNeighborsClassifier
from sklearn import tree
```

1.1. Aprendizaje Computacional

Según la descripción de Langley (1986), el **aprendizaje computacional** es una rama de la Inteligencia Artificial (IA) que estudia los enfoques computacionales capaces de aprender y

mejorar su rendimiento con el tiempo. Inicialmente, el campo se centraba en el desarrollo de representaciones simbólicas, al igual que la IA, aunque también permitía representaciones numéricas. Actualmente, el enfoque ha cambiado, privilegiando las representaciones numéricas sobre las simbólicas. Este documento se centra exclusivamente en las representaciones numéricas.

> Actividad
>
> Leer la carta editorial de Langley (1986) para conocer la visión que se tenía de aprendizaje computacional en esa época y contrastarla con la visión actual.

Según Breiman (2001b), al analizar datos con valores de entrada y respuesta, existen dos objetivos principales: **predecir** la respuesta de futuros eventos y **extraer conocimiento** del proceso o fenómeno. Estos objetivos han dado origen a dos enfoques en el modelado de datos: la cultura del modelado de datos y la cultura del modelado de algoritmos.

En la cultura del modelado de datos, se asume que los datos provienen de una función que depende de los valores de entrada, un conjunto de parámetros y ruido. Utilizando los datos, se estiman los parámetros y, si los datos cumplen con las condiciones impuestas a la función, se puede conocer el procedimiento que genera los datos, logrando así el segundo objetivo. Con los parámetros y la estructura de la función, es posible hacer predicciones de futuros eventos (primer objetivo).

En la cultura del modelado de algoritmos, no se asume ninguna estructura para el sistema que genera los datos. El enfoque es diseñar un algoritmo que replique la respuesta dada las entradas. Dado que no se asume ningún modelo particular, obtener conocimiento del sistema no es una prioridad. En cambio, la prioridad es encontrar el algoritmo que mejor reproduzca los datos, desarrollando diversas estrategias para medir el rendimiento del algoritmo y estimar su comportamiento en diferentes escenarios. El área de aprendizaje computacional se encuentra en esta segunda cultura.

> Actividad
>
> Leer el artículo de Breiman (2001b) para profundizar en las ventajas y desventajas de cada una de las culturas y cómo estas influyen en la forma de abordar un problema. En este momento no es necesario detenerse en la parte técnica de los algoritmos descritos en el artículo.

1.2. Predicción e Inferencia Causal

La oposición que plantea Breiman (2001b) entre las dos culturas tiene una lectura directa en el análisis de políticas públicas. En el trabajo cotidiano de evaluación se estima un efecto, τ, por ejemplo cuánto cambia la deserción escolar por haber participado en un programa de becas.

Ese es un problema de la cultura del modelado de datos, donde importa la interpretación del parámetro y las condiciones que permiten darle un significado causal. En cambio, en un problema de predicción lo que se estima es $\hat{y}$, el valor de la respuesta para una entrada nueva, y lo que importa es qué tan cerca está de y en datos no vistos. Aquí los coeficientes del modelo, si los hay, no se interpretan causalmente.

Kleinberg et al. (2015) muestran que una parte importante de las decisiones públicas depende de $\hat{y}$ y no de τ, a las cuales llaman *prediction policy problems* (problemas de política de predicción). Su ejemplo es decidir a quién operar de la cadera. El beneficio de la operación depende de la probabilidad de que la persona sobreviva los años siguientes, y lo que se requiere es predecir esa probabilidad. Estos problemas se ubican en la cultura del modelado de algoritmos, por lo que son el terreno natural del aprendizaje computacional. Algunos ejemplos son la focalización de programas sociales (predecir qué hogares están en pobreza para dirigirles el apoyo), la priorización de inspecciones (predecir qué establecimientos incumplen la norma), el riesgo de deserción escolar (predecir qué estudiantes abandonarán la escuela para atenderlos antes) y la administración de listas de espera en salud (predecir qué pacientes tienen mayor riesgo para ordenar la atención). Por el contrario, preguntar si el programa de becas redujo la deserción, o si una política de salud mejora los resultados, es un problema causal para el cual la predicción por sí sola no es suficiente y se requiere el diseño de investigación y los supuestos que se estudian en inferencia causal.

Que un problema sea de predicción no significa, sin embargo, que una predicción exacta baste para decidir bien. Sarewitz y Pielke (1999) sostienen que la predicción se ha vuelto el producto científico que más demanda la política, pero que su utilidad para decidir depende, además de la exactitud, del contexto de decisión, de cómo se comunica la incertidumbre, de la relación entre quienes predicen y quienes deciden, y de si existen alternativas a predecir, como las políticas robustas ante la incertidumbre. Advierten también que una predicción puede desplazar la responsabilidad política y generar falsa confianza. Sus ejemplos son ambientales y de riesgo (sismos, clima, inundaciones), y en ellos el aprendizaje computacional puede ser una de las técnicas para estimar esos eventos.

Las dos lecturas se complementan. Kleinberg et al. (2015) indican qué decisiones públicas requieren $\hat{y}$ y Sarewitz y Pielke (1999) qué hace falta, además de exactitud, para que esa $\hat{y}$ sirva para decidir. Este libro cubre dos de esos elementos, la medición honesta del rendimiento fuera de muestra (Capítulo 2) y los costos asimétricos de las decisiones (Capítulo 5).

Mullainathan y Spiess (2017) traducen esta distinción al lenguaje de la econometría, donde la tarea de estimar $\hat{y}$ se contrapone a la de estimar $\widehat{\beta}$, y muestran que la regularización y la validación cruzada sustituyen a la especificación a mano del modelo como mecanismo para controlar la complejidad. Finalmente, Belloni et al. (2014) y Athey y Imbens (2019) reconcilian las dos culturas al poner las herramientas de la cultura algorítmica, por ejemplo Lasso para elegir controles o bosques para estimar efectos heterogéneos, al servicio de la estimación de un efecto causal con inferencia válida. Athey (2019) ofrece un panorama más amplio del impacto del aprendizaje computacional en la economía, desde las aplicaciones a texto e imágenes hasta

los problemas de política de predicción, la equidad y la combinación con inferencia causal. Este libro se enfoca en las herramientas de predicción.

Actividad

Leer los siguientes artículos, escritos para economistas y analistas de política. Cada uno aporta una perspectiva distinta y complementaria a este capítulo.

- Kleinberg et al. (2015) define los *prediction policy problems* y los distingue de los problemas causales.
- Mullainathan y Spiess (2017) explican aprendizaje computacional desde la econometría y por qué los coeficientes de un modelo predictivo no se interpretan causalmente. Es la lectura puente más cercana al perfil de este curso.
- Athey y Imbens (2019) presentan un panorama de los métodos (regularización, árboles, bosques, redes y aprendizaje no supervisado) y de cómo se combinan con inferencia causal. Sirve de mapa de todo el libro.
- Athey (2019) evalúa las primeras contribuciones del aprendizaje computacional a la economía, repasa aplicaciones como texto e imágenes, discute los *prediction policy problems* y las consideraciones de equidad y manipulabilidad, y resume la literatura que combina aprendizaje computacional con inferencia causal. Es un texto más amplio y anterior al de Athey e Imbens.
- Belloni et al. (2014) muestran cómo usar Lasso para elegir controles y seguir estimando un efecto de tratamiento con inferencia válida.
- Varian (2014) es una introducción ligera a árboles, bosques, validación cruzada y selección de variables para economistas, con ejemplos. Es la más accesible de las siete.
- Sarewitz y Pielke (1999) es el contrapunto. Discute por qué la utilidad de una predicción para decidir depende del contexto de decisión y de la comunicación de la incertidumbre, y no solo de su exactitud.

1.3. Tipos de Aprendizaje Computacional

Existen diferentes tipos de aprendizaje computacional, los más comunes son: aprendizaje supervisado, aprendizaje no-supervisado y aprendizaje por refuerzo. En **aprendizaje supervisado** se crean modelos partiendo de un conjunto de pares, entrada y salida, donde el objetivo es encontrar un modelo que logra aprender esta relación y predecir ejemplos no vistos en el proceso, en particular a esto se le conoce como *inductive learning*. Complementando este tipo de aprendizaje supervisado se tiene lo que se conoce como *transductive learning*, en el cual se cuenta con un conjunto de pares y solamente se requiere conocer la salida en otro conjunto de datos. En este segundo tipo de aprendizaje todos los datos son conocidos en el proceso de aprendizaje.

Aprendizaje no-supervisado es aquel donde se tiene un conjunto de entradas y se busca aprender alguna relación de estas entradas, por ejemplo, generando grupos o utilizando estas entradas para hacer una transformación o encontrar un patrón.

Finalmente **aprendizaje por refuerzo** es aquel donde se tiene un agente que tiene que aprender cómo interactuar con un ambiente. La interacción es tomando una acción en cada diferente estado del ambiente. Por ejemplo, el agente puede ser un jugador virtual en un juego de ajedrez entonces la acción es identificar y mover una pieza en el tablero, el objetivo de ganar la partida. La característica de aprendizaje por refuerzo es que el agente va a recibir una recompensa al final de la interacción con el ambiente, e.g., final del juego y el objetivo es optimizar las acciones para que la recompensa sea la mayor posible.

El área de aprendizaje computacional ha tenido un crecimiento importante en los últimos años, algunos ejemplos del impacto de área se pueden encontrar en artículos publicados en la revista de la editorial Nature. Por ejemplo, en el área médica en específico en Cardiología Hannun et al. (2019) propone una metodología para detectar arritmias o en dermatología Esteva et al. (2017) propone un algoritmo para la detección de cáncer.

Cabe mencionar que los tres tipos de aprendizaje no son excluyentes uno del otro, comúnmente para resolver un problema complejo se combinan diferentes tipos de aprendizaje y otras tecnologías de IA para encontrar una solución aceptable. Probablemente una de las pruebas más significativas de lo que puede realizarse con aprendizaje automático es lo realizado por AlphaGo descrito por Silver et al. (2016) y en Silver et al. (2017) se quitan una de las restricciones originales, la cual consiste en contar con un conjunto de jugadas realizadas por expertos.

En el área de aprendizaje, hay una tendencia de utilizar plataformas donde diferentes empresas u organismos gubernamentales o sin fines de lucro, ponen un problema e incentivan al público en general a resolver este problema. La plataforma sirve de mediador en este proceso. Ver por ejemplo https://www.kaggle.com.

En el ámbito científico también se han generado este tipo de plataformas aunque su objetivo es ligeramente diferente, lo que se busca es tener una medida objetiva de diferentes soluciones y en algunos casos facilitar la reproducibilidad de las soluciones. Ver por ejemplo http://codalab.org.

1.4. Metodología General en Aprendizaje Supervisado y No Supervisado

Antes de continuar con la descripción de los diferentes tipos de aprendizaje es importante mencionar la metodología que se sigue en los problemas de aprendizaje supervisado y no supervisado

1. Todo empieza con un conjunto de datos $\mathcal{D}$ que tiene la información del fenómeno de interés.

2. Se selecciona el conjunto de entrenamiento $\mathcal{T} \subseteq \mathcal{D}$.
3. Se diseña un algoritmo, f, utilizando $\mathcal{T}$.
4. Se utiliza f para estimar las características modeladas.
5. Se mide el rendimiento de f.

1.5. Aprendizaje No Supervisado

Iniciamos la descripción de los diferentes tipos de aprendizaje computacional con **aprendizaje no-supervisado**; el cual inicia con un conjunto de elementos. Estos tradicionalmente se pueden transformar en un conjunto de vectores, i.e. $\mathcal{D} = \{x_1, \ldots, x_N\}$, donde $x_i \in \mathbb{R}^d$. Durante este curso asumiremos que esta transformación existe y en algunos casos se hará explícito el algoritmo de transformación.

El **objetivo** en aprendizaje no supervisado es desarrollar algoritmos capaces de encontrar patrones en los datos, es decir, en $\mathcal{D}$. Existen diferentes tareas que se pueden considerar dentro de este tipo de aprendizaje. Por ejemplo, el agrupamiento puede servir para segmentar clientes o productos, en otra línea también cabría el análisis del carrito de compras (Market Basket Analysis); donde el objetivo es encontrar las co-ocurrencias de productos, es decir, se quiere estimar la probabilidad de que habiendo comprado un determinado artículo también se compre otro artículo. Con esta descripción ya se podrá estar imaginando la cantidad de aplicaciones en las que este tipo de algoritmos es utilizado en la actualidad.

Regresando a la representación vectorial, existen casos donde se pueden visualizar los elementos de $\mathcal{D}$, los cuales están representados como puntos que se muestran en la Figura 1.1. Claramente esto solo es posible si $x_i \in \mathbb{R}^2$ o si se hace algún tipo de transformación $f : \mathbb{R}^d \to \mathbb{R}^2$, como se realizó en la figura.

En la Figura 1.1 se pueden observar dos o tres grupos de puntos, entonces el objetivo sería crear el algoritmo que dado $\mathcal{D}$ regrese un identificador por cada elemento, dicho identificador representa el grupo al que pertenece el elemento en cuestión. Esta tarea se le conoce como agrupamiento (Clustering). Asumiendo que se aplica un algoritmo de agrupamiento a los datos anteriores; entonces, dado que podemos visualizar los datos, es factible representar el resultado del algoritmo si a cada punto se le asigna un color dependiendo de la clase a la que pertenece. La Figura 1.2 muestra el resultado de este procedimiento.

Se puede observar en la figura anterior, el algoritmo de agrupamiento separa los puntos en tres grupos, representados por los diferentes colores. Cabe mencionar que utilizando algún otro criterio de optimización se hubiera podido encontrar dos grupos, el primero de ellos sería el grupo de los puntos que se encuentran a la izquierda de la figura y el segundo sería el grupo formado por los grupos que se encuentran en el centro y a la derecha de la figura. Es importante recalcar que no es necesario visualizar los datos para aplicar un algoritmo de agrupamiento. En particular el ejercicio de visualización de datos y del resultado de agrupamiento que se muestra

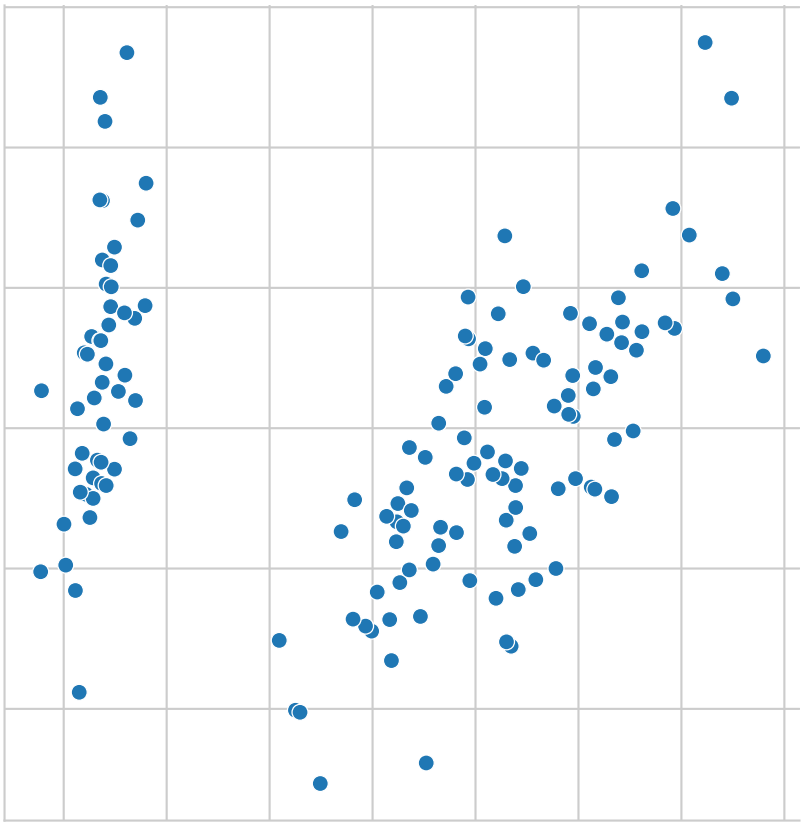


Figura 1.1: Proyección de los datos del Iris en dos dimensiones

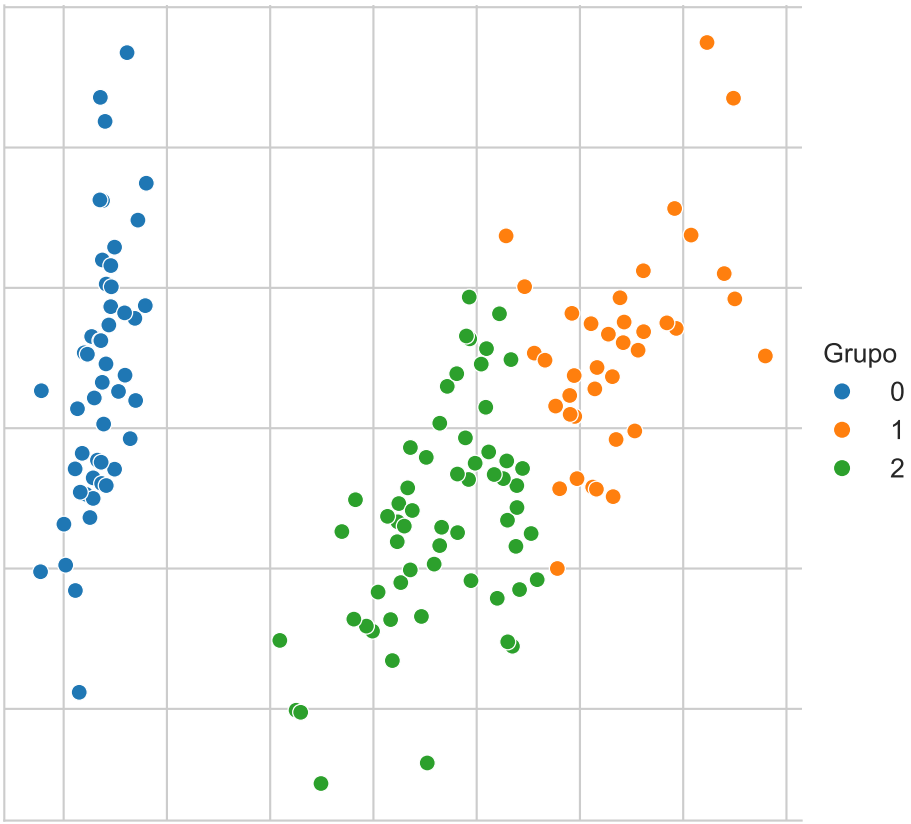


Figura 1.2: Proyección de agrupar los datos del Iris usando K-medias

en las figuras anteriores tiene el objetivo de generar una intuición de lo que está haciendo un algoritmo de agrupamiento.

Actividad

Generar la figura anterior para el conjunto de datos de Breast Cancer Wisconsin (Sección B.2.2.1). Es necesario considerar que ese problema solamente tiene dos clases y el problema del Iris (Sección B.2.2.2) tiene tres clases, entonces se tienen que hacer las modificaciones para atender este cambio.
El procedimiento desarrollado debe de generar una figura similar a la mostrada en la Figura 1.3

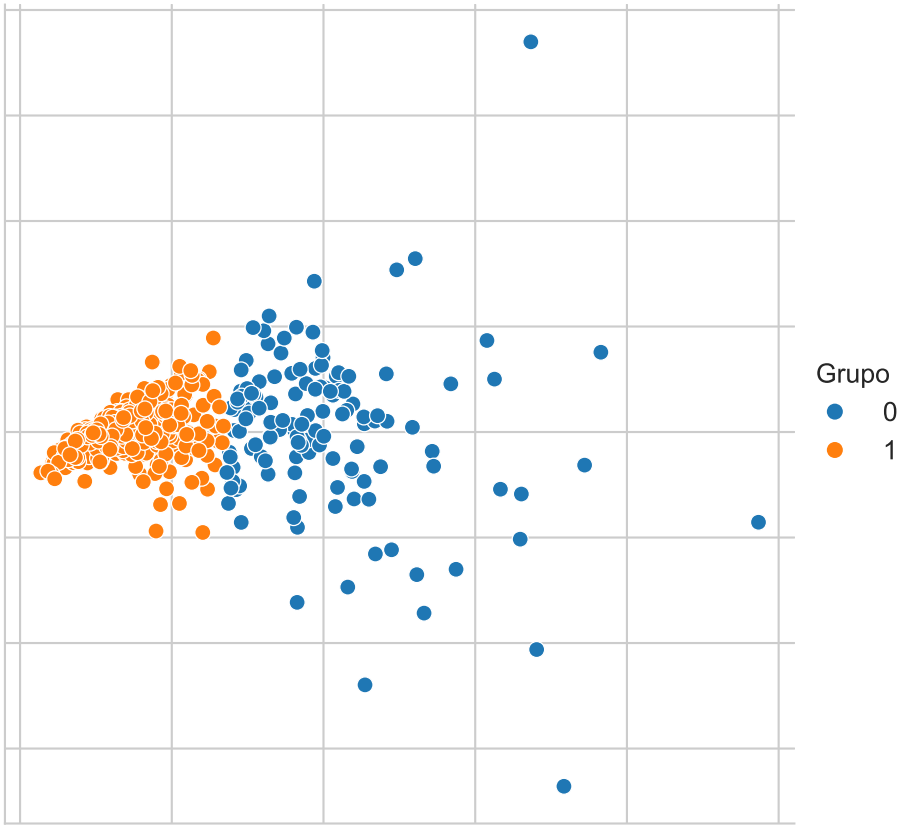


Figura 1.3: Proyección de agrupar los datos de Breast Cancer Wisconsin usando K-medias

1.6. Aprendizaje Supervisado

Aprendizaje supervisado inicia con un conjunto de pares, entrada y salida; la Figura 1.4 ilustra el mecanismo que genera estos pares, del lado izquierdo se tiene las variables medibles que entran al proceso o fenómeno que se desconoce y del lado derecho se mide la(s) variable(s) respuesta, es decir, la(s) salida(s) del sistema. En otras palabras se tiene $\mathcal{D} = \{(x_1, y_1), \ldots, (x_N, y_N)\}$, donde $x_i \in \mathbb{R}^d$ corresponde a la i-ésima entrada y y_i es la salida asociada a esa entrada.



Figura 1.4: Datos de Aprendizaje Supervisado

Considerando que se desconoce el modelo del proceso o fenómeno que generó la respuesta y además que pueden existir variables de entrada que no son medibles, se puede definir el **objetivo** de aprendizaje supervisado como encontrar un algoritmo o función, f, capaz de regresar la salida, y, dada una entrada x.

Los posibles fines de desarrollar la función f es por un lado **predecir** la salida dada una nueva entrada x y por el otro lado **extraer conocimiento** del proceso que asocia la respuesta de las variables de entrada (ver Breiman (2001b)). Estas dos metas se pueden contraponer, es decir, extraer conocimiento implica una reducción en la calidad de la predicción y viceversa mejorar la calidad de predicción en general trae consigo una menor capacidad para entender el fenómeno generador de datos.

Existe una gran variedad de problemas que se puede categorizar como tareas de aprendizaje supervisado, solamente hay que recordar que en todos los casos se inicia con un conjunto $\mathcal{D}$ de pares entrada y salida. En ocasiones la construcción del conjunto es directa, por ejemplo en el caso de que se quiera identificar si una persona será sujeta a un crédito, entonces el conjunto a crear está compuesto por las características de las personas que se les ha otorgado un crédito y el estado final de crédito, es decir, si el crédito fue pagado o no fue pagado. En otro ejemplo, suponiendo que se quiere crear un algoritmo capaz de identificar si un texto dado tiene una polaridad positiva o negativa, entonces el conjunto se crea recolectando textos y a cada texto un conjunto de personas decide si el texto dado es positivo o negativo y la polaridad final es el consenso de varias opiniones; a este problema en general se le conoce como análisis de sentimientos.

La cantidad de problemas que se pueden poner en términos de aprendizaje supervisado es amplia, un problema tangible en esta época y relacionado a la pandemia del COVID-19 sería el crear un algoritmo que pudiera predecir cuántos serán los casos positivos el día de mañana dando como entradas las restricciones en las actividades; por ejemplo escuelas cerradas, restaurantes al 30 % de capacidad entre otras.

Los ejemplos anteriores corresponden a dos de las clases de problemas que se resuelven en aprendizaje supervisado estas son problemas de clasificación y regresión. Definamos de manera formal estos dos problemas. Cuando $y \in \{0, 1\}$ se dice que es un problema de **clasificación binaria**, por otro lado cuando $y \in \{0, 1\}^K$ se encuentra uno en clasificación **multi-clase** o **multi-etiqueta** y finalmente si $y \in \mathbb{R}$ entonces es un problema de **regresión**.

Haciendo la liga entre los ejemplos y las definiciones anteriores, podemos observar que el asignar un crédito o la polaridad a un texto es un problema de clasificación binaria, dado que se puede asociar 0 y 1 a la clase positivo y negativo; y en el otro caso a pagar o no pagar el crédito. Si el problema tiene más categorías, supongamos que se desea identificar positivo, negativo o neutro, entonces se estaría en el problema de clasificación multi-clase. Por otro lado el problema de predecir el número de casos positivos se puede considerar como un problema de regresión, dado que el valor a predecir difícilmente se podría considerar como una categoría.

Al igual que en aprendizaje no supervisado, en algunos casos es posible visualizar los elementos de $\mathcal{D}$, el detalle adicional es que cada objeto tiene asociado una clase, entonces se selecciona un color para representar cada clase. En la Figura 1.5 se muestra el resultado donde los elementos de $\mathcal{D}$ se encuentran en $\mathbb{R}^2$ y el color representa cada una de las clases de este problema de clasificación binaria.

Actividad

Generar la figura anterior para el conjunto de datos de Breast Cancer Wisconsin (Sección B.2.2.1). Como se mencionó, el problema tiene dos clases entonces no se necesita ningún tipo de transformación en el número de clases como se hizo en el ejemplo anterior. La Figura 1.6 muestra el resultado de la actividad.

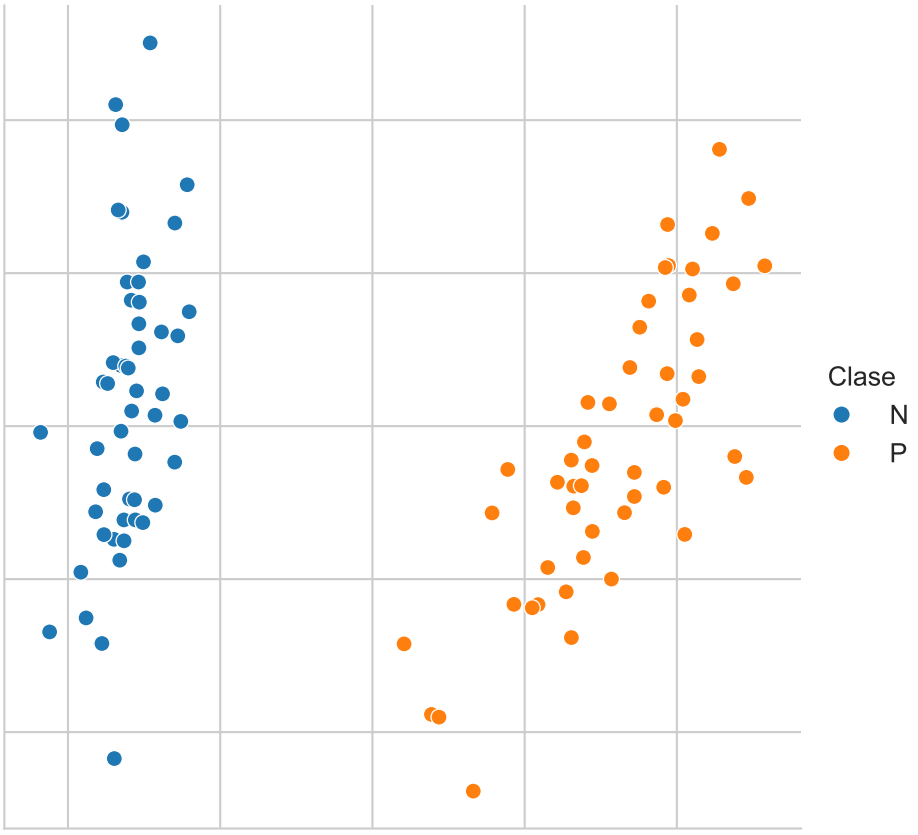


Figura 1.5: Proyección del Iris mostrando dos clases linealmente separables

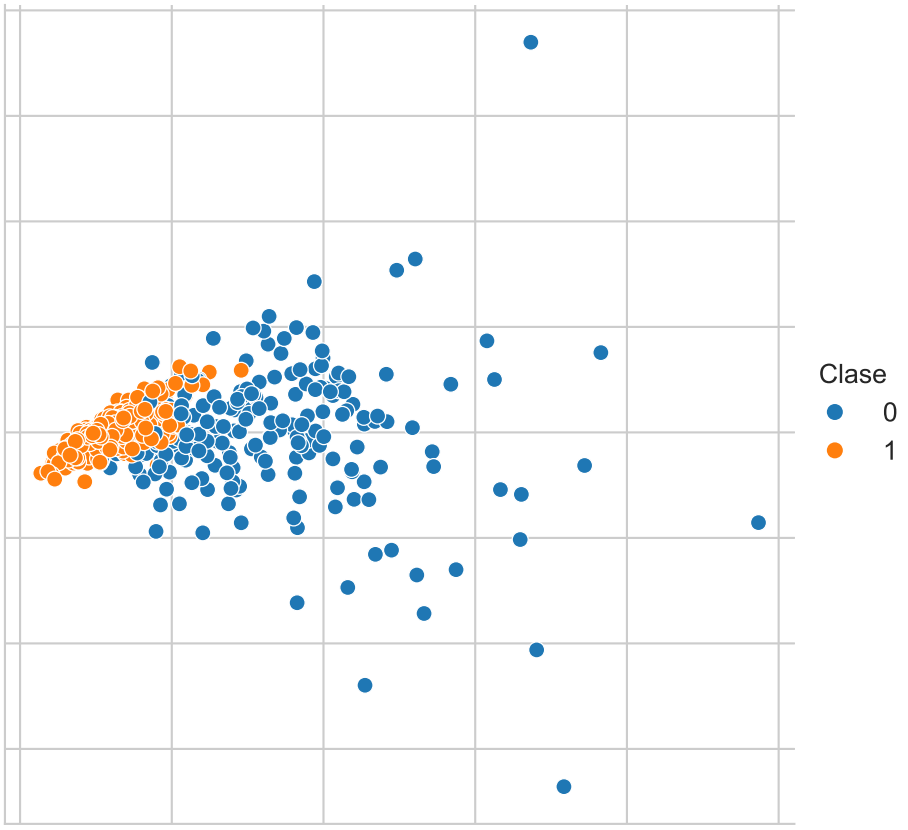


Figura 1.6: Proyección de los datos de Breast Cancer Wisconsin.

Usando esta representación es sencillo imaginar que el problema de clasificación se trata en encontrar una función que separe los puntos naranjas de los puntos azules, como se puede imaginar una simple línea recta podría separar estos puntos. La Figura 1.7 muestra un ejemplo de lo que haría un clasificador representado por la línea; la clase es dada por el signo de $ax + by + c$, donde a, b y c son parámetros identificados a partir de $\mathcal{D}$.

Siguiendo en esta misma línea, también es posible observar los puntos en un problema de regresión, solamente que en este caso un eje corresponde a las entradas, i.e. x, y el otro eje es la salida, i.e. y. La Figura 1.8 muestra un ejemplo de regresión, donde se puede observar que la idea es encontrar una función que pueda seguir de manera adecuada los puntos dados.

El problema de regresión es muy conocido y seguramente ya se imaginaron que la respuesta sería encontrar los parámetros de una parábola. La Figura 1.9 muestra una visualización del regresor, mostrado en color negro y los datos de entrenamiento en color azul.

Al igual que en aprendizaje no supervisado, este ejercicio de visualización no es posible en todos los problemas de aprendizaje supervisado, pero sí permite ganar intuición sobre la forma

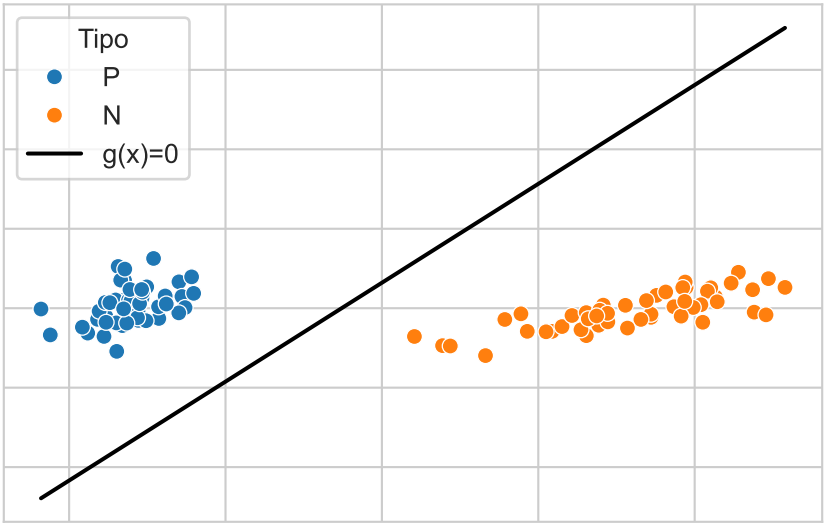


Figura 1.7: Proyección del Iris mostrando dos clases linealmente separables

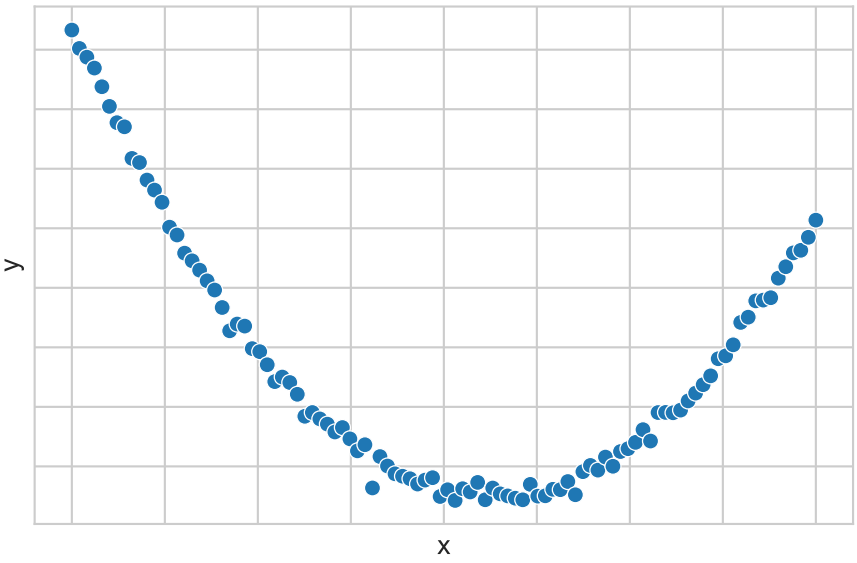


Figura 1.8: Problema de regresión

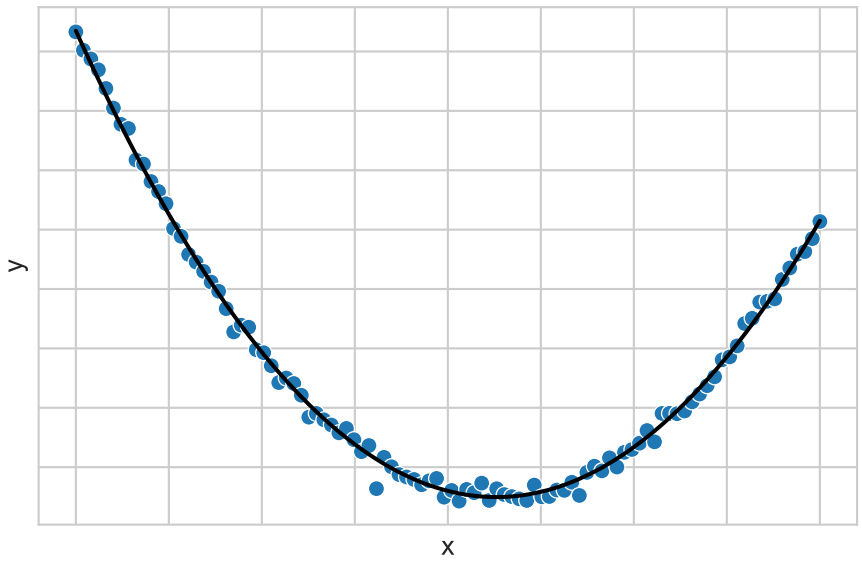


Figura 1.9: Problema de regresión con función estimada

en que trabajan estos algoritmos.

1.7. Definiciones de Aprendizaje Supervisado

El primer paso es empezar a definir los diferentes conjuntos con los que se trabaja en aprendizaje computacional. Todo inicia con el **conjunto de entrenamiento** identificado en este documento como $\mathcal{T}$. Este conjunto se utiliza para estimar los parámetros o en general buscar un algoritmo que tenga el comportamiento esperado.

Se puede asumir que existe una función f que genera la relación entrada salida mostrada en $\mathcal{T}$, es decir, idealmente se tiene que $\forall_{(x,y)\in\mathcal{D}} f(x) = y$. En este contexto, aprendizaje supervisado se entiende como el proceso de encontrar una función h^* que se comporta similar a f.

Para encontrar h^*, se utiliza $\mathcal{T}$; el conjunto de hipótesis (funciones), $\mathcal{H}$, que se considera puede aproximar f; una función de error, L; y el error empírico $E(h \mid \mathcal{T}) = \sum_{(x,y)\in\mathcal{T}} L(y, h(x))$. Utilizando estos elementos la función buscada es: $h^* = \mathsf{argmin}_{h\in\mathcal{H}} E(h \mid \mathcal{T})$.

El encontrar la función h^* no resuelve el problema de aprendizaje en su totalidad, además se busca una función que sea capaz de generalizar, es decir, que pueda predecir correctamente instancias no vistas. Considerando que se tiene un **conjunto de prueba**, $\mathcal{G} = \{(x_i, y_i)\}$ para $i = 1 \ldots M$, donde $\mathcal{T} \cap \mathcal{G} = \emptyset$ y $\mathcal{T} \cup \mathcal{G} = \mathcal{D}$. La idea es que el error empírico sea similar en el conjunto de entrenamiento y prueba. Es decir $E(h^* \mid \mathcal{T}) \approx E(h^* \mid \mathcal{G})$.

El conjunto de prueba $\mathcal{G}$ se utiliza para medir el error empírico y comparar el rendimiento de diferentes algoritmos, permitiendo seleccionar el que tenga las mejores características. La Figura 1.10 muestra el rendimiento utilizando el promedio de la cobertura (macro-recall, ver Capítulo 2). En la figura se observa el rendimiento de clasificadores Gaussianos Ingenuo, LDA (Capítulo 6), Máquinas de Soporte Vectorial lineal (M.S.V., ver Capítulo 8), Vecinos Cercanos (Capítulo 7) y Árboles Aleatorios (Capítulo 11). Se destaca que la M.S.V. presentó el mejor rendimiento, aunque estadísticamente es equivalente a algunos algoritmos marcados con la etiqueta *Equivalente* y es estadísticamente mejor que otros algoritmos marcados con la etiqueta *Diferente*.

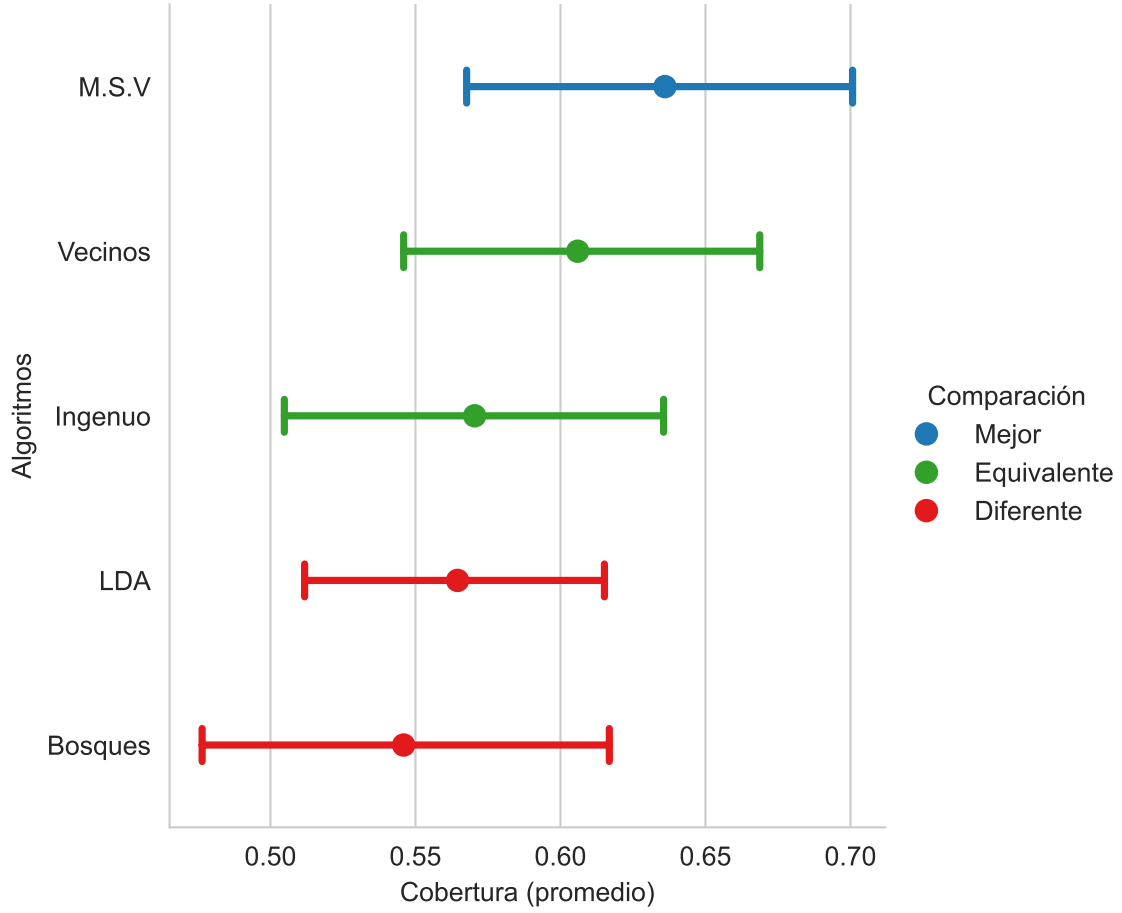


Figura 1.10: Comparación del rendimiento de algoritmos de clasificación en el conjunto de prueba.

1.7.1. Estilos de Aprendizaje

Utilizando $\mathcal{T}$ y $\mathcal{G}$ podemos definir **inductive learning** como el proceso de aprendizaje en donde solamente se utiliza $\mathcal{T}$ y el algoritmo debe de ser capaz de predecir cualquier instancia. Por otro lado, **transductive learning** es el proceso de aprendizaje donde se utiliza $\mathcal{T} \cup \{x \mid (x, y) \in \mathcal{G}\}$ para aprender y solamente es de interés el conocer la clase o variable dependiente del conjunto $\mathcal{G}$.

1.7.2. Sobre-aprendizaje

Existen clases de algoritmos, $\mathcal{H}$, que tienen un mayor grado de libertad el cual se ve reflejado en una capacidad superior para aprender, pero por otro lado, existen problemas donde no se requiere tanta libertad, esta combinación se traduce en que el algoritmo no es capaz de generalizar y cuantitativamente se ve como $E(h^* \mid \mathcal{T}) \ll E(h^* \mid \mathcal{G})$.

Para mostrar este caso hay que imaginar que se tiene un algoritmo que guarda el conjunto de entrenamiento y responde lo siguiente:

$$h^*(x) = \begin{cases} y & \text{si}(x, y) \in \mathcal{T} \\ 0 \end{cases}$$

Es fácil observar que este algoritmo tiene $E(h^* \mid \mathcal{T}) = 0$ dado que se aprende todo el conjunto de entrenamiento.

La Figura 1.11 muestra el comportamiento de un algoritmo que sobre-aprende, el algoritmo se muestra en la línea negra, la línea azul corresponde a una parábola (cuyos parámetros son identificados con los datos de entrenamiento) y los datos de entrenamiento no se muestran (se pueden observar en la Figura 1.8); estos corresponden a una parábola más un error gaussiano. Entonces podemos ver que la línea negra pasa de manera exacta por todos los datos de entrenamiento y da como resultado la línea negra que claramente tiene un comportamiento más complejo que el comportamiento de la parábola que generó los datos.

1.7.3. Sub-aprendizaje

Por otro lado existen problemas donde el conjunto de algoritmos $\mathcal{H}$ no tiene los grados de libertad necesarios para aprender, dependiendo de la medida de error esto se refleja como $E(h^* \mid \mathcal{T}) \gg 0$. La Figura 1.12 muestra un problema de regresión donde el algoritmo de aprendizaje presenta el problema de sub-aprendizaje.

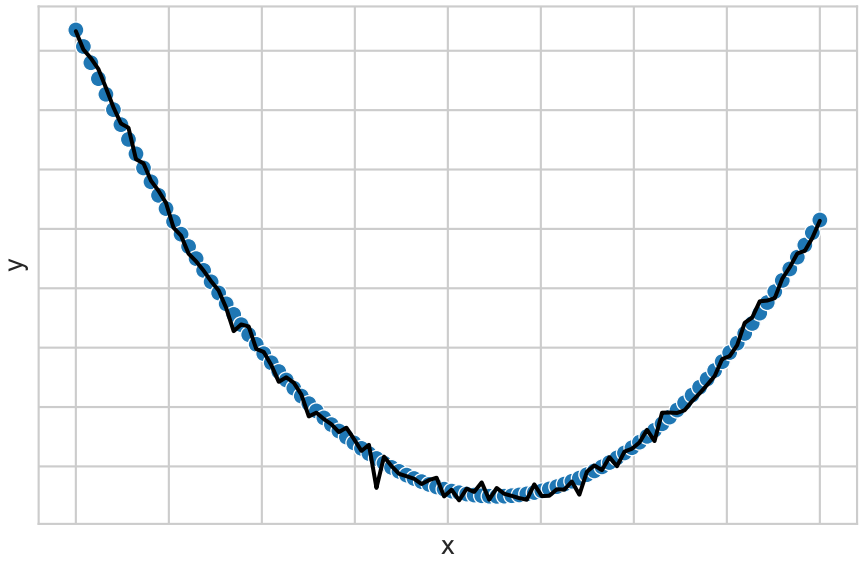


Figura 1.11: Sobre-aprendizaje en un problema de regresión

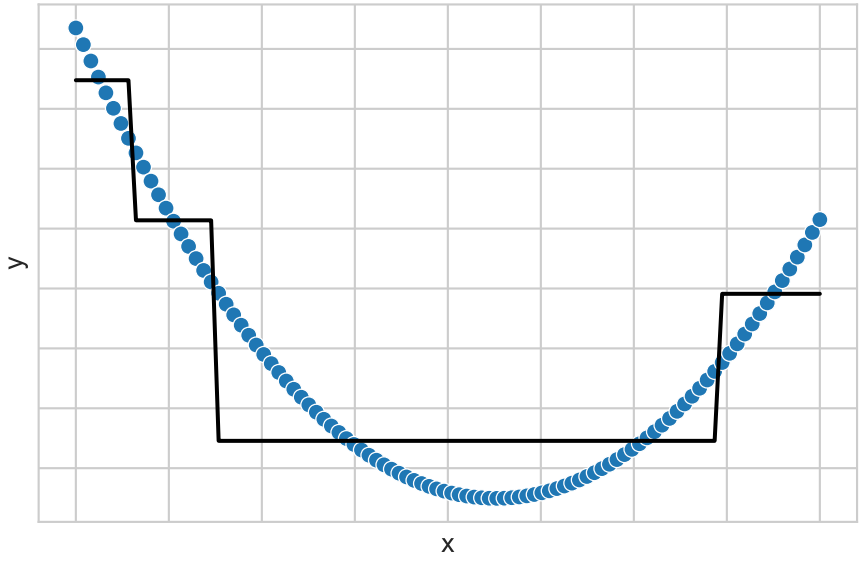


Figura 1.12: Sub-aprendizaje en un problema de regresión

1.8. Organización del Libro

El libro sigue un orden que parte de las preguntas de predicción que ya conoce quien estudió econometría y avanza hacia métodos más flexibles. La Tabla 1.1 resume los bloques, los capítulos que los componen y el curso de METPOL con el que se conectan. Los capítulos marcados como "en preparación" todavía no forman parte de esta versión.

Tabla 1.1: Organización del libro

Bloque	Capítulos	Conexión con METPOL
Marco	Introducción (Capítulo 1) y Rendimiento (Capítulo 2): qué es predecir, cómo se separan los datos y cómo se mide el rendimiento fuera de muestra.	Estadística, Econometría
Regresión y regularización	Regresión y Regularización (Capítulo 3): MCO evaluado por predicción, sesgo y varianza, Ridge y Lasso. Selección de Variables (Capítulo 4).	Econometría
Decisión y modelos probabilísticos	Teoría de Decisión Bayesiana (Capítulo 5), Métodos Paramétricos (Capítulo 6) y Métodos No Paramétricos (Capítulo 7).	Estadística, Econometría
Discriminantes y optimización	Discriminantes Lineales (Capítulo 8) y Optimización (Capítulo 9).	Matemáticas Aplicadas
Métodos flexibles	Árboles de Decisión (Capítulo 10), Ensambles (Capítulo 11) y Redes Neuronales (Capítulo 12).	Econometría, Evaluación de Políticas Públicas
Aprendizaje no supervisado	Reducción de Dimensión (Capítulo 13, con el Análisis de Componentes Principales, Sección 13.2) y Agrupamiento (Capítulo 14).	Manejo de Bases de Datos, Diseño de Investigación

Bloque	Capítulos	Conexión con METPOL
Comparación	Comparación de Algoritmos (Capítulo 15): cómo decidir si un algoritmo es mejor que otro.	Estadística, Métodos Experimentales
Uso responsable e inferencia causal	*Interpretabilidad y Equidad* y *Aprendizaje Computacional e Inferencia Causal* (en preparación).	Inferencia Causal, Evaluación de Políticas Públicas
Texto	*Texto como Datos* (en preparación): clasificación y agrupamiento de documentos.	Métodos Mixtos Aplicados al Análisis de Políticas

Los apéndices contienen un repaso de estadística y la descripción de los conjuntos de datos que se utilizan en el libro.

Un modelo se puede usar para predecir ($\hat{y}$) o para inferir ($\hat{\beta}$), y a lo largo del libro el interés está en la primera tarea (Sección 1.2). El problema que la recorre es el compromiso entre sobre-aprendizaje y sub-aprendizaje (Sección 1.7), pues un modelo que ajusta muy bien los datos disponibles puede fallar con datos nuevos. Para saber si un modelo predice bien hay que medirlo con datos que no usó para aprender, lo cual se aborda en Capítulo 2.

2 Rendimiento

El **objetivo** de la unidad es contrastar las características de diferentes medidas de rendimiento en aprendizaje supervisado, así como simular un procedimiento de aprendizaje supervisado mediante los conjuntos de entrenamiento, prueba y validación. Este capítulo se puede leer sin haber estudiado los algoritmos de clasificación y regresión: los modelos que aparecen en los ejemplos (Capítulo 6) se utilizan como cajas negras que se entrenan con `fit` y predicen con `predict`, y su funcionamiento se describirá más adelante.

Paquetes usados

```
from sklearn.naive_bayes import GaussianNB
from sklearn.discriminant_analysis import QuadraticDiscriminantAnalysis
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import train_test_split
from sklearn.datasets import load_breast_cancer,\
                             load_diabetes
from sklearn.model_selection import train_test_split, KFold
from sklearn import metrics
from CompStats.metrics import accuracy_score, recall_score,\
                              precision_score, f1_score, log_loss,\
                              roc_auc_score, mean_squared_error,\
                              mean_absolute_error, r2_score
import numpy as np
import pandas as pd
from matplotlib import pylab as plt
import seaborn as sns
```

2.1. Introducción

Es importante conocer el rendimiento del algoritmo de aprendizaje computacional desarrollado. En aprendizaje supervisado la medición se hace mediante el conjunto de prueba, $\mathcal{G}$, mientras que en aprendizaje no supervisado es posible utilizar el conjunto de entrenamiento $\mathcal{T}$ o utilizar

un conjunto de prueba. Es importante notar que aunque en el proceso de entrenamiento se puede usar una función de rendimiento para estimar o encontrar el algoritmo que modela los datos, es importante complementar esta medición con otras funciones de rendimiento. Esta unidad describe algunas de las medidas más utilizadas para medir el rendimiento de algoritmos de clasificación y regresión.

Para el análisis de políticas públicas esta pregunta es central: un modelo que se utilice para focalizar un programa o priorizar inspecciones debe evaluarse con datos que no se usaron para construirlo, de la misma manera que un estimador econométrico se valida con datos distintos a los de su ajuste. El primer paso es, entonces, describir cómo se separan los datos.

2.2. Conjunto de Entrenamiento y Prueba

Se parte de un conjunto de datos $\mathcal{D} = (\mathcal{X}, \mathcal{Y})$ donde cada renglón de $\mathcal{X}$ es una realización de la variable aleatoria de entrada y cada elemento de $\mathcal{Y}$ es la realización de la variable que se desea predecir. El objetivo en aprendizaje supervisado es diseñar un algoritmo (función en este caso) que modele la relación entre $\mathcal{X}$ y $\mathcal{Y}$, y para conocer qué tan bien lo hace es necesario medir su rendimiento en instancias que no han sido vistas en el entrenamiento. Medirlo con los mismos datos que se usaron para ajustar el algoritmo produce estimaciones optimistas, porque el algoritmo puede memorizar particularidades de esos datos.

En consecuencia, los datos se dividen en dos conjuntos, el conjunto de entrenamiento, $\mathcal{T}$, que se utiliza para encontrar el algoritmo, y el conjunto de prueba, $\mathcal{G}$, que se utiliza únicamente para medir el rendimiento. $\mathcal{G}$ se crea a partir de $\mathcal{D}$ de tal manera que $\mathcal{G} \cap \mathcal{T} = \emptyset$ y $\mathcal{D} = \mathcal{G} \cup \mathcal{T}$. La siguiente instrucción se puede utilizar para dividir los datos de Breast Cancer Wisconsin (descritos en la Sección B.2.2.1) en estos conjuntos. En la Sección 2.3.9 se utilizan para medir el rendimiento de un clasificador.

```
D, y = load_breast_cancer(return_X_y=True)
T, G, y_t, y_g = train_test_split(D, y,
                                  test_size=0.2,
                                  random_state=0)
```

El parámetro `test_size` indica la proporción del tamaño de conjunto $\mathcal{G}$ en relación con el conjunto $\mathcal{D}$ y `random_state` fija la semilla para que la división sea reproducible.

2.3. Clasificación

En clasificación existen diferentes medidas de rendimiento, algunas de ellas son exactitud (*accuracy*), precisión (*precision*), cobertura (*recall*), y F_1, entre otras. Sebastiani (2015) describe

de manera axiomática algunas de estas medidas y se dan recomendaciones en general sobre medidas de rendimiento para clasificadores.

Varias de las medidas de rendimiento toman como insumo la **Tabla de Confusión** (Tabla 2.1), la cual contiene la información del proceso de clasificación. La siguiente tabla muestra la estructura de esta tabla para un problema binario, donde se tiene una clase positiva identificada con p y una clase negativa (n). La variable y indica las clases reales y la variable $\hat{y}$ representa la estimación (predicción) hecha por el clasificador. Adicionalmente, la tabla se puede extender a K clases siguiendo la misma estructura; la diagonal contiene los elementos correctamente identificados y los elementos fuera de la diagonal muestran los errores.

Tabla 2.1: Tabla de Confusión

	$\hat{y} = p$	$\hat{y} = n$
$y = p$	Verdaderos Pos.	Falsos Neg.
$y = n$	Falsos Pos.	Verdaderos Neg.

La tabla se puede ver como valores nominales, es decir contar el número de ejemplos clasificados como verdaderos positivos o como proporción de tal manera que las cuatro celdas sumen 1. En esta descripción se asume que son proporciones, esto porque se seguirá una interpretación probabilística, descrita por Goutte y Gaussier (2005), para presentar las diferentes medidas de rendimiento.

Viendo la Tabla 2.1 como una proporción y combinando con la interpretación probabilística la tabla quedaría de la siguiente manera.

Tabla 2.2: Tabla de Confusión como Proporción

	$\hat{y} = p$	$\hat{y} = n$
$y = p$	$\mathbb{P}(y = p, \hat{y} = p)$	$\mathbb{P}(y = p, \hat{y} = n)$
$y = n$	$\mathbb{P}(y = n, \hat{y} = p)$	$\mathbb{P}(y = n, \hat{y} = n)$

Partiendo de la Tabla 2.2 se puede calcular la probabilidad marginal de cualquier variable y también las probabilidades condicionales, por ejemplo $\mathbb{P}(y = p) = \sum_k \mathbb{P}(y = p, \hat{y} = k)$ que es la suma de los elementos del primer renglón de la tabla anterior.

2.3.1. Error

Se empieza la descripción con el error de clasificación (el cual se retoma desde la teoría de decisión en la Sección 5.4, más adelante) que es la proporción de errores y se puede definir como

$$\mathsf{error}(y, \hat{y}) = 1 - \mathsf{accuracy}(y, \hat{y}).$$

2.3.2. Exactitud (*Accuracy*)

El error se define mediante la exactitud. La exactitud es la proporción de ejemplos correctamente clasificados, utilizando la notación de la tabla de confusión quedaría como:

$$\mathsf{accuracy}(y, \hat{y}) = \mathbb{P}(y = p, \hat{y} = p) + \mathbb{P}(y = n, \hat{y} = n).$$

Una manera equivalente de ver la exactitud es utilizando la probabilidad condicional, es decir,

$$\begin{aligned}\mathsf{accuracy}(y, \hat{y}) = \mathbb{P}(\hat{y} = p \mid y = p)\mathbb{P}(y = p) \\ + \mathbb{P}(\hat{y} = n \mid y = n)\mathbb{P}(y = n).\end{aligned}$$

Esta manera ayuda a entender el caso cuando se tiene una clase con muchos ejemplos, e.g., $\mathbb{P}(y = p) \gg \mathbb{P}(y = n)$, en ese caso se ve que la exactitud está dominada por el primer término, i.e., $\mathbb{P}(\hat{y} = p \mid y = p)\mathbb{P}(y = p)$. En este caso, la manera trivial de optimizar la exactitud es crear un clasificador que siempre regrese la clase p. Por esta razón la exactitud no es una medida adecuada cuando las clases son desbalanceadas, es buena medida cuando $\mathbb{P}(y = p) \approx \mathbb{P}(y = n)$.

2.3.3. Cobertura (*Recall*)

La siguiente medida de rendimiento es el recall, este calcula la probabilidad de ejemplos correctamente clasificados como p dados todos los ejemplos que se tienen de la clase p. En base a esta ecuación se puede observar que un algoritmo trivial con el máximo valor de recall solamente tiene que predecir como clase p todos los elementos.

La segunda ecuación ayuda a medir en base de la tabla de confusión.

$$\begin{aligned}\mathsf{recall}_p(y, \hat{y}) &= \mathbb{P}(\hat{y} = p \mid y = p) \\ &= \frac{\mathbb{P}(\hat{y} = p, y = p)}{\mathbb{P}(y = p)}\end{aligned} \tag{2.1}$$

2.3.4. Precisión (*Precision*)

La precisión complementa el recall, al calcular la probabilidad de los ejemplos correctamente clasificados como p dadas las predicciones de los ejemplos. Es decir, en la probabilidad condicional se observa que se conocen las predicciones positivas y de esas predicciones se mide si estas son correctamente clasificadas. Basándose en esto, se puede ver que una manera de generar un algoritmo competitivo en esta medida corresponde a predecir la clase solo cuando exista una gran seguridad de la clase.

$$\begin{aligned} \mathsf{precision}_p(y, \hat{y}) &= \mathbb{P}(y = p \mid \hat{y} = p) \\ &= \frac{\mathbb{P}(y = p, \hat{y} = p)}{\mathbb{P}(\hat{y} = p)} \end{aligned} \tag{2.2}$$

2.3.5. F_β

Finalmente, una manera de combinar el recall (Ecuación 2.1) con la precisión (Ecuación 2.2) es la medida F_β, es probable que esta medida se reconozca más cuando $\beta = 1$. La idea de β es ponderar el peso que se le quiere dar a la precisión con respecto al recall.

$$F_\beta^p(y, \hat{y}) = (1 + \beta^2) \frac{\mathsf{precision}_p(y, \hat{y}) \cdot \mathsf{recall}_p(y, \hat{y})}{\beta^2 \cdot \mathsf{precision}_p(y, \hat{y}) + \mathsf{recall}_p(y, \hat{y})} \tag{2.3}$$

2.3.6. Medidas Macro

En las definiciones de precisión (Ecuación 2.2), recall (Ecuación 2.1) y F_β (Ecuación 2.3) se ha usado un subíndice y superíndice con la letra p esto es para indicar que la medida se está realizando con respecto a la clase p. Esto ayuda también a ilustrar que en un problema de K clases se tendrán K diferentes medidas de precisión, recall y F_β; cada una de esas medidas corresponde a cada clase.

En ocasiones es importante tener solamente una medida que englobe el rendimiento en el caso de los tres rendimientos que se han mencionado, se puede calcular su versión macro que es la media de la medida. Esto es para un problema de K clases la precisión, recall y F_β se definen de la siguiente manera.

$$\mathsf{macro\text{-}precision}(y, \hat{y}) = \frac{1}{K} \sum_k \mathsf{precision}_k(y, \hat{y}),$$

$$\mathsf{macro\text{-}recall}(y, \hat{y}) = \frac{1}{K} \sum_k \mathsf{recall}_k(y, \hat{y}),$$

$$\text{macro-}F_\beta(y, \hat{y}) = \frac{1}{K} \sum_k F_\beta^k(y, \hat{y}).$$

2.3.7. Entropía Cruzada

Una función de costo que ha sido muy utilizada en redes neuronales y en particular en aprendizaje profundo es la **Entropía Cruzada** (Cross Entropy) que para una distribución discreta se define como: $H(P, Q) = -\sum_x P(x) \log Q(x)$.

Muchos clasificadores, además de la clase, entregan una estimación de la probabilidad de cada clase dado el ejemplo (la probabilidad *a posteriori*), la cual se denota $\hat{\mathbb{P}}(\mathcal{Y} = k \mid \mathcal{X} = x)$. Para cada ejemplo x se tiene $\mathbb{P}(\mathcal{Y} = k \mid \mathcal{X} = x)$ y el clasificador predice $\hat{\mathbb{P}}(\mathcal{Y} = k \mid \mathcal{X} = x)$. Utilizando estas definiciones se puede decir que $P = \mathbb{P}$ y $Q = \hat{\mathbb{P}}$ en la definición de entropía cruzada. Entonces

$$H(\mathbb{P}(\mathcal{Y} \mid \mathcal{X} = x), \hat{\mathbb{P}}(\mathcal{Y} \mid \mathcal{X} = x)) = \\ -\sum_k^K \mathbb{P}(\mathcal{Y} = k \mid \mathcal{X} = x) \log \hat{\mathbb{P}}(\mathcal{Y} = k \mid \mathcal{X} = x).$$

Finalmente la medida de rendimiento quedaría como $\sum_x H(\mathbb{P}(\mathcal{Y} \mid \mathcal{X} = x), \hat{\mathbb{P}}(\mathcal{Y} \mid \mathcal{X} = x))$.

2.3.8. Área Bajo la Curva *ROC*

El área bajo la curva *ROC* (*Receiver Operating Characteristic*) es una medida de rendimiento que también está basada en la probabilidad a posteriori $\mathbb{P}(\mathcal{Y} \mid \mathcal{X})$ con la característica de que la clase se selecciona en base a un umbral ρ. Es decir, dado un ejemplo x, este ejemplo pertenece a la clase p si $\mathbb{P}(\mathcal{Y} = p \mid \mathcal{X} = x) \geq \rho$.

Se observa que modificando el umbral ρ se tienen diferentes tablas de confusión, para cada tabla de confusión posible se calcula la tasa de verdaderos positivos (TPR) que corresponde al recall (Sección 2.3.3), i.e., $\mathbb{P}(\hat{\mathcal{Y}} = p \mid \mathcal{Y} = p)$, y la tasa de falsos positivos (FPR) que es $\mathbb{P}(\hat{\mathcal{Y}} = p \mid \mathcal{Y} = n)$. Cada par de TPR y FPR representa un punto de la curva *ROC*. El rendimiento corresponde al área debajo de la curva delimitada por los pares TPR y FPR.

2.3.9. Ejemplo

El ejemplo de Breast Cancer Wisconsin (Sección B.2.2.1) se utiliza para ilustrar el uso de las medidas de rendimiento presentadas hasta el momento. En el siguiente código se observa el procedimiento para cargar los datos, después los datos se dividen en entrenamiento y prueba (Sección 2.2), se entrena el algoritmo Analizador Discriminante Cuadrático y se predice el conjunto de prueba. Por ahora este algoritmo se utiliza como una caja negra. Es un clasificador que, para cada clase, estima una distribución normal de las variables de entrada (sus medias y una matriz de covarianza, que indica cómo varían las variables en conjunto) y asigna a cada ejemplo la clase más probable. Se entrena con `fit` y predice con `predict`. Su funcionamiento se describe en la Sección 6.5.1, que se verá más adelante.

```
D, y = load_breast_cancer(return_X_y=True)
T, G, y_t, y_g = train_test_split(D, y,
                                  random_state=0,
                                  test_size=0.2)
gaussian = QuadraticDiscriminantAnalysis(reg_param=1e-3).fit(T, y_t)
hy_gaussian = gaussian.predict(G)
```

> **CompStats**
>
> Para medir el rendimiento de los algoritmos se utilizará la librería CompStats descrita en Nava-Muñoz et al. (2024). Esta librería permite obtener el error estándar de la estadística calculada, así como hacer una comparación entre el rendimiento de diferentes algoritmos incluyendo la significancia estadística.

Para medir la exactitud del algoritmo anterior, se utiliza la función `accuracy_score` tal y como se muestra en el siguiente código.

```
accuracy = accuracy_score(y_g, hy_gaussian)
```

La exactitud estimada del algoritmo es 0.9474 con un error estándar de 0.0205.

Las medidas de `recall`, `precision` y `f1` se presentan en la Tabla 2.3, en la última columna se presenta el promedio (i.e., *macro*) de cada una de las medidas.

```
recall = recall_score(y_g, hy_gaussian,
                      average=None)
precision = precision_score(y_g, hy_gaussian,
                            average=None)
f1 = f1_score(y_g, hy_gaussian,
              average=None)
```

Tabla 2.3: Rendimiento

	$y = 0$	$y = 1$	Promedio (*macro*)
`recall`	0.9362	0.9552	0.9457
`precision`	0.9362	0.9552	0.9457
`f1`	0.9362	0.9552	0.9457

Comparación de cobertura por clase

Continuando con el rendimiento y utilizando las características de la librería, es posible comparar el rendimiento entre dos o más algoritmos. En este ejemplo, se comparará el rendimiento en la cobertura por clase contra el algoritmo Bayesiano Ingenuo, otro clasificador que también se usa como caja negra. Este algoritmo hace lo mismo que el anterior pero supone que, dentro de cada clase, las variables de entrada son independientes entre sí, por lo que solamente estima una media y una varianza por variable. Se describirá en la Sección 6.6. En las siguientes dos líneas se entrena el algoritmo y se predice las clases en el conjunto de prueba.

```
naive = GaussianNB().fit(T, y_t)
hy_naive = naive.predict(G)
```

La Figura 2.1 muestra la comparación de la cobertura por clase de los dos algoritmos, la figura también indica el algoritmo que obtuvo el mejor rendimiento y si la diferencia entre los rendimiento es estadísticamente significante.

```
recall(hy_naive, name="Bayesiano Ingenuo")
recall.plot(comp_legend='Comparación',
            winner_legend='Mejor',
            tie_legend='Equivalente',
            loser_legend='Diferente',
            alg_legend='Algoritmo',
            var_name='Rendimiento')
```

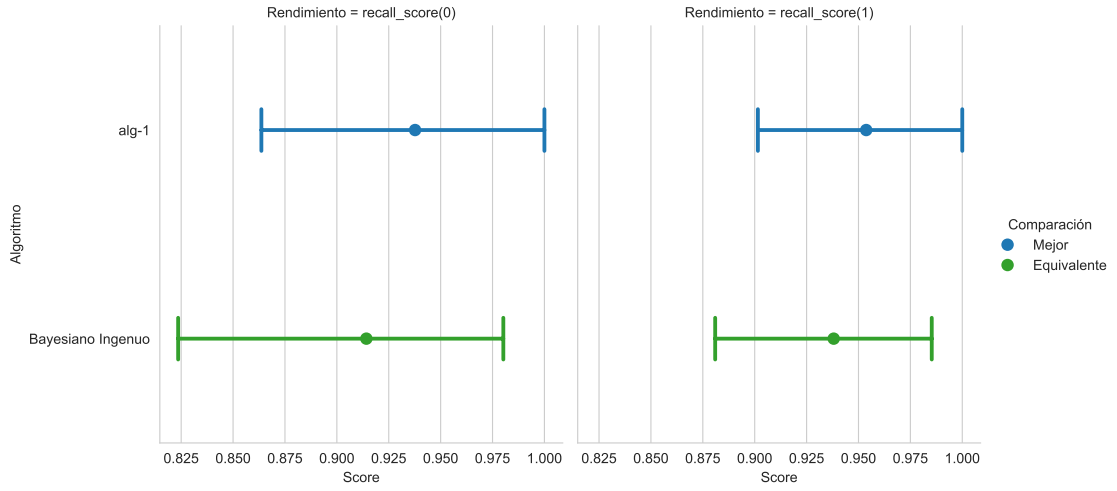


Figura 2.1: Rendimiento entre alg-1 (Analizador Discriminante Cuadrático) y Bayes Ingenuo

Actividad

Medir el rendimiento del algoritmo Bayesiano Ingenuo (el clasificador que supone variables independientes dentro de cada clase, el cual se describirá en la Sección 6.6) en el problema del Iris (ver Sección B.2.2.2) utilizando la función F_β (Sección 2.3.5) variando β entre $[0, 1]$, tal y como se muestra en la Figura 2.2

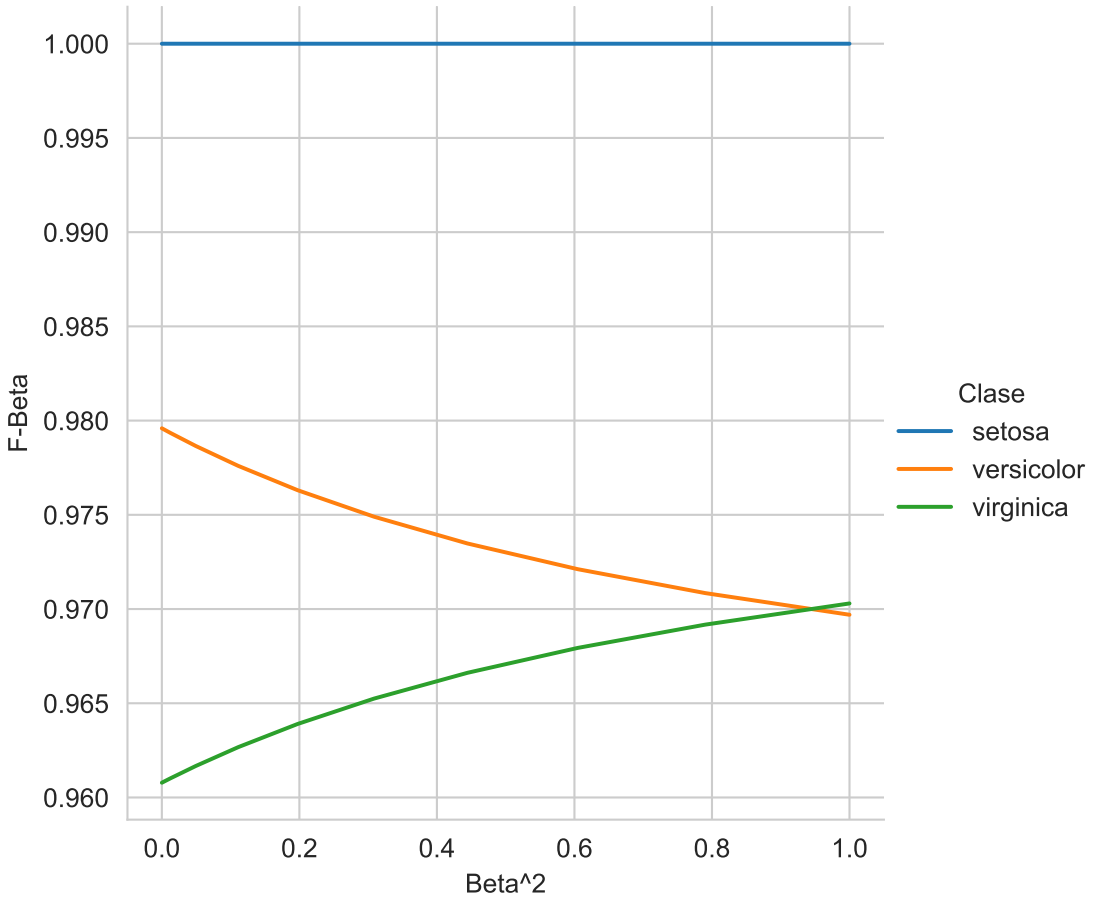


Figura 2.2: Rendimiento de un Clasificador Bayesiano Ingenuo en el problema del Iris estimado mediante una validación cruzada estratificada.

Por otro lado, para calcular el valor de la entropía cruzada se requiere la predicción de la probabilidad de cada clase, lo cual se obtiene con la siguiente instrucción

```
prob = gaussian.predict_proba(G)
```

donde la variable `prob` tiene la probabilidad por clase y el valor de la entropía se estima utilizando la función `log_loss`, e.g.,

```
entropia = log_loss(y_g, prob)
```

teniendo un valor de 0.3251 con un error estándar de 0.1799.

Actividad

Comparar el rendimiento de Bayesiano Ingenuo (el clasificador que supone variables independientes dentro de cada clase, el cual se describirá en la Sección 6.6) utilizando la entropía cruzada, tal y como se muestra en la Figura 2.3.

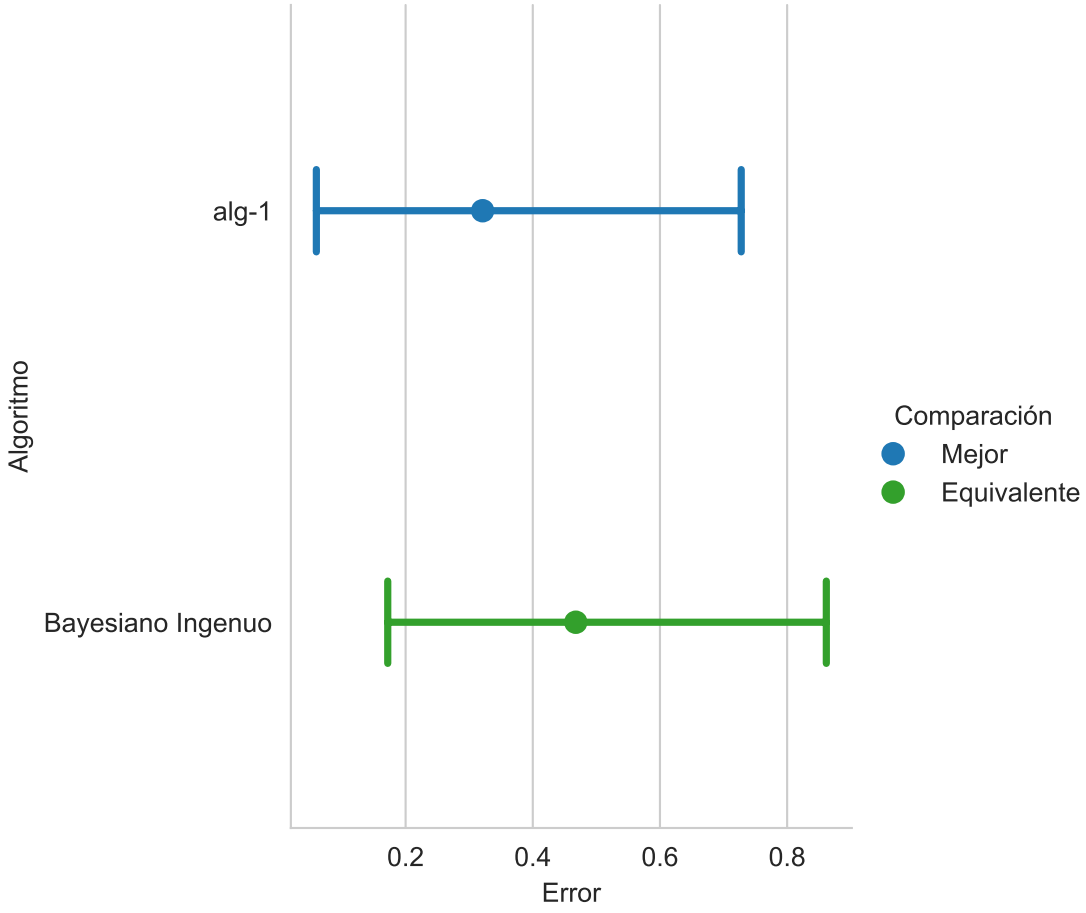


Figura 2.3: Rendimiento usando entropía cruzada entre alg-1 (Analizador Discriminante Cuadrático) y Bayes Ingenuo

Complementando la información de las medidas que se calculan mediante la posteriori se encuentra la curva ROC, la cual se puede calcular con el siguiente código y se muestra en la Figura 2.4

```
fpr, tpr, thresholds = metrics.roc_curve(y_g, prob[:, 1])
df = pd.DataFrame(dict(FPR=fpr, TPR=tpr))
sns.set_style('whitegrid')
```

```
fig = sns.lineplot(df, x='FPR', y='TPR')
```

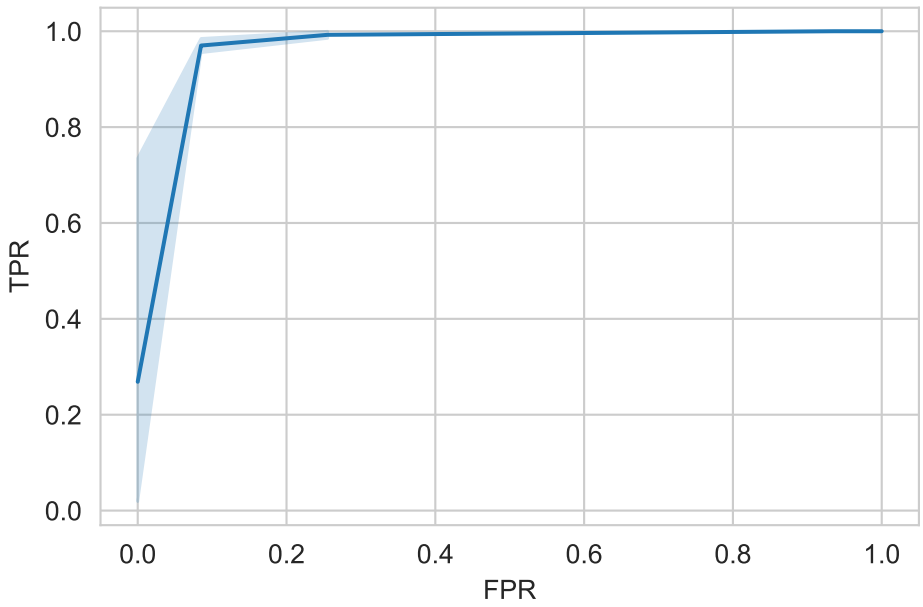


Figura 2.4: ROC

El valor de área bajo la curva se calcula con la siguiente instrucción

```
auc_score = roc_auc_score(y_g, prob[:, 1])
```

teniendo un valor de 0.9936 con un error estándar de 0.0045.

2.4. Regresión

Con respecto a regresión las siguientes funciones son utilizadas como medidas de rendimiento.

Error cuadrático medio (Mean Square Error):

$$\mathsf{mse}(y, \hat{y}) = \frac{1}{N} \sum_{i=1}^{N} (y_i - \hat{y}_i)^2. \tag{2.4}$$

Error absoluto medio (Mean Absolute Error):

$$\mathsf{mae}(y, \hat{y}) = \frac{1}{N} \sum_{i=1}^{N} \mid y_i - \hat{y}_i \mid . \tag{2.5}$$

Media del porcentaje de error absoluto:

$$\mathsf{mape}(y, \hat{y}) = \frac{1}{N} \sum_{i=1}^{N} \mid \frac{y_i - \hat{y}_i}{y_i} \mid . \tag{2.6}$$

La proporción de la varianza explicada por el modelo:

$$R^2(y, \hat{y}) = 1 - \frac{\sum_{i=1}^{N}(y_i - \hat{y}_i)^2)}{\sum_{i=1}^{N}(y_i - \bar{y})^2)}. \tag{2.7}$$

2.4.1. Ejemplo

Las medidas anteriores se ejemplifican utilizando el conjunto de datos de diabetes (que también se analiza en la Sección B.2.3.2), el cual se puede descargar y modelar mediante una regresión lineal, de la siguiente manera. La regresión lineal se utiliza como caja negra. Es un modelo que predice la respuesta como una suma ponderada de las variables de entrada, $\mathbf{w} \cdot \mathbf{x} + w_0$, donde los pesos se ajustan a los datos de entrenamiento minimizando el error cuadrático. Se describirá en la Sección 3.3.

```
X, y = load_diabetes(return_X_y=True)
T, G, y_t, y_g = train_test_split(X, y,
                                  random_state=0,
                                  test_size=0.2)
m = LinearRegression().fit(T, y_t)
```

La predicción en el conjunto de prueba sería:

```
hy = m.predict(G)
```

Las diferentes medidas de rendimiento para problemas de regresión se pueden calcular de la siguiente manera.

El error cuadrático medio (Ecuación 2.4), se calcula mediante la siguiente función

```
mse = mean_squared_error(y_g, hy)
```

teniendo un valor de 3424.2593 con un error estándar de 540.8587. La función que implementa el error absoluto medio (Ecuación 2.5) se muestra en la siguiente instrucción

```
mae = mean_absolute_error(y_g, hy)
```

teniendo un valor de 46.1736 con un error estándar de 3.9444. La varianza explicada por el modelo (Ecuación 2.7) se estima con el siguiente código

```
r2 = r2_score(y_g, hy)
```

teniendo un valor de 0.3322 con un error estándar de 0.0991.

2.5. Conjunto de Validación y Validación Cruzada

Además de los conjuntos de Entrenamiento y Prueba (Sección 2.2), i.e., $\mathcal{T}$ y $\mathcal{G}$, es necesario contar con otro conjunto que se utiliza para optimizar los hiperparámetros del algoritmo de aprendizaje. En particular estos conjuntos se definieron utilizando todos los datos $\mathcal{D}$ con lo que se especifica el problema.

La mayoría de algoritmos de aprendizaje tiene hiperparámetros que pueden ser ajustados para optimizar su comportamiento al conjunto de datos que se está analizando. Estos hiperparámetros pueden estar dentro del algoritmo o pueden ser modificaciones al conjunto de datos para adecuarlos al algoritmo. El segundo caso es el que se analizará en esta unidad. Es decir, se seleccionarán las variables que facilitan el aprendizaje.

Para optimizar los parámetros es necesario medir el rendimiento del algoritmo, es decir, observar cómo se comporta el algoritmo en el proceso de predicción. La manera trivial sería utilizar el conjunto de prueba $\mathcal{G}$ para medir el rendimiento. Pero es necesario recordar que este conjunto no debe ser visto durante el aprendizaje y la optimización de los parámetros es parte de ese proceso. Si se usara $\mathcal{G}$ entonces dejaría de ser el conjunto de prueba y se tendría que seleccionar otro conjunto de prueba.

Entonces para optimizar los parámetros del algoritmo se selecciona del conjunto de entrenamiento, i.e., $\mathcal{T}$, el **conjunto de validación**, $\mathcal{V}$. Este conjunto tiene la característica que $\mathcal{T} \cap \mathcal{V} \cap \mathcal{G} = \emptyset$ y $\mathcal{T} \cup \mathcal{V} \cup \mathcal{G} = \mathcal{D}$. Una manera de realizar esto es seleccionar primeramente el conjunto de prueba $\mathcal{G}$ y de los datos restantes generar los conjuntos de entrenamiento $\mathcal{T}$ y validación $\mathcal{V}$.

Para ejemplificar esta idea se utiliza el ejemplo de Breast Cancer Wisconsin (Sección B.2.2.1) utilizando un Clasificador Bayesiano donde el hiperparámetro es si se utiliza un Bayesiano Ingenuo (variables independientes dentro de cada clase) o se estima la matriz de covarianza

completa (la que además captura cómo se relacionan las variables entre sí). Ambos son los clasificadores usados como cajas negras en la Sección 2.3.9.

El primer paso es obtener los datos del problema, lo cual se muestra en la siguiente instrucción.

```
D, y = load_breast_cancer(return_X_y=True)
```

Con los datos $\mathcal{D}$ se genera el conjunto de prueba $\mathcal{G}$ y los datos para estimar los parámetros y optimizar los hiperparámetros del algoritmo. En la variable `T` se tiene los datos para encontrar el algoritmo y en `G` se tiene el conjunto de prueba.

```
T, G, y_t, y_g = train_test_split(D, y,
                                  random_state=0,
                                  test_size=0.2)
```

Los datos de entrenamiento y validación se generan de manera equivalente tal como se muestra en la siguiente instrucción. El conjunto de validación ($\mathcal{V}$) se encuentra en la variable `V` y la variable dependiente en `y_v`.

```
T, V, y_t, y_v = train_test_split(T, y_t,
                                  random_state=0,
                                  test_size=0.3)
```

En este momento ya se tienen todos los elementos para medir el rendimiento de cada hiperparámetro. Empezando por el clasificador con la matriz de covarianza completa, donde la primera línea entrena el clasificador, en la segunda se predicen las clases en el conjunto de validación y en la tercera se calcula el promedio de cobertura por clase (i.e., *macro-recall*).

```
gaussian = QuadraticDiscriminantAnalysis(reg_param=1e-3).fit(T, y_t)
hy_gaussian = gaussian.predict(V)
recall = recall_score(y_v, hy_gaussian, average='macro', name='QDA')
```

La segunda opción es utilizar un clasificador Bayesiano Ingenuo tal y como se muestra en las siguientes instrucciones.

```
ingenuo = GaussianNB().fit(T, y_t)
hy_ingenuo = ingenuo.predict(V)
```

Faltaría solamente medir la cobertura en las predicciones que se tienen en la variable `hy_ingenuo` tal y como se muestra en la primera línea del siguiente código y la gráfica de la comparación se indica en la segunda línea. La Figura 2.5 muestra la comparación de rendimiento indicando la significancia estadística de la comparación.

```
recall(hy_ingenuo, name="Bayesiano Ingeuo")
recall.plot(comp_legend='Comparación',
            winner_legend='Mejor',
            tie_legend='Equivalente',
            loser_legend='Diferente',
            alg_legend='Algoritmo',
            var_name='Rendimiento')
```

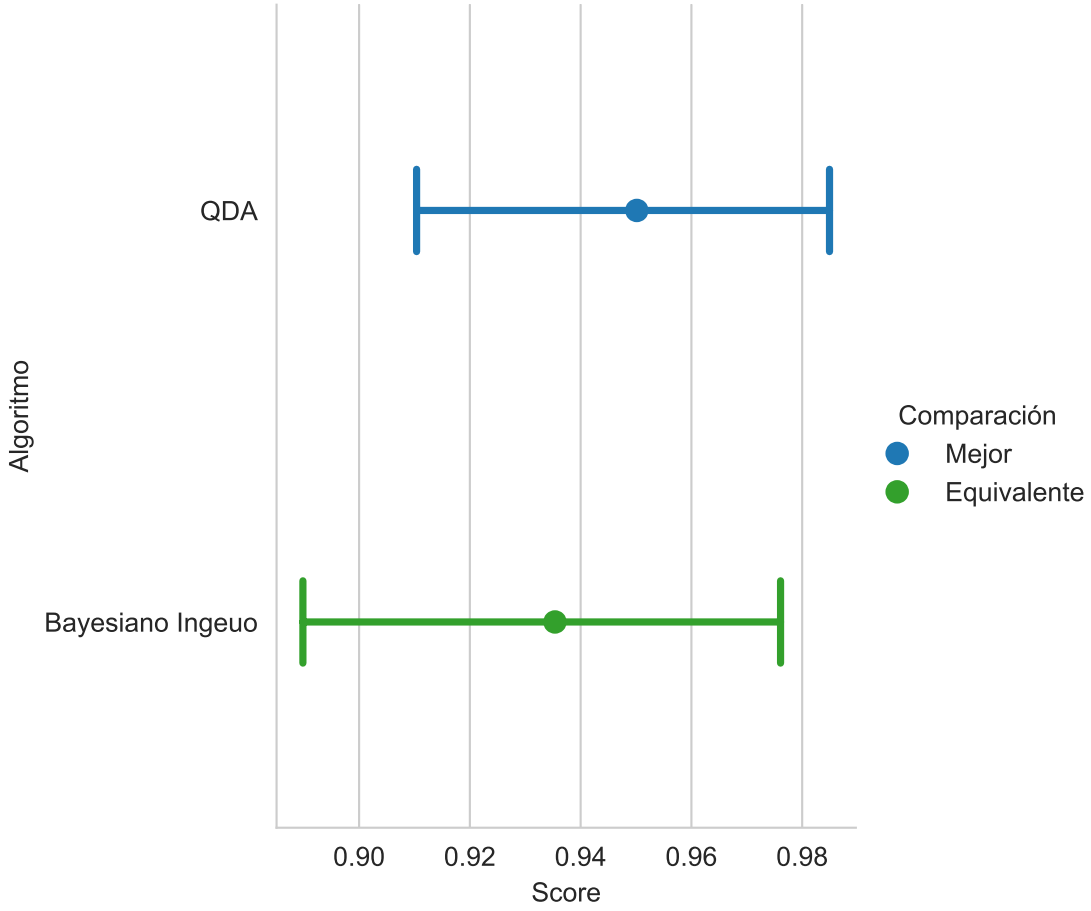


Figura 2.5: Comparación de la cobertura en el conjunto de validación

Comparando el rendimiento de los dos hiperparámetros se observa cuál de los dos modelos obtiene el mejor rendimiento. Con el fin de completar el ejemplo se describe cómo calcular el rendimiento en $\mathcal{G}$ del algoritmo con la matriz de covarianza completa. El procedimiento utilizado es

```
gaussian = QuadraticDiscriminantAnalysis(
    reg_param=1e-3
).fit(np.concatenate((T, V)),
      np.concatenate((y_t, y_v)))
hy_gaussian = gaussian.predict(G)
recall = recall_score(y_g, hy_gaussian, average='macro')
```

dando un valor de 0.9457 con un error estándar de 0.0211.

2.5.1. k-Iteraciones de Validación Cruzada

Cuando se cuenta con pocos datos para medir el rendimiento del algoritmo es común utilizar la técnica de *k-fold cross-validation* la cual consiste en partir k veces el conjunto de entrenamiento para generar k conjuntos de entrenamiento y validación.

La idea se ilustra con la siguiente tabla, donde se asume que los datos son divididos en 5 bloques ($k = 5$), cada columna de la tabla ilustra los datos de ese bloque. Si los datos se dividen en $k = 5$ bloques, entonces existen k iteraciones que son representadas por cada renglón de la siguiente tabla, quitando el encabezado de la misma. La letra en cada celda identifica el uso que se le dará a esos datos en la respectiva iteración, es decir, $\mathcal{T}$ representa que se usará como conjunto de entrenamiento y $\mathcal{V}$ se usa para identificar aquellos datos que se usarán como conjunto de validación.

El objetivo es entrenar y probar el rendimiento del algoritmo k veces usando las particiones en cada renglón. Es decir, la primera vez se usan los datos de la primera columna como el conjunto de validación, y el resto de columnas, $[2, 3, 4, 5]$, como conjunto de entrenamiento para estimar los parámetros del algoritmo. En la segunda iteración se usan los datos del segundo renglón donde se observa que los datos en la cuarta columna corresponden al conjunto de validación y los datos en las columnas $[1, 2, 3, 5]$ son usados como conjunto de prueba. Las iteraciones siguen hasta que todos los datos fueron utilizados en una ocasión como conjunto de validación.

1	2	3	4	5
$\mathcal{V}$	$\mathcal{T}$	$\mathcal{T}$	$\mathcal{T}$	$\mathcal{T}$
$\mathcal{T}$	$\mathcal{T}$	$\mathcal{T}$	$\mathcal{V}$	$\mathcal{T}$
$\mathcal{T}$	$\mathcal{T}$	$\mathcal{V}$	$\mathcal{T}$	$\mathcal{T}$
$\mathcal{T}$	$\mathcal{T}$	$\mathcal{T}$	$\mathcal{T}$	$\mathcal{V}$
$\mathcal{T}$	$\mathcal{V}$	$\mathcal{T}$	$\mathcal{T}$	$\mathcal{T}$

Se utiliza el mismo problema para medir el rendimiento del hiperparámetro del clasificador Gaussiano. Lo primero es seleccionar el conjunto de prueba ($\mathcal{G}$) que se realiza con el siguiente código.

```
T, G, y_t, y_g = train_test_split(D, y,
                                  random_state=0,
                                  test_size=0.2)
```

La validación cruzada con k-iteraciones se puede realizar con la clase `KFold` de la siguiente manera. La primera línea crea una variable para guardar el rendimiento. En la segunda línea se inicializa el procedimiento indicando que los datos sean tomados al azar. Después se realiza el ciclo con las k iteraciones, para cada iteración se genera un índice `ts` que indica cuáles son los datos del conjunto de entrenamiento y `vs` que corresponde a los datos de validación. Se estiman los parámetros usando `ts` tal y como se observa en la cuarta línea. Habiendo estimado los parámetros se predicen los datos del conjunto de validación (quinta línea). Se mide la cobertura promedio (i.e. *macro-recall*) en la última línea.

```
hy_gaussian = np.zeros_like(y_t)
kfold = KFold(shuffle=True, random_state=0)
for ts, vs in kfold.split(T):
    gaussian = QuadraticDiscriminantAnalysis(
        reg_param=1e-3
    ).fit(T[ts], y_t[ts])
    hy_gaussian[vs] = gaussian.predict(T[vs])
recall = recall_score(y_t, hy_gaussian, average='macro', name="QDA")
```

Un procedimiento equivalente se realiza para el caso del clasificador Bayesiano Ingenuo tal y como se muestra a continuación.

```
kfold = KFold(shuffle=True, random_state=0)
hy_naive = np.zeros_like(y_t)

for ts, vs in kfold.split(T):
    nb = GaussianNB().fit(T[ts], y_t[ts])
    hy_naive[vs] = nb.predict(T[vs])
recall = recall(hy_naive, name="Bayesiano Ingenuo")
```

La Figura 2.6 muestra la comparación de los dos algoritmos utilizando la cobertura por clase.

El último paso sería calcular el rendimiento en el conjunto $\mathcal{G}$ lo cual fue presentado anteriormente.

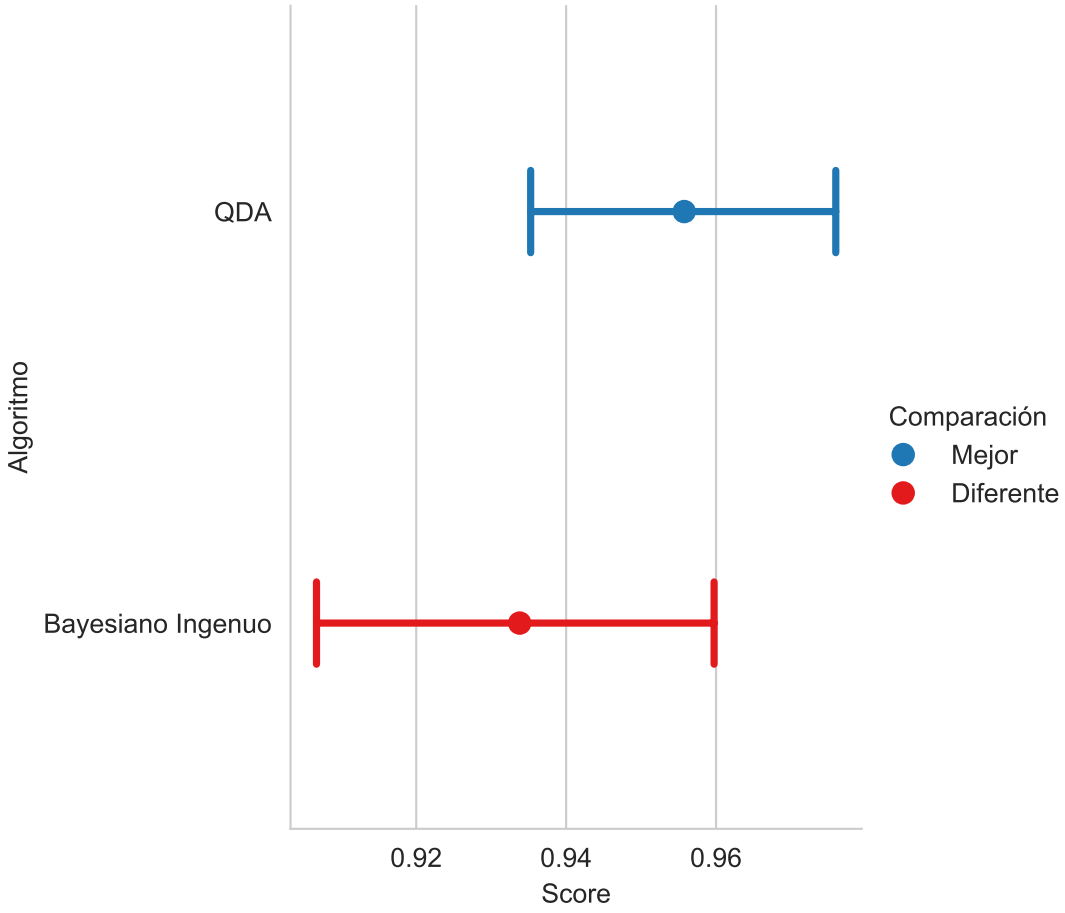


Figura 2.6: Comparación usando validación cruzada de k-iteraciones.

2.6. Resumen

El rendimiento de un algoritmo de aprendizaje supervisado se mide siempre fuera de muestra. Por eso los datos se separan en entrenamiento y prueba (Sección 2.2) y, cuando hay hiperparámetros que ajustar, se agrega un conjunto de validación o se recurre a la validación cruzada (Sección 2.5 y Sección 2.5.1). En clasificación el error y la exactitud (Sección 2.3.2) se complementan con la cobertura (Sección 2.3.3), la precisión (Sección 2.3.4) y su combinación en F_β (Sección 2.3.5). En regresión se utilizan el error cuadrático medio y el error absoluto medio (Ecuación 2.4 y Ecuación 2.5). Toda medida de rendimiento es una estimación y por lo tanto tiene incertidumbre, de modo que comparar dos algoritmos exige decidir si la diferencia observada es mayor que esa incertidumbre, como se hizo con `CompStats` en la Figura 2.6.

En política pública la elección de la medida es parte de la decisión. La cobertura es la proporción de la población objetivo que un programa alcanza, y por lo tanto resume el error de exclusión. La precisión es la proporción de beneficiarios que sí pertenecen a esa población, y por lo tanto resume el error de inclusión. Dos modelos con la misma exactitud pueden tener perfiles muy distintos en estas medidas, y quien diseña el programa debe decidir cuál error le cuesta más.

Con estas herramientas ya es posible evaluar cualquier modelo de predicción. El primero que se evalúa con ellas es el que se conoce de Econometría, la regresión lineal, que se estudia por su capacidad de predecir en Capítulo 3.

3 Regresión y Regularización

El **objetivo** de la unidad es evaluar la regresión lineal por su capacidad de predecir observaciones no vistas, comprender el compromiso entre sesgo y varianza, aplicar las regularizaciones Ridge, Lasso y Elastic Net seleccionando su hiperparámetro con validación cruzada y resolver un problema de política de predicción.

Paquetes usados

```
from sklearn.linear_model import LinearRegression, Ridge, Lasso,\
                                 ElasticNet, RidgeCV, LassoCV,\
                                 ElasticNetCV, LogisticRegression
from sklearn.model_selection import train_test_split, KFold
from sklearn.preprocessing import StandardScaler, PolynomialFeatures
from sklearn.metrics import r2_score as r2, recall_score as recall,\
                            precision_score as precision
from CompStats.metrics import r2_score
import cvxpy as cp
import numpy as np
import pandas as pd
from matplotlib import pylab as plt
import matplotlib as mpl
import seaborn as sns
URL_DATOS = ('https://github.com/INGEOTEC/AprendizajeComputacional/'
             'releases/download/datos-v1')
PALETTE = mpl.cm.Paired
```

3.1. Introducción

Quien ha cursado Econometría conoce los Mínimos Cuadrados Ordinarios (MCO) como la herramienta para estimar $\hat{\beta}$, interpretarlo, calcular su error estándar y probar si es distinto de cero. En este capítulo el mismo modelo se usa con otro propósito. Siguiendo a Mullainathan y Spiess (2017), el objetivo ya no es $\hat{\beta}$ sino $\hat{y}$. El modelo se evalúa por la calidad de sus

predicciones en el conjunto de prueba $\mathcal{G}$ (Sección 2.2), con las medidas de Sección 2.4, y su complejidad no se controla especificando a mano qué variables entran, sino con regularización y con validación cruzada (Sección 2.5). La referencia general sobre regularización es Hastie et al. (2009), cuyo capítulo 3 es de acceso libre.

El problema que guía el capítulo es predecir la tasa de abandono escolar de cada secundaria a partir de las características del plantel (Sección B.1.4), para decidir a qué planteles ofrecer primero un programa de tutorías o de becas. Es un *prediction policy problem* en el sentido de Kleinberg et al. (2015) (Sección 1.2). La decisión necesita saber cuáles planteles tienen una tasa de abandono alta, $\hat{y}$, y no el efecto causal que tendría modificar alguna de sus características.

El capítulo presenta primero MCO y su deducción por máxima verosimilitud. Después presenta el compromiso entre sesgo y varianza, que explica por qué un modelo con más variables no siempre predice mejor. Sigue con las regularizaciones Ridge, Lasso y Elastic Net y con la selección de su hiperparámetro λ por validación cruzada. Continúa con la razón por la cual los coeficientes de un modelo regularizado no se interpretan como efectos y termina con la focalización de un programa social, un problema de clasificación donde la regularización sirve para pedir pocas variables. La selección de variables, que Lasso hace de manera implícita, se trata en el siguiente capítulo (Capítulo 4).

3.2. Datos: Abandono Escolar

Los datos son los de Educación, descritos en la ficha del apéndice (Sección B.1.4), y se leen directamente del release `datos-v1`.

```
educacion = pd.read_csv(f'{URL_DATOS}/sep_f911_educacion.csv.gz')
```

La columna `clave_cct` identifica al plantel y no es una variable predictora, por lo que se descarta junto con la variable que se quiere predecir. También se descartan las columnas constantes, que no aportan información y que hacen singular a la matriz $X^\top X$. En lugar de listarlas a mano, se detectan con el siguiente código.

```
constantes = [c for c in educacion.columns if educacion[c].nunique() == 1]
X = educacion.drop(columns=['tasa_abandono', 'clave_cct'] + constantes)
y = educacion['tasa_abandono'].to_numpy()
```

Las columnas `laboratorios`, `talleres` son constantes. Por otro lado, la regresión necesita números y varias de las variables son texto (la entidad, el sostenimiento, el tipo de servicio, el turno y la organización de los docentes). Cada categoría se convierte en una variable indicadora que vale uno cuando el plantel pertenece a esa categoría y cero en otro caso (*one-hot*, o variables *dummy* en econometría). Por cada variable se omite una categoría de referencia, pues de lo

contrario la suma de las indicadoras sería idéntica a la constante del modelo y la matriz $X^\top X$ no tendría inversa.

```
X = pd.get_dummies(X, drop_first=True, dtype=float)
columnas = X.columns
```

La matriz de diseño tiene $N = 26689$ renglones y $d = 56$ columnas. El siguiente paso es separar el conjunto de entrenamiento $\mathcal{T}$ del de prueba $\mathcal{G}$ (Sección 2.2) y estandarizar las columnas para que tengan media cero y desviación estándar uno. La estandarización utiliza estadísticas de los datos, por lo que se ajusta solamente con $\mathcal{T}$ y después se aplica a $\mathcal{G}$. Si se ajustara con todos los datos, información del conjunto de prueba influiría en el entrenamiento. La codificación de las categorías, en cambio, no aprende nada de y, y por eso se puede hacer antes de separar los datos y así garantizar las mismas columnas en ambos conjuntos.

```
T, G, y_t, y_g = train_test_split(X.to_numpy(), y, test_size=0.2,
                                  random_state=0)
escala = StandardScaler().fit(T)
T = escala.transform(T)
G = escala.transform(G)
```

Se estandarizan todas las columnas, incluidas las indicadoras, para que la penalización de las secciones siguientes trate a todos los coeficientes en la misma escala. Es una decisión discutible, porque un coeficiente de una indicadora estandarizada ya no se lee como "el efecto de pertenecer a la categoría". Como el objetivo es predecir, esta lectura no se necesita.

3.3. Mínimos Cuadrados Ordinarios

El estimador de MCO es el que se conoce en econometría. En regresión, a diferencia de clasificación (Sección 1.6), la respuesta es real, $\mathcal{Y} \in \mathbb{R}$. Para ponerlo en el contexto de los métodos paramétricos, se asume que $\mathcal{Y} \sim \mathcal{N}(\mathbf{w} \cdot \mathbf{x} + \epsilon, \sigma^2)$, de tal manera que $y = \mathbb{E}[\mathcal{N}(\mathbf{w} \cdot \mathbf{x} + \epsilon, \sigma^2)]$.

Trabajando con $y = \mathbb{E}[\mathcal{N}(\mathbf{w} \cdot \mathbf{x} + \epsilon, \sigma^2)]$, se considera lo siguiente $y = \mathbb{E}[\mathcal{N}(\mathbf{w} \cdot \mathbf{x}, 0) + \mathcal{N}(0, \sigma^2)]$ que implica que el error ϵ es independiente de $\mathbf{x}$, lo cual se transforma en $y = \mathbf{w} \cdot \mathbf{x} + \mathbb{E}[\epsilon]$, donde $\mathbb{E}[\epsilon] = 0$. Por lo tanto $y = \mathbf{w} \cdot \mathbf{x}$.

La función de densidad de probabilidad de una Gaussiana corresponde a

$$f(\alpha) = \frac{1}{\sigma\sqrt{2\pi}} \exp -\frac{1}{2}(\frac{\alpha - \mu}{\sigma})^2,$$

donde α, en el caso de regresión, corresponde a $\mathbf{w} \cdot \mathbf{x}$ (i.e., $\alpha = \mathbf{w} \cdot \mathbf{x}$).

Utilizando el método de verosimilitud el cual corresponde a maximizar

$$\begin{aligned}
\mathcal{L}(\mathbf{w}, \sigma) &= \prod_{(\mathbf{x},y)\in\mathcal{D}} f(\mathbf{w}\cdot\mathbf{x}) \\
&= \prod_{(\mathbf{x},y)\in\mathcal{D}} \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(\frac{\mathbf{w}\cdot\mathbf{x}-y}{\sigma}\right)^2\right) \\
\ell(\mathbf{w}, \sigma) &= \sum_{(\mathbf{x},y)\in\mathcal{D}} \log\frac{1}{\sigma\sqrt{2\pi}} - \frac{1}{2}\left(\frac{\mathbf{w}\cdot\mathbf{x}-y}{\sigma}\right)^2 \\
&= -\frac{1}{2\sigma^2}\sum_{(\mathbf{x},y)\in\mathcal{D}} (\mathbf{w}\cdot\mathbf{x}-y)^2 - N\log\frac{1}{\sigma\sqrt{2\pi}}.
\end{aligned}$$

El valor de cada parámetro se obtiene al calcular la derivada parcial con respecto al parámetro de interés, entonces se resuelven d derivadas parciales para cada uno de los coeficientes $\mathbf{w}$. En este proceso se observa que el término $N\log\frac{1}{\sigma\sqrt{2\pi}}$ no depende de $\mathbf{w}$ entonces no afecta el máximo siendo una constante en el proceso de derivación y por lo tanto se desprecia. Lo mismo pasa para la constante $\frac{1}{2\sigma^2}$. Por lo tanto, maximizar la verosimilitud equivale a minimizar $\sum_{(\mathbf{x},y)\in\mathcal{D}}(\mathbf{w}\cdot\mathbf{x}-y)^2$, la suma de los errores al cuadrado. Una vez obtenidos los parámetros $\mathbf{w}$ se obtiene el valor σ.

Una manera equivalente de plantear este problema es como un problema de álgebra lineal, donde se tiene una matriz de observaciones X que se construyen con las variables $\mathbf{x}$ de $\mathcal{X}$, donde cada renglón de X es una observación, y el vector dependiente $\mathbf{y}$ donde cada elemento es la respuesta correspondiente a la observación.

Viéndolo como un problema de álgebra lineal lo que se tiene es

$$X\mathbf{w} = \mathbf{y},$$

donde para identificar $\mathbf{w}$ se puede realizar lo siguiente

$$X^\top X\mathbf{w} = X^\top\mathbf{y}.$$

Despejando $\mathbf{w}$ se tiene

$$\mathbf{w} = (X^\top X)^{-1}X^\top\mathbf{y}.$$

Previamente se ha presentado el error estándar de cada parámetro que se ha estimado, en caso de la regresión el error estándar (Sección A.1.3) de w_j es $\sigma\sqrt{(X^\top X)^{-1}_{jj}}$.

3.3.1. Ejemplo: Abandono Escolar

Con el conjunto de entrenamiento `T` y `y_t` se estiman los parámetros de la regresión lineal, tal y como se muestra a continuación.

```
m = LinearRegression().fit(T, y_t)
w = m.coef_
w_0 = m.intercept_
```

Los tres coeficientes con mayor valor absoluto corresponden a las variables `tipo_sostenimiento_federal transferido` (2.22), `turno_vespertino` (1.70), `tipo_sostenimiento_federal transferido-estatal` (1.49), y el término independiente es $w_0 = 6.86$. Como todas las columnas están estandarizadas, w_0 es la media de `y_t`, que vale 6.86. Es decir, un plantel promedio en todas las variables tiene la tasa de abandono promedio.

Siguiendo la costumbre de la econometría, la pregunta es si estos coeficientes son estadísticamente distintos de cero. Para contestarla se estima σ como la desviación estándar del error y el error estándar de cada coeficiente se calcula con la inversa de la matriz $X^\top X$, para lo cual se utiliza la pseudoinversa (`np.linalg.pinv`) por estabilidad numérica.

```
error = y_t - m.predict(T)
sigma = np.std(error)
se = sigma * np.sqrt(np.diag(np.linalg.pinv(T.T @ T)))
t = w / se
```

El cociente `t` es el estadístico t de cada coeficiente. Un total de 22 de los 56 coeficientes tienen un valor absoluto menor que 2, es decir, no son estadísticamente distintos de cero. En econometría esto llevaría a reespecificar el modelo. Aquí interesa saber si quitar esas variables **mejora la predicción**.

La predicción del conjunto de prueba y su rendimiento, medido con R^2 (Ecuación 2.7), se obtienen con las siguientes instrucciones. La función `r2_score` de `CompStats` regresa un objeto con el valor de la medida y su error estándar, calculado con bootstrap, lo cual permite comparar algoritmos más adelante.

```
hy = m.predict(G)
r2_ols = r2_score(y_g, hy, name='MCO')
```

El R^2 de MCO en el conjunto de prueba es 0.1433, con un error estándar de 0.0182. Es un valor bajo en términos absolutos, pues las características del plantel que registra el Formato 911 explican una parte pequeña de las diferencias en la tasa de abandono, lo cual es frecuente en problemas sociales. La Figura 3.1 presenta las predicciones contra los valores reales, junto con la recta identidad que correspondería a un modelo sin error.

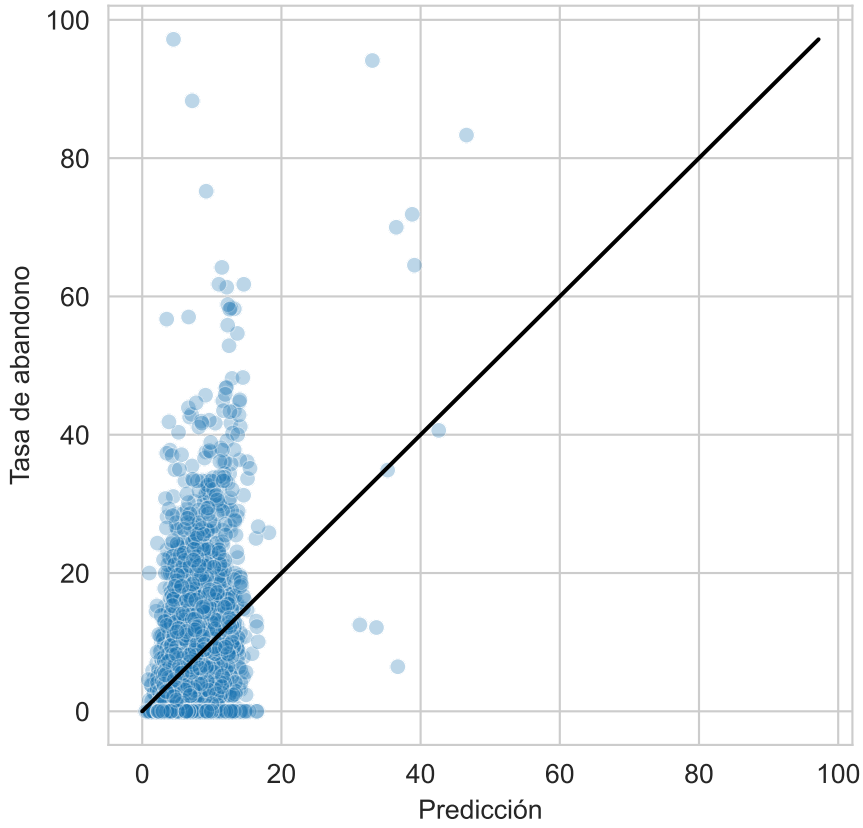


Figura 3.1: Predicción de MCO contra la tasa de abandono observada en el conjunto de prueba.

Las predicciones están comprimidas en un rango estrecho alrededor de la media, mientras que las tasas observadas llegan a valores mucho mayores. El modelo subestima a la mayoría de los planteles con tasas altas, que son justamente los que un programa quisiera identificar.

3.3.2. Modelo Reducido

Siguiendo la idea de la econometría, se estima un segundo modelo con las variables que sí son estadísticamente distintas de cero.

```
mask = np.fabs(t) >= 2
m2 = LinearRegression().fit(T[:, mask], y_t)
hy2 = m2.predict(G[:, mask])
```

La Figura 3.2 compara el rendimiento de los dos modelos en el conjunto de prueba.

```
r2_ols(hy2, name='Reducido')
r2_ols.plot(comp_legend='Comparación', winner_legend='Mejor',
            tie_legend='Equivalente', loser_legend='Diferente',
            alg_legend='Algoritmo', var_name='Rendimiento')
```

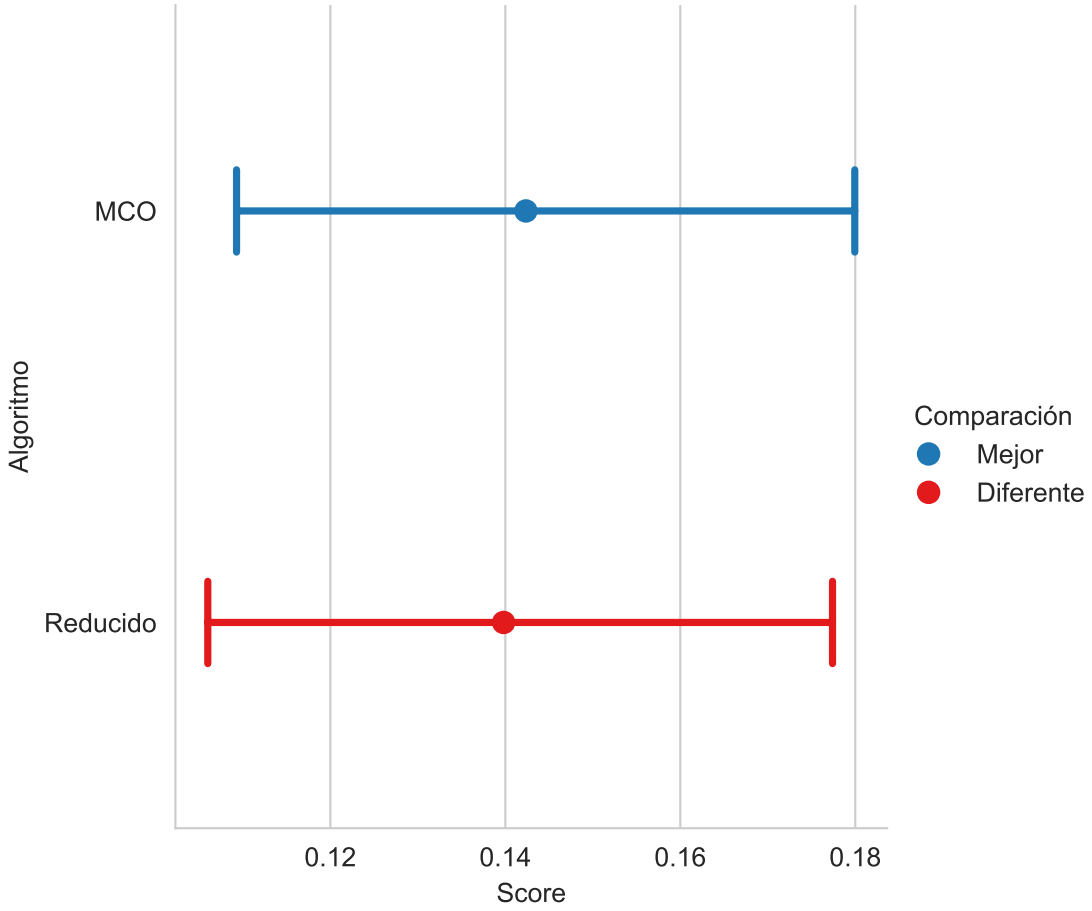


Figura 3.2: Rendimiento (R^2) del modelo completo y del reducido en el conjunto de prueba.

En la figura, el punto es el R^2 de cada modelo, el segmento su intervalo de confianza obtenido con bootstrap y los colores indican si la diferencia con el mejor modelo es estadísticamente significativa. El modelo reducido, con 34 variables, tiene un R^2 de 0.1408, 0.0026 menos que el modelo completo, y la figura lo marca como diferente del mejor. La diferencia es pequeña en magnitud, pero quitar las variables "no significativas" no mejora la predicción e incluso la perjudica un poco. La significancia individual de los coeficientes no es, entonces, un criterio para predecir. Esto motiva los métodos de las siguientes secciones, que controlan la complejidad del modelo con un criterio de predicción y no con pruebas de hipótesis. El modelo reducido es una selección basada en estadísticas, y en el capítulo siguiente (Capítulo 4) se ven otros procedimientos de selección que también se evalúan por su rendimiento.

3.4. Sesgo y Varianza

El error esperado de predicción de un modelo $\hat{f}$ en una observación nueva se puede descomponer en tres partes

$$\mathbb{E}[(y - \hat{f}(\mathbf{x}))^2] = \underbrace{(\mathbb{E}[\hat{f}(\mathbf{x})] - f(\mathbf{x}))^2}_{\text{sesgo}^2} + \underbrace{\mathbb{E}[(\hat{f}(\mathbf{x}) - \mathbb{E}[\hat{f}(\mathbf{x})])^2]}_{\text{varianza}} + \underbrace{\sigma^2}_{\text{ruido}}, \tag{3.1}$$

donde f es la función verdadera, σ^2 es la varianza del ruido que ningún modelo puede eliminar y el valor esperado de $\hat{f}$ es sobre las muestras con las que se podría haber entrenado el modelo.

Esta descomposición se deduce en varios pasos. El primero es entender de dónde viene la aleatoriedad. El modelo $\hat{f}$ se entrena con un conjunto $\mathcal{T}$ que es una muestra aleatoria. Con otra muestra se obtendría otro modelo, así que $\hat{f}(\mathbf{x})$ es una variable aleatoria aun cuando $\mathbf{x}$ sea fijo, y $\mathbb{E}[\hat{f}(\mathbf{x})]$ es la predicción promedio en $\mathbf{x}$ sobre todos los conjuntos de entrenamiento posibles. La simulación que se presenta más adelante aproxima ese promedio con las predicciones de los 100 modelos ajustados. Por otro lado, la observación nueva tiene su propio ruido ϵ. El valor esperado de la Ecuación 3.1 es, entonces, sobre las dos fuentes de aleatoriedad, el conjunto de entrenamiento $\mathcal{T}$ y el ruido ϵ.

Los supuestos son los siguientes. La respuesta es $y = f(\mathbf{x}) + \epsilon$, con $\mathbb{E}[\epsilon] = 0$ y $\mathbb{V}[\epsilon] = \sigma^2$. El ruido ϵ es independiente de $\hat{f}$, porque el ruido de la observación nueva no participó en el entrenamiento. Además, $f(\mathbf{x})$ y $\mathbb{E}[\hat{f}(\mathbf{x})]$ son números fijos y no variables aleatorias. Para abreviar se escribe f y $\hat{f}$ en lugar de $f(\mathbf{x})$ y $\hat{f}(\mathbf{x})$.

Se sustituye y en el error de predicción y después se suma y se resta $\mathbb{E}[\hat{f}]$ para agrupar,

$$\begin{aligned} y - \hat{f} &= f + \epsilon - \hat{f} \\ &= \underbrace{(f - \mathbb{E}[\hat{f}])}_{a} + \underbrace{(\mathbb{E}[\hat{f}] - \hat{f})}_{b} + \epsilon. \end{aligned}$$

El término a es una constante, b depende del conjunto de entrenamiento y ϵ del ruido de la observación nueva. Al elevar al cuadrado el trinomio se obtienen seis términos,

$$(a + b + \epsilon)^2 = a^2 + b^2 + \epsilon^2 + 2ab + 2a\epsilon + 2b\epsilon.$$

Se toma el valor esperado de cada término usando la linealidad del valor esperado, y la constante a sale del valor esperado,

$$\mathbb{E}[(y-\hat{f})^2] = a^2 + \mathbb{E}[b^2] + \mathbb{E}[\epsilon^2] + \underbrace{2a\,\mathbb{E}[b]}_{\mathbb{E}[b]=0} + \underbrace{2a\,\mathbb{E}[\epsilon]}_{\mathbb{E}[\epsilon]=0} + \underbrace{2\,\mathbb{E}[b\,\epsilon]}_{\mathbb{E}[b]\,\mathbb{E}[\epsilon]=0}.$$

Los tres términos cruzados valen cero. El primero, porque $\mathbb{E}[b] = \mathbb{E}[\hat{f}] - \mathbb{E}[\hat{f}] = 0$. El segundo, porque $\mathbb{E}[\epsilon] = 0$ por el supuesto del modelo. En el tercero, la independencia entre el conjunto de entrenamiento y el ruido de la observación nueva implica que $\mathbb{E}[b\,\epsilon] = \mathbb{E}[b]\,\mathbb{E}[\epsilon]$, y por eso también es cero.

Quedan tres términos. El primero es $a^2 = (\mathbb{E}[\hat{f}] - f)^2$, el sesgo al cuadrado. El segundo es $\mathbb{E}[b^2] = \mathbb{E}[(\hat{f} - \mathbb{E}[\hat{f}])^2]$, la varianza de $\hat{f}$, y el signo de b no importa porque se eleva al cuadrado. El tercero es $\mathbb{E}[\epsilon^2] = \mathbb{V}[\epsilon] + \mathbb{E}[\epsilon]^2 = \sigma^2 + 0 = \sigma^2$, por la definición de varianza, y es el ruido. Con esto se obtiene la Ecuación 3.1.

En palabras, un modelo rígido se equivoca de manera parecida en todas las muestras (sesgo), mientras que un modelo flexible cambia mucho de una muestra a otra (varianza). Es el mismo fenómeno que muestran la Figura 1.11 y la Figura 1.12 de la Introducción.

Solo en una simulación se conoce la función verdadera y se pueden repetir las muestras, por lo que el compromiso se ilustra con el problema sintético de regresión del apéndice, $f(x) = \sin(x) + 0.3\cos(3x)$ (Figura B.12). Se generan 100 muestras de 30 puntos con ruido gaussiano de desviación estándar 0.3 y en cada una se ajustan polinomios de grado 1, 3 y 12, es decir, una regresión lineal sobre las variables $x, x^2, \ldots, x^g$.

```
rng = np.random.default_rng(0)
x_malla = np.linspace(-5, 5, 200)
f = lambda x: np.sin(x) + 0.3 * np.cos(3 * x)
grados = [1, 3, 12]
predicciones = {g: [] for g in grados}
for _ in range(100):
    x = rng.uniform(-5, 5, size=30)
    y_sim = f(x) + rng.normal(scale=0.3, size=x.shape[0])
    for g in grados:
        pol = PolynomialFeatures(degree=g)
        X_pol = pol.fit_transform(x[:, None])
        modelo = LinearRegression().fit(X_pol, y_sim)
        predicciones[g].append(modelo.predict(pol.transform(x_malla[:, None])))
```

La Figura 3.3 muestra, para cada grado, la función verdadera en negro, las curvas ajustadas en cada muestra en gris y su promedio en color.

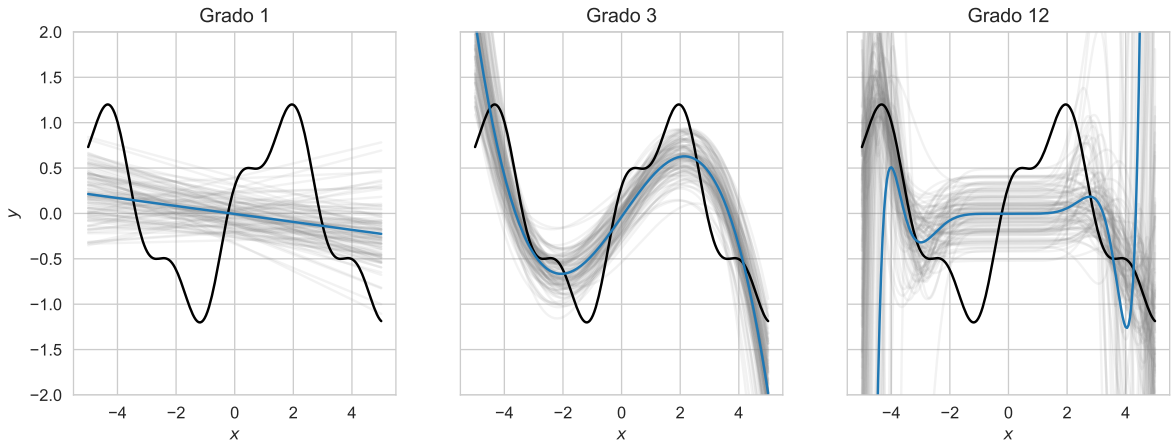


Figura 3.3: Polinomios de diferente grado ajustados a 100 muestras del problema sintético.

Tabla 3.1: Sesgo al cuadrado y varianza promedio en la malla de x para cada grado del polinomio.

Grado	Sesgo^2	Varianza
1	0.5455	0.0469
3	0.1822	0.0641
12	32.3528	647.3958

El polinomio de grado 1 es una recta. El promedio de sus predicciones está lejos de la función verdadera (sesgo alto) pero las rectas de las diferentes muestras se parecen entre sí (varianza baja). El polinomio de grado 12 hace lo contrario. Puede seguir cada muestra, pero cada muestra produce una curva muy distinta y las curvas oscilan de manera violenta, sobre todo en los extremos, donde varias se salen de la figura (varianza altísima). Con una varianza tan grande, el promedio de las 100 curvas todavía está dominado por unas pocas curvas extremas y por eso su sesgo estimado también es grande. El grado 3 tiene el mejor equilibrio entre ambos, tal y como lo cuantifica la Tabla 3.1, pues es el de menor suma de sesgo^2 y varianza. La regularización que se presenta a continuación es una manera de reducir la varianza a cambio de aceptar un poco de sesgo.

3.5. Regresión Ridge

La regresión Ridge (Hoerl y Kennard (1970)) controla la varianza penalizando el tamaño de los coeficientes. En lugar de minimizar solamente la suma de los errores al cuadrado, minimiza

$$\min_{\mathbf{w},w_0} || \mathbf{y} - X\mathbf{w} - w_0 ||_2^2 + \lambda || \mathbf{w} ||_2^2, \tag{3.2}$$

donde $\lambda \geq 0$ controla cuánto se encogen los coeficientes hacia cero. Con $\lambda = 0$ se obtiene MCO. Esta función objetivo tiene solución cerrada, $\mathbf{w} = (X^\top X + \lambda I)^{-1} X^\top \mathbf{y}$ (cuando las columnas están centradas, que es el caso aquí, el término independiente es la media de $\mathbf{y}$). La penalización depende de la escala de cada variable, pues un coeficiente de una variable medida en unidades pequeñas es grande y se penalizaría más. Por eso las variables se estandarizaron en la Sección 3.2. En scikit-learn el hiperparámetro λ se llama `alpha`. En el texto se usa λ y en el código `alpha`.

```
ridge = Ridge(alpha=10).fit(T, y_t)
```

La norma L_2 de los coeficientes de MCO es 4.8202 y la del modelo Ridge con $\lambda = 10$ es 3.4774, es decir, los coeficientes se encogieron. La Figura 3.4 muestra cada uno de los coeficientes en función de λ. Se omite la leyenda porque son demasiadas variables.

```
lambdas = np.logspace(-2, 5, 50)
caminos = np.array([Ridge(alpha=l).fit(T, y_t).coef_ for l in lambdas])
```

Todos los coeficientes tienden a cero de manera suave conforme crece λ, pero ninguno llega a ser exactamente cero. Ridge reduce la varianza sin descartar variables.

3.6. Lasso

Lasso (Tibshirani (1996)) cambia la penalización por la norma L_1 de los coeficientes

$$\min_{\mathbf{w},w_0} \frac{1}{2N} || \mathbf{y} - X\mathbf{w} - w_0 ||_2^2 + \lambda || \mathbf{w} ||_1, \tag{3.3}$$

donde se utiliza la normalización $\frac{1}{2N}$ porque es la que usa la clase `Lasso` de scikit-learn. La norma L_1 hace que algunos coeficientes sean **exactamente cero**, por lo que Lasso selecciona variables al mismo tiempo que ajusta el modelo. A diferencia de Ridge, no tiene una solución cerrada y se resuelve numéricamente, en scikit-learn por descenso por coordenadas (la idea general de la optimización numérica se presenta en Capítulo 9).

```
lasso = Lasso(alpha=0.5).fit(T, y_t)
```

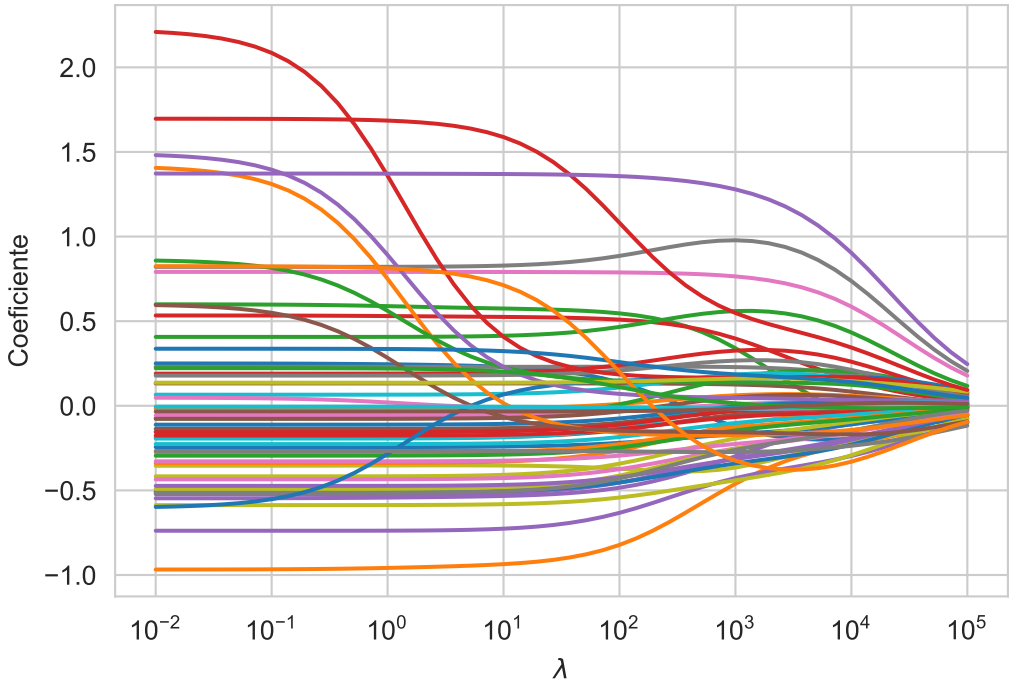


Figura 3.4: Coeficientes de Ridge en función de λ.

Con $\lambda = 0.5$, 49 de los 56 coeficientes son exactamente cero y las variables que sobreviven son `alumnos`, `pct_primer_grado`, `entidad_Michoacán`, `entidad_Oaxaca`, `tipo_servicio_general`, `turno_matutino`, `organizacion_docentes_multigrado`. La Figura 3.5 muestra el camino de los coeficientes, y la Figura 3.6 el número de coeficientes distintos de cero en función de λ.

```
lambdas = np.logspace(-3, 1, 50)
caminos = np.array([Lasso(alpha=l, max_iter=5000).fit(T, y_t).coef_
                    for l in lambdas])
```

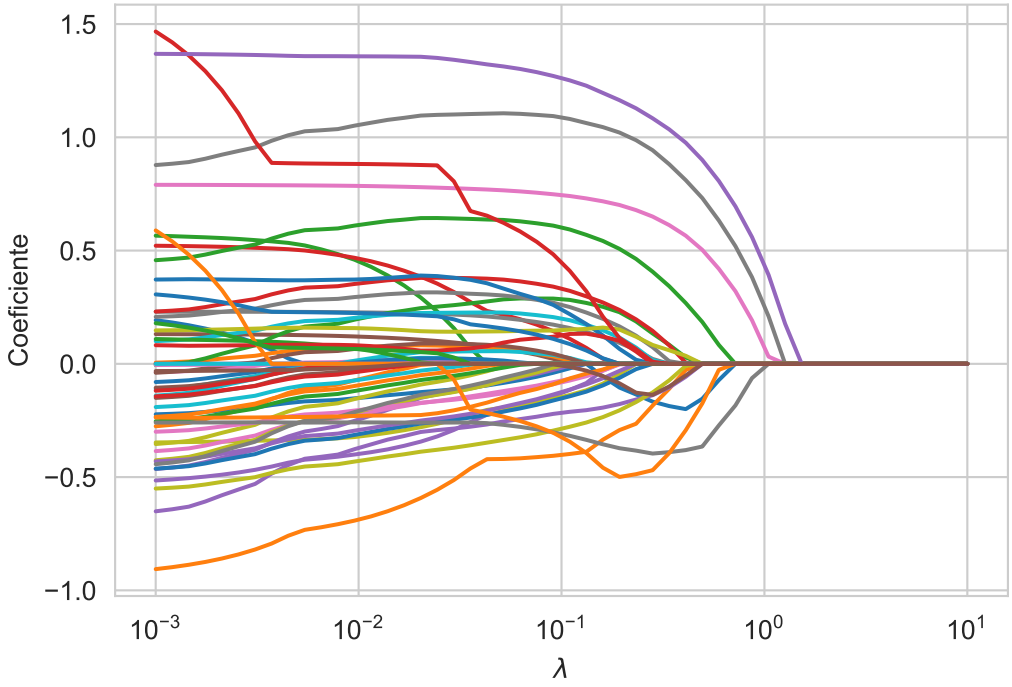


Figura 3.5: Coeficientes de Lasso en función de λ.

En contraste con Ridge, los coeficientes de Lasso llegan a cero de manera abrupta y, para λ suficientemente grande, el modelo se reduce a la media de $\mathbf{y}$ (todos los coeficientes son cero).

Que Lasso seleccione variables al mismo tiempo que ajusta el modelo es una de sus ventajas. En el siguiente capítulo (Capítulo 4) se presentan otros procedimientos de selección de variables y se comparan con lo que elige Lasso.

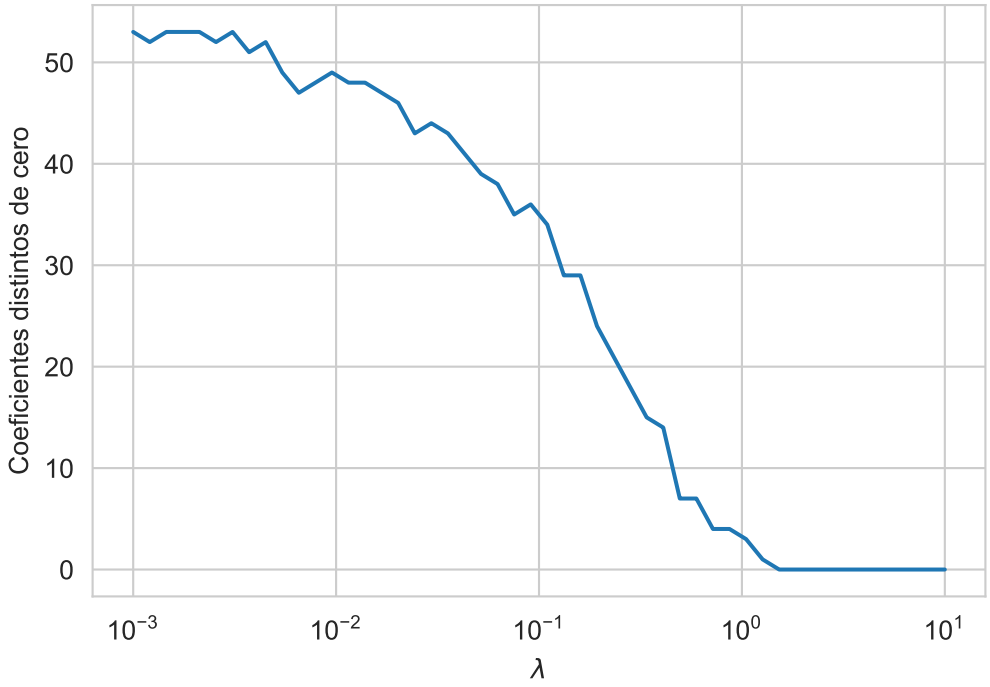


Figura 3.6: Número de coeficientes distintos de cero de Lasso en función de λ.

Lasso como problema con restricción

La forma penalizada de Lasso es equivalente a un problema de optimización con restricción, que consiste en minimizar el error sujeto a que la norma L_1 de los coeficientes no supere un valor γ (a cada λ le corresponde un γ), tal y como se muestra en la Ecuación 3.4.

$$\begin{aligned} &\text{mín} \mid\mid \mathbf{y} - (X\mathbf{w} + w_0) \mid\mid_2 \\ &\text{sujeto a} \\ &\mid\mid \mathbf{w} \mid\mid_1 \leq \gamma \end{aligned} \tag{3.4}$$

Tener el problema como uno de optimización permite incluir de manera eficiente otras restricciones. El siguiente código codifica y resuelve el problema de la Ecuación 3.4 con la librería CVXPY (Diamond y Boyd (2016)). Para que el solver resuelva el problema en poco tiempo se utiliza una submuestra de 2 000 renglones de $\mathcal{T}$.

```
sub = rng.choice(T.shape[0], size=2000, replace=False)
T_sub, y_sub = T[sub], y_t[sub]
w_cp = cp.Variable(T.shape[1])
w0_cp = cp.Variable(1)
gamma = cp.Parameter(nonneg=True)
gamma.value = 20
objetivo = cp.Minimize(cp.norm(y_sub - (T_sub @ w_cp + w0_cp), 2))
problema = cp.Problem(objetivo, [cp.norm(w_cp, 1) <= gamma])
_ = problema.solve()
```

La norma L_1 de los coeficientes de MCO es 25.9484. Con $\gamma = 20$ la restricción está activa y 7 de los coeficientes quedan por debajo de 10^{-5}, es decir, son prácticamente cero, y la norma L_1 de la solución es 20.0000.

3.6.1. Elastic Net

Elastic Net (Zou y Hastie (2005)) combina las penalizaciones de Ridge y de Lasso

$$\underset{\mathbf{w}, w_0}{\text{mín}} \frac{1}{2N} \mid\mid \mathbf{y} - X\mathbf{w} - w_0 \mid\mid_2^2 + \lambda \left(\underbrace{\rho \mid\mid \mathbf{w} \mid\mid_1}_{\text{Lasso}} + \underbrace{\frac{1-\rho}{2} \mid\mid \mathbf{w} \mid\mid_2^2}_{\text{Ridge}} \right), \tag{3.5}$$

donde $\rho \mid\mid \mathbf{w} \mid\mid_1$ es la penalización de Lasso (Ecuación 3.3) y $\frac{1-\rho}{2} \mid\mid \mathbf{w} \mid\mid_2^2$ la de Ridge (Ecuación 3.2). El parámetro λ controla la fuerza total de la penalización y el parámetro ρ

(`l1_ratio` en scikit-learn) el reparto entre las dos normas. Con $\rho = 1$ se obtiene Lasso y con ρ cercano a cero el modelo se comporta como Ridge.

Al igual que Lasso tiene una forma con restricción (Ecuación 3.4), Elastic Net equivale a minimizar el error sujeto a que una combinación de las dos normas, $\rho \mid\mid \mathbf{w} \mid\mid_1 + \frac{1-\rho}{2} \mid\mid \mathbf{w} \mid\mid_2^2$, no supere un valor γ. Es útil cuando hay grupos de variables correlacionadas, porque Lasso tiende a elegir una de ellas, casi al azar, mientras que Elastic Net reparte el coeficiente entre las variables del grupo.

```
enet = ElasticNet(alpha=0.5, l1_ratio=0.5, max_iter=5000).fit(T, y_t)
```

Este modelo, con $\lambda = 0.5$ y $\rho = 0.5$, tiene 34 coeficientes exactamente cero.

3.7. Selección de λ por Validación Cruzada

El parámetro λ es un hiperparámetro. No se estima al minimizar el error de entrenamiento (siempre elegiría $\lambda = 0$) y tampoco debe elegirse con el conjunto de prueba $\mathcal{G}$, pues este se reserva para medir el rendimiento final (Sección 2.5). Se elige con k iteraciones de validación cruzada (Sección 2.5.1) dentro de $\mathcal{T}$. Para cada valor de λ se entrena con $k-1$ partes, se predice la parte restante y se calcula el error cuadrático medio, y el valor elegido es el que lo minimiza. El siguiente código muestra el procedimiento a mano para Lasso.

```
kfold = KFold(n_splits=5, shuffle=True, random_state=0)
lambdas = np.logspace(-3, 1, 30)
error_cv = []
for l in lambdas:
    hy_v = np.zeros_like(y_t)
    for tr, vs in kfold.split(T):
        modelo = Lasso(alpha=l, max_iter=5000).fit(T[tr], y_t[tr])
        hy_v[vs] = modelo.predict(T[vs])
    error_cv.append(np.mean((y_t - hy_v)**2))
lambda_opt = lambdas[np.argmin(error_cv)]
```

La Figura 3.7 muestra el error de validación en función de λ. El valor que lo minimiza es $\lambda = 0.0092$.

Los algoritmos `LassoCV`, `RidgeCV` y `ElasticNetCV` hacen lo mismo que el ciclo anterior, y el valor seleccionado de λ queda en el atributo `alpha_`.

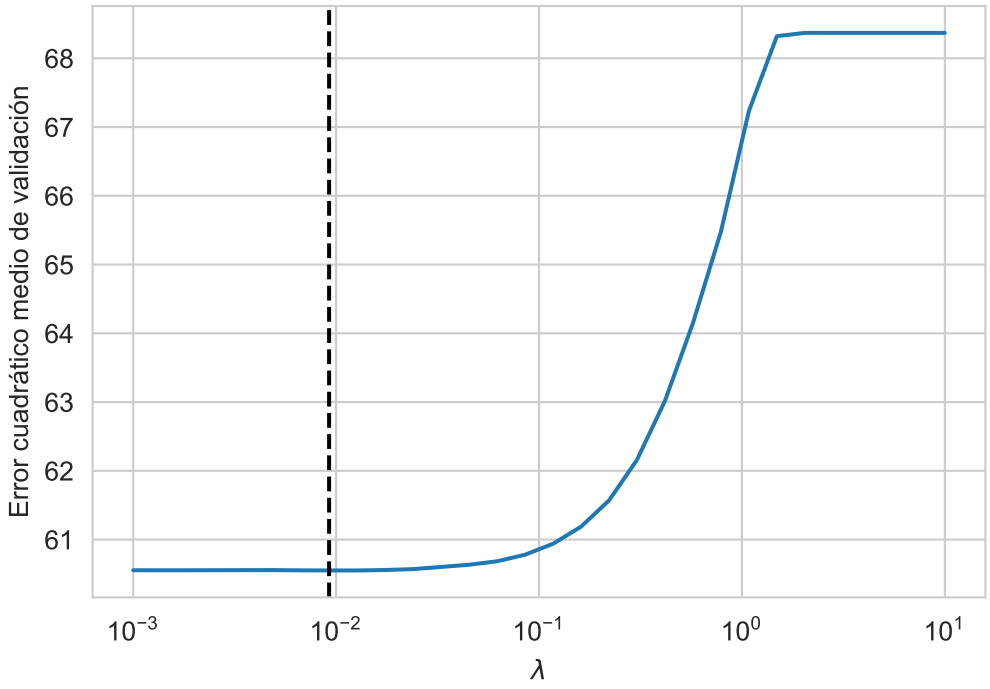


Figura 3.7: Error cuadrático medio de validación cruzada de Lasso en función de λ. La línea vertical indica el valor óptimo.

```
lasso_cv = LassoCV(cv=kfold, alphas=lambdas, max_iter=5000).fit(T, y_t)
ridge_cv = RidgeCV(alphas=np.logspace(-2, 5, 30), cv=kfold).fit(T, y_t)
enet_cv = ElasticNetCV(l1_ratio=[0.2, 0.5, 0.8], cv=kfold,
                       max_iter=5000).fit(T, y_t)
```

`LassoCV` selecciona $\lambda = 0.0092$, que coincide con el valor calculado a mano. `RidgeCV` selecciona $\lambda = 126.8961$, y `ElasticNetCV` selecciona $\lambda = 0.0144$ con $\rho = 0.5$. Con estos valores, Lasso mantiene 50 coeficientes distintos de cero y Elastic Net 50, de un total de 56.

La Figura 3.8 compara, en el conjunto de prueba, el rendimiento de MCO y del modelo reducido (Sección 3.3.2) con el de Ridge, Lasso y Elastic Net con el λ seleccionado por validación cruzada.

```
r2_ols(ridge_cv.predict(G), name='Ridge')
r2_ols(lasso_cv.predict(G), name='Lasso')
r2_ols(enet_cv.predict(G), name='Elastic Net')
r2_ols.plot(comp_legend='Comparación', winner_legend='Mejor',
            tie_legend='Equivalente', loser_legend='Diferente',
            alg_legend='Algoritmo', var_name='Rendimiento')
```

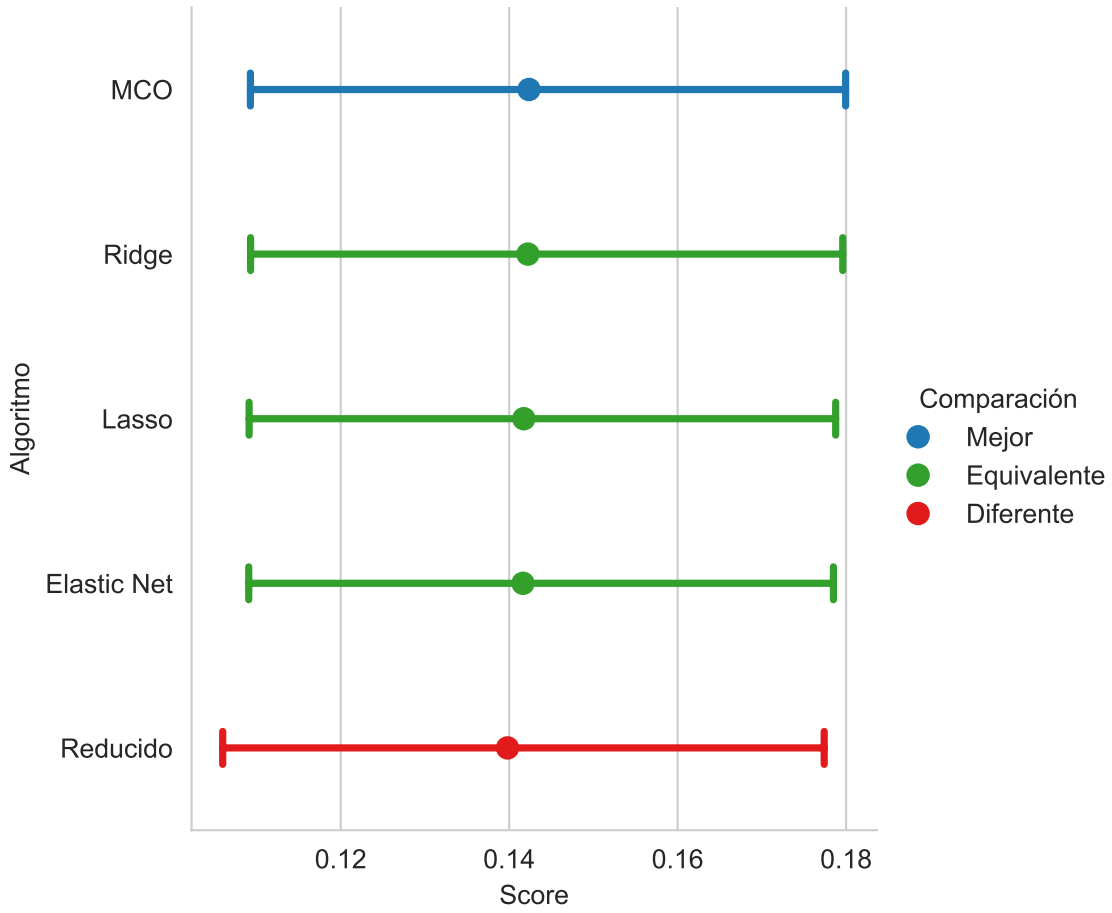


Figura 3.8: Rendimiento (R^2) de MCO, del modelo reducido y de los modelos regularizados en el conjunto de prueba.

Con $N = 26689$ y $d = 56$ ninguno de los modelos regularizados supera a MCO. Ridge, Lasso y Elastic Net son estadísticamente equivalentes a él y el único modelo que la figura marca como diferente es el reducido. Con muchos datos y pocas variables MCO ya tiene poca varianza y la regularización tiene poco que corregir. La ganancia de Lasso, cuando existe, es un modelo con menos variables y el mismo rendimiento, que es lo que interesa cuando el modelo se aplica con información que hay que recabar. Aquí es modesta, pues conserva 50 de las 56 variables. El R^2 es bajo en todos los casos, pues ningún método puede extraer de las características del plantel más información de la que tienen.

3.8. Los Coeficientes no se Interpretan Causalmente

Lasso y Ridge son útiles para predecir, pero sus coeficientes no se leen como los de MCO en un estudio de efectos. La razón es que las variables que Lasso conserva no son estables. Con variables correlacionadas, pequeños cambios en la muestra cambian la variable que entra y la que sale. El siguiente código lo muestra ajustando `LassoCV` en 10 submuestras aleatorias del 50 % de $\mathcal{T}$ y registrando qué variables tienen un coeficiente distinto de cero, y el R^2 de cada modelo en el conjunto de prueba.

```
seleccion = []
r2_sub = []
for _ in range(10):
    idx = rng.choice(T.shape[0], size=T.shape[0] // 2, replace=False)
    modelo = LassoCV(cv=5, max_iter=5000).fit(T[idx], y_t[idx])
    seleccion.append(modelo.coef_ != 0)
    r2_sub.append(r2(y_g, modelo.predict(G)))
seleccion = np.array(seleccion)
frecuencia = seleccion.mean(axis=0)
```

La Figura 3.9 muestra la frecuencia con la que cada variable fue seleccionada. De las 56 variables, 31 entran en las 10 submuestras y 25 entran en algunas y en otras no, mientras que el R^2 en el conjunto de prueba se mantiene entre 0.1358 y 0.1436.

Varias variables entran y salen según la muestra aunque el rendimiento sea casi idéntico. Es el **efecto Rashomon** de Breiman (2001b), que existen muchos modelos distintos con la misma capacidad de predicción, y es también el hallazgo del ejemplo de los precios de la vivienda de Mullainathan y Spiess (2017). La conclusión es que un coeficiente de Lasso (o de Ridge) dice cuánto contribuye esa variable a predecir **dado el resto de variables que el algoritmo eligió**, y no cuál sería el efecto de modificarla. Con variables correlacionadas, la que sale puede ser una sustituta de la que importa. La misma inestabilidad afecta a los procedimientos de selección de variables del capítulo siguiente (Capítulo 4), pues eligen subconjuntos distintos con un rendimiento similar.

Hay un caso donde la selección con Lasso sí es un problema para quien busca un efecto. Cuando lo que interesa es el efecto de una variable (un tratamiento) y Lasso se usa para elegir los controles, seleccionar con un solo Lasso de y sesga la estimación, porque omite controles que predicen poco y pero mucho el tratamiento. Belloni et al. (2014) proponen la *post-double-selection*, que selecciona los controles que predicen y y los que predicen el tratamiento. Ese procedimiento se desarrolla en el capítulo de Aprendizaje Computacional e Inferencia Causal (en preparación), y la interpretación de los modelos predictivos se trata en el capítulo de Interpretabilidad y Equidad (en preparación).

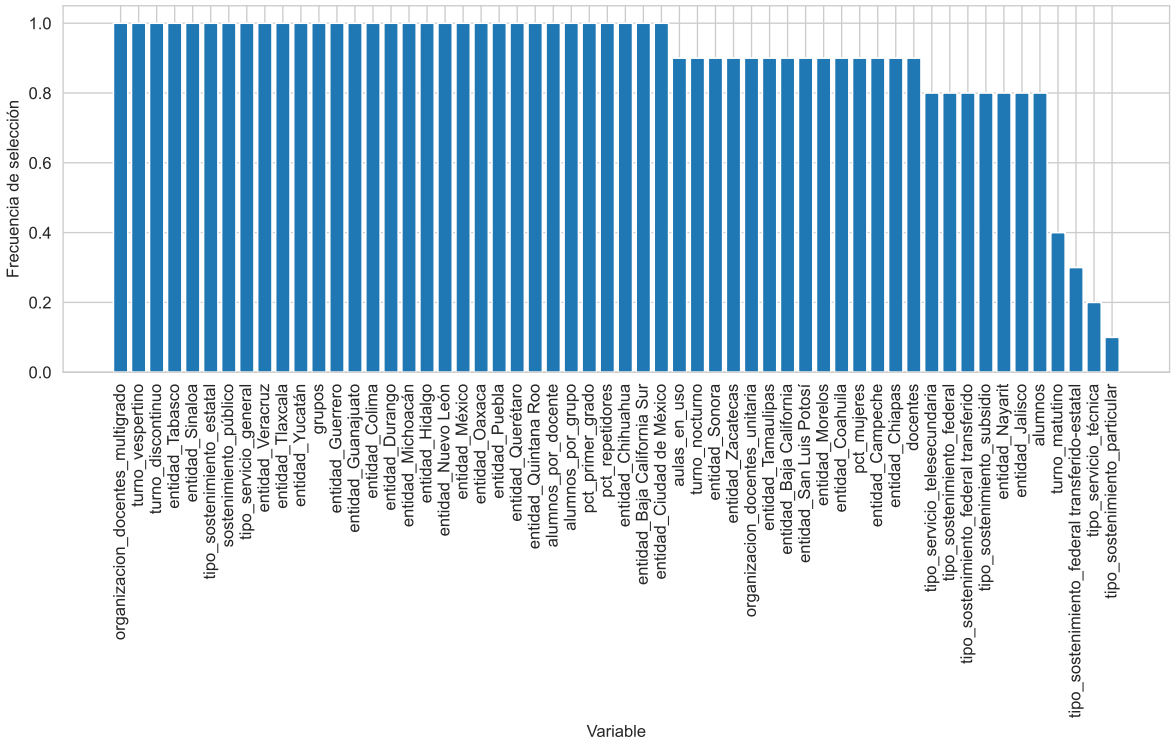


Figura 3.9: Frecuencia con la que Lasso selecciona cada variable en 10 submuestras de $\mathcal{T}$.

Actividad

Lea las secciones sobre regularización de Mullainathan y Spiess (2017) y la introducción de Belloni et al. (2014). Para un *policy paper* en el que usted quiera estimar el efecto de un programa de becas sobre el abandono escolar, escriba qué variable sería el "tratamiento" y cuáles los controles, y argumente si el problema es de $\hat{y}$ o de $\hat{\beta}$.

3.9. Focalización: un Problema de Política de Predicción

Un programa social con recursos limitados necesita decidir a qué hogares dirigirse. Verificar el ingreso de cada hogar es costoso, por lo que muchos programas usan una *prueba de medios sustituta* (*proxy means test*). Con ella se predice si un hogar es pobre con **pocas** variables observables de la vivienda y el hogar, porque cada variable que se incluye hay que verificarla en campo. Los procedimientos de selección del capítulo siguiente (Capítulo 4) son una alternativa a la penalización L_1 para reducir el número de variables. Los datos son los de Pobreza del apéndice (Sección B.1.1).

Es un problema de clasificación y no de regresión, pues el objetivo `pobre_ingresos` es binario. Se usa regresión logística con penalización L_1 como una caja negra. El modelo se describe en la Sección 8.5 y aquí basta saber que `fit` y `predict` funcionan igual y que la penalización L_1 vuelve cero algunos coeficientes, como en Lasso. En scikit-learn el hiperparámetro es `C`, el **inverso** de λ, de manera que un valor pequeño de `C` es una penalización más fuerte. Se codifica y se estandariza igual que antes. No se usa el factor de expansión (`factor`) porque el objetivo es la decisión por hogar y no una estimación de la población.

```
pobreza = pd.read_csv(f'{URL_DATOS}/enigh_pobreza.csv.gz')
Xp = pd.get_dummies(pobreza.drop(columns=['pobre_ingresos', 'factor']),
                    drop_first=True, dtype=float)
columnas_p = Xp.columns
yp = pobreza['pobre_ingresos'].to_numpy()
Tp, Gp, yp_t, yp_g = train_test_split(Xp.to_numpy(), yp, test_size=0.2,
                                      random_state=0, stratify=yp)
escala_p = StandardScaler().fit(Tp)
Tp = escala_p.transform(Tp)
Gp = escala_p.transform(Gp)
```

La matriz de diseño tiene $N = 89988$ hogares y $d = 129$ columnas, y 32.7 % de los hogares son pobres por ingresos. El siguiente código ajusta el modelo para seis valores de `C` y mide, en el conjunto de prueba, cuántas variables conserva el modelo, la cobertura (*recall*) y la precisión.

```
Cs = [0.001, 0.003, 0.01, 0.03, 0.1, 1]
resultados = []
modelos_p = []
for C in Cs:
    clf = LogisticRegression(penalty='l1', C=C, solver='liblinear',
                             max_iter=1000).fit(Tp, yp_t)
    hy_p = clf.predict(Gp)
    modelos_p.append(clf)
    resultados.append(dict(C=C, variables=int((clf.coef_ != 0).sum()),
                           cobertura=recall(yp_g, hy_p),
                           precision=precision(yp_g, hy_p)))
resultados = pd.DataFrame(resultados)
```

Tabla 3.2: Número de variables, cobertura y precisión de la regresión logística con penalización L_1 en el conjunto de prueba.

C	Variables	Cobertura	Precisión
0.001	34	0.5372	0.7240
0.003	67	0.5756	0.7282
0.01	100	0.5914	0.7236
0.03	115	0.5965	0.7232
0.1	121	0.5970	0.7219
1.0	129	0.5982	0.7220

La Tabla 3.2 y la Figura 3.10 muestran que con 34 variables se alcanza una cobertura de 0.5372, frente a 0.5982 con 129 variables. Con 67 variables la cobertura es 0.5756, 96.2 % de la que se logra con todas. La precisión casi no cambia. Reducir el número de variables cuesta, entonces, algo de cobertura, y la política debe decidir cuánta está dispuesta a perder a cambio de verificar menos información en campo. Las variables con mayor coeficiente en valor absoluto en el modelo más pequeño son `integrantes`, `menores_12`, `vehiculos`, `tipo_hogar_unipersonal`, `combustible_cocina_leña`, `personas_por_cuarto`, `televisores_digitales`, `computadoras`, `tam_localidad_menos de 2,500`, `escolaridad_jefe_profesional completa`.

En términos de política, la cobertura es la proporción de hogares pobres que el programa alcanza y 1− precisión es la proporción de beneficiarios que no son pobres. Son, respectivamente, los errores de exclusión y de inclusión. El modelo se evaluó con el umbral que usa `predict` por omisión. Qué umbral usar cuando ambos errores cuestan distinto se trata en Capítulo 5.

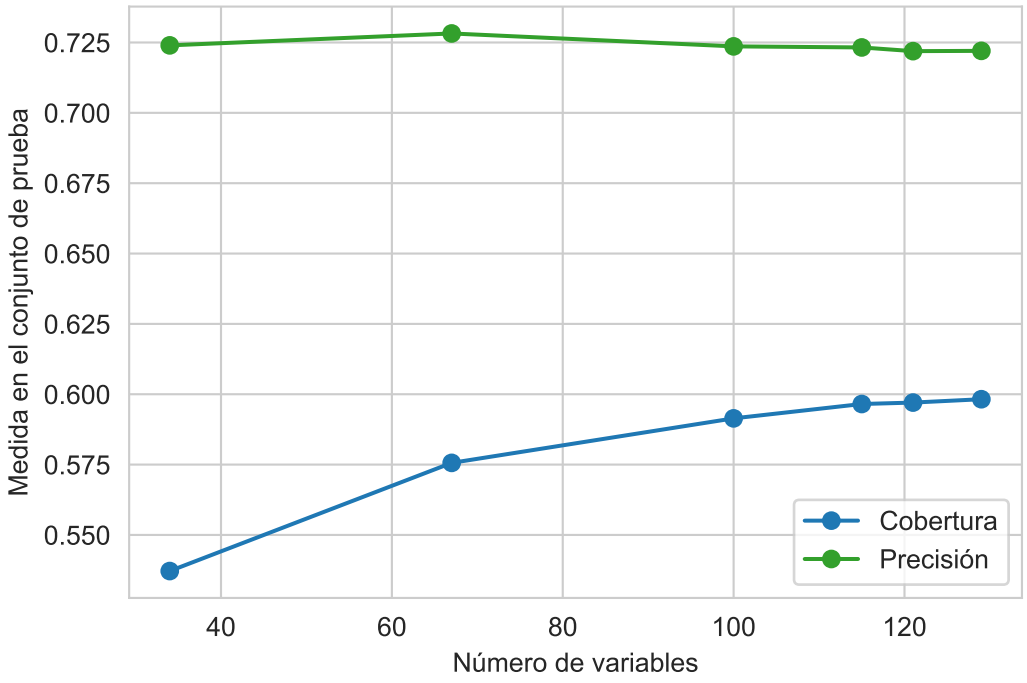


Figura 3.10: Cobertura y precisión en el conjunto de prueba contra el número de variables que conserva el modelo.

3.10. Resumen

En este capítulo se evaluó la regresión lineal por su capacidad de predecir observaciones no vistas y no por la significancia de sus coeficientes (Sección 3.3). El error de predicción se descompone en sesgo y varianza (Ecuación 3.1), y de ahí se entiende que un modelo con muchas variables y pocos datos puede rendir peor fuera de muestra que uno más simple (Sección 3.4). Ridge (Sección 3.5), Lasso (Sección 3.6) y Elastic Net (Sección 3.6.1) aceptan algo de sesgo a cambio de reducir la varianza, y el hiperparámetro λ se selecciona con validación cruzada (Sección 3.7) y no con el conjunto de prueba. Los coeficientes de un modelo regularizado no se interpretan como efectos causales (Sección 3.8), porque las variables que Lasso selecciona cambian con la muestra aunque el rendimiento casi no cambie.

La utilidad para la política pública se vio en la Sección 3.9. Con los datos de Abandono Escolar y de Pobreza, un modelo regularizado permite estimar qué escuelas o qué hogares requieren atención y evaluar ese ejercicio con la cobertura y la precisión, es decir, con los errores de exclusión y de inclusión de un programa. Quien viene de Econometría puede reconocer aquí el mismo modelo de siempre, pero se evalúa con otro criterio, pues importa qué tan bien predice y no qué tan bien se interpreta.

Lasso selecciona variables como un efecto secundario de la regularización, y queda la pregunta de qué otros procedimientos existen para reducir el número de variables y cuánto cuesta hacerlo. Esa pregunta se responde en Capítulo 4.

Actividades

Actividad

Repita el procedimiento del capítulo (MCO, Ridge y Lasso con λ seleccionado por validación cruzada, y comparación con `CompStats`) con el conjunto de Territorio (Sección B.1.5). El objetivo es `grado_promedio_escolaridad` y se descartan `clave_ageb`, `municipio`, `pct_viv_internet`, `pct_sin_servicio_salud` y `pct_jefatura_femenina`. Con un número pequeño de renglones y de variables la regularización debe notarse más que en Educación. Conteste las siguientes preguntas. ¿Qué sectores de establecimientos selecciona Lasso? ¿Cambian si se repite con otra partición?

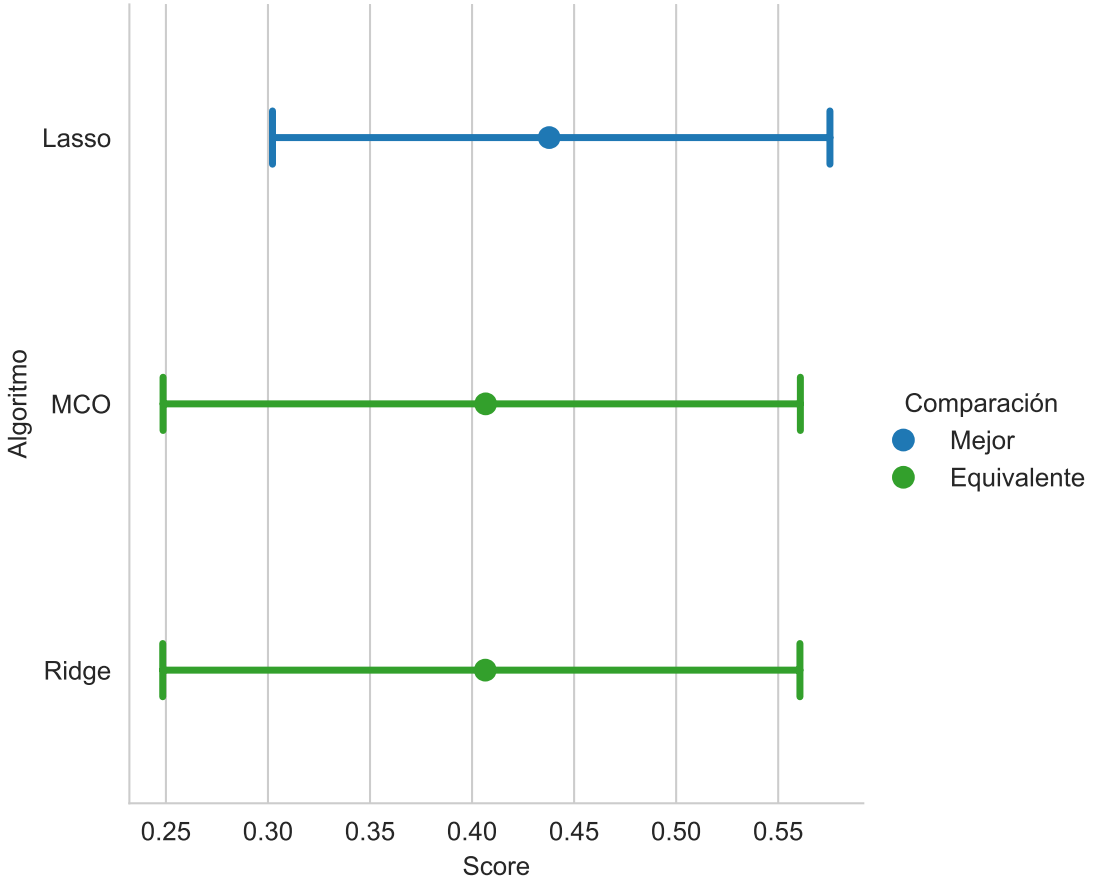


Figura 3.11: Rendimiento (R^2) de MCO, Ridge y Lasso en el problema de Territorio.

El resultado esperado se muestra en la Figura 3.11, con $N = 464$ AGEB y $d = 30$ variables. Las variables que conserva Lasso son `pob_total`, `viviendas_habitadas`, `est_agropecuario`, `est_alojamiento_alimentos`, `est_construccion`, `est_corporativos`, `est_educacion`, `est_energia_y_agua`, `est_esparcimiento`, `est_finanzas_seguros`, `est_gobierno_organismos`, `est_informacion_medios`, `est_inmobiliarios`, `est_manufactura`, `est_mineria`, `est_otros_servicios`, `est_salud_asistencia`, `est_servicios_apoyo`, `est_transporte`, `est_0_5_personas`, `est_6_10_personas`, `est_11_30_personas`, `est_51_100_personas`, `est_101_250_personas`, `est_251_o_mas_personas`.

4 Selección de Variables

El **objetivo** de la unidad es aplicar procedimientos de selección de variables en un problema de regresión, a saber, filtros basados en estadísticas, selección hacia adelante y hacia atrás, y selección mediante un modelo, y comparar las variables que elige cada uno con las que elige Lasso.

Paquetes usados

```
from sklearn.linear_model import LinearRegression, Lasso, LassoCV
from sklearn.model_selection import train_test_split, KFold
from sklearn.preprocessing import StandardScaler
from sklearn.feature_selection import f_regression, SelectKBest,\
                                      SequentialFeatureSelector,\
                                      SelectFromModel
from sklearn.metrics import r2_score as r2
from CompStats.metrics import r2_score
import numpy as np
import pandas as pd
from matplotlib import pylab as plt
import matplotlib as mpl
import seaborn as sns
URL_DATOS = ('https://github.com/INGEOTEC/AprendizajeComputacional/'
             'releases/download/datos-v1')
PALETTE = mpl.cm.Paired
```

4.1. Introducción

Lasso (Sección 3.6) selecciona variables al mismo tiempo que ajusta el modelo, y el modelo reducido (Sección 3.3.2) quitó las variables cuyo estadístico t era pequeño. Este capítulo presenta los procedimientos clásicos de selección, que son los filtros basados en estadísticas, la búsqueda hacia adelante y hacia atrás, y la selección mediante un modelo, y los compara con lo que eligió Lasso.

Todos parten de la idea de que existen variables que no contribuyen a la solución o cuyo aporte ya está dado por otras, y una introducción general a estos procedimientos es Guyon y Elisseeff (2003). Esto trae como consecuencia, en el mejor de los casos, un mayor costo computacional o de recolección y, en uno menos afortunado, un modelo con un rendimiento menor al que se hubiera obtenido seleccionando las variables.

Los datos son los de Abandono Escolar y la preparación es la misma que en la Sección 3.2, por lo que no se vuelve a explicar. El siguiente código lee los datos, codifica las variables categóricas, separa los conjuntos de entrenamiento y prueba con el mismo `random_state` y estandariza con $\mathcal{T}$.

```
educacion = pd.read_csv(f'{URL_DATOS}/sep_f911_educacion.csv.gz')
constantes = [c for c in educacion.columns if educacion[c].nunique() == 1]
X = educacion.drop(columns=['tasa_abandono', 'clave_cct'] + constantes)
y = educacion['tasa_abandono'].to_numpy()
X = pd.get_dummies(X, drop_first=True, dtype=float)
columnas = X.columns
T, G, y_t, y_g = train_test_split(X.to_numpy(), y, test_size=0.2,
                                  random_state=0)
escala = StandardScaler().fit(T)
T = escala.transform(T)
G = escala.transform(G)
```

Para comparar con Lasso se recalcula el λ que selecciona la validación cruzada (Sección 3.7).

```
kfold = KFold(n_splits=5, shuffle=True, random_state=0)
lambdas = np.logspace(-3, 1, 30)
lasso_cv = LassoCV(cv=kfold, alphas=lambdas, max_iter=5000).fit(T, y_t)
lambda_opt = lasso_cv.alpha_
```

El λ seleccionado es 0.0092 y Lasso conserva el subconjunto de variables con coeficiente distinto de cero de entre las 56 variables.

4.2. Basada en Estadísticas

Una manera de seleccionar es descartar las variables que no tienen relación con la respuesta. En regresión, la prueba es la estadística F de la regresión lineal simple de y sobre cada variable, cuya hipótesis nula es que el coeficiente es cero. Está implementada en la función `f_regression`. (En clasificación la prueba equivalente es Kruskal-Wallis, o ANOVA si se supone normalidad.) Con esas estadísticas se pueden ordenar las variables y seleccionar las k mejores con `SelectKBest`.

```
f_est, p_valores = f_regression(T, y_t)
sel = SelectKBest(score_func=f_regression, k=10).fit(T, y_t)
seleccionadas = columnas[sel.get_support()]
```

Las diez variables con mayor estadística F son `alumnos`, `grupos`, `docentes`, `pct_primer_grado`, `aulas_en_uso`, `entidad_Oaxaca`, `tipo_sostenimiento_particular`, `tipo_servicio_general`, `tipo_servicio_telesecundaria`, `organizacion_docentes_multigrado`. De ellas, 8 están entre las que conserva Lasso con el λ elegido por validación cruzada.

4.2.1. Ventajas y Limitaciones

Las técnicas basadas en estadísticas requieren de pocos recursos computacionales y están basadas en pruebas que permiten saber cuáles son las razones de su funcionamiento. Estas fortalezas también son origen de sus debilidades, pues observan las variables de manera aislada y no consideran que pueden interactuar. Por otro lado, la selección es agnóstica del algoritmo de aprendizaje utilizado.

4.3. Selección hacia Adelante y hacia Atrás

Un procedimiento que pone en el centro del proceso de selección al algoritmo de aprendizaje utilizado es **Selección hacia Adelante** y su complemento, **Selección hacia Atrás.** El algoritmo de selección hacia adelante es un procedimiento iterativo que selecciona una variable a la vez guiada por el rendimiento de esa variable cuando es usada en el algoritmo de aprendizaje. Al igual que los procedimientos anteriores, no modifica las características del problema, solamente selecciona las que se consideran relevantes.

En selección hacia adelante y hacia atrás se inicia con el conjunto de entrenamiento $\mathcal{T} = \{(x_i, y_i)\}$, con una función L que mide el rendimiento del algoritmo de aprendizaje $\mathcal{H}$. La idea es ir seleccionando de manera iterativa aquellas variables que generan un modelo con mejores capacidades de generalización. Para medir la generalización se puede dividir $\mathcal{T}$ en dos conjuntos, entrenamiento y validación, o utilizar k iteraciones de validación cruzada.

Suponga un conjunto $\pi \subseteq \{1, 2, \ldots, d\}$ de tal manera que $\mathcal{T}_\pi$ solamente cuenta con las variables identificadas en el conjunto π. Utilizando esta notación el algoritmo se puede definir de la siguiente manera. Inicialmente $\pi^0 = \emptyset$, en el siguiente paso $\pi^{j+1} \leftarrow \pi^j \cup \arg\max_{\{i|i\in\{1,2,\ldots,d\}, i\notin\pi^j\}} \mathcal{P}(\mathcal{H}, \mathcal{T}_{\pi\cup i}, L)$, donde $\mathcal{P}$ representa el rendimiento del algoritmo $\mathcal{H}$ en el subconjunto $\pi \cup i$ usando la función de rendimiento L. Este proceso continúa si $\mathcal{P}^{j+1} > \mathcal{P}^j$ donde $\mathcal{P}^0 = 0$.

Es importante mencionar que el algoritmo antes descrito es un algoritmo voraz y que el encontrar el óptimo de este problema de optimización no se garantiza con este tipo de algoritmos. Lo que quiere decir es que el algoritmo encontrará un óptimo local.

Ilustrando la primera iteración en el problema de abandono escolar, $\mathcal{H}$ es la regresión lineal y L es R^2 medido con validación cruzada. Como inicialmente $\pi^0 = \emptyset$, solo es necesario ajustar un modelo con cada una de las variables por separado. El siguiente código itera por todas las variables, selecciona en `T1` los datos con esa única variable, hace k iteraciones de validación cruzada y guarda el rendimiento en `perf`.

```
perf = []
for var in range(T.shape[1]):
    T1 = T[:, [var]]
    hy_v = np.zeros_like(y_t)
    for tr, vs in kfold.split(T1):
        hy_v[vs] = LinearRegression().fit(T1[tr], y_t[tr]).predict(T1[vs])
    perf.append(r2(y_t, hy_v))
```

La Figura 4.1 muestra el R^2 de cada variable en la primera iteración. La mejor variable es `organizacion_docentes_multigrado` con un R^2 de 0.0289, y solo 37 de las 56 variables tienen un R^2 de validación positivo, es decir, mejor que predecir siempre la media. Esta variable es la que se agregaría en la primera iteración.

> **Nota**
>
> El algoritmo de selección hacia adelante y hacia atrás se implementa en la clase `SequentialFeatureSelector`. Para que el procedimiento no tarde, se pide seleccionar diez variables.
>
> ```
> seq = SequentialFeatureSelector(LinearRegression(), n_features_to_select=10,
>                                 direction='forward', scoring='r2',
>                                 cv=kfold, n_jobs=-1).fit(T, y_t)
> adelante = columnas[seq.get_support()]
> ```
>
> Las variables que selecciona el procedimiento hacia adelante son `grupos`, `pct_primer_grado`, `entidad_Chiapas`, `entidad_Chihuahua`, `entidad_Durango`, `entidad_Michoacán`, `entidad_Oaxaca`, `tipo_servicio_general`, `turno_matutino`, `organizacion_docentes_multigrado`. La selección hacia atrás se obtiene con `direction='backward'`. Empieza con todas las variables y elimina una a la vez, la que menos deteriora el rendimiento. Con 56 variables es mucho más lenta que la selección hacia adelante, pues cada eliminación evalúa casi todas las variables en cada una de las iteraciones de validación cruzada, y por eso no se ejecuta aquí. Como ambos son algoritmos voraces, cada uno llega a un óptimo local distinto y las variables que selecciona

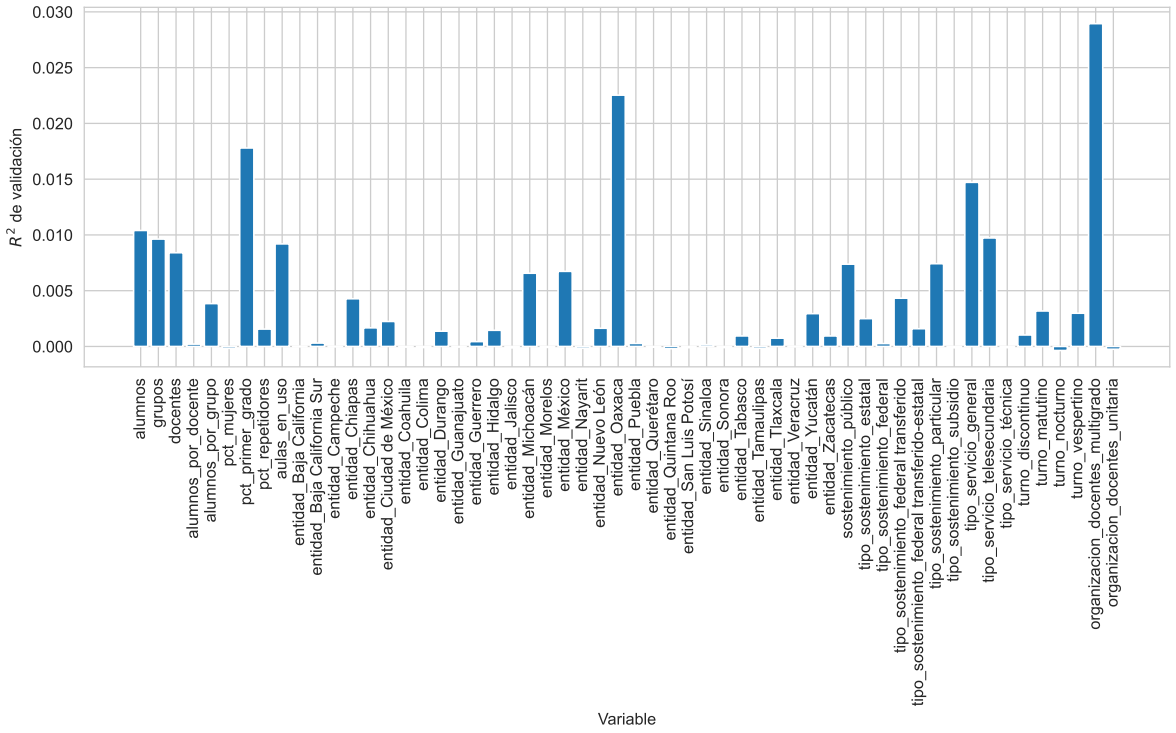


Figura 4.1: Rendimiento (R^2) de cada variable en la primera iteración de la selección hacia adelante.

la versión hacia atrás no tienen por qué coincidir con las de la versión hacia adelante.

4.3.1. Ventajas y Limitaciones

Una de las ventajas de la selección hacia atrás y adelante es que el algoritmo termina a lo más cuando se han analizado todas las variables, esto es, para un problema en $\mathbb{R}^d$ se analizarán un máximo de d variables. La principal desventaja es que estos algoritmos son voraces, es decir, toman la mejor decisión en el momento, lo cual tiene como consecuencia que solo puedan garantizar llegar a un máximo local y en ocasiones este máximo local no corresponde al máximo global. Complementando esta idea, en un problema $\mathbb{R}^d$ se tiene un espacio de búsqueda de $2^d - 1$ subconjuntos de variables. En los algoritmos vistos se observa un máximo de d elementos de ese total.

4.4. Selección mediante Modelo

Existen algoritmos de aprendizaje supervisado donde sus parámetros indican la importancia que tiene cada característica en el problema. Considerando que las variables están estandarizadas, el valor absoluto de un coeficiente de una regresión lineal indica el efecto que tiene esa variable en el resultado y permite ordenarlas por importancia. La clase `SelectFromModel` selecciona las características que el modelo considera más importantes. Con `max_features` se indica cuántas y `prefit=True` indica que el modelo ya está entrenado. El siguiente código lo ilustra con el Lasso del λ óptimo.

```
lasso_opt = Lasso(alpha=lambda_opt, max_iter=5000).fit(T, y_t)
sel = SelectFromModel(lasso_opt, max_features=4,
                      threshold=-np.inf, prefit=True)
cuatro = columnas[sel.get_support()]
```

Las cuatro variables con mayor coeficiente en valor absoluto son `pct_primer_grado`, `entidad_Oaxaca`, `turno_vespertino`, `organizacion_docentes_multigrado`. Habiendo descrito el procedimiento, es necesario encontrar cuál es el número de variables que produce el mejor rendimiento. Para esto se realizan k iteraciones de validación cruzada (Sección 2.5.1), donde se varía el número de variables y en cada caso se mide el rendimiento con R^2 (Sección 2.4).

```
perf_sel = []
for dim in range(2, T.shape[1] + 1):
    modelo = SelectFromModel(lasso_opt, max_features=dim,
                             threshold=-np.inf, prefit=True)
```

```
    Dt = modelo.transform(T)
    hy_v = np.zeros_like(y_t)
    for tr, vs in kfold.split(Dt):
        m_sel = LinearRegression().fit(Dt[tr], y_t[tr])
        hy_v[vs] = m_sel.predict(Dt[vs])
    perf_sel.append(dict(r2=r2(y_t, hy_v), numero=dim))
perf_sel = pd.DataFrame(perf_sel)
```

La Figura 4.2 muestra el R^2 en validación cruzada desde el modelo con las dos variables más importantes hasta el que usa todas. El rendimiento pasa de 0.0520 con dos variables a 0.0961 con diez, y llega a un máximo de 0.1153 con 37 variables. Con todas las variables vale 0.1142. Es decir, el rendimiento mejora rápidamente con las primeras variables y después se estabiliza, de manera que agregar las últimas casi no lo modifica.

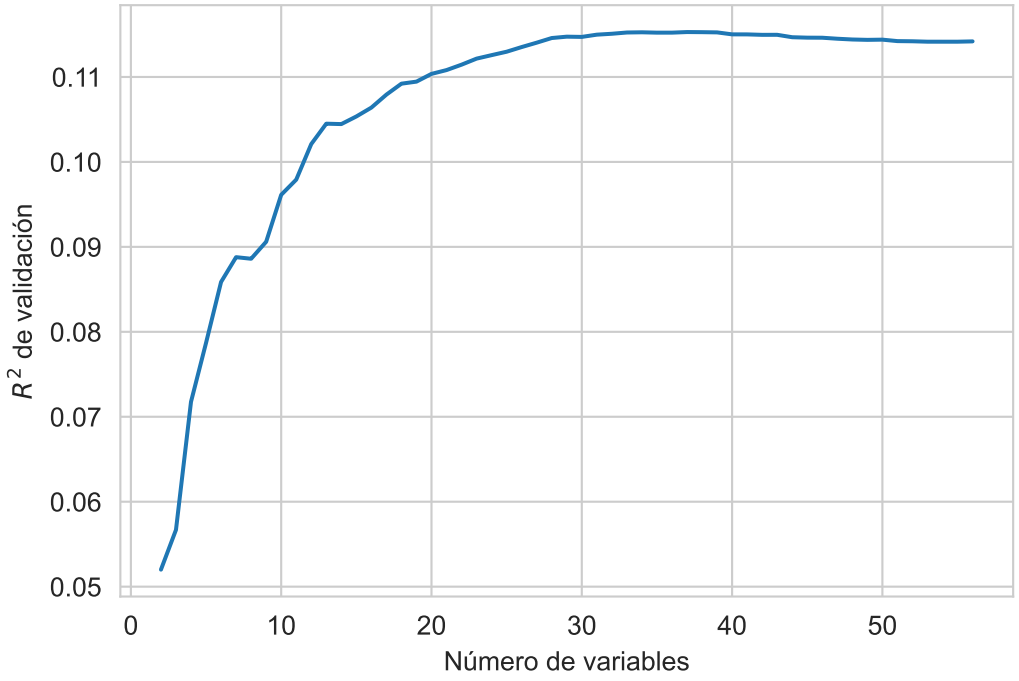


Figura 4.2: Rendimiento (R^2) en validación cruzada variando el número de variables seleccionadas.

4.4.1. Ventajas y Limitaciones

Una vez entrenado el modelo, la selección es barata, pues solo ordena las variables por la magnitud de sus coeficientes y no requiere ajustar un modelo por cada subconjunto, como

lo hacen la selección hacia adelante y hacia atrás. La desventaja es que el orden depende del modelo y de la escala de las variables, que en este capítulo son comparables porque se estandarizaron con $\mathcal{T}$. Además, los coeficientes de un modelo lineal no capturan las interacciones entre variables, y cuando dos variables están correlacionadas el modelo reparte el coeficiente entre ellas de una manera que depende de la muestra.

4.5. Comparación de los Procedimientos

Hasta aquí cada procedimiento se evaluó con validación cruzada dentro de $\mathcal{T}$. Para compararlos entre sí y con Lasso, el conjunto de prueba $\mathcal{G}$ (Sección 2.2), que no se ha usado, mide qué tan bien predice cada subconjunto. El siguiente código reúne los subconjuntos de variables, que son las diez de `SelectKBest`, las diez de la selección hacia adelante, las que elige `SelectFromModel` con el número de variables que maximizó el rendimiento en la Figura 4.2 y las que conserva Lasso con `lambda_opt`. A cada uno se le ajusta una regresión lineal en $\mathcal{T}$ y se mide el R^2 en $\mathcal{G}$. Como referencia se incluye el modelo con todas las variables.

```
mejor_dim = int(perf_sel.numero[perf_sel.r2.idxmax()])
modelo_opt = SelectFromModel(lasso_opt, max_features=mejor_dim,
                             threshold=-np.inf, prefit=True)
subconjuntos = {'Estadísticas': seleccionadas,
                'Adelante': adelante,
                'Modelo': columnas[modelo_opt.get_support()],
                'Lasso': columnas[lasso_cv.coef_ != 0],
                'Todas': columnas}
r2_comp = None
resumen = []
for nombre, variables in subconjuntos.items():
    mascara = columnas.isin(variables)
    hy_g = LinearRegression().fit(T[:, mascara], y_t).predict(G[:, mascara])
    resumen.append(dict(procedimiento=nombre, variables=int(mascara.sum()),
                        r2=r2(y_g, hy_g)))
    if r2_comp is None:
        r2_comp = r2_score(y_g, hy_g, name=nombre, use_tqdm=False)
    else:
        r2_comp(hy_g, name=nombre)
resumen = pd.DataFrame(resumen)
```

Tabla 4.1: Número de variables y R^2 en el conjunto de prueba de la regresión lineal ajustada con las variables que selecciona cada procedimiento.

Procedimiento	Variables	R^2
Estadísticas	10	0.1061
Adelante	10	0.1258
Modelo	37	0.1434
Lasso	50	0.1434
Todas	56	0.1433

La Tabla 4.1 presenta el número de variables y el R^2 de cada procedimiento. La selección basada en estadísticas usa 10 variables y alcanza un R^2 de 0.1061, la selección hacia adelante usa 10 y alcanza 0.1258, `SelectFromModel` usa 37 y alcanza 0.1434 y Lasso usa 50 y alcanza 0.1434. Con todas las variables el R^2 es 0.1433. La Figura 4.3 muestra los mismos valores con su intervalo de confianza obtenido con bootstrap y señala los procedimientos cuya diferencia con el mejor es estadísticamente significativa.

```
r2_comp.plot(comp_legend='Comparación', winner_legend='Mejor',
             tie_legend='Equivalente', loser_legend='Diferente',
             alg_legend='Algoritmo', var_name='Rendimiento')
```

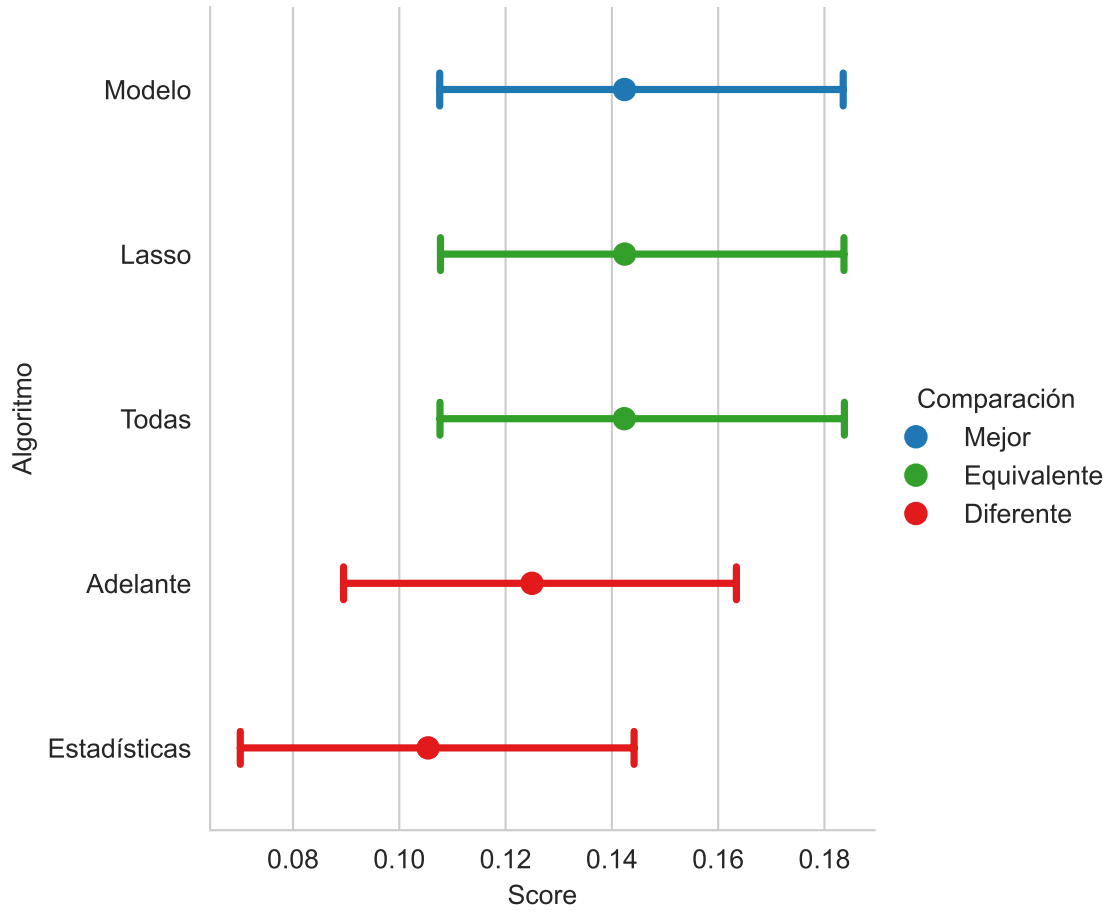


Figura 4.3: Rendimiento (R^2) en el conjunto de prueba de la regresión lineal ajustada con las variables que selecciona cada procedimiento.

Falta saber si los procedimientos eligen las mismas variables. La Tabla 4.2 cuenta, para cada par de procedimientos, cuántas variables comparten, de manera que la diagonal es el número de variables que selecciona cada uno.

```
nombres = ['Estadísticas', 'Adelante', 'Modelo', 'Lasso']
comparten = pd.DataFrame([[len(set(subconjuntos[a]) & set(subconjuntos[b]))
                           for b in nombres] for a in nombres],
                         index=nombres, columns=nombres)
en_todos = set.intersection(*[set(subconjuntos[n]) for n in nombres])
```

Tabla 4.2: Número de variables que comparten los subconjuntos que selecciona cada procedimiento.

	Estadísticas	Adelante	Modelo	Lasso
Estadísticas	10	5	8	8
Adelante	5	10	9	9
Modelo	8	9	37	37
Lasso	8	9	37	50

Los subconjuntos de diez variables pierden rendimiento frente al modelo con todas. La selección basada en estadísticas pierde 0.0372 de R^2 y la selección hacia adelante 0.0176, y la Figura 4.3 marca a ambas como diferentes del mejor. Con el mismo número de variables, la selección hacia adelante supera por 0.0196 a la basada en estadísticas porque evalúa el modelo y no cada variable por separado. En cambio, `SelectFromModel` y Lasso, que conservan más variables, igualan el rendimiento del modelo con todas. De las 37 variables que elige `SelectFromModel`, 37 están entre las 50 que conserva Lasso, pues ordena los coeficientes del mismo modelo.

La Tabla 4.2 muestra que los procedimientos eligen subconjuntos distintos. La selección hacia adelante y la basada en estadísticas, ambas de diez variables, comparten solo 5, y las variables que eligen los cuatro procedimientos son `entidad_Oaxaca`, `grupos`, `organizacion_docentes_multigrado`, `pct_primer_grado`, `tipo_servicio_general`, un total de 5. Es la misma lección del efecto Rashomon de Sección 3.8, pues subconjuntos distintos pueden tener un rendimiento similar. Con muchos datos y pocas variables, como aquí, la ganancia de seleccionar es tener un modelo con menos variables que recabar y no un mejor R^2.

Esa es la idea de la Sección 3.9. Cuando cada variable que entra al modelo hay que recabarla, usar pocas variables deja de ser un asunto de rendimiento y se vuelve el objetivo de política, y la Tabla 4.1 muestra el precio de reducir el modelo a diez variables. Como el subconjunto seleccionado cambia con la muestra (Figura 3.9), conviene verificar que la conclusión no depende de una sola partición antes de pedir a un programa que recabe un conjunto específico de variables.

4.6. Resumen

Los procedimientos de selección de variables se agrupan en tres familias. Los filtros evalúan cada variable con una prueba estadística (Sección 4.2), los procedimientos voraces agregan o quitan una variable a la vez según el rendimiento del modelo (Sección 4.3) y los basados en modelo aprovechan los coeficientes o la importancia que el propio modelo asigna (Sección 4.4). Cada una tiene ventajas y limitaciones que se resumen en la Sección 4.5, donde además se comparan en el conjunto de prueba. Esa comparación muestra que los procedimientos eligen subconjuntos

distintos con un rendimiento parecido, que es otra manifestación del efecto Rashomon de Sección 3.8, y que reducir el número de variables cuesta poco rendimiento.

Para la política pública la selección de variables es una decisión de diseño. Cuando cada variable hay que recabarla en campo, un cuestionario más corto significa un programa más barato de operar, y el costo de reducirlo se lee directamente en la pérdida de rendimiento. Como el subconjunto seleccionado depende de la muestra, conviene verificar su estabilidad antes de pedir que se recabe un conjunto específico de variables.

Hasta aquí el problema era predecir un valor numérico. Cuando lo que se debe decidir es una acción y los errores no cuestan lo mismo, el problema cambia y el tema se retoma con la teoría de decisión en Capítulo 5.

Actividades

Actividad

Repita la comparación de procedimientos con el conjunto de Territorio (Sección B.1.5). El objetivo es `grado_promedio_escolaridad` y se descartan `clave_ageb`, `municipio`, `pct_viv_internet`, `pct_sin_servicio_salud` y `pct_jefatura_femenina`. Conteste las siguientes preguntas. ¿Cuántas variables se necesitan para acercarse al R^2 que se obtiene con todas? ¿Los procedimientos coinciden en los sectores de establecimientos que seleccionan?

Actividad

Suponga que un programa de becas tiene que decidir qué información recabar en cada plantel, y que recabar cada variable tiene un costo distinto. Con los resultados de la Tabla 4.1 escriba el párrafo de un *policy paper* que justifique qué subconjunto de variables usaría y por qué. Considere el número de variables, el R^2 en el conjunto de prueba y la estabilidad de la selección.

5 Teoría de Decisión Bayesiana

El **objetivo** de la unidad es analizar el uso de la teoría de la probabilidad para la toma de decisiones. En particular el uso del teorema de Bayes para resolver problemas de clasificación y su uso para tomar la decisión que reduzca el riesgo.

Paquetes usados

```
from scipy.stats import multivariate_normal
from matplotlib import pylab as plt
import numpy as np
import pandas as pd
import seaborn as sns
```

5.1. Introducción

Al diseñar una solución a un problema particular lo mejor que uno puede esperar es tener una certeza absoluta sobre la respuesta dada. Por ejemplo, si uno diseña un algoritmo que ordene un conjunto de números uno espera que ese algoritmo siempre regrese el orden correcto independientemente de la entrada dada, es más, un algoritmo de ordenamiento que en ocasiones se equivoca se consideraría de manera estricta erróneo.

Sin embargo, existen problemas cuyas características, como incertidumbre en la captura de los datos, variables que no se pueden medir, entre otros factores hacen que lo mejor que se puede esperar es un algoritmo exacto y preciso. Todos los problemas que trataremos en Aprendizaje Computacional caen dentro del segundo escenario. El lenguaje que nos permite describir de manera adecuada este tipo de ambiente, que se caracteriza por variables aleatorias es el de la probabilidad. En el capítulo de Rendimiento (Capítulo 2) se describió cómo medir qué tan bien (o mal) decide un algoritmo. En esta unidad se describe cómo construir un clasificador que decide con base en probabilidades y cómo ajustar la decisión cuando los errores tienen costos diferentes.

5.2. Probabilidad

En Sección 1.6 se describió que el punto de inicio de aprendizaje supervisado es el conjunto $\mathcal{D} = \{(x_1, y_1), \ldots, (x_N, y_N)\}$, donde $x_i \in \mathbb{R}^d$ corresponde a la i-ésima entrada y y_i es la salida asociada a esa entrada; este conjunto tiene el objetivo de guiar un proceso de búsqueda para encontrar un método que capture la relación entre x y y.

Se pueden tratar las variables x y y de $\mathcal{D}$ como dos variables aleatorias $\mathcal{X}$ y $\mathcal{Y}$, respectivamente; en este dominio el problema de identificar la respuesta ($\mathcal{Y}$) dada la entrada ($\mathcal{X}$) se puede describir como encontrar la probabilidad de observar $\mathcal{Y}$ habiendo visto $\mathcal{X}$, es decir, $\mathbb{P}(\mathcal{Y} \mid \mathcal{X})$.

5.2.1. Ejemplos

Por ejemplo, en un problema de clasificación binaria se tiene que la respuesta tiene dos posibles valores, e.g., $\mathcal{Y} = \{0, 1\}$. Entonces el problema es saber si dada una entrada x el valor de la respuesta es 1 o 0. Utilizando probabilidad la pregunta quedaría como conocer la probabilidad de que $\mathcal{Y} = 1$ o $\mathcal{Y} = 0$ cuando se observa $\mathcal{X} = x$, es decir, encontrar $\mathbb{P}(\mathcal{Y} = 1 \mid \mathcal{X} = x)$ y compararlo contra $\mathbb{P}(\mathcal{Y} = 0 \mid \mathcal{X} = x)$. Tomando en cuenta estos valores de probabilidad se puede concluir el valor de la salida dado que $\mathcal{X} = x$. También está el caso que las probabilidades sean iguales, e.g., si $\mathbb{P}(\mathcal{Y} = 1 \mid \mathcal{X} = x) = \mathbb{P}(\mathcal{Y} = 0 \mid \mathcal{X} = x) = 0.5$ o que su diferencia sea muy pequeña y entonces se toma la decisión de desconocer el valor de la salida.

Para el caso de regresión ($y \in \mathbb{R}$), el problema se puede plantear asumiendo que $\mathcal{Y}$ proviene de una distribución particular cuyos parámetros están dados por la entrada $\mathcal{X}$. Por ejemplo, en regresión lineal se asume que $\mathcal{Y}$ proviene de una distribución Gaussiana con parámetros dados por $\mathcal{X}$, es decir, $\mathbb{P}(\mathcal{Y} \mid \mathcal{X} = x) = \mathcal{N}(g(x) + \epsilon, \sigma^2)$, donde los parámetros de la función g son identificados mediante $\mathcal{X}$ y $\epsilon \sim \mathcal{N}(0, \sigma^2)$ es el error con media cero y desviación estándar σ. Con estas condiciones la salida y es $\mathbb{E}[\mathcal{Y} \mid \mathcal{X} = x]$; asumiendo que esa variable se distribuye como una normal entonces $\mathbb{E}[\mathcal{Y} \mid \mathcal{X} = x] = \mathbb{E}[g(x) + \epsilon] = g(x) + \mathbb{E}[\epsilon] = g(x)$.

5.3. Teorema de Bayes

El problema se convierte en cómo calcular $\mathbb{P}(\mathcal{Y} \mid \mathcal{X})$, lo cual se puede realizar mediante el Teorema de Bayes el cual se deriva a continuación.

La probabilidad conjunta se puede expresar como $\mathbb{P}(\mathcal{X}, \mathcal{Y})$, esta probabilidad es conmutativa por lo que $\mathbb{P}(\mathcal{X}, \mathcal{Y}) = \mathbb{P}(\mathcal{Y}, \mathcal{X})$. En este momento se puede utilizar la definición de **probabilidad condicional** que es $\mathbb{P}(\mathcal{Y}, \mathcal{X}) = \mathbb{P}(\mathcal{Y} \mid \mathcal{X})\mathbb{P}(\mathcal{X})$. Utilizando estas ecuaciones el **Teorema de Bayes** queda como

$$\mathbb{P}(\mathcal{Y} \mid \mathcal{X}) = \frac{\mathbb{P}(\mathcal{X} \mid \mathcal{Y})\mathbb{P}(\mathcal{Y})}{\mathbb{P}(\mathcal{X})}, \tag{5.1}$$

donde al término $\mathbb{P}(\mathcal{X} \mid \mathcal{Y})$ se le conoce como **verosimilitud**, $\mathbb{P}(\mathcal{Y})$ es la probabilidad **a priori** y $\mathbb{P}(\mathcal{X})$ es la **evidencia**.

Es importante mencionar que la evidencia se puede calcular mediante la probabilidad total, es decir:

$$\mathbb{P}(\mathcal{X}) = \sum_{y \in \mathcal{Y}} \mathbb{P}(\mathcal{X} \mid \mathcal{Y} = y)\mathbb{P}(\mathcal{Y} = y). \tag{5.2}$$

5.3.1. Problema Sintético

Con el objetivo de entender el funcionamiento del Teorema de Bayes, esta sección presenta un problema sintético. El procedimiento es el siguiente, primero se generarán los datos, los cuales van a ser tres nubes de puntos generadas mediante tres distribuciones gaussianas multivariadas. Con estas tres nubes de puntos, se utilizará el Teorema de Bayes (Ecuación 5.1) para clasificar todos los puntos generados.

El primer paso es definir las tres distribuciones gaussianas multivariadas, para este objetivo se usa la clase `multivariate_normal` como se muestra a continuación.

```
p1 = multivariate_normal(mean=[5, 5],
                         cov=[[4, 0], [0, 2]])
p2 = multivariate_normal(mean=[1.5, -1.5],
                         cov=[[2, 1], [1, 3]])
p3 = multivariate_normal(mean=[12.5, -3.5],
                         cov=[[2, 3], [3, 7]])
```

Los parámetros de la distribución son el vector de medias y la matriz de covarianza, para la primera distribución estos corresponden a $= [5, 5]^\top$ y

$$\Sigma = \begin{pmatrix} 4 & 0 \\ 0 & 2 \end{pmatrix}.$$

Una vez definidas las distribuciones podemos generar números aleatorios de las mismas, en el siguiente código se generan 1000 vectores aleatorios de las tres distribuciones.

```
X_1 = p1.rvs(size=1000)
X_2 = p2.rvs(size=1000)
X_3 = p3.rvs(size=1000)
```

Para graficar estas tres nubes de puntos se puede hacer uso del siguiente código, donde se hace uso de la librería `pandas` y `seaborn` para generar la gráfica.

```
D = np.concatenate((X_1, X_2, X_3))
clase = [1] * 1000 + [2] * 1000 + [3] * 1000
D = np.concatenate((D, np.atleast_2d(clase).T), axis=1)
df = pd.DataFrame(D, columns=['x', 'y', 'clase'])
_ = sns.relplot(data=df, kind='scatter', x='x',
                y='y', hue='clase')
```

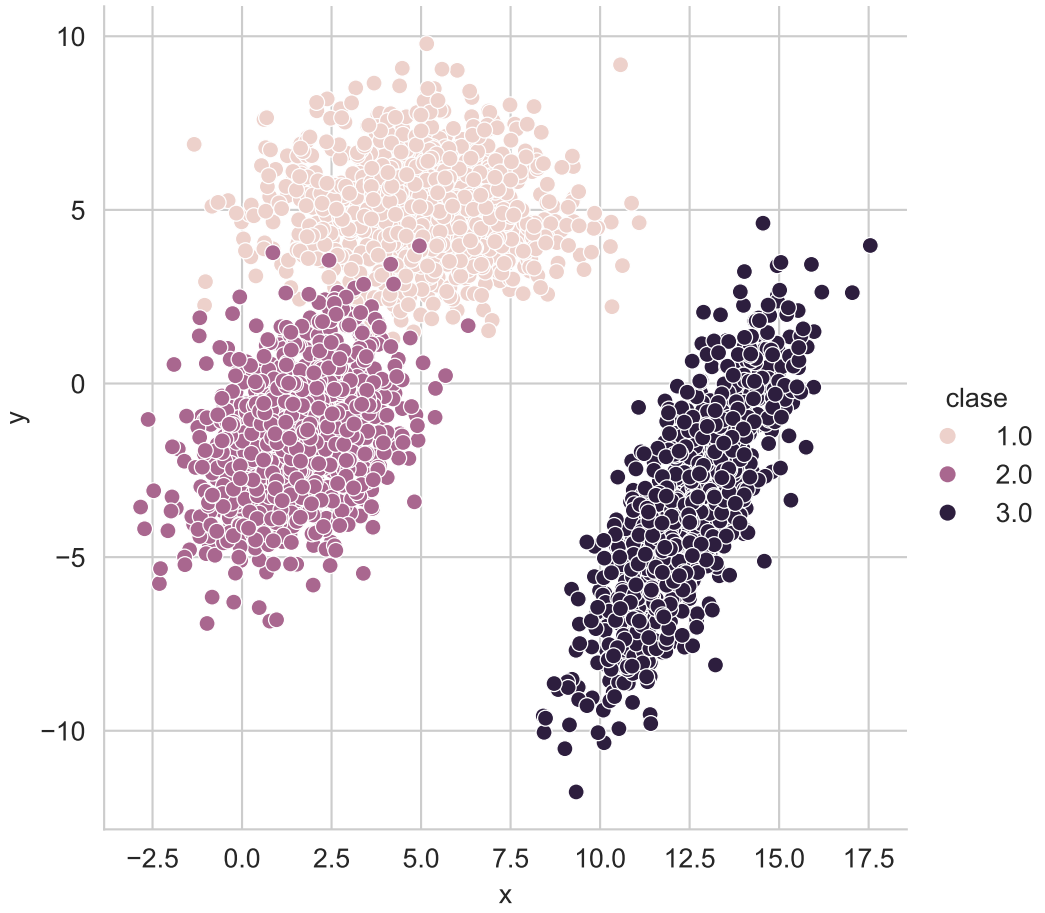


Figura 5.1: Muestras de 3 distribuciones Gaussianas

El resultado del código anterior se muestra en la Figura 5.1, donde se puede visualizar las tres nubes de puntos, donde el color indica la clase.

Actividad

Generar una nube de puntos similar a la que se muestra en la Figura 5.2. Observar que ambos ejes de la figura están en el rango $[-20, 20]$.

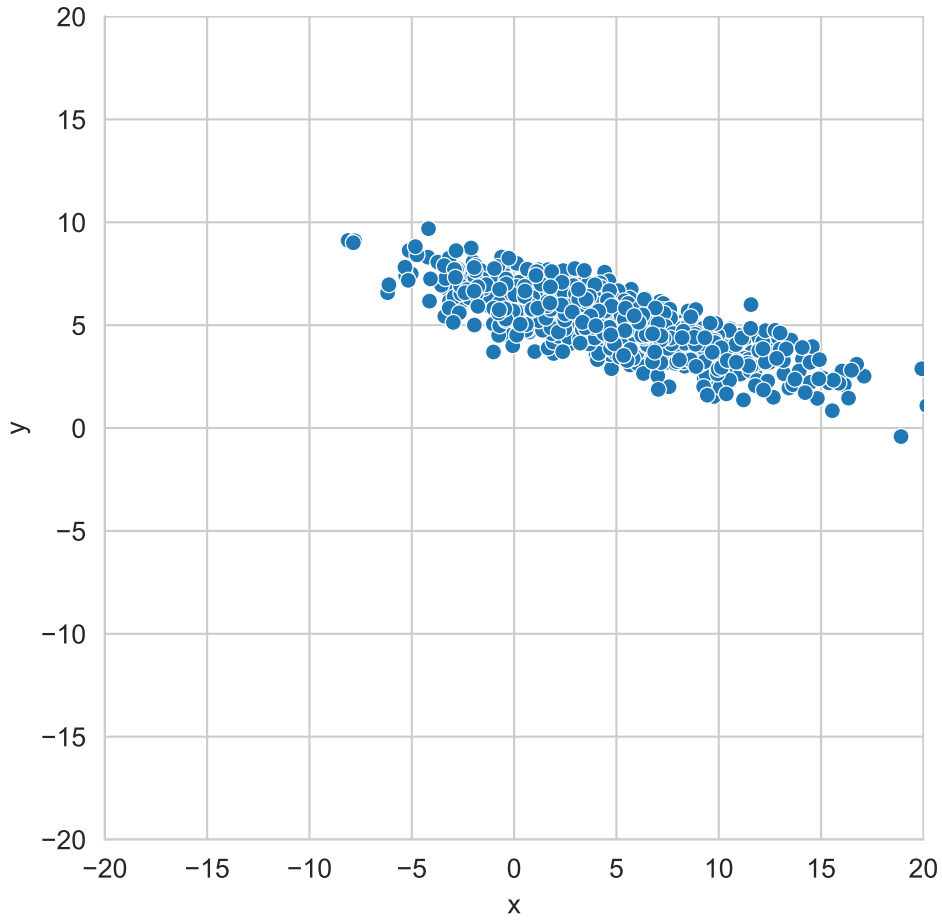


Figura 5.2: Distribución Gaussiana

5.3.2. Predicción

En esta sección se describe el primer ejemplo del paso 4 de la metodología general (ver Sección 1.4) de los algoritmos de aprendizaje supervisado. El algoritmo f mencionado en la metodología corresponde en este ejemplo al uso del Teorema de Bayes y las distribuciones `p1`, `p2` y `p3` y los correspondientes valores a priori.

Quitando la evidencia del Teorema de Bayes (Ecuación 5.1) se observa que $\mathbb{P}(\mathcal{Y} \mid \mathcal{X}) \propto \mathbb{P}(\mathcal{X} \mid$

$y)\mathbb{P}(y)$. En el ejemplo creado se observa que $\mathbb{P}(y = 1) = \frac{1000}{3000}$, las otras probabilidades a priori tienen el mismo valor, es decir, $\mathbb{P}(y = 2) = \mathbb{P}(y = 3) = \frac{1}{3}$.

La verosimilitud está definida en las variables `p1`, `p2` y `p3`; en particular en la función `pdf`, es decir, $\mathbb{P}(\mathcal{X} \mid y = 1)$ es `p1.pdf`, $\mathbb{P}(\mathcal{X} \mid y = 2)$ corresponde a `p2.pdf` y equivalentemente `p3.pdf` es la verosimilitud cuando $y = 3$.

Utilizando esta información $\mathbb{P}(\mathcal{X} \mid y)\mathbb{P}(y)$ se calcula de la siguiente manera.

```
X = np.concatenate((X_1, X_2, X_3))
posterior = (np.vstack([p1.pdf(X),
                        p2.pdf(X),
                        p3.pdf(X)]) * 1 / 3).T
```

La evidencia (Ecuación 5.2) es un factor normalizador que hace que las probabilidades sumen a uno, el siguiente código calcula la evidencia, $\mathbb{P}(\mathcal{X})$

```
evidencia = posterior.sum(axis=1)
```

Finalmente, $\mathbb{P}(y \mid \mathcal{X})$ se obtiene normalizando $\mathbb{P}(\mathcal{X} \mid y)\mathbb{P}(y)$ que se puede realizar de la siguiente manera.

```
posterior = posterior / np.atleast_2d(evidencia).T
```

La clase corresponde a la probabilidad máxima, en este caso se compara la probabilidad de $\mathbb{P}(y = 1 \mid \mathcal{X})$, $\mathbb{P}(y = 2 \mid \mathcal{X})$ y $\mathbb{P}(y = 3 \mid \mathcal{X})$; y la clase es aquella que tenga mayor probabilidad. El siguiente código muestra este procedimiento, donde el primer paso es crear un arreglo para mapear el índice a la clase. El segundo paso es seleccionar la probabilidad máxima y después transformar el índice de la probabilidad máxima a la clase.

```
clase = np.array([1, 2, 3])
indice = posterior.argmax(axis=1)
prediccion = clase[indice]
```

En la variable `prediccion` se tienen las predicciones de las clases, ahora se analizará si estas predicciones corresponden con la clase original que fue generada. Por la forma en que se generó `X` se sabe que los primeros 1000 elementos pertenecen a la clase 1, los siguientes 1000 a la clase 2 y los restantes a la clase 3. A continuación se muestra el arreglo `y` que tiene esta estructura.

```
y = np.array([1] * 1000 + [2] * 1000 + [3] * 1000)
```

Teniendo las predicciones y los valores reales de las clases, lo que se busca es visualizar los ejemplos que no fueron clasificados de manera correcta, el siguiente código muestra este procedimiento.

```
_ = [dict(x=x, y=y, error=error)
     for (x, y), error in zip(X, y != prediccion)]
df_error = pd.DataFrame(_)
_ = sns.relplot(data=df_error, kind='scatter',
                x='x', y='y', hue='error')
```

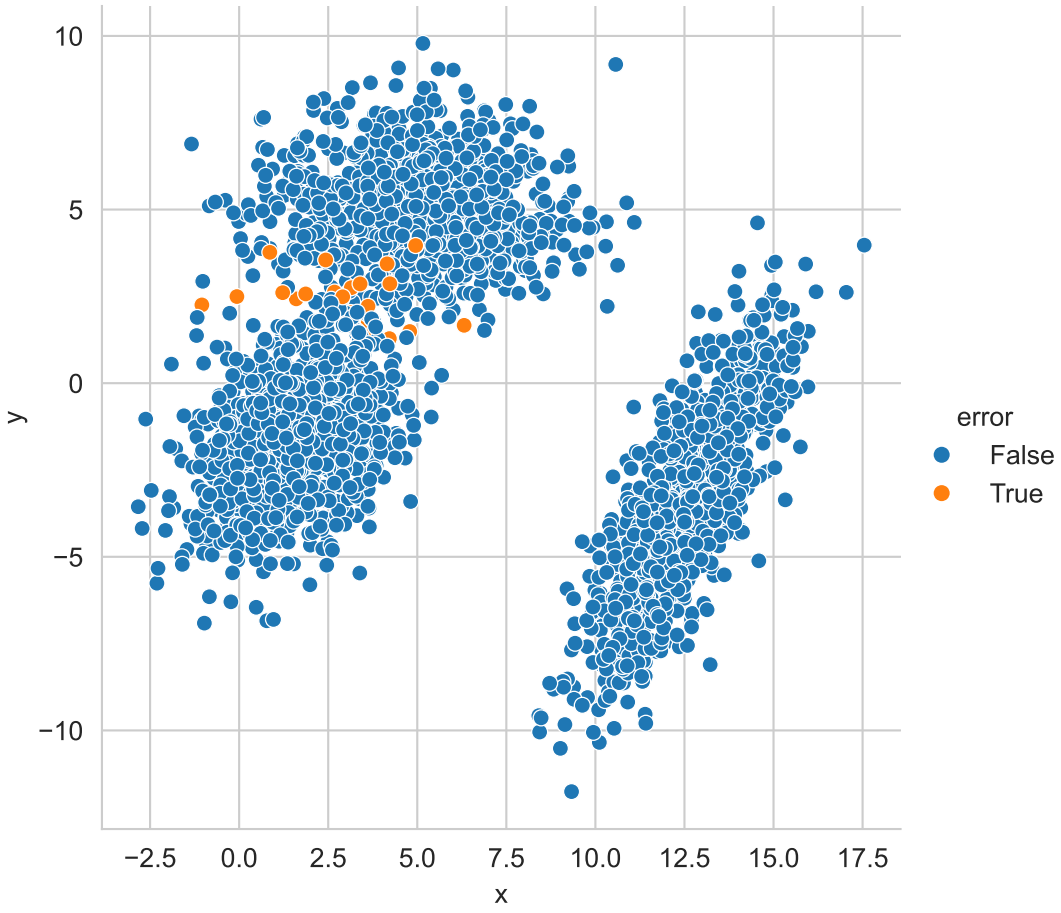


Figura 5.3: Error en problema de clasificación

La Figura 5.3 muestra todos los datos generados, en color azul se muestran aquellos datos que fueron correctamente clasificados y en color naranja (error igual a True) se muestran aquellos ejemplos donde el proceso de clasificación cometió un error.

5.4. Error de Clasificación

Este ejemplo ayuda a ilustrar el caso donde, aun teniendo el modelo perfecto, este produce errores al momento de usarlo para clasificar. Se podía asumir que este error en clasificación iba a ocurrir desde el momento que las nubes de puntos de la clase 1 y 2 se traslapan como se observa en la Figura 5.1.

El ejemplo sirve también para ilustrar el quinto paso de la metodología general (ver Sección 1.4) de los algoritmos de aprendizaje supervisado que corresponde a medir el rendimiento de un modelo. Primero se empieza por medir el error promedio utilizando el siguiente código; donde el `error` es 0.0073.

```
error = (y != prediccion).mean()
```

La siguiente pregunta es conocer cuánto varía este error si se vuelve a realizar el muestreo de las distribuciones `p1`, `p2` y `p3`. Una manera de conocer esta variabilidad de la medición del error es calculando su **error estándar**.

El error estándar (ver Sección A.1) está definido como $\sqrt{\mathbb{V}(\hat{\theta})}$ donde $\hat{\theta}$ es el valor estimado, en este caso el `error`. El error es una variable aleatoria que sigue una distribución de Bernoulli, dado que para cada ejemplo tiene dos valores 1 que indica que en ese ejemplo el clasificador se equivocó y 0 cuando se predice la clase correcta. El parámetro de la distribución Bernoulli, p, se estima como la media entonces el error estándar de p corresponde al error estándar de la media (ver Sección A.1.1), i.e., $\sqrt{\mathbb{V}(\hat{p})} = \sqrt{\frac{\hat{p}(1-\hat{p})}{N}}$, dado que la varianza σ^2 de una distribución Bernoulli con parámetro p es $p(1-p)$. Para el ejemplo analizado el error estándar se calcula con la siguiente instrucción; teniendo un valor de 0.0016.

```
se_formula = np.sqrt(error * (1 - error) / 3000)
```

Aunque el error estándar del parámetro p de la distribución Bernoulli sí se puede calcular analíticamente, se usará la técnica de Bootstrap (ver Sección A.2) para ejemplificar aquellas estadísticas donde no se puede. Esta técnica requiere generar B muestras de N elementos con remplazo de los datos. En este caso los datos son los errores entre `y` y `prediccion`. Siguiendo el método descrito en el apéndice (Sección A.2) se generan los índices para generar la muestra como se observa en la primera línea del siguiente código. En la segunda línea se hacen las B repeticiones las cuales consisten en calcular $\hat{p}$. Se puede observar cómo se usa directamente `y` y `prediccion` junto con el arreglo de índices `s` para calcular la media del error. Finalmente se calcula la desviación estándar de `B` (tercera línea) y ese valor corresponde al error estándar.

```
S = np.random.randint(y.shape[0], size=(500, y.shape[0]))
B = [(y[s] != prediccion[s]).mean() for s in S]
se = np.std(B)
```

El error estándar, `se`, calculado es 0.0015.

El error estándar corresponde a la distribución que tiene la estimación del parámetro de interés; mediante la técnica de muestreo bootstrap se simuló esta distribución y con el siguiente código se puede observar su histograma, donde los datos estimados se encuentran en la lista `B`.

```
_ = sns.displot(B, kde=True)
```

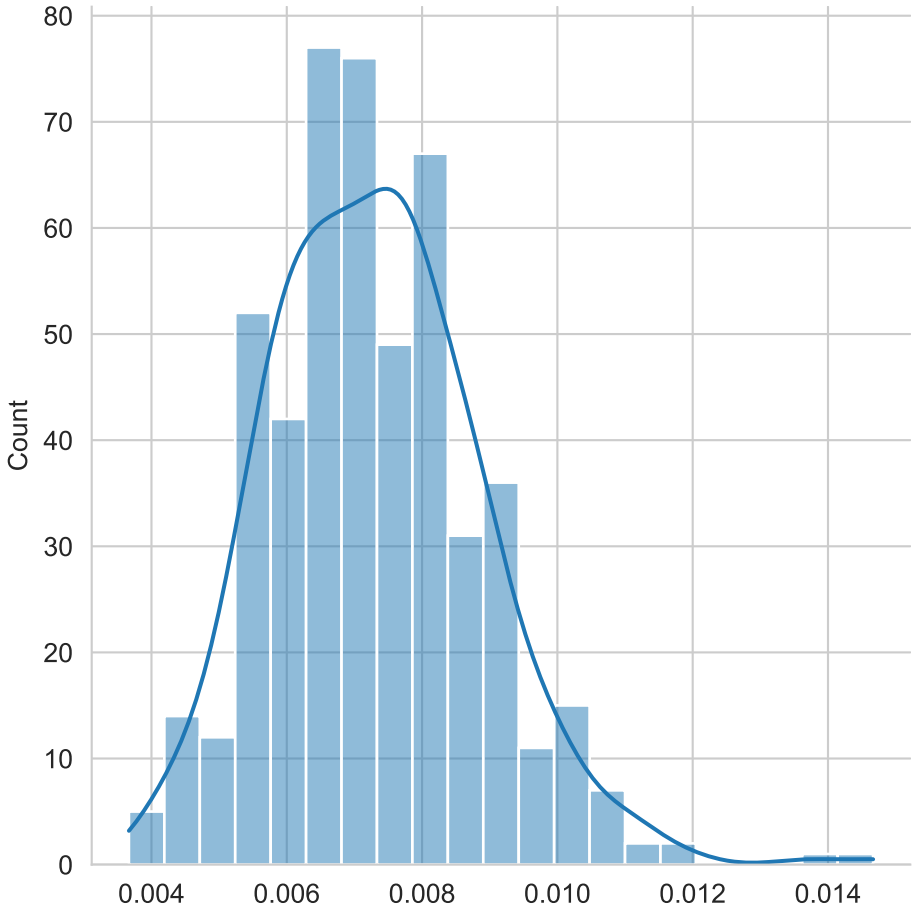


Figura 5.4: Distribución del error de clasificación

La Figura 5.4 muestra el histograma de la estimación del error en el ejemplo analizado.

5.5. Error Bayesiano

El ejemplo anterior deja una pregunta abierta, ¿por qué un modelo que conoce exactamente las distribuciones que generaron los datos (`p1`, `p2` y `p3`) comete errores al clasificar? La respuesta está en que el error no depende únicamente del método utilizado para clasificar, sino también de la superposición entre las distribuciones de las clases; esta sección formaliza esta idea mediante el concepto de **error bayesiano** y muestra que la regla utilizada en Sección 5.3.2, es decir, seleccionar la clase con mayor probabilidad *a posteriori*, es la que menor error comete entre todos los clasificadores posibles.

Sea $f : \mathcal{X} \to \mathcal{Y}$ un clasificador, es decir, una función que asigna una clase $f(x)$ a cada entrada x; por ejemplo, la variable `prediccion` del ejemplo anterior corresponde a $f(x)$ evaluado en cada uno de los elementos de `X`. La probabilidad de que f se equivoque, condicionada a una entrada $\mathcal{X} = x$, es

$$\mathbb{P}(f(\mathcal{X}) \neq \mathcal{Y} \mid \mathcal{X} = x) = 1 - \mathbb{P}(\mathcal{Y} = f(x) \mid \mathcal{X} = x), \tag{5.3}$$

dado que $f(x)$ únicamente puede tomar un valor y el complemento de acertar es equivocarse. El error del clasificador f, sin condicionar a una entrada particular, se obtiene promediando sobre todas las posibles entradas, es decir, $\mathbb{P}(f(\mathcal{X}) \neq \mathcal{Y}) = \mathbb{E}_{\mathcal{X}}\left[\mathbb{P}(f(\mathcal{X}) \neq \mathcal{Y} \mid \mathcal{X})\right]$.

El clasificador utilizado en Sección 5.3.2 corresponde a la regla

$$f^*(x) = \arg\max_k \mathbb{P}(\mathcal{Y} = k \mid \mathcal{X} = x), \tag{5.4}$$

conocida como la **regla de Bayes**, y al error que esta regla produce, $\mathbb{P}(f^*(\mathcal{X}) \neq \mathcal{Y})$, se le conoce como **error bayesiano**. Usando la Ecuación 5.3 en f^* se tiene que

$$\mathbb{P}(f^*(\mathcal{X}) \neq \mathcal{Y} \mid \mathcal{X} = x) = 1 - \max_k \mathbb{P}(\mathcal{Y} = k \mid \mathcal{X} = x). \tag{5.5}$$

El error bayesiano no depende del algoritmo utilizado sino de qué tan traslapadas están las clases; en el ejemplo de Sección 5.3.1 el valor 0.0073 estimado no es producto de un método imperfecto – `p1`, `p2` y `p3` son las distribuciones exactas – sino que corresponde, salvo el error de estimación medido con `se_f`, al error bayesiano del problema, es decir, es un error irreducible.

Falta mostrar que f^* es, de entre todos los clasificadores posibles, el que tiene el menor error esperado. Sea f cualquier otro clasificador y, para simplificar la notación, sea $p_k(x) = \mathbb{P}(\mathcal{Y} = k \mid \mathcal{X} = x)$. Por definición de máximo, para toda entrada x se cumple que

$$p_{f(x)}(x) \leq \max_k p_k(x), \tag{5.6}$$

dado que el lado derecho es el mayor valor que puede tomar $p_k(x)$ mientras que el lado izquierdo es solo uno de esos valores, el correspondiente a la clase $f(x)$ que selecciona el clasificador f.

El siguiente paso es multiplicar ambos lados de la Ecuación 5.6 por -1, operación que invierte el sentido de la desigualdad, y después sumar 1 a ambos lados, lo cual no altera el sentido de la desigualdad al sumarse la misma constante en ambos lados:

$$\begin{aligned} p_{f(x)}(x) &\leq \max_k p_k(x) \\ -p_{f(x)}(x) &\geq -\max_k p_k(x) \\ 1 - p_{f(x)}(x) &\geq 1 - \max_k p_k(x). \end{aligned}$$

Finalmente se identifica cada lado de esta última desigualdad, el lado izquierdo, $1 - p_{f(x)}(x) = 1 - \mathbb{P}(\mathcal{Y} = f(x) \mid \mathcal{X} = x)$, corresponde a $\mathbb{P}(f(\mathcal{X}) \neq \mathcal{Y} \mid \mathcal{X} = x)$ por la Ecuación 5.3; el lado derecho, $1 - \max_k p_k(x)$, corresponde a $\mathbb{P}(f^*(\mathcal{X}) \neq \mathcal{Y} \mid \mathcal{X} = x)$ por la Ecuación 5.5. Sustituyendo ambas identidades se obtiene

$$\mathbb{P}(f(\mathcal{X}) \neq \mathcal{Y} \mid \mathcal{X} = x) \geq \mathbb{P}(f^*(\mathcal{X}) \neq \mathcal{Y} \mid \mathcal{X} = x) \quad \text{para toda } x.$$

Como esta desigualdad se cumple para cada valor de x, se preserva al tomar el valor esperado sobre $\mathcal{X}$ en ambos lados, por lo tanto

$$\mathbb{P}(f(\mathcal{X}) \neq \mathcal{Y}) \geq \mathbb{P}(f^*(\mathcal{X}) \neq \mathcal{Y}) \quad \text{para todo clasificador } f,$$

es decir, ningún clasificador puede tener un error esperado menor al de la regla de Bayes; esta propiedad se conoce como la **optimalidad del clasificador Bayesiano**. En la siguiente sección se retoma esta idea desde la perspectiva del riesgo, donde se observará que minimizar el riesgo bajo un costo 0/1 es equivalente a minimizar el error aquí definido.

5.6. Riesgo

Como es de esperarse, existen aplicaciones donde el dar un resultado equivocado tiene un mayor impacto dependiendo de la clase. Por ejemplo, en un sistema de autenticación, equivocarse dándole acceso a una persona que no tiene permisos, es mucho más grave que no dejar entrar a una persona con los privilegios adecuados.

Una manera de incorporar el costo de equivocarse en el proceso de selección de la clase es modelarlo como una función de riesgo, es decir, seleccionar la clase que tenga el menor riesgo. Para realizar este procedimiento es necesario definir α_i como la acción que se toma al seleccionar la clase $\mathcal{Y} = i$. Entonces el riesgo esperado por tomar la acción α_i está definido por:

$$R(\alpha_i \mid x) = \sum_k \lambda_{ik} \mathbb{P}(\mathcal{Y} = k \mid \mathcal{X} = x),$$

donde λ_{ik} es el costo de tomar la acción i en la clase k.

Suponiendo una función de costo 0/1, donde el escoger la clase correcta tiene un costo 0 y el equivocarse en cualquier caso tiene un costo 1 se define como:

$$\lambda_{ik} = \begin{cases} 0 \text{ si } i = k \\ 1 \text{ de lo contrario} \end{cases}.$$

Usando la función de costo 0/1 el riesgo se define de la siguiente manera:

$$\begin{aligned} R(\alpha_i \mid x) &= \sum_k \lambda_{ik} \mathbb{P}(\mathcal{Y} = k \mid \mathcal{X} = x) \\ &= \sum_{k \neq i} \mathbb{P}(\mathcal{Y} = k \mid \mathcal{X} = x) \\ &= 1 - \mathbb{P}(\mathcal{Y}_i \mid \mathcal{X} = x). \end{aligned}$$

Recordando que $\sum_k \mathbb{P}(\mathcal{Y} = k \mid \mathcal{X} = x) = 1$. Por lo tanto en el caso de costo 0/1 se puede observar que el mínimo riesgo corresponde a la clase más probable.

5.6.1. Acción nula

En algunas ocasiones es importante diseñar un procedimiento donde la acción a tomar sea el avisar que no se puede tomar una acción de manera automática y que se requiere una intervención manual.

La primera idea podría ser incrementar el número de clases y asociar una clase a la intervención manual, sin embargo en este procedimiento estaríamos incrementando la complejidad del problema. Un procedimiento más adecuado sería incrementar el número de acciones, α de tal manera que la acción α_{K+1} corresponda a la intervención esperada, esto para cualquier problema de K clases.

La extensión del costo 0/1 para este caso estaría definida como:

$$\lambda_{ik} = \begin{cases} 0 \text{ si } i = k \\ \lambda \text{ si } i = K + 1 \\ 1 \text{ de lo contrario} \end{cases},$$

donde $0 < \lambda < 1$.

Usando la definición de riesgo, el riesgo de tomar la acción α_{K+1} es

$$\begin{aligned} R(\alpha_{K+1} \mid x) &= \sum_{k}^{K} \lambda_{(K+1)k} \mathbb{P}(y = k \mid \mathcal{X} = x) \\ &= \sum_{k}^{K} \lambda \mathbb{P}(y = k \mid \mathcal{X} = x) \\ &= \lambda \sum_{k}^{K} \mathbb{P}(y = k \mid \mathcal{X} = x) = \lambda. \end{aligned}$$

5.7. Seleccionando la acción

Tomando en cuenta lo que hemos visto hasta el momento y usando como base el costo 0/1 que incluye la acción nula, se puede observar que el riesgo de seleccionar una clase está dado por $R(\alpha_i \mid x) = 1 - \mathbb{P}(y = i \mid \mathcal{X} = x)$ y el riesgo de la acción nula es $R(\alpha_{K+1} \mid x) = \lambda$.

En estas circunstancias se selecciona la clase $\hat{y}$ si es la clase con la probabilidad máxima (i.e., $\hat{y} = \arg\max_k \mathbb{P}(y = k \mid \mathcal{X} = x)$) y además $\mathbb{P}(y = \hat{y} \mid \mathcal{X} = x) > 1 - \lambda$.

5.7.1. Ejemplo

El siguiente ejemplo ilustra el comportamiento de seleccionar la clase considerando que se tiene un riesgo en la acción nula. Lo primero es generar dos conjuntos de datos uno para la clase positiva y otro para la negativa, tal y como lo indica el siguiente código. `p1` y `p1` son distribuciones Gaussianas, los elementos generados por `p1` serán asociados a la clase positiva y los generados por `p2` a la clase negativa.

```
p1 = multivariate_normal(mean=[5, 5],
                         cov=[[20, -5],
                              [-5, 2]])
p2 = multivariate_normal(mean=[-5, 0],
                         cov=[[20, 5],
                              [5, 2]])
X1 = p1.rvs(size=1000)
X2 = p2.rvs(size=1000)
X = np.concatenate((X1, X2))
y = np.array(['P'] * 1000 + ['N'] * 1000)
```

La Figura 5.5 muestra el conjunto de datos donde se realizará el ejemplo de seleccionar la clase considerando el riesgo.

```
df = pd.DataFrame(X, columns=['x', 'y'])
df['Clase'] = y
fig = sns.relplot(data=df, kind='scatter', x='x',
                  y='y', hue='Clase')
# fig.ax.set_xlim(-20, 20)
# fig.ax.set_ylim(-20, 20)
```

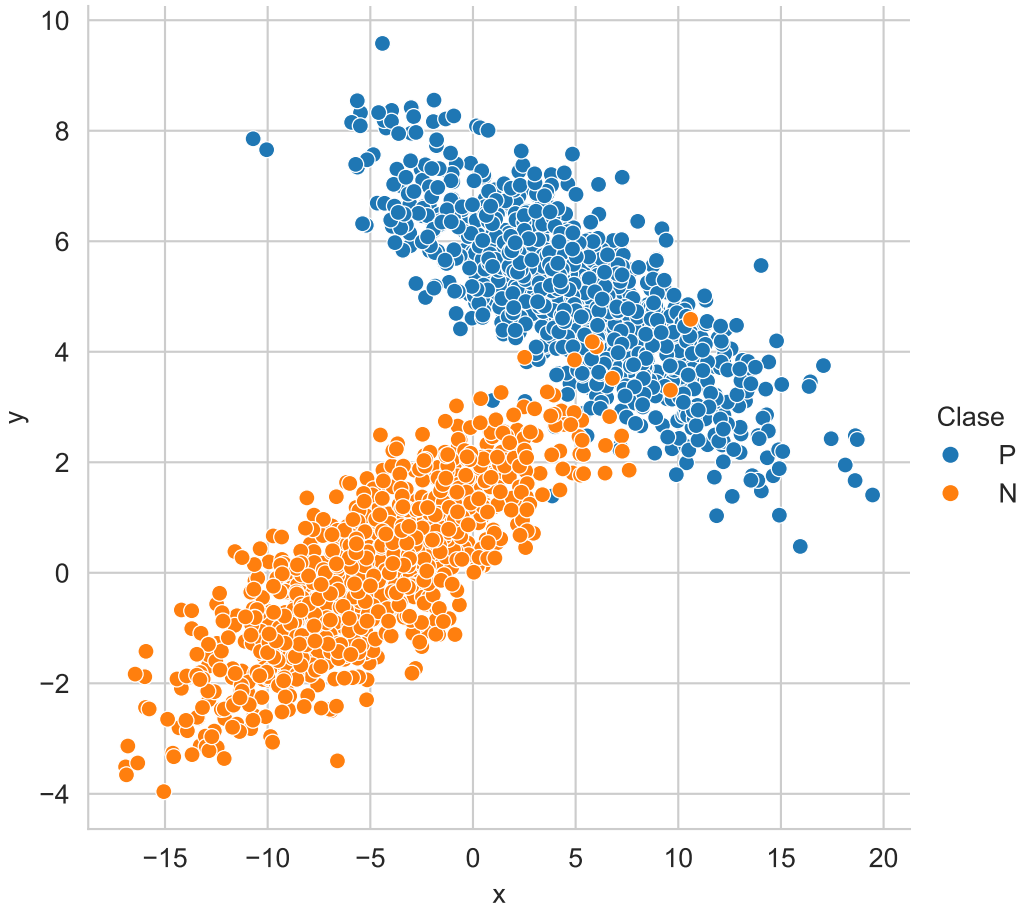


Figura 5.5: Dos distribuciones Gaussianas asociadas a dos clases

Para no introducir ningún error adicional con la estimación de parámetros, se utilizan los parámetros con los que se generaron los datos para calcular $\mathbb{P}(\mathcal{Y} \mid \mathcal{X})$ tal y como lo muestra el siguiente código.

```
posterior = np.c_[p1.pdf(X), p2.pdf(X)] * 1 / 2
evidencia = posterior.sum(axis=1)
posterior = posterior / np.c_[evidencia]
```

Habiendo calculado la probabilidad de cada clase en todos los elementos de `X`, es momento de predecir la clase y calcular el error del proceso de clasificación.

```
m = {0: 'P', 1: 'N'}
hy = np.array([m[i]
               for i in posterior.argmax(axis=1)])
error = (y != hy).mean()
```

El error que se tiene corresponde a 0.0080. El siguiente paso es definir un riesgo para la clase nula, e.g. $\lambda = 0.2$ y utilizarlo para saber cuáles son los elementos que cumplen con la condición $\mathbb{P}(\mathcal{Y} = \hat{y} \mid \mathcal{X} = x) > 1 - \lambda$. Estos elementos se guardan en la variable `valid` como muestra el siguiente código.

```
riesgo = 0.20
valid = posterior.max(axis=1) > 1 - riesgo
```

Utilizando `valid` se puede calcular el error de aquellos elementos los cuales tienen una clase positiva o negativa. El siguiente código calcula el error.

```
error = (y[valid] != hy[valid]).mean()
```

El error obtenido con los elementos válidos es 0.0056, se puede observar que este error es menor que el error estimado con todos los elementos. El número de elementos válidos es np.int64(1979).

Para completar el ejemplo, la Figura 5.6 muestra el conjunto de datos original, con las respectivas clases y se añade una etiqueta adicional para observar aquellos elementos que fueron incorrectamente clasificados. En la figura de la derecha se presentan solamente aquellos elementos para los cuales no se seleccionó la acción nula. Se puede observar que todavía existen errores en la predicción y que la frontera entre la clase positiva y negativa es más explícita quitando los elementos asociados a la clase nula.

```
y_error = y.copy()
y_error[y != hy] = 'E'
df = pd.DataFrame(X, columns=['x', 'y'])
df['Clase'] = y_error
df['Conjunto'] = 'Original'
```

```
df2 = pd.DataFrame(X[valid], columns=['x', 'y'])
df2['Clase'] = y_error[valid]
df2['Conjunto'] = 'Reducido'
color=sns.color_palette()
palette = dict(P=color[0], N=color[1], E=color[3])

fig = sns.relplot(data=pd.concat((df, df2)), kind='scatter', x='x',
                  palette=palette,
                  y='y', hue='Clase', col='Conjunto')
```

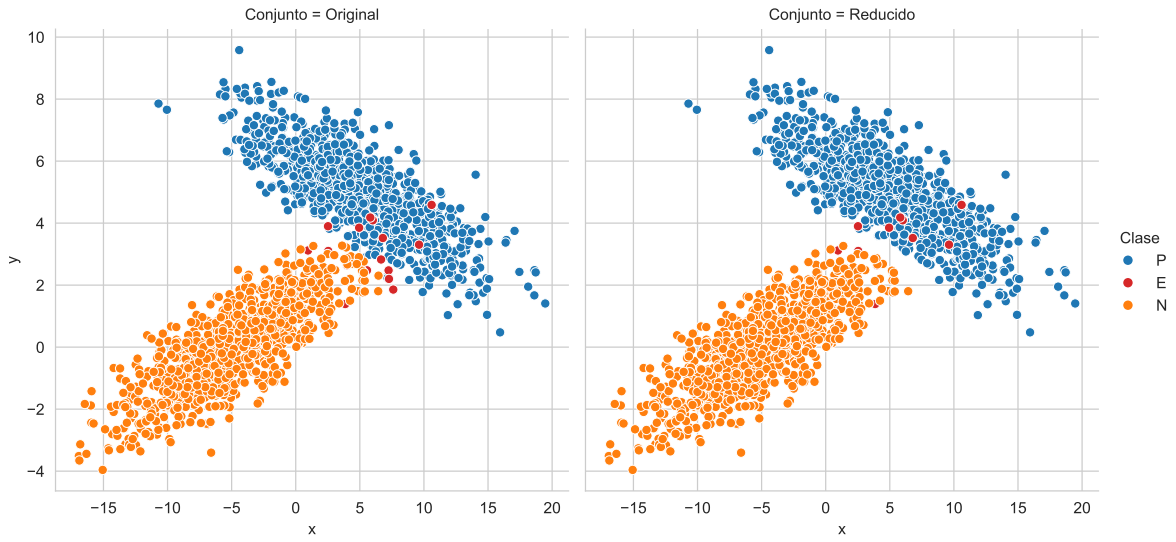


Figura 5.6: Predicción del conjunto original y el conjunto que elimina aquellos elementos que se asocian a la clase nula

Actividad

Utilizando los siguientes parámetros $= [5,5]^\top = \mu_1 = \mu_2$, $\Sigma_1 = \begin{pmatrix} 20 & -5 \\ -5 & 2 \end{pmatrix}$ y $\Sigma_2 = \begin{pmatrix} 20 & -5 \\ -5 & 2 \end{pmatrix}$, generar 1,000 muestras de las siguientes distribuciones $\mathcal{N}_1(\mu, \Sigma_1)$ y $\mathcal{N}_2(\mu, \Sigma_2)$. Asociar, a los datos generados por la primera distribución, la clase positiva y los elementos negativos corresponden a los 1,000 elementos generados mediante $\mathcal{N}_2$.
La actividad corresponde en calcular el error y el número de elementos que no están asociados a la clase nula cuando $\lambda = 0.2$. La Figura 5.7 muestra los datos generados y los datos válidos considerando el nivel de riesgo solicitado así como los errores en la predicción.

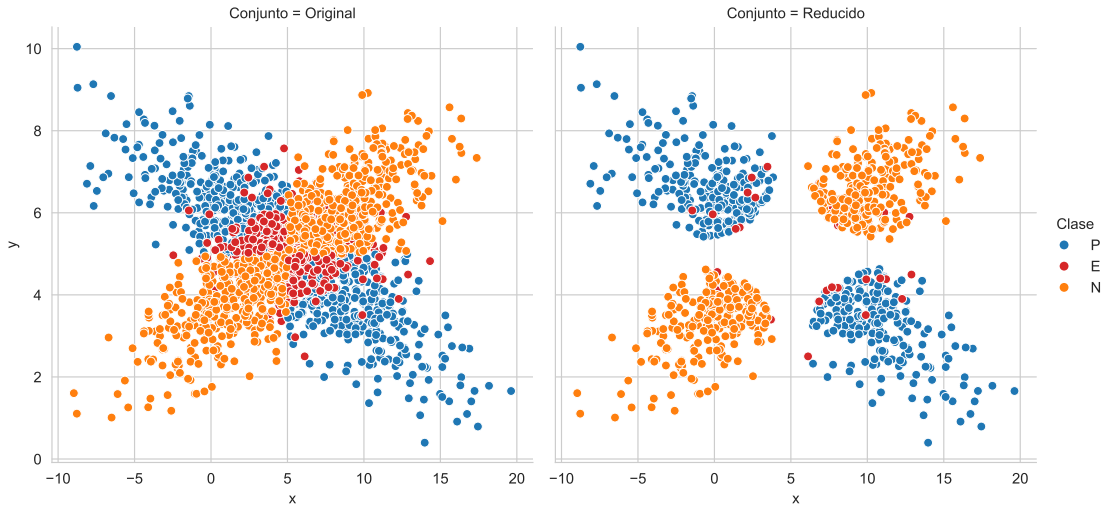


Figura 5.7: Predicción del conjunto original y el conjunto que elimina aquellos elementos que se asocian a la clase nula

5.8. Resumen

La teoría de decisión bayesiana plantea el aprendizaje supervisado como un problema de probabilidad. El teorema de Bayes (Ecuación 5.1) permite calcular la probabilidad de cada clase dada la entrada, y seleccionar la clase más probable produce el clasificador de Bayes (Ecuación 5.4). Su error, el error bayesiano (Sección 5.5), es la cota inferior de lo que cualquier algoritmo puede lograr con esas variables. Cuando los errores no cuestan lo mismo se utiliza el riesgo, y la acción nula permite abstenerse de decidir si la incertidumbre es alta (Sección 5.7).

Esta es una forma de leer el umbral de una política. Decidir a quién no asignar un programa cuando la incertidumbre es alta, o a quién se le pide una verificación adicional, es una decisión de política y no un detalle técnico. El costo de equivocarse por exclusión o por inclusión determina dónde conviene poner el umbral, y la acción nula es la forma de formalizar una revisión adicional de los casos dudosos.

En este capítulo las distribuciones se tomaron como conocidas, y en un problema real hay que estimarlas a partir de los datos. Los métodos que suponen una forma para esas distribuciones y estiman sus parámetros se estudian en Capítulo 6.

6 Métodos Paramétricos

El **objetivo** de la unidad es conocer las características de los modelos paramétricos y aplicar máxima verosimilitud para estimar los parámetros del modelo paramétrico en problemas de clasificación.

Paquetes usados

```
from sklearn.discriminant_analysis import QuadraticDiscriminantAnalysis
from sklearn.discriminant_analysis import LinearDiscriminantAnalysis
from sklearn.naive_bayes import GaussianNB
from sklearn.model_selection import train_test_split
from sklearn.datasets import load_breast_cancer
from scipy.stats import norm, multivariate_normal
from scipy.special import logsumexp
from matplotlib import pylab as plt
import numpy as np
import pandas as pd
import seaborn as sns
from CompStats.metrics import accuracy_score
```

6.1. Introducción

Existen diferentes tipos de algoritmos que se puede utilizar para resolver problemas de aprendizaje supervisado y no supervisado. En particular, esta unidad se enfoca en presentar las técnicas que se pueden caracterizar como métodos paramétricos.

Los métodos paramétricos se identifican por asumir que los datos provienen de una distribución de la cual se desconocen los parámetros y el procedimiento es encontrar los parámetros de la distribución que mejor modelen los datos. Una vez obtenidos los parámetros se cuenta con todos los elementos para utilizar el modelo y predecir la característica para la cual fue entrenada.

La regresión lineal, que también es un método paramétrico, se presentó en Capítulo 3; este capítulo se concentra en clasificación.

6.2. Metodología

Hasta el momento se han presentado ejemplos de los pasos 4 y 5 de la metodología general (ver Sección 1.4); esto fue en la Sección 5.3.2 y en la Sección 5.4. Esta sección complementa los ejemplos anteriores al utilizar todos los pasos de la metodología general de aprendizaje supervisado (ver Sección 1.4). En particular se enfoca al paso 3 que corresponde al diseño del algoritmo f que modela el fenómeno de interés utilizando los datos $\mathcal{T} \subset \mathcal{D}$.

El algoritmo f corresponde a asumir que los datos $\mathcal{D}$ provienen de una distribución F la cual tiene una serie de parámetros θ que son identificados con $\mathcal{T}$.

6.3. Estimación de Parámetros

Se inicia la descripción de métodos paramétricos presentando el procedimiento general para estimar los parámetros de una distribución. Se cuenta con un conjunto $\mathcal{D}$ donde los elementos $x \in \mathcal{D}$ son $x \in \mathbb{R}^d$. Los elementos $x \in \mathcal{D}$ tienen una distribución F, i.e., $x \sim F$, son independientes y F está definida por la función de densidad de probabilidad f_θ, que a su vez está definida por θ parámetros. Utilizando $\mathcal{D}$ el objetivo es identificar los parámetros θ que hacen observar a $\mathcal{D}$ lo más probable.

6.3.1. Verosimilitud

Una solución para maximizar el observar $\mathcal{D}$ es maximizando la verosimilitud. La verosimilitud es la función distribución conjunta de los elementos en $\mathcal{D}$, i.e., $f_\theta(x_1, x_2, \dots, x_N)$. Considerando que las muestras son independientes entonces $f_\theta(x_1, x_2, \dots, x_N) = \prod_{x \in \mathcal{D}} f_\theta(x)$. La función de verosimilitud considera la ecuación anterior como una función de los parámetros θ, es decir,

$$\mathcal{L}(\theta) = \prod_{x \in \mathcal{D}} f_\theta(x),$$

siendo el logaritmo de la verosimilitud

$$\ell(\theta) = \log \mathcal{L}(\theta) = \sum_{x \in \mathcal{D}} \log f_\theta(x).$$

6.3.2. Distribución de Bernoulli

La verosimilitud se ejemplifica con la identificación del parámetro p de una distribución Bernoulli. Una distribución Bernoulli modela dos estados, por un lado se tiene la clase negativa identificada por 0; identificando la clase positiva como 1. Entonces, la probabilidad de observar 1 es $\mathbb{P}(X = 1) = p$ y $\mathbb{P}(X = 0) = 1 - p$. Estas ecuaciones se pueden combinar para definir $f_\theta(x) = p^x(1-p)^{1-x}$.

Utilizando el logaritmo de la verosimilitud se tiene:

$$\ell(p) = \sum_{i=1}^{N} \log p^{x_i}(1-p)^{1-x_i} = \sum_{i=1}^{N} x_i \log p + (1 - x_i) \log(1-p).$$

Recordando que el máximo de $\ell(p)$ se obtiene cuando $\frac{d}{dp}\ell(p) = 0$, entonces estimar p corresponde a resolver lo siguiente:

$$\begin{aligned}
\frac{d}{dp}\ell(p) &= 0 \\
\frac{d}{dp}[\sum_{i=1}^{N} x_i \log p + (1 - x_i) \log(1-p)] &= 0 \\
\frac{d}{dp}[\sum_{i=1}^{N} x_i \log p + \log(1-p)(N - \sum_{i=1}^{N} x_i)] &= 0 \\
\sum_{i=1}^{N} x_i \frac{d}{dp} \log p + (N - \sum_{i=1}^{N} x_i) \frac{d}{dp} \log(1-p) &= 0 \\
\sum_{i=1}^{N} x_i \frac{1}{p} + (N - \sum_{i=1}^{N} x_i) \frac{-1}{(1-p)} &= 0
\end{aligned}$$

Realizando algunas operaciones algebraicas se obtiene:

$$\hat{p} = \frac{1}{N} \sum_{i=1}^{N} x_i.$$

6.3.3. Ejemplo: Distribución Gaussiana

Esta sección sigue un camino práctico, presentando el código para estimar los parámetros de una distribución Gaussiana donde se conocen todos los parámetros. La distribución se usa para generar 1000 muestras y después de esta población se estiman los parámetros; de esta manera se tienen todos los elementos para comparar los parámetros reales θ de los parámetros estimados $\hat{\theta}$.

La distribución que se usará se utilizó para generar un problema sintético (ver Sección 5.3.1) de tres clases. Los parámetros de la distribución son: $= [5, 5]^\top$ y $\Sigma = \begin{pmatrix} 4 & 0 \\ 0 & 2 \end{pmatrix}$. La siguiente instrucción se puede utilizar para generar 1000 muestras de esa distribución.

```
D = multivariate_normal(mean=[5, 5],
                        cov=[[4, 0],
                             [0, 2]]).rvs(size=1000)
```

La media estimada de los datos en `D` se calcula usando la función `np.mean` de la siguiente manera

```
mu = np.mean(D, axis=0)
```

donde el eje de operación es el primero que corresponde al índice 0. La media estimada es: $\hat{\mu} = [5.0062, 4.9310]^\top$ con un error estándar (`se`) de $[0.0634, 0.0460]^\top$ que se calcula con el siguiente código.

```
se = np.std(D, axis=0) / np.sqrt(1000)
```

Hasta el momento se ha estimado μ, falta por estimar Σ, que se puede realizar con la siguiente instrucción

```
cov = np.cov(D, rowvar=False)
```

donde el parámetro `rowvar` indica la forma en que están proporcionados los datos. La estimación da los siguientes valores $\hat{\Sigma} = \begin{pmatrix} 4.0262 & 0.1056 \\ 0.1056 & 2.1148 \end{pmatrix}$; se puede observar que son similares al parámetro con que se simularon los datos.

Siguiendo con la inercia de presentar el error estándar de cada estimación, en las siguientes instrucciones se presenta el error estándar de $\hat{\Sigma}$, el cual se calcula utilizando la técnica de bootstrap (ver Sección A.2) implementada en el siguiente código.

```
S = np.random.randint(D.shape[0],
                      size=(500, D.shape[0]))
B = [np.cov(D[s], rowvar=False) for s in S]
se = np.std(B, axis=0)
```

Se puede observar que la función `np.cov` se ejecuta utilizando la muestra indicada en la variable `s`. El error estándar (`se`) de $\hat{\Sigma}$ corresponde a $\begin{pmatrix} 0.1818 & 0.0946 \\ 0.0946 & 0.0950 \end{pmatrix}$. Se observa que los elementos

fuera de la diagonal tienen un error estándar tal que el cero se encuentra en el intervalo $\hat{\Sigma} \pm se$; lo cual indica que el cero es un valor factible. Lo anterior se puede verificar tomando en cuenta que se conoce Σ y que el parámetro real es 0 para aquellos elementos fuera de la diagonal.

6.4. Metodología de Clasificación

Habiendo descrito el proceso para estimar los parámetros de una distribución, por un lado se presentó de manera teórica con la distribución Bernoulli (ver Sección 6.3.2) y de manera práctica con una distribución Gaussiana (ver Sección 6.3.3), se está en la posición de usar todos estos elementos para presentar el proceso completo de clasificación. La metodología general de aprendizaje supervisado (ver Sección 1.4) está definida por cinco pasos, estos pasos se especializan para el problema de clasificación y regresión, utilizando modelos paramétricos, de la siguiente manera.

1. Todo empieza con un conjunto de datos $\mathcal{D}$ que tiene la información del fenómeno de interés.
2. Se selecciona el conjunto $\mathcal{T} \subset \mathcal{D}$, el procedimiento se describe en la Sección 2.2.
3. Se diseña un algoritmo, f, el cual se basa en un modelo (ver Sección 6.5) y la estimación de sus parámetros (ver Sección 6.5.1) utilizando $\mathcal{T}$.
4. En la Sección 6.5.2 se describe el uso de f para predecir.
5. La Sección 6.5.3 muestra el procedimiento para medir el rendimiento utilizando un conjunto de prueba (ver Sección 2.2).

La metodología de clasificación se ilustra utilizando el problema sintético (ver Sección 5.3.1) de tres clases que se presentó en el Capítulo 5.

Específicamente, las entradas que definían a cada clase están en las variables `X_1`, `X_2` y `X_3`. Entonces las clases se pueden colocar en la variable `y` tal como se indica a continuación.

```
X = np.concatenate((X_1, X_2, X_3))
y = np.array([1] * 1000 + [2] * 1000 + [3] * 1000)
```

Las variables `X` y `y` contienen la información del conjunto $\mathcal{D} = (\mathcal{X}, \mathcal{Y})$ donde cada renglón de `X` es una realización de la variable aleatoria $\mathcal{X}$ y equivalentemente cada elemento en `y` es una realización de $\mathcal{Y}$.

El procedimiento para dividir $\mathcal{D}$ en el conjunto de entrenamiento, $\mathcal{T}$, y el de prueba, $\mathcal{G}$, se describió en la Sección 2.2 del capítulo de Rendimiento (Capítulo 2). En este caso, $\mathcal{T}$ se utiliza para estimar los parámetros del modelo (por ejemplo, para maximizar la verosimilitud, Sección 6.3.3) y $\mathcal{G}$ para medir su rendimiento. La división se realiza con la siguiente instrucción.

```
T, G, y_t, y_g = train_test_split(X, y,
                                  test_size=0.2,
                                  random_state=seed)
```

6.5. Clasificador

El inicio de métodos paramétricos es el Teorema de Bayes (Ecuación 5.1) $\mathbb{P}(\mathcal{Y} \mid \mathcal{X}) = \frac{\mathbb{P}(\mathcal{X}|\mathcal{Y})\mathbb{P}(\mathcal{Y})}{\mathbb{P}(\mathcal{X})}$ donde se usa la verosimilitud $\mathbb{P}(\mathcal{X} \mid \mathcal{Y})$ y la probabilidad a priori $\mathbb{P}(\mathcal{Y})$ para definir la probabilidad a posteriori $\mathbb{P}(\mathcal{Y} \mid \mathcal{X})$. En métodos paramétricos se asume que se puede modelar la verosimilitud con una distribución particular, que por lo general es una distribución Gaussiana multivariada. Es decir, la variable aleatoria $\mathcal{X}$ dado $\mathcal{Y}$ (i.e., $\mathcal{X}_{|\mathcal{Y}}$) es $\mathcal{X}_{|\mathcal{Y}} \sim \mathcal{N}(\mu_{\mathcal{Y}}, \Sigma_{\mathcal{Y}})$, donde se observa que los parámetros de la distribución Gaussiana dependen de la variable aleatoria $\mathcal{Y}$ y estos pueden ser identificados cuando $\mathcal{Y}$ tiene un valor específico.

6.5.1. Estimación de Parámetros

Dado que por definición del problema (ver Sección 5.3.1) se conoce que la verosimilitud para cada clase proviene de una Gaussiana, i.e., $\mathcal{X}_{|\mathcal{Y}} \sim \mathcal{N}(\mu_{\mathcal{Y}}, \Sigma_{\mathcal{Y}})$, en esta sección se estimarán los parámetros utilizando este conocimiento.

El primer paso en la estimación de parámetros es calcular la probabilidad a priori $\mathbb{P}(\mathcal{Y})$, el cual corresponde a clasificar el evento sin observar el valor de $\mathcal{X}$. Esto se puede modelar mediante una distribución Categórica con parámetros p_i donde $\sum_i^K p_i = 1$. Estos parámetros se pueden estimar utilizando la función `np.unique` de la siguiente manera

```
labels, counts = np.unique(y_t, return_counts=True)
prior = counts / counts.sum()
```

La variable `prior` contiene en el primer elemento $\mathbb{P}(\mathcal{Y} = 1) = 0.3179$, en el segundo $\mathbb{P}(\mathcal{Y} = 2) = 0.3387$ y en el tercero $\mathbb{P}(\mathcal{Y} = 3) = 0.3433$ que es aproximadamente $\frac{1}{3}$ el cual es el valor real de la probabilidad a priori.

Siguiendo los pasos en estimación de parámetros de una Gaussiana (Sección 6.3.3) se pueden estimar los parámetros para cada Gaussiana dada la clase. Es decir, se tiene que estimar los parámetros μ y Σ para la clase 1, 2 y 3. El algoritmo de clasificación que estima μ y Σ para cada clase se le conoce como **Analizador Discriminante Cuadrático** implementado en la clase `QuadraticDiscriminantAnalysis`.

Una implementación directa para la estimación de los parámetros se puede realizar iterando por las etiquetas contenidas en la variable `labels` y seleccionando los datos en `T` que corresponden a la clase analizada, ver el uso de la variable `mask` en la línea 4 y 5. Después se inicializa una

instancia de la clase `multivariate_normal` para ser utilizada en el cómputo de la función de densidad de probabilidad. El paso final es guardar las instancias de las distribuciones en la lista `likelihood`.

```
likelihood = []
for k in labels:
    mask = y_t == k
    mu = np.mean(T[mask], axis=0)
    cov = np.cov(T[mask], rowvar=False)
    likelihood_k = multivariate_normal(mean=mu, cov=cov)
    likelihood.append(likelihood_k)
```

Los valores estimados para la media, en cada clase son: $\hat{\mu}_1 = [5.0267, 4.9626]^\top$, $\hat{\mu}_2 = [1.5687, -1.4642]^\top$ y $\hat{\mu}_3 = [12.5188, -3.4715]^\top$. Para las matrices de covarianza, los valores estimados corresponden a $\hat{\Sigma}_1 = \begin{pmatrix} 3.8108 & -0.0363 \\ -0.0363 & 1.9319 \end{pmatrix}$, $\hat{\Sigma}_2 = \begin{pmatrix} 1.8221 & 0.8862 \\ 0.8862 & 2.8153 \end{pmatrix}$ y $\hat{\Sigma}_3 = \begin{pmatrix} 1.9043 & 2.8677 \\ 2.8677 & 6.7392 \end{pmatrix}$.

Estas estimaciones se pueden comparar con los parámetros reales (Sección 5.3.1). También se puede calcular su error estándar para identificar si el parámetro real, θ, se encuentra en el intervalo definido por $\hat{\theta} - 2\hat{se} \leq \hat{\theta} \leq \hat{\theta} + 2\hat{se}$ que corresponde aproximadamente al 95 % de confianza asumiendo que la distribución de la estimación del parámetro es Gaussiana.

Nota

El código anterior tiene el fin de explicar el procedimiento para estimar los parámetros, la clase `QuadraticDiscriminantAnalysis` implementa diferentes métodos de estimación y se puede utilizar con el siguiente código.

```
qda = QuadraticDiscriminantAnalysis(store_covariance=True).fit(T, y_t)
```

Los parámetros μ se encuentran en el siguiente atributo. Se puede observar que los valores estimados por el método explicado y el implementado en QDA es el mismo.

```
qda.means_
```

```
array([[ 5.0267,  4.9626],
       [ 1.5687, -1.4642],
       [12.5188, -3.4715]])
```

Los parámetros estimados para Σ_1 se pueden obtener en el siguiente atributo

```
qda.covariance_[0]
```

```
array([[ 3.8058, -0.0363],
       [-0.0363,  1.9293]])
```

Se observa que los valores son equivalentes entre los dos procedimientos, es importante mencionar que estos parámetros solamente están disponibles si la clase se inicializa con el parámetro `store_covariance` en verdadero.

Cuando se asume que las matrices de covarianza son iguales para todas las clases, se está en la presencia del algoritmo **Analizador Discriminante Lineal**. Este algoritmo está implementado en la clase `LinearDiscriminantAnalysis`.

i Nota

La clase `LinearDiscriminantAnalysis` se utiliza con la siguiente instrucción, el parámetro `store_covariance` se asigna para poder mostrar la matriz de covarianza.

```
lda = LinearDiscriminantAnalysis(store_covariance=True).fit(T, y_t)
```

Los parámetros μ se encuentran en el siguiente atributo. Se puede observar que los valores estimados por el método explicado son los encontrados anteriormente.

```
lda.means_
```

```
array([[ 5.0267,  4.9626],
       [ 1.5687, -1.4642],
       [12.5188, -3.4715]])
```

Los parámetros estimados para la matriz de covarianza, Σ, se pueden obtener en el siguiente atributo

```
lda.covariance_
```

```
array([[2.4794, 1.2717],
       [1.2717, 3.8769]])
```

6.5.2. Predicción

Una vez que se tiene la función que modela los datos, se está en condiciones de utilizarla para predecir (ver Sección 5.3.2) nuevos datos.

En esta ocasión se organiza el procedimiento de predicción en diferentes funciones, la primera función recibe los datos a predecir `X` y los componentes del modelo, que son la verosimilitud

(`likelihood`) y el `prior`. La función calcula $\mathbb{P}(\mathcal{Y} = y \mid \mathcal{X} = x)$ que es la probabilidad de cada clase dada la entrada x. Se puede observar en la primera línea que se usa la función de densidad de probabilidad (`pdf`) para cada clase y esta se multiplica por el `prior` y en la tercera línea se calcula la evidencia. Finalmente, se regresa el a posteriori.

```
def predict_prob(X, likelihood, prior):
    likelihood = [m.pdf(X) for m in likelihood]
    posterior = np.vstack(likelihood).T * prior
    evidence = posterior.sum(axis=1)
    return posterior / np.atleast_2d(evidence).T
```

La función `predict_proba` se utiliza como base para predecir la clase, para la cual se requiere el mapa entre índices y clases que se encuentra en la variable `labels`. Se observa que se llama a la función `predict_proba` y después se calcula el argumento que tiene la máxima probabilidad regresando la etiqueta asociada.

```
def predict(X, likelihood, prior, labels):
    _ = predict_prob(X, likelihood, prior)
    return labels[np.argmax(_, axis=1)]
```

> **Nota**
>
> La predicción en la clase `QuadraticDiscriminantAnalysis` se puede realizar invocando al siguiente método tal y como se muestra en la siguiente línea.
>
> ```
> qda_hy = qda.predict(G)
> ```
>
> La probabilidad se puede obtener utilizando el método `predict_proba.`
>
> ```
> qda_prob = qda.predict_proba(G)
> ```
>
> De manera similar la predicción del algoritmo `LinearDiscriminantAnalysis` se realiza con la siguiente instrucción.
>
> ```
> lda_hy = lda.predict(G)
> ```

6.5.3. Rendimiento

El rendimiento del algoritmo se mide en el conjunto de prueba `G`, utilizando como medida el error de clasificación (Sección 5.4). El primer paso es predecir las clases de los elementos en `G`,

utilizando la función `predict` que fue diseñada anteriormente. Después se mide el error, con la instrucción de la segunda línea.

```
hy = predict(G, likelihood, prior, labels)
error = (y_g != hy).mean()
```

El error que tiene el algoritmo en el conjunto de prueba es 0.0117.

Nota

El error utilizado `qda_hy` corresponde a 0.0117.

Actividad

Utilizando la probabilidad en el conjunto de prueba, que se tiene en la variable `qda_prob`, calcular la variación del número de elementos que son asociados a la acción nula cuando se varía el nivel de riesgo (ver Sección 5.7), incluir en la figura o en una figura adicional, la dinámica del error en el conjunto de prueba para los elementos válidos. La Figura 6.1 muestra el resultado de este proceso. Se observa cómo va disminuyendo el número de elementos asociados a la acción nula cuando el riesgo se incrementa y al mismo tiempo cómo el error aumenta.

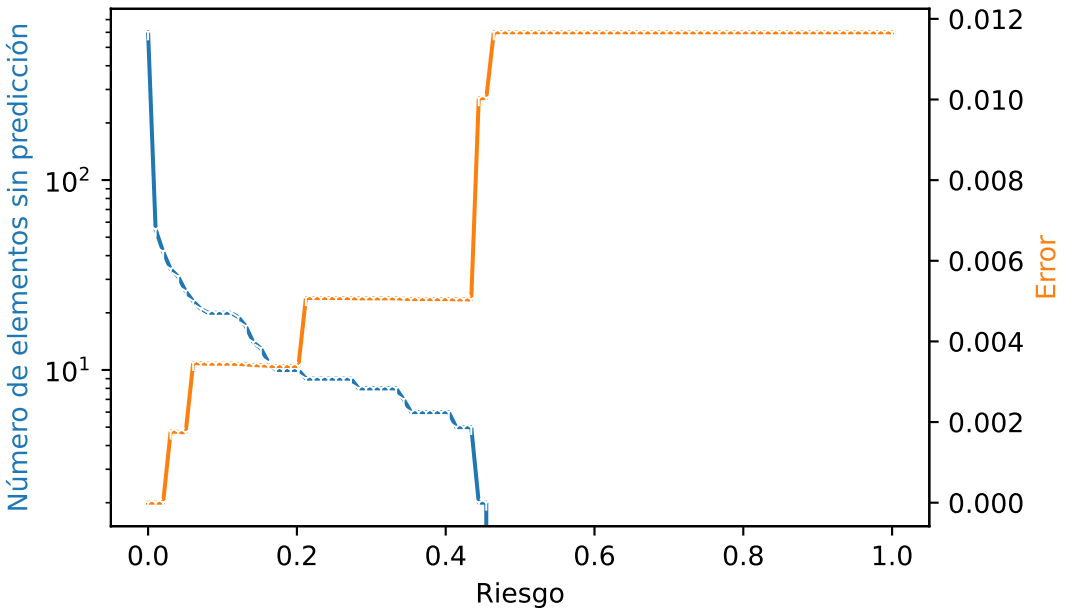


Figura 6.1: Variación del número de elementos que seleccionan la acción nula y el error en el conjunto de prueba respecto al riesgo

Para calcular el error estándar se utiliza el siguiente código

```
se_formula = np.sqrt(error * (1 - error) / y_g.shape[0])
```

dando un valor de 0.0044.

Actividad

Generar la distribución del error utilizando el método de Bootstrap (ver Sección A.2), tal y como se muestra en la Figura 6.2.

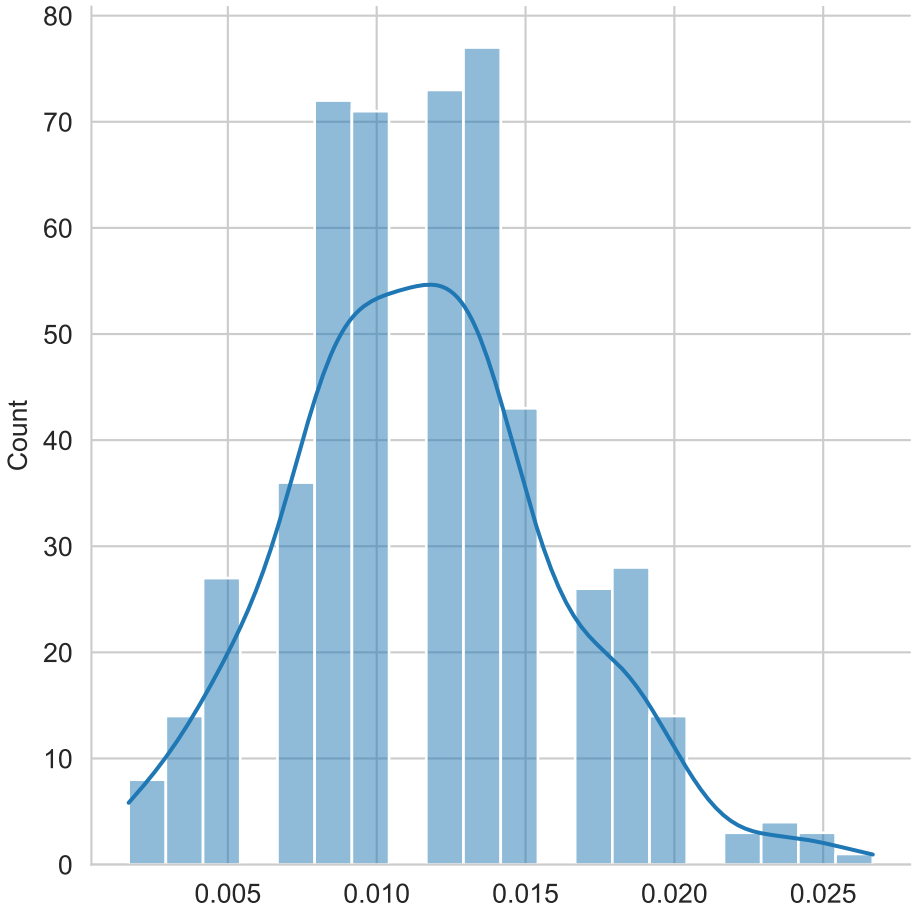


Figura 6.2: Distribución del error

El error estándar calculado con los datos mostrados en la figura anterior es 0.0045

6.6. Clasificador Bayesiano Ingenuo

Uno de los clasificadores más utilizados, sencillo de implementar y competitivo, es el clasificador Bayesiano Ingenuo. En la Sección 6.5 se asumió que la variable aleatoria $\mathcal{X} = (\mathcal{X}_1, \mathcal{X}_2, \dots, \mathcal{X}_d)$ dado $\mathcal{Y}$ ($\mathcal{X}_{|y}$) es $\mathcal{X}_{|y} \sim \mathcal{N}(\mu_y, \Sigma_y)$, donde $\mu_y \in \mathbb{R}^d$, $\Sigma_y \in \mathbb{R}^{d \times d}$ y $f(\mathcal{X}_1, \mathcal{X}_2, \dots, \mathcal{X}_d)$ es la función de densidad de probabilidad conjunta.

En el clasificador Bayesiano Ingenuo se asume que las variables $\mathcal{X}_i$ y $\mathcal{X}_j$ para $i \neq j$ son independientes, esto trae como consecuencia que $f(\mathcal{X}_1, \mathcal{X}_2, \dots, \mathcal{X}_d) = \prod_i^d f(\mathcal{X}_i)$. Esto quiere decir que cada variable está definida como una Gaussiana donde se tiene que identificar μ y σ^2.

La estimación de los parámetros de estas distribuciones se puede realizar utilizando un código similar siendo la única diferencia que se calcula σ^2 de cada variable en lugar de la covarianza Σ, esto se puede observar en la quinta línea donde se usa la función `np.var` en el primer eje. El resto del código es equivalente al usado en la Sección 6.5.1.

```
likelihood = []
for k in labels:
    mask = y_t == k
    mu = np.mean(T[mask], axis=0)
    var = np.var(T[mask], axis=0, ddof=1)
    likelihood_k = multivariate_normal(mean=mu, cov=var)
    likelihood.append(likelihood_k)
```

Los parámetros estimados en la versión ingenua son equivalentes con respecto a las medias, i.e., $\hat{\mu}_1 = [5.0267, 4.9626]^\top$, $\hat{\mu}_2 = [1.5687, -1.4642]^\top$ y $\hat{\mu}_3 = [12.5188, -3.4715]^\top$. La diferencia se puede observar en las varianzas, que a continuación se muestran como matrices de covarianza para resaltar la diferencia, i.e., $\hat{\Sigma}_1 = \begin{pmatrix} 3.8108 & 0.0000 \\ 0.0000 & 1.9319 \end{pmatrix}$, $\hat{\Sigma}_2 = \begin{pmatrix} 1.8221 & 0.0000 \\ 0.0000 & 2.8153 \end{pmatrix}$ y $\hat{\Sigma}_3 = \begin{pmatrix} 1.9043 & 0.0000 \\ 0.0000 & 6.7392 \end{pmatrix}$ se observa como los elementos fuera de la diagonal son ceros, lo cual indica la independencia entra las variables de entrada.

Finalmente, el código para predecir se utiliza el código descrito en la Sección 6.5.2 dado que el modelo está dado en las variables `likelihood` y `prior`.

El `error` del clasificador Bayesiano Ingenuo, en el conjunto de prueba, es de 0.01 y su error estándar (`se_formula`) es 0.0041.

Nota

El código anterior tiene la finalidad de explicar la estimación de parámetros del Clasificador Bayesiano Ingenuo. Este procedimiento se encuentra en la clase `GaussianNB`, en ese paquete se pueden encontrar implementaciones con otras distribuciones.
El siguiente código muestra su uso.

```
naive = GaussianNB().fit(T, y_t)
```

Los parámetros μ se pueden consultar con la siguiente instrucción

```
naive.theta_
```

```
array([[ 5.0267,  4.9626],
       [ 1.5687, -1.4642],
       [12.5188, -3.4715]])
```

y σ^2 en

```
naive.var_
```

```
array([[3.8058, 1.9293],
       [1.8199, 2.8119],
       [1.902 , 6.731 ]])
```

6.7. Ejemplo: Breast Cancer Wisconsin

Esta sección ilustra el uso del clasificador Bayesiano al generar dos modelos; Clasificador Bayesiano (mejor conocido como el algoritmo de Análisis Discriminante Cuadrático) y Bayesiano Ingenuo en el conjunto de datos de *Breast Cancer Wisconsin*. Estos datos se pueden obtener utilizando la función `load_breast_cancer` tal y como se muestra a continuación.

```
X, y = load_breast_cancer(return_X_y=True)
```

El primer paso es contar con los conjuntos de entrenamiento y prueba para poder realizar de manera completa la evaluación del proceso de clasificación. Esto se realiza ejecutando la siguiente instrucción.

```
T, G, y_t, y_g = train_test_split(X, y, test_size=0.2,
                                  random_state=seed)
```

6.7.1. Entrenamiento

Los dos modelos que se utilizarán serán el clasificador de Análisis Discriminante Cuadrático y Bayesiano Ingenuo, utilizando las clases `QuadraticDiscriminantAnalysis` y `GaussianNB`. Las siguientes dos instrucciones inicializan estos dos clasificadores.

```
qda = QuadraticDiscriminantAnalysis(reg_param=1e-3).fit(T, y_t)
naive = GaussianNB().fit(T, y_t)
```

6.7.2. Predicción

Habiendo definido los dos clasificadores, las predicciones del conjunto de prueba se realizan de la siguiente manera.

```
hy_qda = qda.predict(G)
hy_naive = naive.predict(G)
```

6.7.3. Rendimiento

El rendimiento de ambos clasificadores se calcula de la siguiente manera

```
error_qda = (y_g != hy_qda).mean()
error_naive = (y_g != hy_naive).mean()
```

El clasificador Bayesiano Gaussiano tiene un error de 0.0526 y el error de Bayesiano Ingenuo es 0.0702. Se ha visto que el error es una variable aleatoria, entonces la pregunta es saber si esta diferencia en rendimiento es significativa o es una diferencia que proviene de la aleatoriedad de los datos.

6.8. Diferencias en Rendimiento

Una manera de ver si existe una diferencia en rendimiento es calcular la diferencia entre los dos errores de clasificación, esto es

```
naive = (y_g != hy_naive).mean()
completo = (y_g != hy_qda).mean()
if naive > completo:
    diff = naive - completo
else:
    diff = completo - naive
```

que tiene un valor de 0.0175. De la misma manera que se ha utilizado la técnica de bootstrap (Sección A.2) para calcular el error estándar de la media, se puede usar para estimar el error estándar de la diferencia en rendimiento. El siguiente código muestra el procedimiento para estimar este error estándar.

```
S = np.random.randint(y_g.shape[0],
                      size=(500, y_g.shape[0]))
if naive > completo:
    diff_f = lambda s: (y_g[s] != hy_naive[s]).mean() -\
                       (y_g[s] != hy_qda[s]).mean()
else:
    diff_f = lambda s: (y_g[s] != hy_qda[s]).mean() -\
                       (y_g[s] != hy_naive[s]).mean()
B = [diff_f(s) for s in S]
se = np.std(B, axis=0)
```

El error estándar de la diferencia de rendimiento es de 0.0178, un procedimiento simple para saber si la diferencia observada es significativa, es dividir la diferencia entre su error estándar dando un valor de 0.9846. En el caso que el valor absoluto fuera igual o superior a 2 se sabría que la diferencia es significativa con una confianza de al menos 95 %, esto asumiendo que la diferencia se comporta como una distribución Gaussiana.

El histograma de los datos que se tienen en la variable `B` se observa en la Figura 6.3. Se puede ver que la forma del histograma asemeja una distribución Gaussiana y que el cero está en el cuerpo de la Gaussiana, tal y como lo confirmó el cociente que se calculó.

Se puede conocer la probabilidad de manera exacta calculando el área bajo la curva a la izquierda del cero, este sería el valor p, si este es menor a 0.05 quiere decir que se tiene una confianza mayor del 95 % de que los rendimientos son diferentes. Para este ejemplo, el área se calcula con el siguiente código

```
dist = norm(loc=diff, scale=se)
p_value = dist.cdf(0)
```

teniendo el valor de 0.1624, lo que significa que se tiene una confianza del 83 % de que los dos algoritmos son diferentes considerando el error de clasificación como medida de rendimiento.

> **Nota**
>
> El error es el complemento de la exactitud (Sección 2.3.2), utilizando la librería CompStats (Nava-Muñoz et al. (2024)), en particular la función que implementa la exactitud, se puede medir el rendimiento de los dos algoritmos tal y como se muestra en el siguiente código. En la primera línea se mide el rendimiento de QDA y en la segunda el rendimiento que

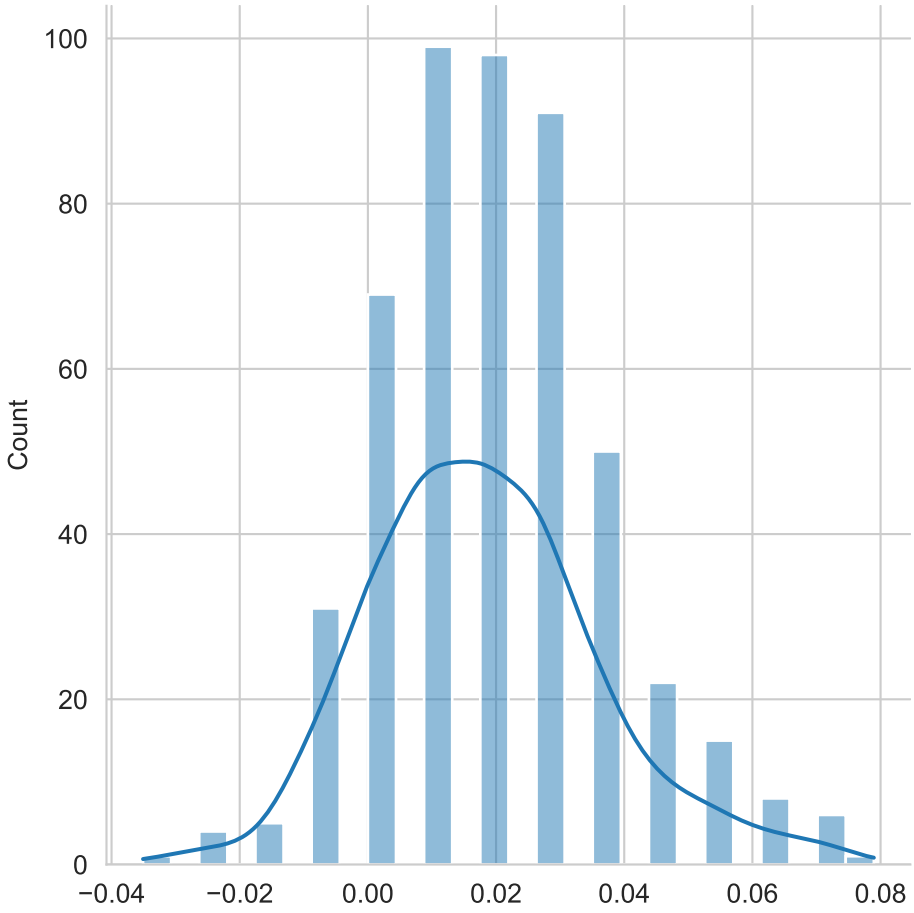


Figura 6.3: Diferencia entre Clasificadores Bayesianos

corresponde a Bayesiano Ingenuo. La última línea grafica el rendimiento.

```
score = accuracy_score(y_g, hy_qda, name='QDA')
score(hy_naive, name='Bayesiano Ingenuo')
score.plot(comp_legend='Comparación',
           winner_legend='Mejor',
           tie_legend='Equivalente',
           loser_legend='Diferente',
           alg_legend='Algoritmo',
           var_name='Rendimiento')
```

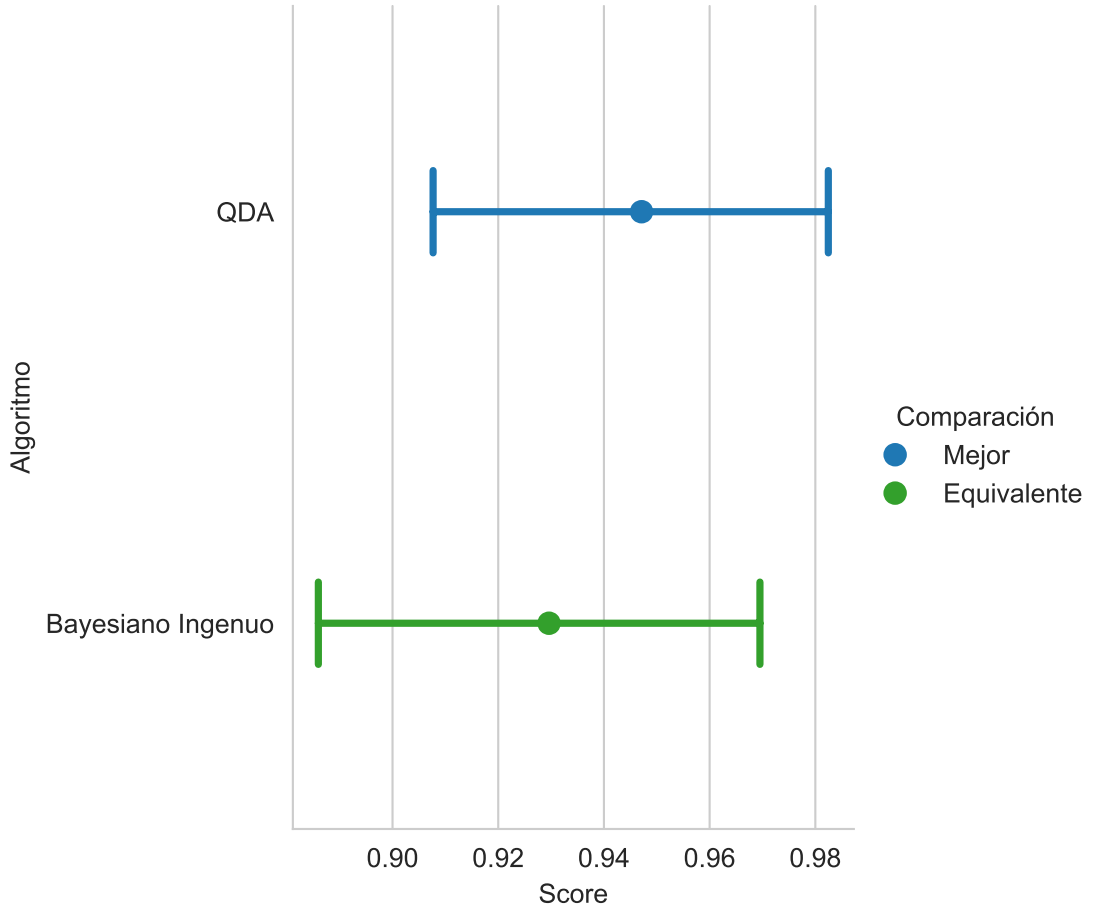


Figura 6.4: Rendimiento entre QDA y Bayesiano Ingenuo.

En la Figura 6.4 se observa el rendimiento, con su intervalo de confianza al 95 %. También

se incluye, el resultado de comparar estadísticamente (95 %) la diferencia de rendimiento mediante el color.

Actividad

Incluir en la comparación anterior el algoritmo Analizador Discriminante Lineal, tal y como se muestra en la Figura 6.5.

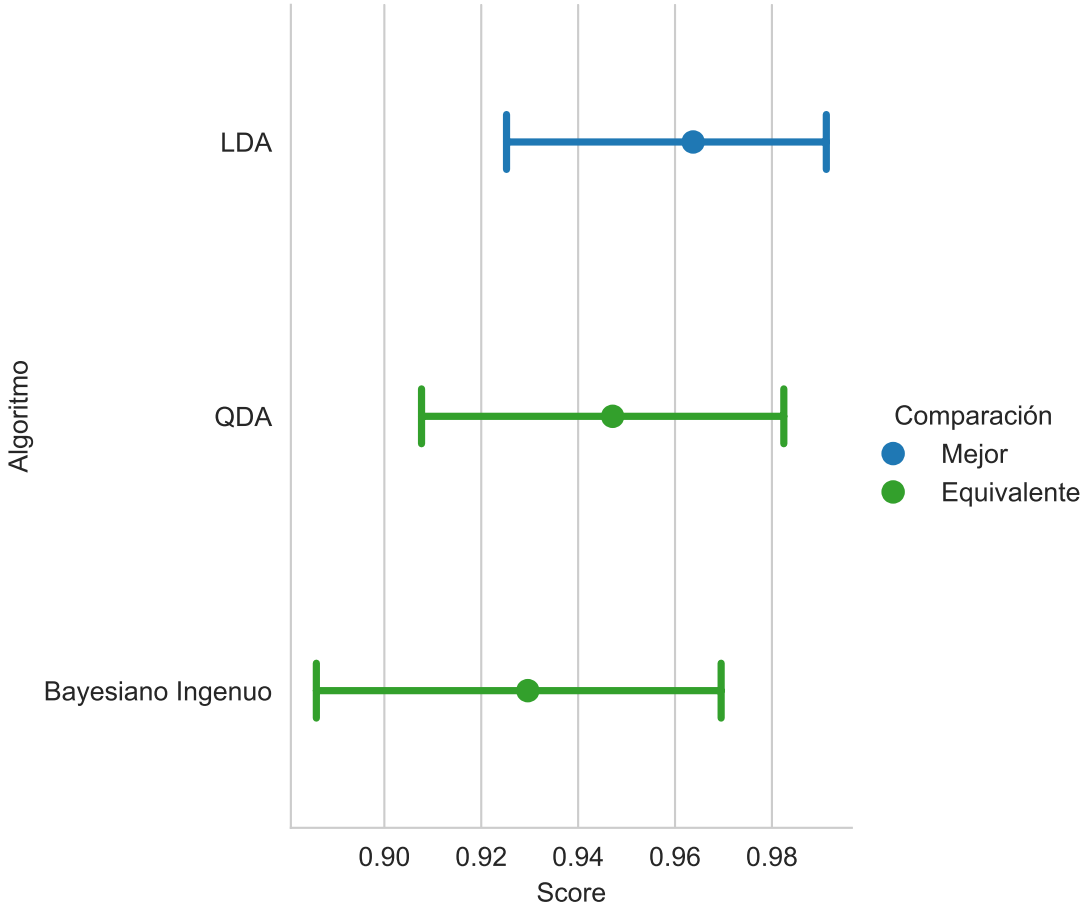


Figura 6.5: Rendimiento entre QDA y Bayesiano Ingenuo.

6.9. Resumen

Los métodos paramétricos suponen que los datos de cada clase provienen de una distribución con una forma conocida y reducen el aprendizaje a estimar sus parámetros. El criterio es la máxima verosimilitud (Sección 6.3.1), que aplicado a una distribución Gaussiana con la matriz de covarianza completa produce el clasificador cuadrático (QDA) de la Sección 6.5. Si además se supone que las variables son independientes dentro de cada clase se obtiene el Bayesiano Ingenuo (Sección 6.6), que estima menos parámetros. Lo que manda en estos métodos es el supuesto sobre la distribución, y la Figura 6.3 muestra que la comparación estadística del rendimiento permite saber si la diferencia entre dos supuestos es real.

Para la política pública esto es útil cuando hay pocos datos y se puede defender un supuesto razonable sobre cómo se distribuyen las variables. Las estimaciones son estables y los parámetros se pueden reportar, pero el resultado es tan bueno como el supuesto. Por eso el supuesto debe documentarse y contrastarse con el rendimiento fuera de muestra.

Qué pasa cuando no es razonable suponer una forma para la distribución es la pregunta que sigue. Los métodos que prescinden de ese supuesto y se apoyan directamente en los datos se presentan en Capítulo 7.

7 Métodos No Paramétricos

El **objetivo** de la unidad es conocer las características de diferentes métodos no paramétricos y aplicarlos para resolver problemas de regresión y clasificación.

7.1. Paquetes usados

```
from sklearn.neighbors import NearestNeighbors,\
                              KNeighborsClassifier,\
                              KNeighborsRegressor
from sklearn.metrics import pairwise_distances
from sklearn.model_selection import train_test_split
from sklearn.datasets import load_digits, load_diabetes
from scipy.stats import norm
from collections import Counter
from matplotlib import pylab as plt
import numpy as np
import pandas as pd
import seaborn as sns
```

7.2. Introducción

Los métodos paramétricos asumen que los datos provienen de un modelo común, esto da la ventaja de que el problema de estimar el modelo se limita a encontrar los parámetros del mismo, por ejemplo los parámetros de una distribución Gaussiana. Por otro lado en los métodos no paramétricos asumen que datos similares se comportan de manera similar, estos algoritmos también se les conoce como algoritmos de memoria o basados en instancias.

7.3. Histogramas

El primer problema que estudiaremos será la estimación no paramétrica de una función de densidad, f, recordando que se cuenta con un conjunto $\mathcal{D} = \{x_i\}$ que es tomado de f y el objetivo es usar $\mathcal{D}$ para estimar la función de densidad $\hat{f}$.

El **histograma** es una manera para estimar la función de densidad. Para formar un histograma se divide la línea en h segmentos disjuntos, los cuales se denominan *bins*. El histograma corresponde a una función constante por partes, donde la altura es la proporción de elementos de $\mathcal{D}$ que caen en el bin analizado.

Suponiendo que todos los valores en $\mathcal{D}$ están en el rango $[0, 1]$, los bins se pueden definir como:

$$B_1 = [0, \frac{1}{m}), B_2 = [\frac{1}{m}, \frac{2}{m}), ..., B_m = [\frac{m-1}{m}, 1],$$

donde m es el número de bins y $h = \frac{1}{m}$. Se puede definir a $\hat{p}_j = \frac{1}{N} \sum_{x \in \mathcal{D}} 1(x \in B_j)$ y $p_j = \int_{B_j} f(u)du$, donde p_j es la probabilidad del j-ésimo bin y $\hat{p}_j$ es su estimación. Usando esta definición se puede definir la estimación de f como:

$$\hat{f}(x) = \sum_{j=1}^{N} \frac{\hat{p}_j}{h} 1(x \in B_j).$$

Con esta formulación se puede ver la motivación de usar histogramas como estimador de f véase:

$$\mathbb{E}(\hat{f}(x)) = \frac{\mathbb{E}(\hat{p}_j)}{h} = \frac{p_j}{h} = \frac{\int_{B_j} f(u)du}{h} \approx \frac{hf(x)}{h} = f(x).$$

7.3.1. Selección del tamaño del bin

Una parte crítica para usar un histograma es la selección de h o equivalentemente el número de bins del estimador. Utilizando el método descrito en Wasserman (2004), el cual se basa en minimizar el riesgo haciendo una validación cruzada, obteniendo la siguiente ecuación:

$$\hat{J}(h) = \frac{2}{(N-1)h} - \frac{N+1}{(N-1)h} \sum_{j=1}^{N} \hat{p}_j^2.$$

Para ilustrar el uso de la ecuación de minimización del riesgo se utilizará en el ejemplo utilizado en Wasserman (2004). Los datos se pueden descargar de http://www.stat.cmu.edu/~larry/all-of-statistics/=Rprograms/a1882_25.dat.

El primer paso es leer el conjunto de datos, dentro del ejemplo usado en Wasserman (2004) se eliminaron todos los datos menores a 0.2, esto se refleja en la última línea.

```
D = np.r_[[list(map(float, x.strip().split()))
          for x in open("a1882_25.dat").readlines()]]
D = D[:, 2]
D = D[D <= 0.2]
```

Haciendo un paréntesis en el ejemplo, para poder calcular $\hat{p}_j$ es necesario calcular el histograma; dado que los valores están normalizados podemos realizar el histograma utilizando algunas funciones de `numpy` y librerías tradicionales.

Para ilustrar el método para generar el histograma se genera un histograma con 100 bins (primera línea). El siguiente paso (segunda línea) es encontrar los límites de los bins, para este proceso se usa la función `np.linspace`. En la tercera línea se encuentra el bin de cada elemento, con la característica que `np.searchsorted` regresa 0 si el valor es menor que el límite inferior y el tamaño del arreglo si es mayor. Entonces las líneas 4 y 5 se encargan de arreglar estas dos características. Finalmente se cuenta el número de elementos que pertenecen a cada bin con la ayuda de la clase `Counter`.

```
m = 100
limits = np.linspace(D.min(), D.max(), m + 1)
_ = np.searchsorted(limits, D, side='right')
_[_ == 0] = 1
_[_ == m + 1] = m
p_j = Counter(_)
```

Realizando el procedimiento anterior se obtiene el histograma presentado en la Figura 7.1

Uniendo estos elementos se puede definir una función de riesgo de la siguiente manera

```
def riesgo(D, m=10):
    """Riesgo de validación cruzada de histograma"""
    N = D.shape[0]
    limits = np.linspace(D.min(), D.max(), m + 1)
    h = limits[1] - limits[0]
    _ = np.searchsorted(limits, D, side='right')
    _[_ == 0] = 1
    _[_ == m + 1] = m
```

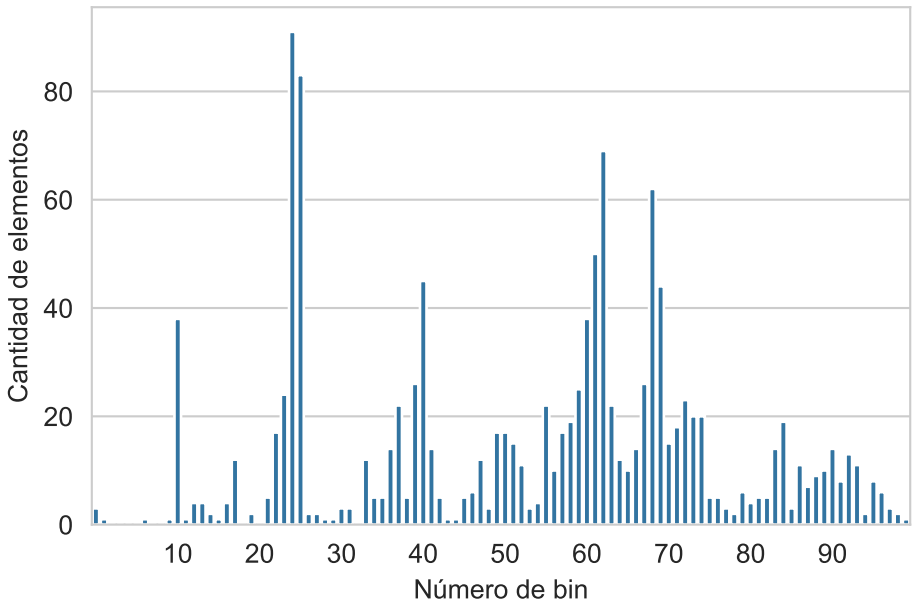


Figura 7.1: Histograma

```
    p_j = Counter(_)
    cuadrado = sum([(x / N)**2 for x in p_j.values()])
    return (2 / ((N - 1) * h)) - ((N + 1) * cuadrado / ((N - 1) * h))
```

donde las partes que no han sido descritas solamente implementan la ecuación $\hat{J}(h)$.

Finalmente se busca el valor h que minimiza la ecuación, iterando por diferentes valores de m se obtiene la Figura 7.2 donde se observa la variación del riesgo con diferentes niveles de bin.

7.4. Estimador de Densidad por Kernel

Como se puede observar el histograma es un estimador discreto, otro estimador muy utilizado que cuenta con la característica de ser suave es el estimador de densidad por kernel, K, el cual está definido de la siguiente manera.

$$\hat{f}(x) = \frac{1}{hN} \sum_{w \in \mathcal{D}} K(\frac{x - w}{h}),$$

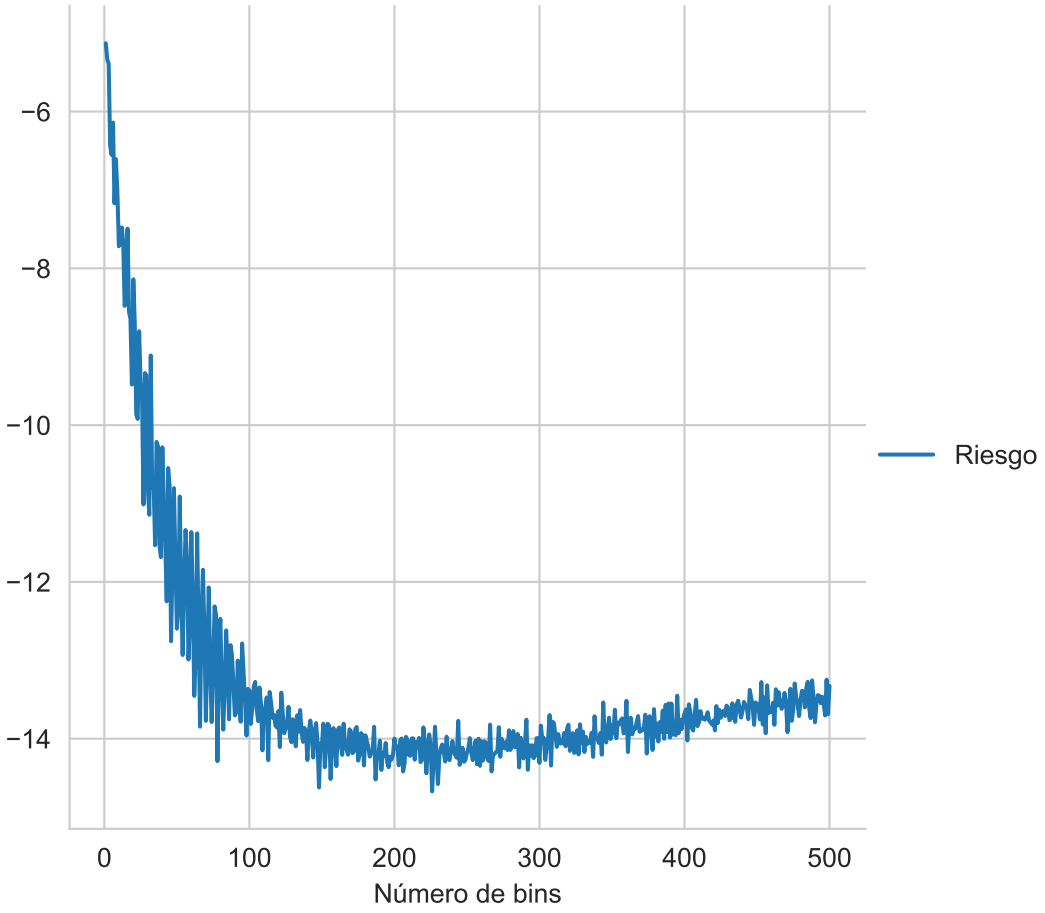


Figura 7.2: Riesgo

donde el kernel K podría ser $K(x) = \frac{1}{\sqrt{2\pi}} \exp[-\frac{x^2}{2}]$, con parámetros $\mu = 0$ y $\sigma = 1$. La Figura 7.3 muestra la estimación obtenida, con $h = 0.003$, en los datos utilizados en el ejemplo del histograma.

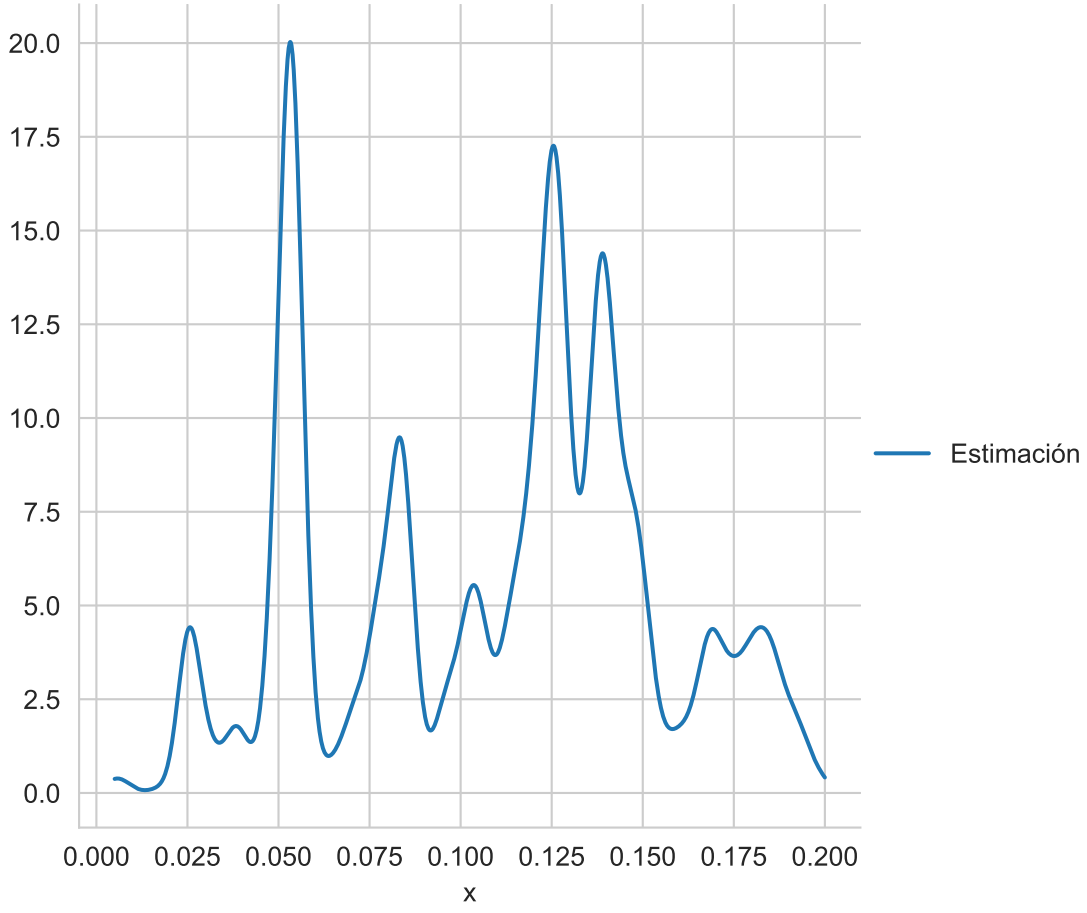


Figura 7.3: Estimación por Kernel

7.4.1. Caso multidimensional

Para el caso multidimensional el estimador quedaría como

$$\hat{f}(\mathbf{x}) = \frac{1}{h^d N} \sum_{\mathbf{w} \in \mathcal{D}} K(\frac{\mathbf{x} - \mathbf{w}}{h}),$$

donde d corresponde al número de dimensiones. Un kernel utilizado es:

$$K(\mathbf{x}) = (\frac{1}{\sqrt{2\pi}})^d \exp[-\frac{|| \mathbf{x} ||^2}{2}].$$

7.5. Estimador de Densidad por Vecinos Cercanos

Dado un conjunto $\mathcal{D} = (x_1, \ldots, x_N)$, es decir, donde se conoce la posición de x en $\mathcal{D}$ y una medida de distancia d, los k vecinos cercanos a x, $\mathsf{kNN}(x)$, se puede calcular ordenando $\mathcal{D}$ de la siguiente manera. Sea $(\pi_1, \pi_2, \ldots, \pi_N)$ la permutación tal que $x_{\pi_1} = \mathsf{arg\ min}_{w \in \mathcal{D}} d(x, w)$, donde $w_{\pi_1} \in \mathcal{D}$, π_2 corresponde al segundo índice menor, y así sucesivamente. Usando esta notación los k vecinos corresponden a $\mathsf{kNN}(x) = (x_{\pi_1}, x_{\pi_2}, \ldots, x_{\pi_k})$.

Una manera intuitiva de definir h sería en lugar de pensar en un valor constante para toda la función, utilizar la distancia que existe con el k vecino más cercano, es decir, $h = d(w_{\pi_k}, x) = d_k(x)$, donde $w_{\pi_k} \in \mathcal{D}$. Remplazando esto en el estimado de densidad por kernel se obtiene:

$$\hat{f}(x) = \frac{1}{d_k(x) N} \sum_{w \in \mathcal{D}} K(\frac{x - w}{d_k(x)}).$$

Utilizando los datos anteriores el estimador por vecinos cercanos, con $k = 50$, quedaría como:

7.6. Clasificador de vecinos cercanos

El clasificador de vecinos cercanos (Fix y Hodges (1951)) es un clasificador simple de entender, la idea es utilizar el conjunto de entrenamiento y una función de distancia para asignar la clase de acuerdo a los k-vecinos más cercanos al objeto deseado.

Utilizando la notación $kNN(x)$ se define el volumen de $kNN(x)$ como $V(x)$ y $N_c(x) = \sum_{x_\pi \in \mathsf{kNN}(x)} 1(y_\pi = c)$ donde y_π es la salida asociada a x_π. $N_c(x)$ corresponde al número de vecinos de x que pertenecen a la clase c. Con esta notación se define la verosimilitud como:

$$\mathbb{P}(\mathcal{X} = x \mid \mathcal{Y} = c) = \frac{N_c(x)}{N_c V(x)},$$

donde N_c es el número de elementos en $\mathcal{D}$ de la clase c.

Utilizando el Teorema de Bayes y sabiendo que $\mathcal{P}(Y = c) = \frac{N_c}{N}$ la probabilidad a posteriori queda como:

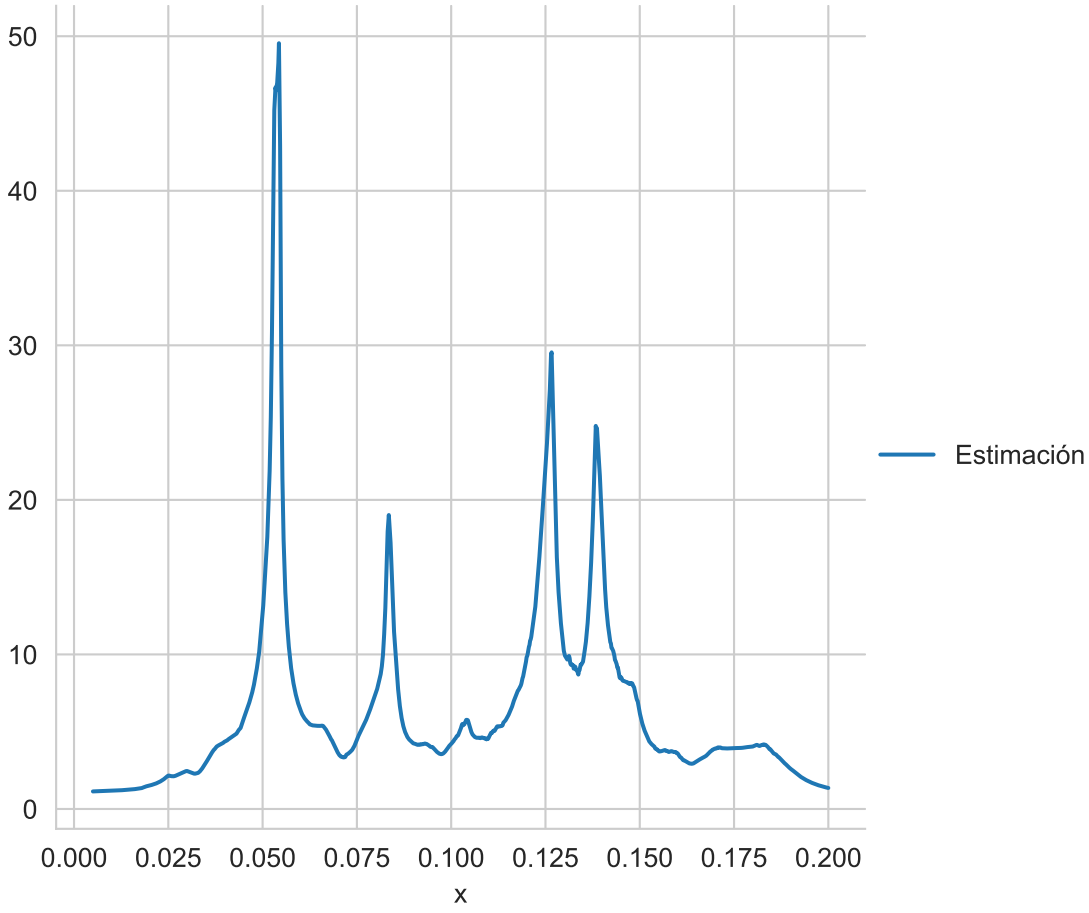


Figura 7.4: Estimación por Vecinos Cercanos

$$\begin{aligned}\mathcal{P}(\mathcal{Y} = c \mid \mathcal{X} = x) &= \frac{\frac{N_c(x)}{N_c V(x)} \frac{N_c}{N}}{\sum_u \frac{N_u(x)}{N_u V(x)} \frac{N_u}{N}} \\ &= \frac{N_c(x)}{\sum_u N_u(x)} \\ &= \frac{N_c(x)}{k},\end{aligned}$$

donde $\sum_u N_u(x) = k$ porque $N_u(x)$ corresponde al número de elementos de $\mathsf{kNN}(x)$ que pertenecen a la clase u y en total se seleccionan k elementos.

7.6.1. Implementación

El clasificador de vecinos cercanos tiene una implementación directa, aunque ineficiente, cuando el número de ejemplos en el conjunto de entrenamiento es grande. Esta implementación se ejemplifica con los datos de dígitos que se cargan y se dividen en el conjunto de entrenamiento y prueba de la siguiente manera.

```
X, y = load_digits(return_X_y=True)
T, G, y_t, y_g = train_test_split(X, y, test_size=0.2)
```

7.6.1.1. kNN

Lo primero que se realiza es la función para calcular los $\mathsf{kNN}(x)$ esto se puede hacer generando una función `kNN` que recibe de parámetros x, el conjunto $\mathcal{D}$, la cantidad de vecinos (k) y la distancia.

El código de la función `kNN` se muestra a continuación, donde en la primera línea se convierte a x en un arreglo de dos dimensiones. Esto tiene el objetivo de generar un código que pueda buscar los k vecinos cercanos de un conjunto de puntos. Por ejemplo, se podría calcular los vecinos cercanos de todo el conjunto $\mathcal{G}$.

La segunda línea calcula los vecinos cercanos usando la función `argsort` lo único que se tiene que conocer es el eje donde se va a realizar la operación que en este caso es el 0. La transpuesta es para regresar el índice de los vecinos en cada renglón.

```
def kNN(x, D, k=1, d=lambda x, y: pairwise_distances(x, y)):
    x = np.atleast_2d(x)
    return (d(D, x).argsort(axis=0))[:k].T
```

En este momento es importante mencionar que el problema de los k vecinos cercanos tiene muchas aplicaciones además de los algoritmos de aprendizaje supervisado que se verán en esta unidad. Por ejemplo, cuando uno tiene una colección de objetos que podrían ser documentos, videos, fotografías o cualquier objeto, este problema permite encontrar los objetos más cercanos a un objeto dado. Lo que se desea es que el algoritmo regrese el resultado lo antes posible y por ese motivo no se puede utilizar el algoritmo que se acaba de mencionar dado que compara x contra todos los elementos de $\mathcal{D}$. El área que estudia este tipo de problemas es el área de Recuperación de Información.

Por ejemplo, el siguiente código calcula los cinco vecinos más cercanos de los tres primeros elementos de $\mathcal{G}$.

```
kNN(G[:3], T, k=5)
```

```
array([[1296,  331, 1392,  944,  632],
       [1162, 1301, 1207,  282,  429],
       [  43,  859, 1378,  727,  648]])
```

La manera más sencilla de crear el clasificador de vecinos cercanos es utilizando un método exhaustivo en el cálculo de distancia. Como se comentó, existen métodos más eficientes y la clase `NearestNeighbors` implementa dos de ellos adicionales al método exhaustivo. Por ejemplo, el siguiente código realiza el procedimiento equivalente al ejemplo visto previamente.

```
knn = NearestNeighbors(n_neighbors=5).fit(T)
knn.kneighbors(G[:3], return_distance=False)
```

```
array([[1296,  331, 1392,  944,  632],
       [1162, 1301, 1207,  282,  429],
       [  43,  859, 1378,  727,  648]])
```

7.6.1.2. $N_c(x)$

El clasificador se basa en la función $N_c(x)$, esta función se implementa conociendo las etiquetas y $\mathsf{kNN}(x)$. Aunque $N_c(x)$ requiere el parámetro de la clase, la función calculará $N_c(x)$ para todas las clases. La función `N_c` recibe de parámetros todos los parámetros de `kNN` y además requiere las clases de cada elemento de $\mathcal{D}$ estas clases se dan como un arreglo adicional. El siguiente código muestra la función, donde en la primera línea se calcula los k vecinos y después se transforman los índices a las clases correspondientes, el resultado es guardado en la variable `knn`. La segunda línea usa la clase `Counter` para contar la frecuencia de cada clase en cada ejemplo dado en `x`.

```
def N_c(x, D, clases, k=1,
        d=lambda x, y: pairwise_distances(x, y)):
    knn = clases[kNN(x, D, k=k, d=d)]
    return [Counter(x) for x in knn]
```

Por ejemplo, la siguiente instrucción calcula $N_c(x)$ para todos los datos en $\mathcal{G}$ usando $k = 5$.

```
nc = N_c(G, T, y_t, k=5)
```

El elemento en el índice 100, tiene el siguiente resultado Counter({np.int64(6): 5}), que indica que la clase 6, fue vista 5. El error de este algoritmo en el conjunto de prueba es 0.0250, calculado con las siguientes instrucciones. Se observa que la primera línea genera las predicciones usando la función `most_common` y a continuación se calcula el error.

```
hy = np.array([x.most_common(n=1)[0][0] for x in nc])
error = (y_g != hy).mean()
```

> **Nota**
>
> La información dada hasta el momento tiene la finalidad de explicar el funcionamiento del algoritmo, una implementación del clasificador de vecinos cercanos usando métodos eficientes para calcular kNN se encuentra en la clase `KNeighborsClassifier` la cual se puede utilizar de la siguiente manera.
>
> ```
> kcl = KNeighborsClassifier().fit(T, y_t)
> hy = kcl.predict(G)
> ```

7.7. Regresión

La idea de utilizar vecinos cercanos no es solamente para problemas de clasificación, en problemas de regresión se puede seguir un razonamiento equivalente, el único cambio es en la función $N_c(x)$ donde en lugar de calcular la frecuencia de las clases de los vecinos cercanos a x se hace un promedio (pesado) de la respuesta de cada uno de los vecinos cercanos.

Para ilustrar esta adecuación en problemas de regresión se utiliza el conjunto de datos de diabetes, estos datos y los conjuntos se obtienen con las siguientes instrucciones.

```
X, y = load_diabetes(return_X_y=True)
T, G, y_t, y_g = train_test_split(X, y, test_size=0.2)
```

Se puede observar en la función `regresion` que la diferencia con clasificación es que se calcula el promedio, en lugar de contar la frecuencia de las clases.

```
def regresion(x, D, respuesta, k=1,
              d=lambda x, y: pairwise_distances(x, y)):
    knn = respuesta[kNN(x, D, k=k, d=d)]
    return knn.mean(axis=1)
```

La media del error absoluto en el conjunto $\mathcal{G}$ es 45.7933 calculado con las siguientes instrucciones.

```
hy = regresion(G, T, y_t, k=5)
error = np.fabs(y_g - hy).mean()
```

La clase equivalente a `KNeighborsClassifier` para regresión es `KNeighborsRegressor` la cual se puede utilizar así.

```
krg = KNeighborsRegressor().fit(T, y_t)
hy = krg.predict(G)
```

7.8. Resumen

Los métodos no paramétricos cambian el supuesto sobre la forma de la distribución por el supuesto de que los datos parecidos se comportan de manera parecida. La densidad se puede estimar con histogramas (Sección 7.3), con kernels (Figura 7.3) o con vecinos cercanos (Figura 7.4), y los mismos vecinos sirven para clasificar y para hacer regresión (Sección 7.7). A cambio de no suponer una forma, estos métodos conservan los datos de entrenamiento y los consultan en cada predicción. Además, su comportamiento depende de hiperparámetros como el tamaño del bin o el número de vecinos, que deben ajustarse con datos de validación, y de que haya suficientes datos cercanos, algo que es más difícil conforme crece el número de variables.

Para la política pública la idea de decidir según los casos parecidos es intuitiva y fácil de explicar, y puede servir como comparación para un método más estructurado. Su costo es que requiere bases de datos suficientemente grandes y que la decisión sobre un caso depende de qué casos se tengan registrados.

Una alternativa a guardar todos los datos es modelar directamente la frontera que separa a las clases. Los discriminantes lineales, que hacen justamente eso, se presentan en Capítulo 8.

8 Discriminantes Lineales

El **objetivo** de la unidad es conocer y aplicar diferentes métodos lineales de discriminación para atacar problemas de clasificación.

8.1. Paquetes usados

```
from sklearn.svm import LinearSVC, SVC, LinearSVR
from sklearn.linear_model import LogisticRegression
from sklearn.decomposition import PCA
from sklearn.model_selection import train_test_split
from sklearn.metrics import r2_score
from sklearn.pipeline import make_pipeline
from scipy.stats import multivariate_normal
from sklearn.preprocessing import Normalizer
from sklearn.datasets import load_iris, load_diabetes, load_digits
from CompStats.metrics import recall_score, f1_score, precision_score
from matplotlib import pylab as plt
import numpy as np
import cvxpy as cp
import pandas as pd
import seaborn as sns
```

8.2. Introducción

En unidades anteriores se han visto diferentes técnicas para discriminar entre clases; en particular se ha descrito el uso de la probabilidad $\mathbb{P}(\mathcal{Y} \mid \mathcal{X})$ para encontrar la clase más probable. Los parámetros de $\mathbb{P}(\mathcal{Y} \mid \mathcal{X})$ se han estimado utilizando métodos paramétricos y no paramétricos. En esta unidad se describe el uso de funciones discriminantes para la clasificación y su similitud con el uso de $\mathbb{P}(\mathcal{Y} \mid \mathcal{X})$.

8.3. Función Discriminante

En la unidad de Teoría de Decisión Bayesiana (Capítulo 5) se describió el uso de $\mathbb{P}(\mathcal{Y} \mid \mathcal{X})$ para clasificar, se mencionó que la clase a la que pertenece $\mathcal{X} = x$ es la de mayor probabilidad, es decir,

$$C(x) = \mathsf{argmax}_{k=1}^{K} \mathbb{P}(\mathcal{Y} = k \mid \mathcal{X} = x),$$

donde K es el número de clases y $\mathcal{Y} = k$ representa la k-ésima clase. Considerando que la evidencia es un factor que normaliza, entonces, $C(x)$ se puede definir de la siguiente manera.

$$C(x) = \mathsf{argmax}_{k=1}^{K} \mathbb{P}(\mathcal{X} = x \mid \mathcal{Y} = k)\mathbb{P}(\mathcal{Y} = k).$$

Agrupando la probabilidad a priori y verosimilitud en una función g_k, es decir, $g_k(x) = P(\mathcal{X} = x \mid \mathcal{Y} = k)\mathbb{P}(\mathcal{Y} = k)$, hace que $C(x)$ sea:

$$C(x) = \mathsf{argmax}_{k=1}^{K} g_k(x).$$

Observando $C(x)$ y olvidando los pasos utilizados para derivarla, uno se puede imaginar que lo único necesario para generar un clasificador de K clases es definir un conjunto de funciones g_k que separen las clases correctamente. En esta unidad se presentan diferentes maneras para definir g_k con la característica de que todas ellas son lineales, e.g., $g_k(\mathbf{x}) = \mathbf{w}_k \cdot \mathbf{x} + w_{k_0}$.

8.3.1. Clasificación Binaria

La descripción de discriminantes lineales empieza con el caso particular de dos clases, i.e., $K = 2$. En este caso $C(\mathbf{x})$ es encontrar el máximo de las dos funciones g_1 y g_2. Una manera equivalente sería definir a $C(\mathbf{x})$ como

$$C(\mathbf{x}) = \mathsf{sign}(g_1(\mathbf{x}) - g_2(\mathbf{x})),$$

donde sign es la función que regresa el signo, entonces solo queda asociar el signo positivo a la clase 1 y el negativo a la clase 2. Utilizando esta definición se observa lo siguiente

$$\begin{aligned} g_1(\mathbf{x}) - g_2(\mathbf{x}) &= (\mathbf{w}_1 \cdot \mathbf{x} + w_{1_0}) - (\mathbf{w}_2 \cdot \mathbf{x} + w_{2_0}) \\ &= (\mathbf{w}_1 + \mathbf{w}_2) \cdot \mathbf{x} + (w_{1_0} - w_{2_0}) \quad , \\ &= \mathbf{w} \cdot \mathbf{x} + w_0 \end{aligned}$$

donde se concluye que para el caso binario es necesario definir solamente una función discriminante y que los parámetros de esta función son $\mathbf{w}$ y $\mathbf{w}_0$. Otra característica que se ilustra es que el parámetro $\mathbf{w}_0$ está actuando como un umbral, es decir, $\mathbf{x}$ corresponde a la clase positiva si $\mathbf{w} \cdot \mathbf{x} > -w_0$.

En la Figura 8.1 se observa el plano (línea) que divide las dos clases, este plano representa los puntos que satisfacen $g(\mathbf{x}) = 0$.

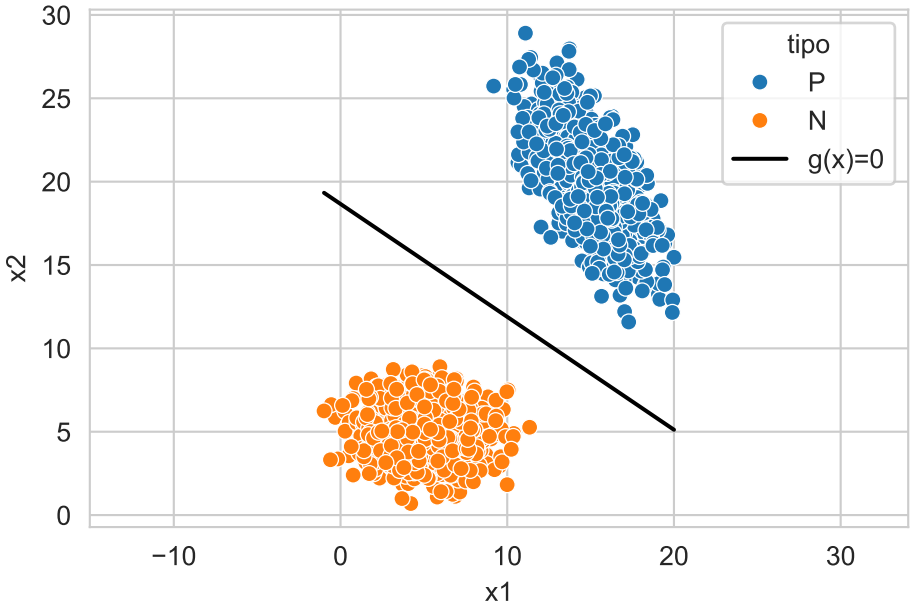


Figura 8.1: Función Discriminante

8.3.2. Geometría de la Función de Decisión

La función discriminante $g(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} + w_0$ tiene una representación gráfica. Lo primero que se observa es que los parámetros $\mathbf{w}$ viven en el mismo espacio que los datos, tal y como se puede observar en la Figura 8.2.

Siguiendo con la descripción, los parámetros $\mathbf{w}$ y la función $g(\mathbf{x})$ son ortogonales, tal y como se muestra en la Figura 8.3. Analíticamente la ortogonalidad se define de la siguiente manera. Sea $\mathbf{x}_a$ y $\mathbf{x}_b$ dos puntos en $g(\mathbf{x}) = 0$, es decir,

$$\begin{aligned} g(\mathbf{x}_a) &= g(\mathbf{x}_b) \\ \mathbf{w} \cdot \mathbf{x}_a + w_0 &= \mathbf{w} \cdot \mathbf{x}_b + w_0 \\ \mathbf{w} \cdot (\mathbf{x}_a - \mathbf{x}_b) &= 0, \end{aligned}$$

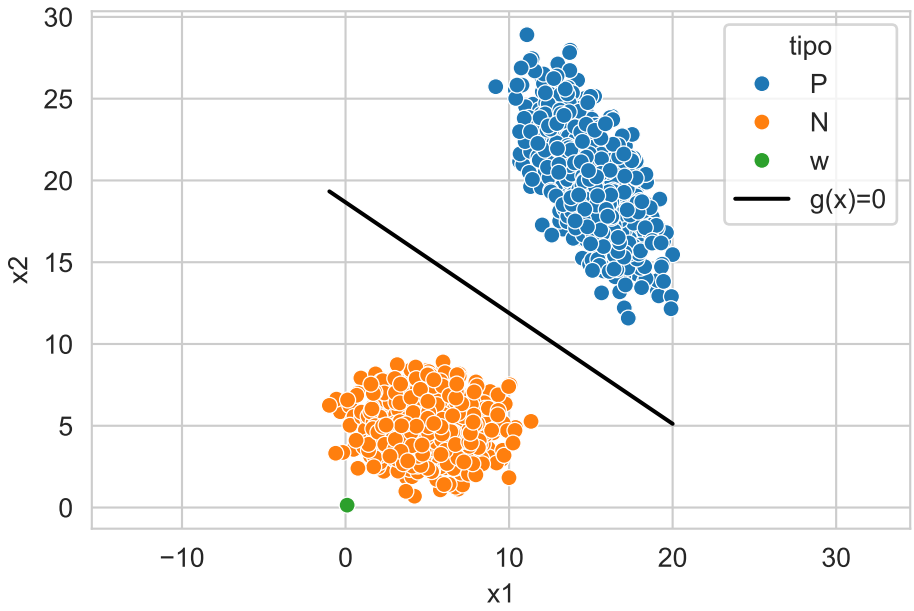


Figura 8.2: Función discriminante

donde el vector $\mathbf{x}_a - \mathbf{x}_b$ es paralelo a $g(\mathbf{x}) = 0$, ortogonal a $\mathbf{w}$ y el sub-espacio generado por $\mathbf{w} \cdot (\mathbf{x}_a - \mathbf{x}_b) = 0$ pasa por el origen.

En la figura anterior, $\ell\mathbf{w}$ corresponde al vector $\mathbf{w}$ multiplicado por un factor ℓ de tal manera que intersecte con $g(\mathbf{x}) = 0$. El factor ℓ corresponde a la distancia que hay del origen a $g(\mathbf{x}) = 0$ la cual es $\ell = \frac{w_0}{||\mathbf{w}||}$. El signo de ℓ indica el lado donde se encuentra el origen con respecto a $g(\mathbf{x}) = 0$.

La Figura 8.4 muestra en rojo la línea generada por $\mathbf{w} \cdot \mathbf{x} = 0$, la función discriminante $g(\mathbf{x}) = 0$ (negro), la línea puntuada muestra la distancia entre ellas, que corresponde a ℓ y el vector $\mathbf{w}$. Visualmente, se observa que $\mathbf{w}$ está pegado a la línea roja, pero esto solo es un efecto de la resolución y estos elementos no se tocan.

Finalmente, será de utilidad representar a cada punto en $\mathcal{D}$ de la siguiente manera

$$\mathbf{x} = \mathbf{x}_g + \ell \frac{\mathbf{w}}{|| \mathbf{w} ||},$$

donde $\mathbf{x}_g$ corresponde a la proyección en el hiperplano ($g(\mathbf{x}) = 0$) de $\mathbf{x}$ y ℓ es la distancia que hay del hiperplano a $\mathbf{x}$. Utilizando esta representación se puede derivar la distancia ℓ de $\mathbf{x}$ con el siguiente procedimiento.

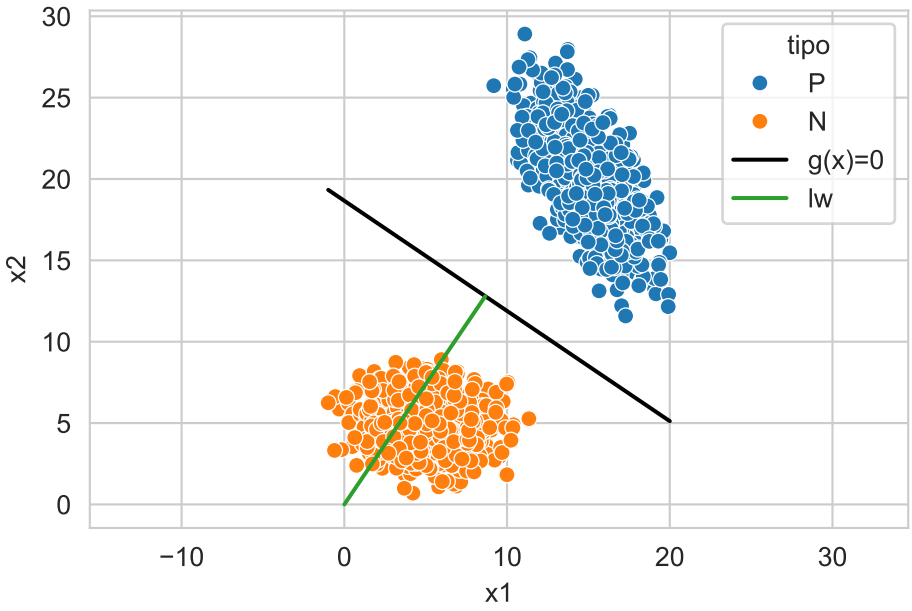


Figura 8.3: Visualizando que **w** y la función discriminante son ortogonales.

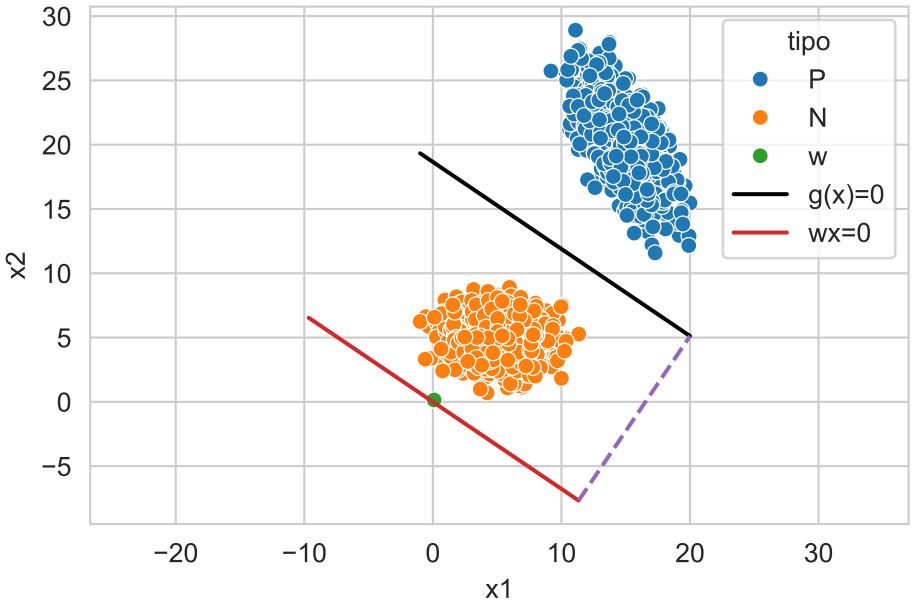


Figura 8.4: Geometría de la función discriminante.

$$
\begin{aligned}
g(\mathbf{x}) &= g(\mathbf{x}_g + \ell \frac{\mathbf{w}}{||\ \mathbf{w}\ ||}) \\
&= \mathbf{w} \cdot (\mathbf{x}_g + \ell \frac{\mathbf{w}}{||\ \mathbf{w}\ ||}) + w_0 \\
&= \mathbf{w} \cdot (\mathbf{x}_g + \ell \frac{\mathbf{w}}{||\ \mathbf{w}\ ||}) \\
&= \mathbf{w} \cdot \mathbf{x}_g + \ell \mathbf{w} \cdot \frac{\mathbf{w}}{||\ \mathbf{w}\ ||} \\
&= \ell \mathbf{w} \cdot \frac{\mathbf{w}}{||\ \mathbf{w}\ ||} \\
&= \ell\ ||\ \mathbf{w}\ || \\
\ell &= \frac{g(\mathbf{x})}{||\ \mathbf{w}\ ||}
\end{aligned}
\tag{8.1}
$$

Como ya se había visto la distancia del origen al hiperplano está dada por $\ell_0 = \frac{w_0}{||\mathbf{w}||}$ y de cualquier elemento por $\ell_{\mathbf{x}} = \frac{g(\mathbf{x})}{||\mathbf{w}||}$. La Figura 8.5 muestra la $\ell_{\mathbf{x}}$ en un elemento de la clase negativa. Se puede observar el punto $\mathbf{x}_g$ que es donde intersecta la línea con el hiperplano.

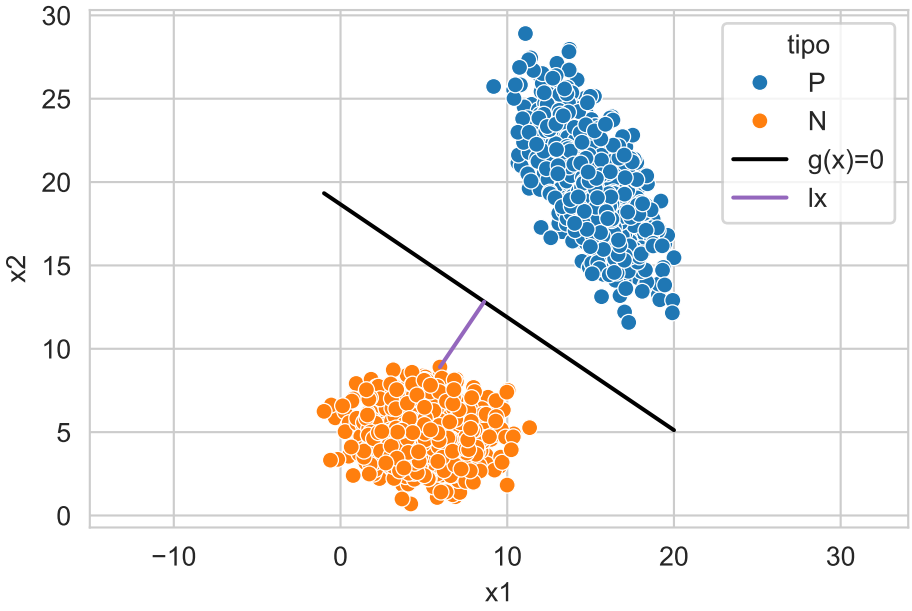


Figura 8.5: Distancia ($\ell_{\mathbf{x}} = x$) de un elemento al hiperplano

Considerando que el problema mostrado en la figura anterior está en $\mathbb{R}^2$, entonces $\mathbf{x}_g$ está dado por

$$\mathbf{x}_g = \frac{\mathbf{x} \cdot \mathbf{x}_0}{\mathbf{x}_0 \cdot \mathbf{x}_0}\mathbf{x}_0 - \ell_0 \frac{\mathbf{w}}{|| \mathbf{w} ||},$$

donde ℓ_0 es la distancia del origen al hiperplano y $\mathbf{x}_0$ es cualquier vector que está en $\mathbf{x}_0 \cdot \mathbf{w} = 0$. Para dimensiones mayores el término $\frac{\mathbf{x} \cdot \mathbf{x}_0}{\mathbf{x}_0 \cdot \mathbf{x}_0}$ es la proyección al hiperplano A tal que $A\mathbf{w} = 0$.

8.3.3. Múltiples Clases

Una manera de tratar un problema de K clases, es convertirlo en K problemas de clasificación binarios, a este procedimiento se le conoce como *Uno vs Resto*. La idea es entrenar K clasificadores donde la clase positiva corresponde a cada una de las clases y la clase negativa se construye con todas las clases que no son la clase positiva en esa iteración. Finalmente, la clase predicha corresponde al clasificador que tiene el valor máximo en la función discriminante.

La Figura 8.6 ejemplifica el comportamiento de esta técnica en un problema de tres clases y utilizando un clasificador con discriminante lineal. En la figura se muestra las tres funciones discriminantes $g_k(\mathbf{x}) = 0$, los parámetros escalados de esas funciones, i.e., $\ell_k \mathbf{w}_k$ y los datos. Por ejemplo se observa cómo la clase 1 mostrada en azul, se separa de las otras dos clases con la función $g_1(\mathbf{x}) = 0$, es decir, para $g_1(\mathbf{x}) = 0$ la clase positiva es 1 y la clase negativa corresponde a los elementos que corresponden a las clases 2 y 3.

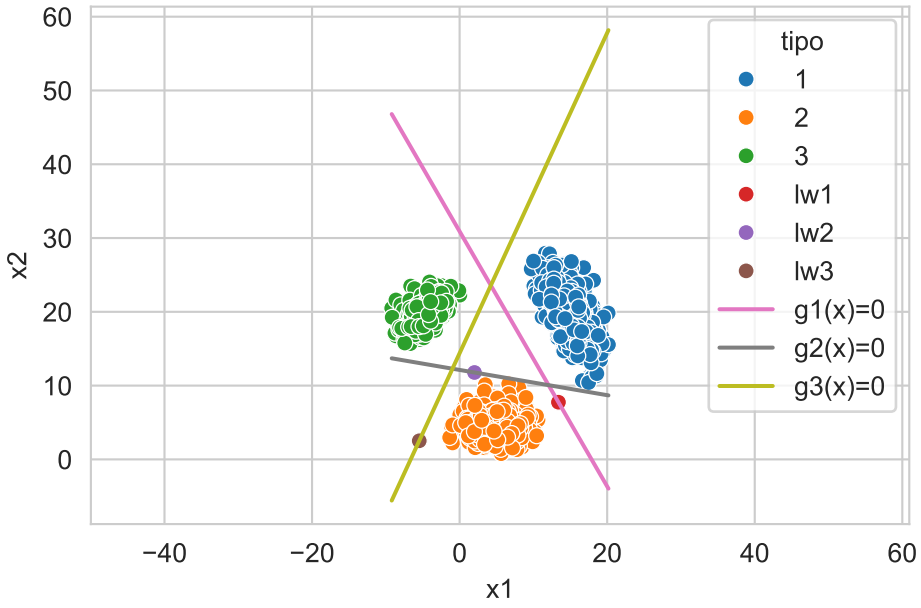


Figura 8.6: Problema multiclase

8.4. Máquinas de Soporte Vectorial

Es momento de describir algunos algoritmos para estimar los parámetros $\mathbf{w}$, y w_0 empezando por las Máquinas de Soporte Vectorial (MSV) propuestas por Cortes y Vapnik (1995). En este clasificador se asume un problema binario y las clases están representadas por -1 y 1, es decir, $y \in \{-1, 1\}$. Entonces, las máquinas de soporte vectorial tratan de encontrar una función con las siguientes características.

Sea $\mathbf{x}_i$ un ejemplo que corresponde a la clase 1 entonces se busca $\mathbf{w}$ tal que

$$\mathbf{w} \cdot \mathbf{x}_i + w_0 \geq +1.$$

En el caso contrario, es decir, $\mathbf{x}_i$ un ejemplo de la clase -1, entonces

$$\mathbf{w} \cdot \mathbf{x}_i + w_0 \leq -1.$$

Estas ecuaciones se pueden escribir como

$$(\mathbf{w} \cdot \mathbf{x}_i + w_0) y_i \geq +1,$$

donde $(\mathbf{x}_i, y_i) \in \mathcal{D}$.

La función discriminante es $g(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} + w_0$ y la distancia (Ecuación 8.1) que existe entre cualquier punto $\mathbf{x}_i$ al discriminante está dada por

$$\frac{g(\mathbf{x}_i)}{|| \mathbf{w} ||} y_i.$$

Entonces, se puede ver que lo que se busca es encontrar $\mathbf{w}$ de tal manera que cualquier punto $\mathbf{x}_i$ esté lo más alejada posible del discriminante, esto se logra minimizando $\mathbf{w}$, es decir, resolviendo el siguiente problema de optimización:

$$\begin{aligned} &\text{mín} \frac{1}{2} || \mathbf{w} || \\ &\text{sujeto a} \\ &\qquad (\mathbf{w} \cdot \mathbf{x}_i + w_0) y_i \geq 1 \end{aligned} \tag{8.2}$$

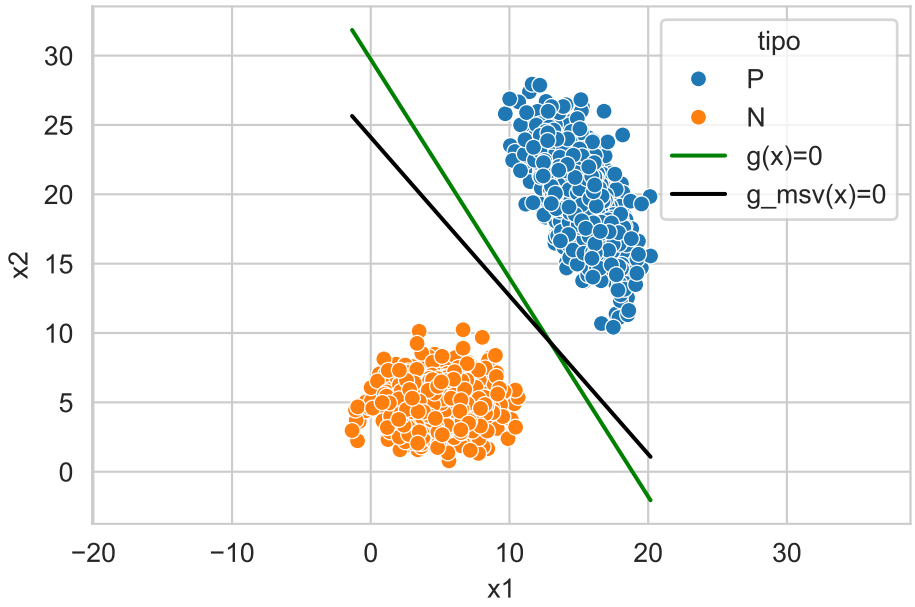
El problema de optimización de la Ecuación 8.2 tiene solución solamente que los ejemplos sean linealmente separables. El siguiente código muestra la codificación de la Ecuación 8.2 utilizando CVXPY (Diamond y Boyd (2016)). Las primeras dos líneas corresponden a los datos

de clasificación, `X` tiene las variables independientes y `y` corresponde a la clase. Las variables del problema de optimización están en `w` y `w0`; las restricciones están codificadas en la variable `constraints`y la función objetivo en la variable `obj`. La penúltima línea genera el problema de optimización y se resuelve en la última instrucción.

```
X = np.concatenate((X_1, X_2))
y = np.array([1] * X_1.shape[0] + [-1] * X_2.shape[0])
w = cp.Variable(X.shape[1])
w0 = cp.Variable()
constraints = [cp.multiply(X @ w + w0, y) >= 1]
obj = cp.norm(w) / 2
prob = cp.Problem(cp.Minimize(obj), constraints=constraints)
_ = prob.solve()
```

Actividad

Graficar la función de decisión encontrada al optimizar la Ecuación 8.2. La función de decisión se observa en color verde con la leyenda $g(x)$; además se incluye la función encontrada por una MSV lineal identificada con la leyenda g_{msv}. Modificar el parámetro `C` (utilizar un número cercano a cero y un número considerablemente grande e.g. 1^{10}) de la clase `LinearSVC` y graficar nuevamente las funciones de decisión para tener una intuición de lo que está haciendo ese parámetro.



El problema de clasificación anterior se puede modificar para generar un problema que no sea linealmente separable, una manera es cambiar un ejemplo de clase tal y como se muestra en la

siguiente instrucción.

```
y[-1] = 1
```

Con la modificación anterior el problema de optimización se vuelve infactible tal y como se puede observar al ejecutar el siguiente código,

donde el atributo `prob.status` regresa el valor de infeasible.

Para que este problema tenga una solución factible es necesario relajar las restricciones permitiendo que algunas de las restricciones no se cumplan, esto se realiza utilizando una variable ξ_i la cual sea no negativa (i.e., $\xi_i \geq 0$), de tal manera que si todas las restricciones se cumplen se llega a la Ecuación 8.2. Adicionalmente, se requiere incluir el peso de las restricciones que no se han cumplido, esto se hace incorporando $\sum_i \xi$ y pesando el término por un parámetro $C > 0$. El resultado final se observa en la Ecuación 8.3, donde se utiliza $\mathbf{w} \cdot \mathbf{w}$, en lugar de $|| \mathbf{w} ||$ para seguir la formulación propuesta en Cortes y Vapnik (1995).

$$\begin{aligned} &\text{mín} \frac{1}{2}\mathbf{w} \cdot \mathbf{w} + C \sum_i \xi_i \\ &\text{sujeto a} \\ &\qquad (\mathbf{w} \cdot \mathbf{x}_i + w_0) y_i \geq 1 - \xi_i \\ &\qquad \xi_i \geq 0 \end{aligned} \tag{8.3}$$

La Ecuación 8.3 se codifica utilizando las siguientes instrucciones. El producto punto $\mathbf{w} \cdot \mathbf{w}$ se codifica utilizando la función `cp.quad_over_lin`, se observa que la variable ξ_i está en el arreglo `xi`, que el parámetro C está en una variable con el mismo nombre y que se le asigna el valor de 1.

al ejecutar el código anterior se obtiene en el atributo `prob.status` el valor de optimal.

El hiperplano que se encuentra en `w` se codifica como

$$\mathbf{w} = \sum_i \alpha_i y_i \mathbf{x}_i, \tag{8.4}$$

donde α_i son los valores de las variables duales de las restricciones. Para comprobar la Ecuación 8.4, el siguiente código muestra en la variable `alpha` los valores de las variables duales y la variable `w_codificado` tiene el valor del hiperplano, lo cual se puede comparar con el valor que está en el atributo `w.value`.

```
alpha = constraints[0].dual_value
w_codificado = (np.c_[alpha * y] * X).sum(axis=0)
```

Actividad

Comparar los valores estimados para $\mathbf{w}$ y w_0 cuando el problema es linealmente separable y cuando fue modificado con el cambio `y[-1]=1`.

La Figura 8.7 muestra un ejemplo donde existe un elemento negativo que se encuentra entre la función de decisión y el hiperplano de margen, i.e., el que corresponde a la restricción $\mathbf{w} \cdot \mathbf{x}_i + w_0 \geq 1$, es decir ese punto tiene un $0 < \xi < 1$. También se observa un elemento positivo que está muy cerca a $g(\mathbf{x}) = 1$.

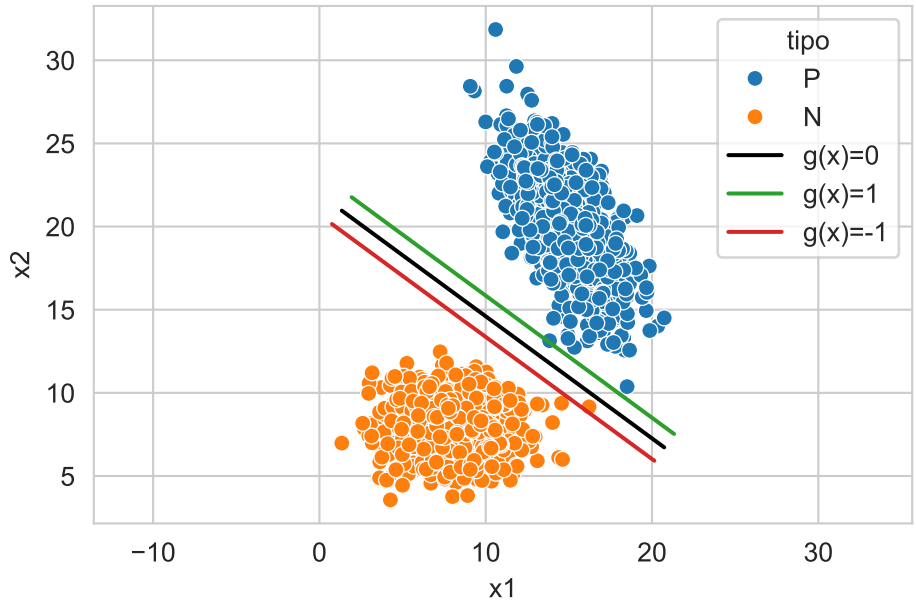


Figura 8.7: Hiperplanos

Continuando con el análisis del problema de optimización (Ecuación 8.3), se puede observar que el parámetro C controla la penalización que se hace a los elementos que se encuentran en el lado incorrecto del hiperplano o dentro del margen. La Figura 8.8 muestra el hiperplano generado utilizando $C = 1$ y $C = 0.01$, en la figura se aprecia cómo el elemento que está correctamente clasificado en $C = 1$ pasa al lado incorrecto del hiperplano, además la función de decisión rota cuando el valor de C cambia.

Continuando con el comportamiento de las MSV lineales, esta se encuentra implementada en la clase `LinearSVC` y su uso se ejemplifica utilizando el problema de dígitos (Sección B.2.2.3); los datos se obtienen y se parten en los conjuntos de entrenamiento y prueba utilizando las siguientes instrucciones.

El modelo se entrena siguiendo un procedimiento equivalente al de los otros modelos de clasificación vistos hasta ahora, tal y como se muestra a continuación.

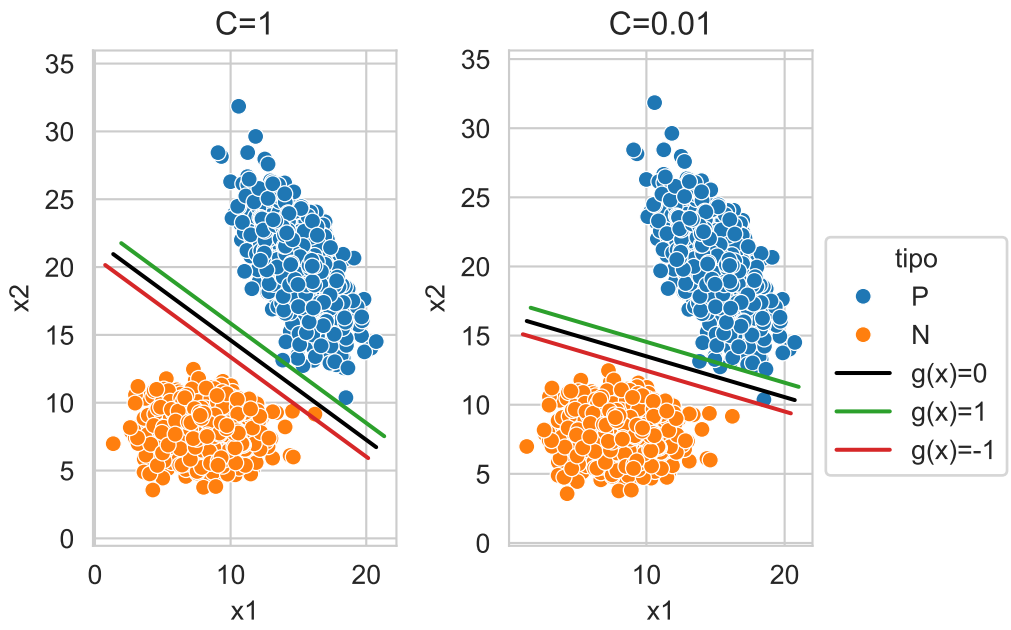


Figura 8.8: Hiperplanos para diferentes valores de C. Se observa que en $C = 0.01$ se clasifica incorrectamente un elemento positivo.

```
svm = LinearSVC().fit(Xtrain, ytrain)
svm_n = make_pipeline(Normalizer(),
                      LinearSVC()).fit(Xtrain,
                                       ytrain)
```

En algunas ocasiones el rendimiento de MSV mejora cuando las entradas están normalizadas a tener una longitud uno.

En algunas ocasiones, el rendimiento de las MSV mejora cuando las entradas están normalizadas a tener una longitud unitaria. El siguiente código muestra un flujo de trabajo donde el primer paso es normalizar las entradas para tener una longitud unitaria y, posteriormente, se entrena una MSV.

```
svm_n = make_pipeline(Normalizer(),
                      LinearSVC()).fit(Xtrain,
                                       ytrain)
```

La Figura 8.9 muestra el promedio de la cobertura (macro-recall, ver Capítulo 2) entre las MSV sin la normalización (MSV) y cuando las entradas están normalizadas (MSV (Norm.)). Se

observa que el mejor rendimiento corresponde a la MSV normalizada aunque es estadísticamente equivalente a la máquina con las entradas originales.

```
score = recall_score(ytest, average='macro',
                     use_tqdm=False)
score(svm.predict(Xtest), name='MSV')
score(svm_n.predict(Xtest), name='MSV (Norm.)')
score.plot(value_name='Cobertura (promedio)',
           alg_legend='Algoritmos',
           comp_legend='Comparación',
           winner_legend='Mejor',
           tie_legend='Equivalente',
           loser_legend='Diferente')
```

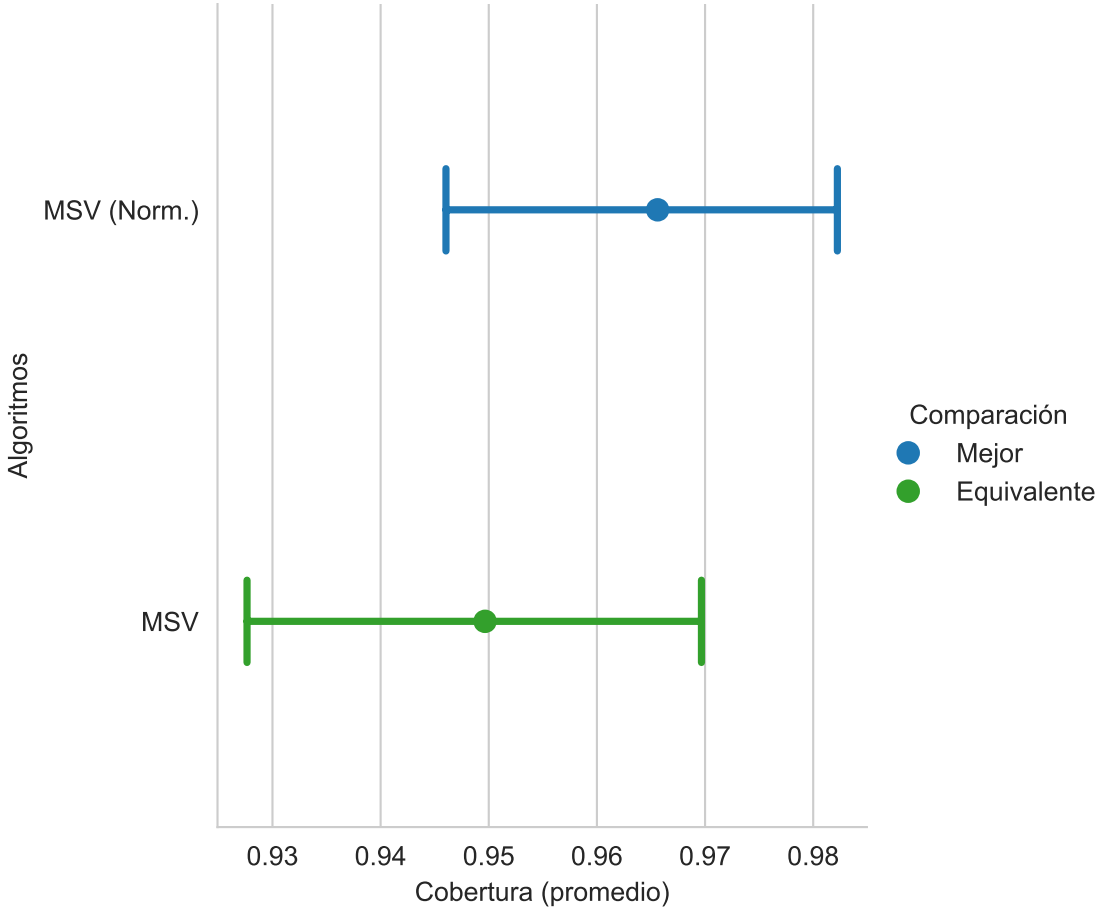


Figura 8.9: Comparación entre MSV con y sin normalización

8.4.1. Kernel

En lugar de utilizar directamente las características $\mathbf{x}$ se puede realizar una transformación ϕ a estas características, esto haría que el hiperplano (Ecuación 8.4) quede como $\mathbf{w} = \sum_i \alpha_i y_i \phi(\mathbf{x}_i)$, pasando esto a la función discriminante g queda como $g(\mathbf{x}) = \sum_i \alpha_i y_i \phi(\mathbf{x}_i) \cdot \phi(x) + w_0$. El producto punto se puede cambiar por una función **Kernel**, i.e., $K(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i) \cdot \phi(\mathbf{x}_j)$ lo cual hace que sea innecesaria la transformación al espacio ϕ.

La función discriminante está dada por $g(\mathbf{x}) = \sum_i^N \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}) + w_0$, donde aquellos elementos donde $\alpha_i > 0$ se les conoce como los vectores de soporte. Estos elementos son los que se encuentran en el margen, dentro del margen y en el lado incorrecto de la función discriminante.

La Figura 8.10 muestra los datos del iris (proyectados a dos dimensiones, para poder dibujarlos, con Análisis de Componentes Principales, técnica que se describirá en la Sección 13.2), las clases se encuentran en color azul, naranja y verde. En color rojo se muestran los vectores de soporte. La figura derecha muestra en color negro aquellos vectores de soporte que se encuentran en el lado incorrecto del hiperplano. Por otro lado se puede observar cómo los vectores de soporte separan las clases, del lado izquierdo se encuentran todos los elementos de la clase 0, después se observan las clases 1 y del lado derecho las clases 2. Los vectores de soporte están en la frontera de las clases y los errores se encuentran entre las clases 1 y 2 que corresponden a las que no son linealmente separables.

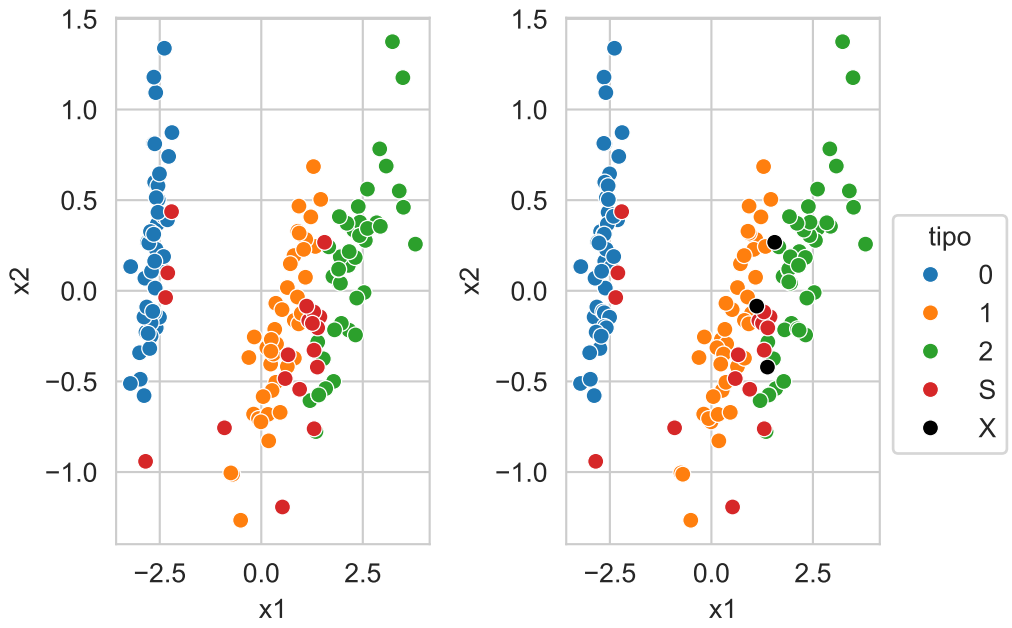


Figura 8.10: Visualización de los vectores de soporte usando PCA.

El uso de la MSV con un kernel polinomial de grado dos se ejemplifica en el siguiente código.

La Figura 8.11 muestra el rendimiento de las MSV lineal con entradas originales y normalizadas, y una MSV con un kernel estimado en el paso anterior; se observa que el kernel hace que el rendimiento sea estadísticamente superior a las MSV lineales.

```
score(svm_k.predict(Xtest), name='MSV (Kernel)')
score.plot(value_name='Cobertura (promedio)',
           alg_legend='Algoritmos',
           comp_legend='Comparación',
           winner_legend='Mejor',
           tie_legend='Equivalente',
           loser_legend='Diferente')
```

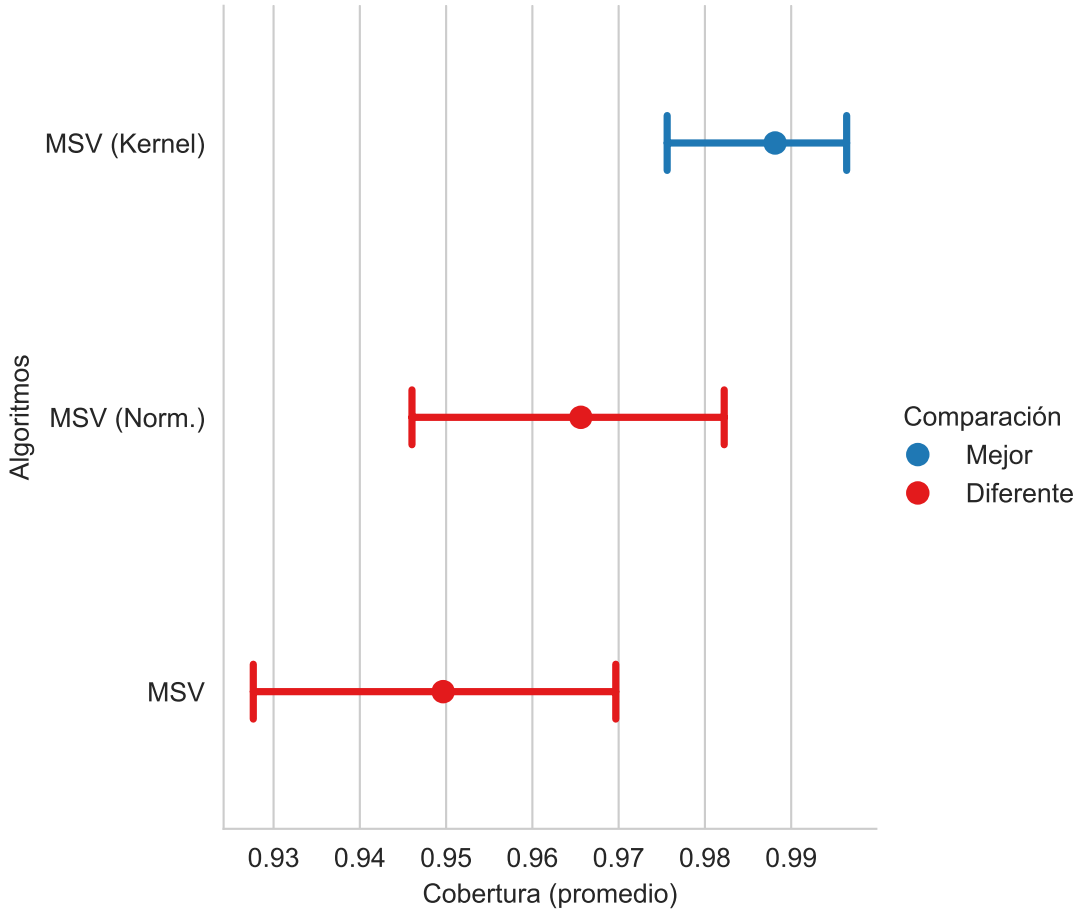


Figura 8.11: Comparación entre MSV lineales y con kernel polinomial de grado dos.

8.4.2. Regresión

Las máquinas de soporte vectorial también se pueden utilizar para resolver problemas de regresión; su uso se ejemplifica utilizando el problema de Diabetes (Sección B.2.3.2), como se muestra en las siguientes dos instrucciones.

```
X, y = load_diabetes(return_X_y=True)
Xtrain, Xtest, ytrain, ytest = train_test_split(X, y, random_state=13)
```

La clase `LinearSVR` implementa la máquina de soporte vectorial lineal y su uso sigue la misma dinámica que en el caso de clasificación, e.g.,

```
svr = LinearSVR(C=100).fit(Xtrain, ytrain)
hy_svr = svr.predict(Xtest)
```

donde la varianza capturada por el modelo (Ecuación 2.7) es: 0.4352.

8.5. Regresión Logística

En clasificación binaria (Sección 8.3.1) se describió que la función discriminante se puede definir como la resta, i.e., $g_1(\mathbf{x}) - g_2(\mathbf{x})$; equivalentemente se pudo haber seleccionado la división $(\frac{g_1(\mathbf{x})}{g_2(\mathbf{x})})$ para generar la función discriminante o el logaritmo de la división, i.e., $\log \frac{g_1(\mathbf{x})}{g_2(\mathbf{x})}$. Esta última ecuación en el caso de $g_i(\mathbf{x}) = \mathbb{P}(\mathcal{Y} = i \mid \mathcal{X} = \mathbf{x})$ corresponde a la función logit, tal y como se muestra a continuación.

$$\begin{aligned}\log \frac{\mathbb{P}(\mathcal{Y} = 1 \mid \mathcal{X} = \mathbf{x})}{\mathbb{P}(\mathcal{Y} = 2 \mid \mathcal{X} = \mathbf{x})} &= \log \frac{\mathbb{P}(\mathcal{Y} = 1 \mid \mathcal{X} = \mathbf{x})}{1 - \mathbb{P}(\mathcal{Y} = 1 \mid \mathcal{X} = \mathbf{x})} \\ &= \mathsf{logit}(\mathbb{P}(\mathcal{Y} = 1 \mid \mathcal{X} = \mathbf{x})),\end{aligned}$$

donde la inversa del logit es la función sigmoide, $\mathsf{sigmoid}(x) = \frac{1}{1+\exp(-x)}$, es decir $\mathsf{sigmoid}(\mathsf{logit}(y)) = y$.

Trabajando un poco con el logit se puede observar que para el caso de dos clases esta función queda como

$$\begin{aligned}\mathsf{logit}(\mathbb{P}(\mathcal{Y}=1 \mid \mathcal{X}=\mathbf{x})) &= \log \frac{\mathbb{P}(\mathcal{Y}=1 \mid \mathcal{X}=\mathbf{x})}{\mathbb{P}(\mathcal{Y}=2 \mid \mathcal{X}=\mathbf{x})} \\ &= \log \frac{\mathbb{P}(\mathcal{X}=\mathbf{x} \mid \mathcal{Y}=1)\mathbb{P}(\mathcal{Y}=1)}{\mathbb{P}(\mathcal{X}=\mathbf{x} \mid \mathcal{Y}=2)\mathbb{P}(\mathcal{Y}=2)} \\ &= \log \frac{\mathbb{P}(\mathcal{X}=\mathbf{x} \mid \mathcal{Y}=1)}{\mathbb{P}(\mathcal{X}=\mathbf{x} \mid \mathcal{Y}=2)} + \log \frac{\mathbb{P}(\mathcal{Y}=1)}{\mathbb{P}(\mathcal{Y}=2)}\end{aligned},$$

asumiendo que la matriz de covarianza (Σ) es compartida entre las dos clases la ecuación anterior quedaría como:

$$\begin{aligned}\mathsf{logit}(\mathbb{P}(\mathcal{Y}=1 \mid \mathcal{X}=\mathbf{x})) &= \log \frac{(2\pi)^{-\frac{d}{2}} \mid \Sigma \mid^{-\frac{1}{2}} \exp\left(-\frac{1}{2}(\mathbf{x}-{}_1)^\top \Sigma^{-1}(\mathbf{x}-{}_1)\right)}{(2\pi)^{-\frac{d}{2}} \mid \Sigma \mid^{-\frac{1}{2}} \exp\left(-\frac{1}{2}(\mathbf{x}-{}_2)^\top \Sigma^{-1}(\mathbf{x}-{}_2)\right)} \\ &\quad + \log \frac{\mathbb{P}(\mathcal{Y}=1)}{\mathbb{P}(\mathcal{Y}=2)} \\ &= \mathbf{w} \cdot \mathbf{x} + w_0\end{aligned}$$

donde $\mathbf{w} = \Sigma^{-1}({}_1 - {}_2)$ y $w_0 = -\frac{1}{2}({}_1 + {}_2)^\top \Sigma^{-1}({}_1 + {}_2) + \log \frac{\mathbb{P}(\mathcal{Y}=1)}{\mathbb{P}(\mathcal{Y}=2)}$.

En el caso de regresión logística, se asume que $\mathsf{logit}(\mathbb{P}(\mathcal{Y}=1 \mid \mathcal{X}=\mathbf{x})) = \mathbf{w} \cdot \mathbf{x} + w_0$ y no se asume nada con respecto a la distribución que tienen los datos. Equivalentemente, se puede asumir que $\log \frac{\mathbb{P}(\mathcal{Y}=1 \mid \mathcal{X}=\mathbf{x})}{\mathbb{P}(\mathcal{Y}=2 \mid \mathcal{X}=\mathbf{x})} = \mathbf{w} \cdot \mathbf{x} + w_0^0$, realizando algunas substituciones se puede ver que $w_0 = w_0^0 + \log \frac{\mathbb{P}(\mathcal{Y}=1)}{\mathbb{P}(\mathcal{Y}=2)}$.

8.5.1. Optimización

Se puede asumir que $\mathcal{Y} \mid \mathcal{X}$ sigue una distribución Bernoulli en el caso de dos clases, entonces el logaritmo de la verosimilitud (Sección 6.3.1) quedaría como:

$$\ell(\mathbf{w}, w_0 \mid \mathcal{D}) = \prod_{(\mathbf{x},y)\in\mathcal{D}} (C(\mathbf{x}))^y (1 - C(\mathbf{x})))^{1-y},$$

donde $C(\mathbf{x})$ es la clase estimada por el clasificador.

Siempre que se tiene que obtener el máximo de una función esta se puede transformar a un problema de minimización, por ejemplo, para el caso anterior definiendo como $E = -\log \ell$, utilizando esta transformación el problema sería minimizar la siguiente función:

$$E(\mathbf{w}, w_0 \mid \mathcal{D}) = -\sum_{(\mathbf{x},y)\in\mathcal{D}} y \log C(x) + (1-y)\log(1-C(x)). \tag{8.5}$$

Es importante notar que la ecuación anterior corresponde a Entropía cruzada (Sección 2.3.7), donde $y = \mathbb{P}(\mathcal{Y} = y \mid \mathcal{X} = \mathbf{x}))$ y $C(\mathbf{x}) = \hat{\mathbb{P}}(\mathcal{Y} = y \mid \mathcal{X} = \mathbf{x})$ y los términos $1-y$ y $1-C(\mathbf{x})$ corresponden a la otra clase.

Otra característica de $E(\mathbf{w}, w_0 \mid \mathcal{D})$ es que no tiene una solución cerrada y por lo tanto es necesario utilizar un método de optimización para encontrar los parámetros $\mathbf{w}$ y w_0. En esta unidad el problema se resuelve con CVXPY (Diamond y Boyd (2016)), tomándolo como una herramienta que regresa los parámetros que minimizan la función. En la Capítulo 9, más adelante, se describe cómo resolver este mismo problema con descenso por gradiente.

En el caso de regresión logística, el logaritmo de la verosimilitud está dado por la Ecuación 8.6; esta función es cóncava, lo cual hace que pueda ser maximizada por algún algoritmo de optimización convexa.

$$\log \ell(\mathbf{w}, w_0) = \sum_i y_i \mathbf{w}\cdot\mathbf{x}_i + w_0 - \log(1+\exp^{\mathbf{w}\cdot\mathbf{x}_i + w_0}) \tag{8.6}$$

Normalmente, se suele incluir una función que penaliza la complejidad del modelo, normalmente utilizando alguna norma sobre los parámetros. Siguiendo esta idea la Ecuación 8.7 muestra el problema de optimización que se sigue en la regresión logística, donde el parámetro C pesa el término que mide la complejidad del modelo, i.e., $||\ \mathbf{w}\ ||$.

$$\text{máx}\ \ \log \ell(\mathbf{w}, w_0) - C\ ||\ \mathbf{w}\ || \tag{8.7}$$

La Ecuación 8.7 se puede codificar en CVXPY (Diamond y Boyd (2016)) utilizando las siguientes instrucciones. Las primeras dos líneas ponen en la variable `X` las variables independientes y en `y` la clase. En `w` y `w0` están los parámetros del modelo, es decir, las variables a optimizar, siguiendo por el parámetro `C` que penaliza la complejidad. La variable `verosimilitud` calcula la Ecuación 8.6, el problema de optimización se encuentra en la variable `prob` y se optimiza la última línea.

```
X = np.concatenate((X_1, X_2))
y = np.array([1] * X_1.shape[0] + [0] * X_2.shape[0])
w = cp.Variable(X.shape[1])
w0 = cp.Variable()
C = cp.Parameter(pos=True)
hy = X @ w + w0
verosimilitud = cp.mean(cp.multiply(hy, y) - cp.logistic(hy))
```

```
prob = cp.Problem(cp.Maximize(verosimilitud - C * cp.norm(w)))
C.value = 1
_ = prob.solve(solver='SCS')
```

8.5.2. Múltiples clases

En el caso de tener múltiples clases, en el caso de regresión logística, se puede modelar con una función categórica, donde el logaritmo de la verosimilitud está dado por

$$\log \ell(W, W_0) = \sum_i \log \hat{\mathbb{P}}(\mathcal{Y} = y_i \mid \mathcal{X} = \mathbf{x}_i) \tag{8.8}$$

y $\hat{\mathbb{P}}(\mathcal{Y} \mid \mathcal{X} = \mathbf{x}) = \mathsf{softmax}(W \cdot \mathbf{x} + W_0)$, donde $\mathsf{softmax}$ transforma un vector $\mathbf{v}$ de K valores en probabilidades, $\mathsf{softmax}(\mathbf{v})_i = \frac{\exp v_i}{\sum_{j=1}^{K} \exp v_j}$, y es la generalización de la función sigmoide a K clases (ver también Ecuación 12.1). Siguiendo el procedimiento anterior el siguiente código codifica en CVXPY el problema de regresión logística multinomial.

En la primera línea se cargan los datos del problema de clasificación, en las variables `X` y `y`, la segunda línea cuenta el número de clases. La variable `Wt` y `W0` contienen los parámetros del modelo es decir $W^\top$ y W_0, `den` calcula el valor del denominador de la función $\mathsf{softmax}$ y `logit` corresponde al numerador solamente de la clase medida. La variable `verosimilitud` contiene el valor calculado en la Ecuación 8.8, el problema de optimización está en `prob` y se ejecuta en la última línea.

8.6. Comparación

Es momento de comparar el comportamiento de los dos métodos de discriminantes lineales vistos en la unidad, estos son, Máquinas de Soporte Vectorial (MSV) y Regresión Logística (RL). La Figura 8.12 muestra el hiperplano generado por MSV y RL, además se puede observar los valores de los pesos $\mathbf{w}$ para cada uno de los algoritmos.

Complementando la comparación anterior con los datos del iris que se pueden obtener con las siguientes dos instrucciones.

```
D, y = load_iris(return_X_y=True)
T, G, y_t, y_g = train_test_split(D, y,
                                  test_size=0.4,
                                  random_state=3)
```

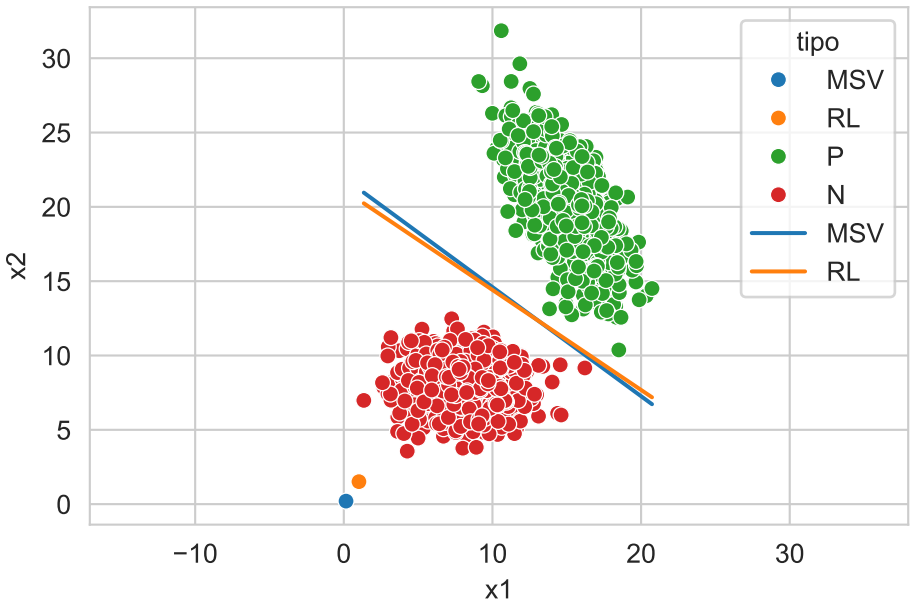


Figura 8.12: Comparación de dos métodos lineales

Los clasificadores a comparar son una máquina de soporte vectorial lineal, una máquina de soporte vectorial usando un kernel polinomial de grado 1 y una regresión logística, tal y como se muestra en el siguiente código.

```
svm = LinearSVC(dual=False).fit(T, y_t)
svm_k = SVC(kernel='poly', degree=1).fit(T, y_t)
lr = LogisticRegression().fit(T, y_t)
```

La Tabla 8.1 muestra el rendimiento (en medidas macro) de estos algoritmos en el conjunto de prueba, se puede observar que estos algoritmos tienen rendimientos diferentes para esta selección del conjunto de entrenamiento y prueba. También en esta ocasión la regresión lineal es la que presenta el mejor rendimiento. Aunque es importante aclarar que este rendimiento es resultado del proceso aleatorio de selección del conjunto de entrenamiento y prueba.

Tabla 8.1: Rendimiento de clasificadores lineales

Clasificador	Precisión	Recall	F_1
MSV - Lineal	0.9524	0.9500	0.9473
MSV - Kernel	0.9474	0.9481	0.9473
RL	0.9667	0.9667	0.9649

8.7. Resumen

Los discriminantes lineales modelan directamente la frontera de decisión mediante una función discriminante (Sección 8.3), cuya geometría se describió en la Sección 8.3.2 y que se extiende a más de dos clases en la Sección 8.3.3. Las máquinas de soporte vectorial (Sección 8.4) buscan el hiperplano de mayor margen y, con el truco del kernel, la misma idea produce fronteras no lineales (Figura 8.10). La regresión logística (Sección 8.5) es el modelo logit que se conoce de Econometría, aunque aquí se evalúa por su capacidad de predicción. La máquina de soporte vectorial lineal, la que usa kernel y la regresión logística se compararon en el conjunto de prueba (Tabla 8.1), y esa diferencia depende de la partición de los datos.

En política pública estos modelos son una base natural para clasificar casos, por ejemplo para decidir si un hogar o una escuela entra a un programa. El vector de pesos del discriminante indica qué variables empujan la decisión en cada dirección, pero igual que con los coeficientes regularizados de Sección 3.8, no son efectos causales.

Los parámetros de estos modelos se encontraron con solucionadores que se usaron como cajas negras. Cómo se obtienen esos parámetros, y cómo se puede hacer con cualquier modelo cuya pérdida sea derivable, es el tema de Capítulo 9.

9 Optimización

El **objetivo** de la unidad es conocer y aplicar el método de **Descenso de Gradiente** y **Propagación hacia Atrás** para estimar los parámetros de modelos de clasificación y regresión.

9.1. Paquetes usados

```
from sklearn.linear_model import LogisticRegression
from sklearn.preprocessing import StandardScaler, minmax_scale
from scipy.stats import multivariate_normal
from jax import grad, jit, value_and_grad, random
from jax.scipy.optimize import minimize
import jax.lax as lax
import jax.numpy as jnp
from matplotlib import pylab as plt
import numpy as np
import pandas as pd
import seaborn as sns
```

9.2. Introducción

Existen diferentes modelos de clasificación y regresión donde no es posible encontrar una solución analítica para estimar los parámetros, por ejemplo en Regresión Logística (Sección 8.5). Es en este escenario donde se voltea a métodos de optimización iterativos para calcular los parámetros.

En esta unidad se describe posiblemente el método de optimización más conocido que es **Descenso de Gradiente**. Este método como su nombre lo indica utiliza el gradiente como su ingrediente principal; se describirá cómo se puede calcular el gradiente utilizando un método gráfico y cómo este método naturalmente realiza **Propagación hacia Atrás**.

9.3. Descenso por Gradiente

En un modelo de clasificación y regresión interesa encontrar un vector de parámetros, $\mathbf{w}^*$, que minimicen una función de error, E, de la siguiente manera:

$$\mathbf{w}^* = \mathsf{argmin}_{\mathbf{w}} E(\mathbf{w} \mid \mathcal{D}).$$

En el caso de que $E(\mathbf{w} \mid \mathcal{D})$ sea una función diferenciable, el gradiente está dado por:

$$\nabla_{\mathbf{w}} E(\mathbf{w} \mid \mathcal{D}) = [\frac{\partial E}{\partial \mathbf{w}_1}, \frac{\partial E}{\partial \mathbf{w}_2}, ...]^\top.$$

La idea general es tomar la dirección opuesta al gradiente para encontrar el mínimo de la función. Entonces el cambio de parámetro está dado por

$$\begin{aligned} \Delta \mathbf{w} &= -\eta \nabla_{\mathbf{w}} E \\ \mathbf{w}^{t+1} &= \mathbf{w}^{t-1} + \Delta \mathbf{w} \\ &= \mathbf{w}^{t-1} - \eta \nabla_{\mathbf{w}} E \end{aligned}$$

9.3.1. Ejemplo - Regresión Lineal

Suponiendo que se quieren estimar los parámetros de la siguiente ecuación lineal: $f(x) = ax + b$, para lo cual se tiene un conjunto de entrenamiento en el intervalo $x = [-10, 10]$, generado con los parámetros $a = 2.3$ y $b = -3$. Importante no olvidar que los parámetros $a = 2.3$ y $b = -3$ son desconocidos y se quieren estimar usando **Descenso por Gradiente** y también es importante mencionar que para este problema en particular es posible tener una solución analítica para estimar los parámetros.

El primer paso es definir la función de error $E(a, b \mid \mathcal{D})$, en problemas de regresión una función de error viable es: $E(a, b \mid \mathcal{D}) = \sum_{(x,y)\in\mathcal{D}} (y - f(x))^2$.

La regla para actualizar los valores iniciales es: $w = w - \eta \nabla_w E$; por lo que se procede a calcular $\nabla_w E$ donde w corresponde a los parámetros a y b.

$$\begin{aligned} \frac{\partial E}{\partial w} &= \frac{\partial}{\partial w} \sum (y - f(x))^2 \\ &= 2 \sum (y - f(x)) \frac{\partial}{\partial w} (y - f(x)) \\ &= -2 \sum (y - f(x)) \frac{\partial}{\partial w} f(x) \end{aligned}$$

donde $\frac{\partial}{\partial a} f(x) = x$ y $\frac{\partial}{\partial b} f(x) = 1.0$ Las ecuaciones para actualizar a y b serían:

$$
\begin{aligned}
e(y, x) &= y - f(x) \\
a &= a + 2\eta \sum_{(x,y)\in\mathcal{D}} e(y, x)x \\
b &= b + 2\eta \sum_{(x,y)\in\mathcal{D}} e(y, x)
\end{aligned}
$$

Con el objetivo de visualizar descenso por gradiente y completar el ejemplo anterior, el siguiente código implementa el proceso de optimización mencionado. Lo primero es generar el conjunto de entrenamiento.

```
x = np.linspace(-10, 10, 50)
y = 2.3 * x - 3
```

El proceso inicia con valores aleatorios de a y b, estos valores podrían ser 5.3 y -5.1, además se utilizará una $\eta = 0.0001$, se guardarán todos los puntos visitados en la lista `D`. Las variables y valores iniciales quedarían como:

```
a = 5.3
b = -5.1
delta = np.inf
eta = 0.0001
D = [(a, b)]
```

El siguiente ciclo realiza la iteración del proceso de optimización y se detiene cuando los valores estimados varían poco entre dos iteraciones consecutivas, en particular cuando en promedio el cambio en las constantes sea menor a 0.0001.

```
while delta > 0.0001:
    hy = a * x + b
    e = (y - hy)
    a = a + 2 * eta * (e * x).sum()
    b = b + 2 * eta * e.sum()
    D.append((a, b))
    delta = np.fabs(np.array(D[-1]) - np.array(D[-2])).mean()
```

En la Figura 9.1 se muestra el camino que siguieron los parámetros hasta llegar a los parámetros que generaron el problema. Los parámetros que generaron el problema se encuentran marcados en negro.

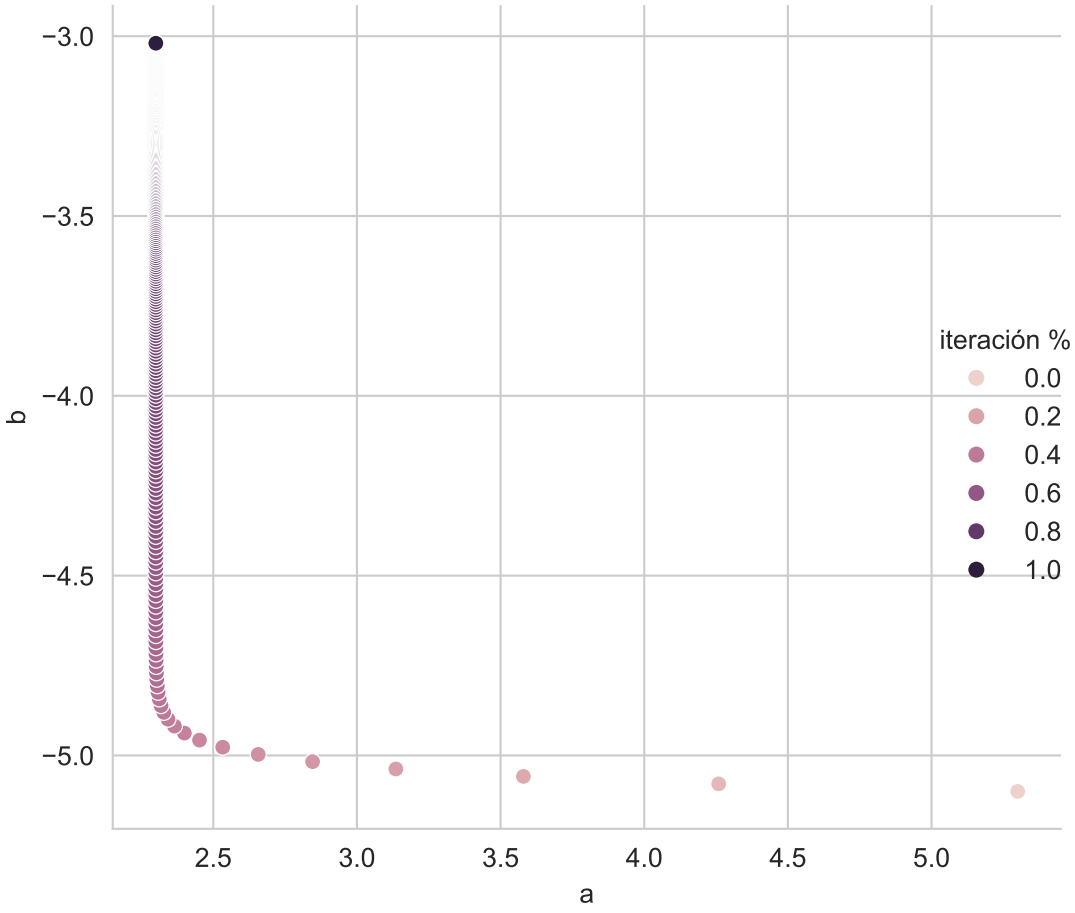


Figura 9.1: Camino de los parámetros en el proceso de optimización.

9.4. Diferenciación Automática

No en todos los casos es posible encontrar una ecuación cerrada para actualizar los parámetros; también el trabajo manual que se requiere para encontrar la solución analítica es considerable y depende de la complejidad de la función objetivo que se quiere derivar. Observando el procedimiento para actualizar los parámetros, i.e., $\mathbf{w}^{t+1} = w^{t-1} - \eta \nabla_{\mathbf{w}} E$, se concluye que se requiere evaluar $\nabla_{\mathbf{w}} E$ en un punto en particular, entonces, para solucionar el problema, es suficiente contar con un procedimiento que permita conocer el valor de $\nabla_{\mathbf{w}} E$ en cualquier punto deseado, y en particular no es necesario conocer la solución analítica de $\nabla_{\mathbf{w}} E$. Al procedimiento que encuentra el valor de la derivada de cualquier función en un punto de manera automática se le conoce como diferenciación automática.

9.4.1. Una Variable

Se puede entender el proceso de diferenciación automática siguiendo un par de ejemplos. Sea $f(x) = x^2$, en este caso $f'(x) = 2x$. Ahora considerando que se quiere evaluar $f'(2.5)$, se sabe que $f'(2.5) = 5$, pero también se puede generar un programa donde en la primera fase se calcule $f(2.5) = (2.5)^2$ y al momento de calcular f se guarde en un espacio asociado a f el valor de $f'(2.5)$. Es decir 5. Se puede observar que este procedimiento soluciona este problema simple para cualquier función de una variable.

La librería JAX permite hacer diferenciación automática en Python. Siguiendo el ejemplo anterior, se genera la función $f(x) = x^2$ con el siguiente código

```
def sq(x):
    return x**2
```

Esta función se puede evaluar como `sq(2.5)`; lo interesante es que `sq` se puede componer con la función `grad` para calcular la derivada de la siguiente manera.

```
res = grad(sq)(2.5)
```

Ejecutando el código anterior se obtiene 5, `grad` internamente guarda 5, `grad` asociado a `sq`.

Ahora en el caso de una composición, por ejemplo, sea $g(x) = \sin(x)$ y se desea conocer $\frac{d}{dx} g(f(x))$, siguiendo el mismo principio primero se evalúa $f(2.5)$ y se guarda asociado a f el valor de 5 que corresponde a f', después se evalúa $g(5)$ y se guarda asociado a g el valor $\cos(2.5^2)$. Ahora para conocer el valor de $\frac{d}{dx} g(f(2.5))$ se camina en el sentido inverso multiplicando todos los valores guardados, es decir, se multiplica $5 \times \cos(2.5^2)$. Implementando este ejemplo en Python quedaría como:

```
def sin_sq(x):
    return jnp.sin(sq(x))
```

donde la función `sin_sq` tiene la composición de $g \circ f$. Ahora la derivada de esta composición en 2.5 se obtiene como `grad(sin_sq)(2.5)` obteniendo un valor de 4.9972.

9.4.2. Dos Variables

El ejemplo anterior se puede extender para cualquier composición de funciones, pero ese ejemplo no deja claro lo que pasaría con una función de dos o más variables, como por ejemplo, $h(x, y) = x \times y$. En este caso, el objetivo es calcular tanto $\frac{d}{dx}h$ como $\frac{d}{dy}h$.

El procedimiento es similar, con el ingrediente extra de que se tiene que recordar la función y la posición del argumento, es decir, para $h(2, 5)$ se asocia el valor $\frac{\partial}{\partial x}h$ con el primer argumento de la función h y $\frac{\partial}{\partial x}h$ con el segundo argumento de la función h. Para $h'(2, 5)$ se asocia el valor de 5 con el primer argumento de h y 2 con el segundo argumento de h. Se puede observar que los valores guardados corresponden a $\frac{\partial}{\partial x}h(2, 5) = y = 5$ y $\frac{\partial}{\partial y}h(2, 5) = x = 2$. Escribiendo este ejemplo en Python quedaría como

```
def prod(x):
    return x[0] * x[1]
```

calculando la derivada como `grad(prod)(jnp.array([2., 5.]))` se obtiene `[5., 2.]` que corresponde a la derivada parcial en cada argumento.

9.4.3. Visualización

Una manera de visualizar este proceso de diferenciación automática es poniéndolo en un árbol de expresión, en la Figura 9.2 se muestra la ecuación $ax^2 + bx + c$. Dentro de cada nodo se observa el valor que se tiene que guardar para cualquier valor de a, b, c y x.

9.4.4. Regresión Lineal

En esta sección se realiza utilizando diferenciación automática el ejemplo de regresión lineal (Sección 9.3.1). Lo primero que se tiene que hacer es definir la función para la cual se quieren optimizar los parámetros. Esta función es $ax + b$ la cual se define con el siguiente código. El primer argumento de la función son los parámetros y después vienen los argumentos de la función que en este caso son los valores de x.

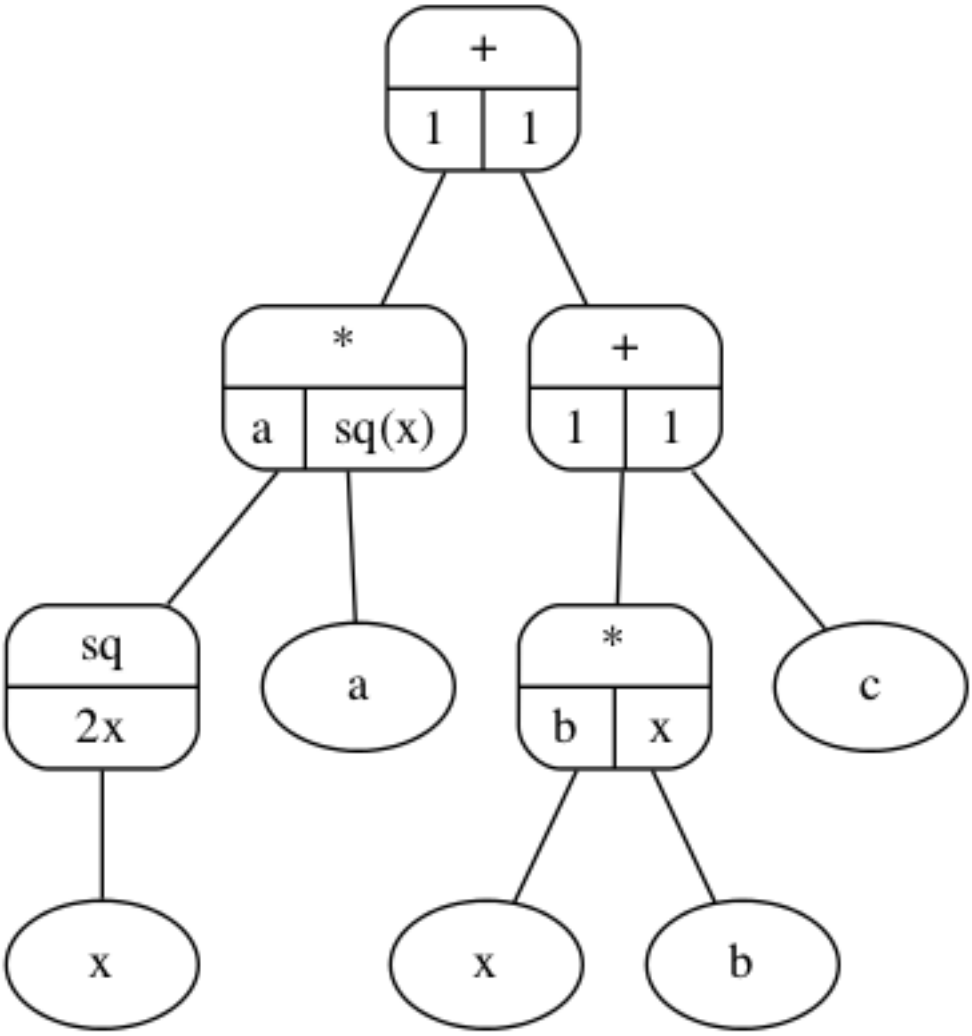


Figura 9.2: Árbol de expresión

```
def func(params, x):
    a, b = params
    return a * x + b
```

El siguiente paso es definir la función de error, en este caso la función de error definida previamente es $\sum_{i=1}^{N}(y_i - \hat{y}_i)^2$ tal y como se muestra en la siguiente función.

```
def error(params, x, y):
    hy = func(params, x)
    return lax.fori_loop(0, x.shape[0],
                         lambda i, acc: acc + (y[i] - hy[i])**2,
                         0)
```

Finalmente, se actualizan los parámetros siguiendo un procedimiento equivalente al mostrado anteriormente. La primera línea define el valor de η, el valor de la variable `delta` indica el término del ciclo, la tercera línea define los parámetros iniciales (`params`), la siguiente guarda todos los puntos visitados (cuarta línea) y la quinta línea deriva la función de `error` para calcular el gradiente. La primera instrucción dentro del ciclo actualiza los parámetros.

```
eta = 1e-5
delta = np.inf
params = jnp.array([5.3, -5.1])
x = jnp.array(x)
y = jnp.array(y)
D = [params]
error_grad = grad(error)
while delta > 0.01:
    params -= eta * error_grad(params, x, y)
    D.append(params)
    delta = jnp.fabs(D[-1] - D[-2]).mean()
```

9.5. Regresión Logística

En esta sección, se presenta la implementación de Regresión Logística (Sección 8.5) utilizando diferenciación automática.

El método se probará en los datos generados por dos normales en $\mathbb{R}^2$ que se generan con las siguientes instrucciones.

```
X_1 = multivariate_normal(mean=[15, 20], cov=[[3, -3], [-3, 8]]).rvs(1000)
X_2 = multivariate_normal(mean=[8, 8], cov=[[4, 0], [0, 2]]).rvs(1000)
T = np.concatenate((X_1, X_2))
normalize = StandardScaler().fit(T)
T = jnp.array(normalize.transform(T))
y_t = jnp.array([1] * X_1.shape[0] + [0] * X_2.shape[0])
```

Siguiendo los pasos utilizados en el ejemplo anterior, la primera función a implementar es el modelo, es decir la función sigmoide, i.e., $\mathsf{sigmoid}(\mathbf{x}) = \frac{1}{1+\exp(-(\mathbf{w}\cdot\mathbf{x}+w_0))}$.

```
def modelo(params, x):
    _ = jnp.exp(-(jnp.dot(x, params[:2]) + params[-1]))
    return 1 / (1 + _)
```

El siguiente paso es implementar la función de error que guía el proceso de optimización, en el caso de regresión logística de dos clases la función de error corresponde a la media de la Entropía Cruzada (Ecuación 8.5). Esta función se implementa en dos pasos, primero se calcula la entropía cruzada usando el siguiente procedimiento. Donde la primera línea verifica si se trata de la clase positiva (1) o de la clase negativa 0 y calcula el $\log \hat{y}$ o $\log(1-\hat{y})$ respectivamente.

```
def entropia_cruzada(y, hy):
    _ = lax.cond(y == 1, lambda w: jnp.log(w), lambda w: jnp.log(1 - w), hy)
    return lax.cond(_ == -jnp.inf, lambda w: jnp.log(1e-6), lambda w: w, _)
```

El segundo paso es calcular la media de la entropía cruzada de cada elemento de $\mathcal{D}$, esto se puede realizar con la siguiente función.

```
def suma_entropia_cruzada(params, x, y):
    hy = modelo(params, x)
    return - lax.fori_loop(0, y.shape[0],
                           lambda i, x: x + entropia_cruzada(y[i], hy[i]),
                           1) / y.shape[0]
```

El paso final es actualizar los parámetros, en esta ocasión se utilizará la función `value_and_grad` que regresa la evaluación de la función así como la derivada, esto para poder desplegar cómo el error disminuye con el paso de las iteraciones. El código es similar al mostrado anteriormente. Las diferencias son la forma en generar los parámetros iniciales, primeras tres líneas, el parámetro η, que se itera por $n = 5000$ iteraciones y la función `value_and_grad`.

```
key = random.PRNGKey(0)
key, subkey = random.split(key)
params = random.normal(subkey, (3,)) * jnp.sqrt(2 / 2)
eta = 0.1
error = []
error_grad  = value_and_grad(suma_entropia_cruzada)
for i in range(5000):
    _, g = error_grad(params, T, y_t)
    error.append(_)
    params -= eta * g
```

La Figura 9.3 muestra cómo se reduce la media de la entropía cruzada con respecto al número de iteraciones, este error sigue bajando aunque la velocidad disminuye drásticamente.

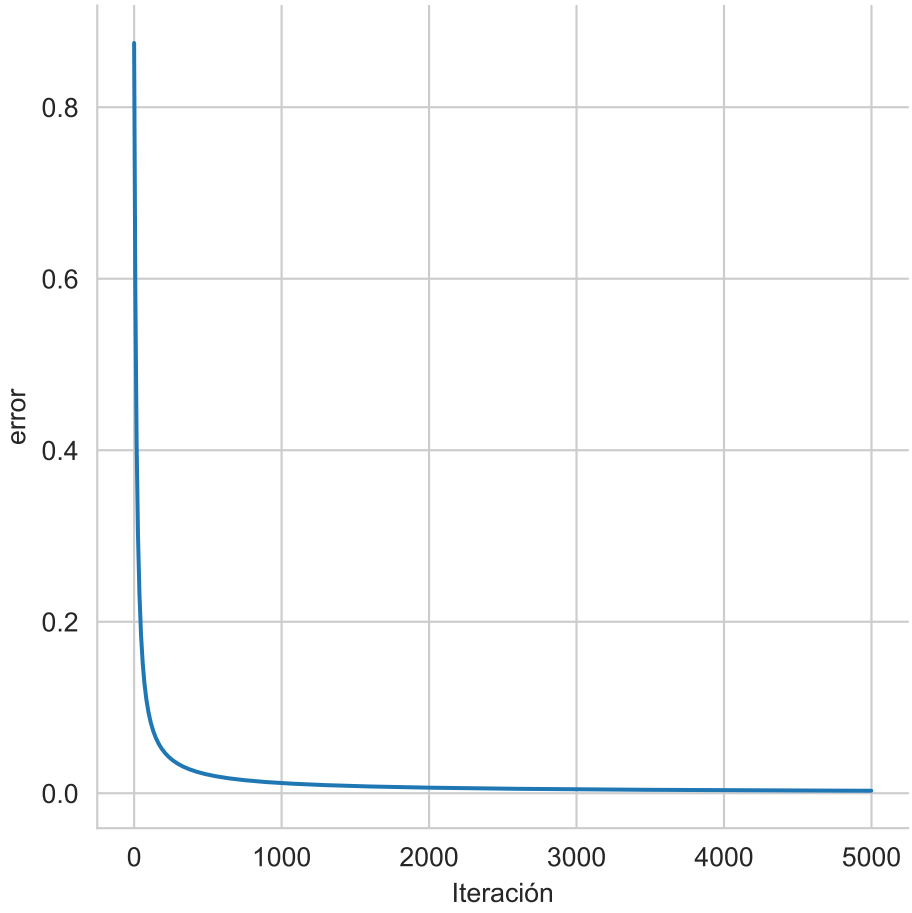


Figura 9.3: Descenso de Entropía Cruzada

Optimizando los parámetros de la regresión logística utilizando el procedimiento de diferenciación automática se obtiene [3.8981, 4.3871, -0.4956].

En Discriminantes Lineales (Capítulo 8) se presentó el procedimiento para entrenar un clasificador logístico usando la siguiente instrucción.

```
lr = LogisticRegression().fit(T, y_t)
```

Los parámetros son [3.2309, 4.5126, -0.3074]. El error en el conjunto de entrenamiento se puede calcular utilizando el siguiente código.

```
Array(0.00344871, dtype=float32)
```

En comparación el error obtenido por diferenciación automática es 0.0029, por supuesto este puede variar cambiando el número de iteraciones.

9.6. Actualización de Parámetros

Por supuesto la regla $\mathbf{w}^{t+1} = \mathbf{w}^{t-1} - \eta \nabla_{\mathbf{w}} E$ para actualizar los parámetros $\mathbf{w}$ no es única y existe una gama de métodos que se pueden seleccionar dependiendo de las características del problema. En particular regresión logística es un problema de optimización convexo, en este tipo de problemas un algoritmo para encontrar los parámetros es el `BFGS`. Por ejemplo el siguiente código utiliza este algoritmo para encontrar los parámetros de la regresión logística.

```
p = random.normal(subkey, (3,)) * jnp.sqrt(2 / 2)
res = minimize(suma_entropia_cruzada, p, args=(T, y_t), method='BFGS')
```

Se observa cómo se usa la misma función de error (`suma_entropia_cruzada`) y los mismos parámetros iniciales. Los parámetros que se encuentran con este método son [22.7586, 36.8742, 3.6319] y tiene un error -0.0003.

La Figura 9.4 muestra la función discriminante obtenida por cada uno de los métodos, el método de diferenciación automática (JAX), el método de la librería `sklearn` y el algoritmo `BFGS`. Se puede observar que el plano de `sklearn` y `BFGS` son más similares, esto no es sorpresa porque los dos métodos implementan el mismo método de optimización, es decir, `BFGS`. Por supuesto las implementaciones tienen algunas diferencias, que pueden ir desde el número de iteraciones y la forma de generar los parámetros iniciales. Si se escalan los parámetros $\mathbf{w}$ para que tengan una longitud de 1 se observaría que `sklearn` y `BFGS` se tocan.

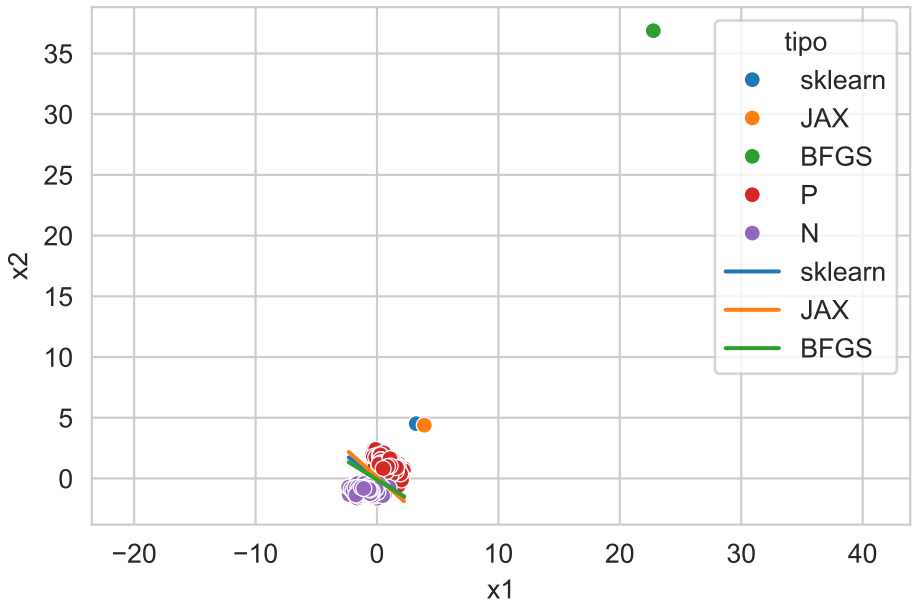


Figura 9.4: Comparación de modelos lineales con diferentes optimizadores

9.7. Resumen

Entrenar un modelo es resolver un problema de optimización, y el descenso por gradiente (Sección 9.3) es la idea central que actualiza los parámetros en la dirección contraria al gradiente del error. La diferenciación automática (Sección 9.4) calcula ese gradiente sin derivarlo a mano, lo que permite optimizar cualquier modelo cuya función de error se pueda escribir como código, como la regresión lineal (Sección 9.3.1) y la regresión logística (Sección 9.5). Existen además otras reglas para actualizar los parámetros, como `BFGS`, cuyos resultados son comparables con los del descenso por gradiente (Sección 9.6 y Figura 9.4).

Esta es la maquinaria que comparten los modelos regularizados, las máquinas de soporte vectorial, la regresión logística y las redes neuronales. Para quien usa estos modelos en un problema de política pública, entenderla ayuda a saber cuándo un resultado depende del punto inicial, de la escala de las variables o de que el procedimiento no haya convergido, y por lo tanto a decidir cuánta confianza darle.

Hasta aquí los modelos han sido funciones con una forma fija. Una familia distinta construye fronteras de decisión mediante reglas fáciles de leer, y se presenta en Capítulo 10.

10 Árboles de Decisión

El **objetivo** de la unidad es conocer y aplicar árboles de decisión a problemas de clasificación y regresión.

10.1. Paquetes usados

```
from sklearn import tree
from sklearn.model_selection import train_test_split
from sklearn.datasets import load_breast_cancer, load_diabetes
from sklearn.inspection import DecisionBoundaryDisplay
from scipy.stats import multivariate_normal
from matplotlib import pylab as plt
import numpy as np
import pandas as pd
import seaborn as sns
```

10.2. Introducción

Los árboles de decisión son una estructura de datos jerárquica, la cual se construye utilizando una estrategia de divide y vencerás. Los árboles son un método no paramétrico diseñado para problemas de regresión y clasificación.

El árbol se camina desde la raíz hacia las hojas; en cada nodo se tiene una regla que muestra el camino de acuerdo a la entrada y la hoja indica la clase o respuesta que corresponde a la entrada.

10.3. Clasificación

Utilizando el procedimiento para generar tres Distribuciones Gaussianas (Sección 5.3.1) se generan las siguientes poblaciones (Figura 10.1) con medias $\mu_1 = [5, 5]^\top$, $\mu_2 = [-5, -10]^\top$ y $\mu_3 = [15, -6]^\top$; utilizando las matrices de covarianza originales.

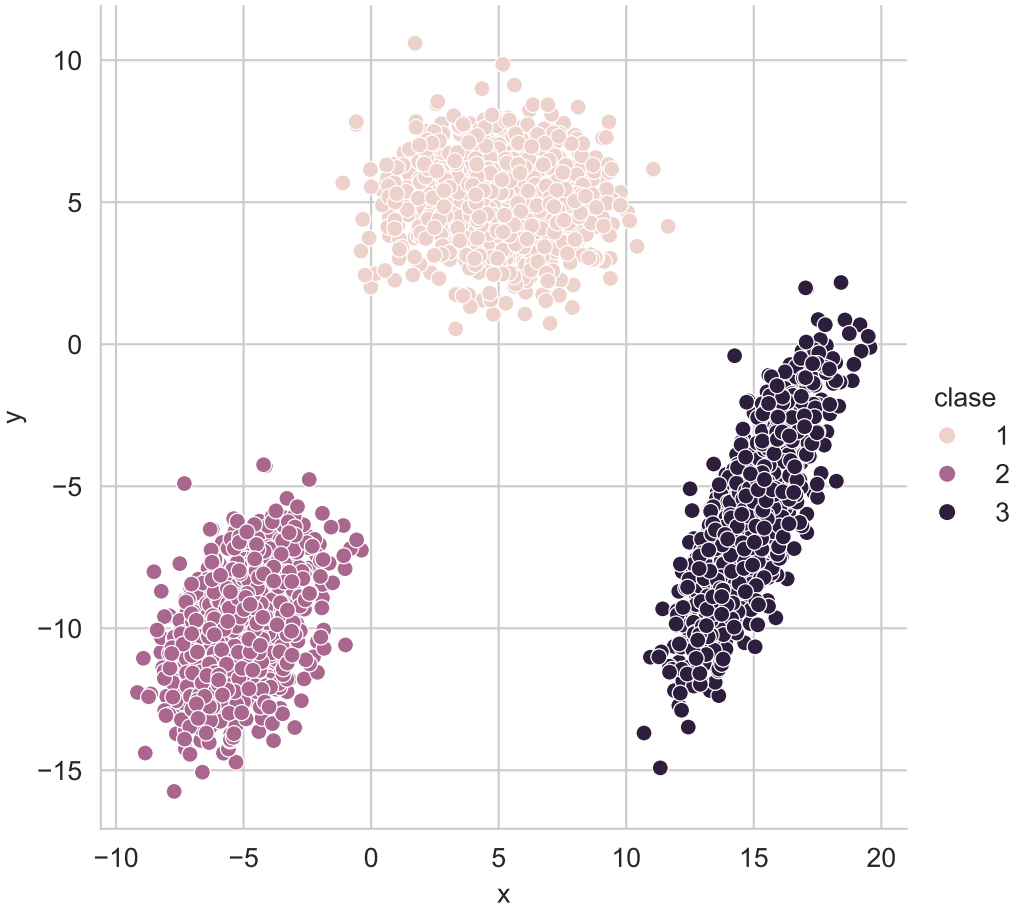


Figura 10.1: Tres distribuciones Gaussianas

Con estas tres poblaciones, donde cada distribución genera una clase se crea un árbol de decisión. El árbol se muestra en la Figura 10.2, donde se observa, en cada nodo interno, la siguiente información. La primera línea muestra el identificador del nodo, la segunda corresponde a la función de corte, la tercera línea es la entropía ($H(\mathcal{Y}) = -\sum_{y\in\mathcal{Y}} \mathbb{P}(\mathcal{Y}=y)\log_2 \mathbb{P}(\mathcal{Y}=y)$), la cuarta es el número de elementos que llegaron al nodo y la última la frecuencia de cada clase en ese nodo.

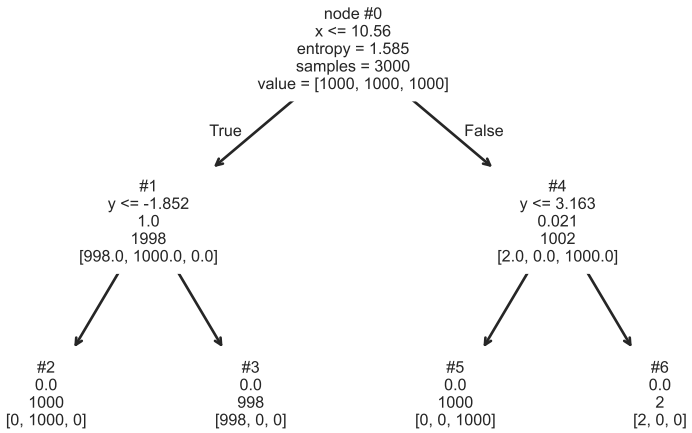


Figura 10.2: Árbol de decisión

Por ejemplo el nodo raíz del árbol tiene una entropía de 1.5850, la función de decisión es $x \leq 10.5605$ que indica que todos los elementos con un valor en x menor o igual del valor calculado están del lado izquierdo. Las hojas (nodos #2, #3, #5, y #6) no cuentan con una función de corte, dado que son la parte final del árbol. En el árbol mostrado se observa que la entropía en todos los casos es 0, lo cual indica que todos los elementos que llegaron a ese nodo son de la misma clase. No en todos los casos las hojas tienen entropía cero y existen parámetros en la creación del árbol que permiten crear árboles más simples. Por ejemplo, hay hojas que tienen muy pocos ejemplos, uno se podría preguntar ¿qué pasaría si esas hojas se eliminan? para tener un árbol más simple.

La siguiente Figura 10.3 muestra el árbol generado cuando se remueven el nodo #6. Se observa un árbol con menos nodos, aunque la entropía es diferente de cero en algunas hojas. La segunda parte de la figura muestra la función de decisión que genera el árbol de decisión. Se observa que cada regla divide el espacio en dos usando la información que se muestra en cada nodo.

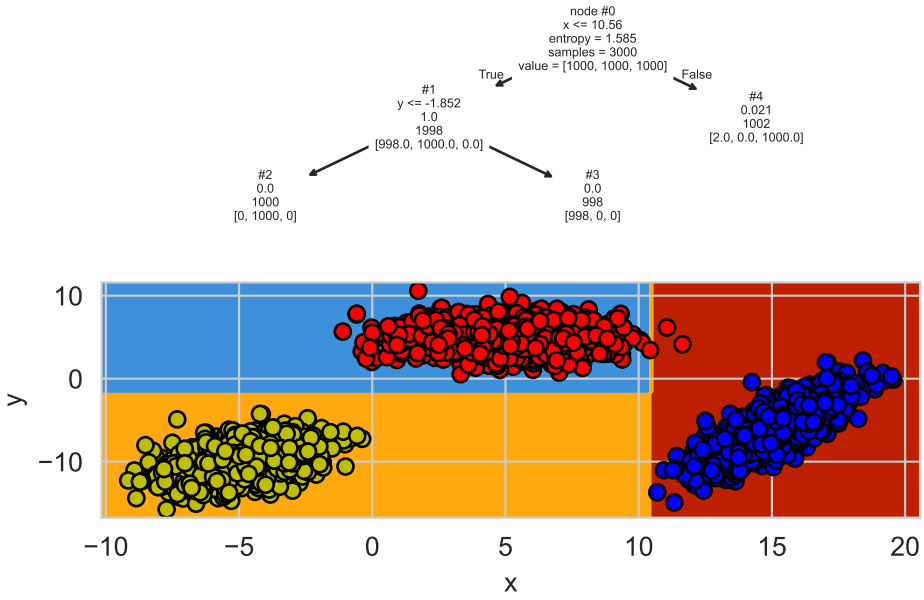


Figura 10.3: Árbol de decisión y función

10.3.1. Predicción

Utilizando el árbol y la función de decisión mostrada en Figura 10.3, se puede explicar el proceso de clasificar un nuevo elemento. Por ejemplo, el elemento $\mathbf{u} = (x = -3, y = 0.5)$ pasaría por los nodos #0, #1 y #3 para llegar a la clase correspondiente.

10.3.2. Entrenamiento

Existen diferentes sistemas para la generación de un árbol de decisión (e.g., Quinlan (1986)) la mayoría de ellos comparten la siguiente estructura general. La construcción de un árbol se realiza mediante un procedimiento recursivo en donde se aplica la función de corte $f_m(\mathbf{x}) = x_i \leq a$ en el nodo m, donde el parámetro a y la componente x_i se identifican utilizando los datos que llegan al nodo m de tal manera que se maximice una función de costo.

Una función de costo podría estar basada en la entropía, es decir, para cada posible corte se mide la entropía en los nodos generados y se calcula la esperanza de la entropía de la siguiente manera.

$$L(x_i, a) = \sum_h \frac{\mid \mathcal{D}_h \mid}{\mid \mathcal{D}_m \mid} H(\mathcal{D}_h),$$

donde $H(\mathcal{D}_h)$ es la entropía de las etiquetas del conjunto $\mathcal{D}_h$, la entropía se puede calcular con la siguiente función. La función recibe un arreglo con las clases, está protegida para calcular $0 \log 0 = 0$ y finalmente regresa la entropía de `arr`.

```
def H(arr):
    a, b = np.unique(arr, return_counts=True)
    b = b / b.sum()
    return - (b * np.log2(b, where=b != 0)).sum()
```

La función que optimiza $L(x_i, a)$, para encontrar a se implementa en el procedimiento `corte_var`. Este procedimiento asume que las etiquetas (`labels`) están ordenadas por la variable x_i, es decir la primera etiqueta corresponde al valor mínimo de x_i y la última al valor máximo. Considerando esto, el valor de a es el índice con el menor costo. En la primera línea se inicializa la variable `mejor` para guardar el valor de a con mejor costo. La segunda línea corresponde a $\mid \mathcal{D}_m \mid$, en la tercera línea se identifican los diferentes valores de a que se tiene que probar, solo se tienen que probar aquellos puntos donde cuando la clase cambia con respecto al elemento adyacente, esto se calcula con la función `np.diff`; dado que esta quita el primer elemento entonces es necesario incrementar 1. El ciclo es por todos los puntos de corte, se calcula el costo para los elementos que están a la izquierda y derecha del corte y se compara el resultado con el costo con menor valor encontrado hasta el momento. La última línea regresa el costo mejor así como el índice donde se encontró.

```
def corte_var(labels):
    mejor = (np.inf, None)
    D_m = labels.shape[0]
    corte = np.where(np.diff(labels))[0] + 1
    for j in corte:
        izq = labels[:j]
        der = labels[j:]
        a = (izq.shape[0] / D_m) * H(izq)
        b = (der.shape[0] / D_m) * H(der)
        perf = a + b
        if perf < mejor[0]:
          mejor = (perf, j)
    return mejor
```

En el siguiente ejemplo se usa la función `corte_var`; la función regresa un costo de 0.4591 y el punto de corte es el elemento 3, se puede observar que es el mejor punto de corte en el arreglo dado.

```
costo, indice = corte_var(np.array([0, 0, 1, 0, 0, 0]))
```

Con la función `corte_var` se optimiza el valor a de $L(x_i, a)$, ahora es el turno de optimizar x_i con respecto a la función de costo. El procedimiento `corte` encuentra el mínimo con respecto de x_i, esta función recibe los índices (`idx`) donde se buscará estos valores, en un inicio `idx` es un arreglo de 0 al número de elementos del conjunto $\mathcal{D}$ menos uno. La primera línea define la variable donde se guarda el menor costo, en la segunda línea se ordenan las variables, la tercera línea se obtienen las etiquetas involucradas. El ciclo va por todas las variables x_i. Dentro del ciclo se llama a la función `corte_var` donde se observa cómo las etiquetas van ordenadas de acuerdo a la variable que se está analizando; la función regresa el corte con menor costo y se compara con el menor costo obtenido hasta el momento, si es menor se guarda en `mejor`. Finalmente, se regresa `mejor` y los índices ordenados para poder identificar los elementos del hijo izquierdo y derecho.

```
def corte(idx):
    mejor = (np.inf, None, None)
    orden = np.argsort(X[idx], axis=0)
    labels = y[idx]
    for i, x in enumerate(orden.T):
        comp = corte_var(labels[x])
        if comp[0] < mejor[0]:
            mejor = (comp[0], i, comp[1])
    return mejor, idx[orden[:, mejor[1]]]
```

Con la función `corte` se puede encontrar los parámetros de la función de corte $f_m(\mathbf{x}) = x_i \leq a$ para cada nodo del árbol completo del ejemplo anterior. Por ejemplo, los parámetros de la función de decisión para la raíz (#0) que se observa en la Figura 10.3 se puede obtener con el siguiente código.

```
best, orden = corte(np.arange(X.shape[0]))
perf, i, j = best
(X[orden[j], i] + X[orden[j-1], i]) / 2
```

```
np.float64(10.560464864725406)
```

La variable `orden` tiene la información para dividir el conjunto dado, lo cual se realiza en las siguientes instrucciones, donde `idx_i` corresponde a los elementos a la izquierda y `idx_d` son los de la derecha.

```
idx_i = orden[:j]
idx_d = orden[j:]
```

Teniendo los elementos a la izquierda y derecha, se puede calcular los parámetros de la función de corte del nodo #1 los cuales se pueden calcular con las siguientes instrucciones.

```
best, orden = corte(idx_i)
perf, i, j = best
(X[orden[j], i] + X[orden[j-1], i]) / 2
```

```
np.float64(-1.8516821607950367)
```

> **Nota**
>
> La función `corte` no verifica que se esté en una hoja, entonces si se hace el corte en una hoja regresará `(np.inf, none, None)`

10.3.3. Ejemplo: Breast Cancer Wisconsin

Se utiliza el conjunto de datos de Breast Cancer Wisconsin para ejemplificar el algoritmo de Árboles de Decisión. Con las siguientes instrucciones se descargan los datos y se dividen en los conjuntos de entrenamiento y prueba.

```
X, y = load_breast_cancer(return_X_y=True)
T, G, y_t, y_g = train_test_split(X, y, test_size=0.2)
```

La siguiente instrucción entrena un árbol de decisión utilizando como función de costo la entropía. En la librería se encuentran implementadas otras funciones como el coeficiente Gini y Entropía Cruzada Sección 2.3.7 (*Log-loss*).

```
arbol = tree.DecisionTreeClassifier(criterion='entropy').fit(T, y_t)
```

Como es de esperarse la predicción se realiza con el método `predict` como se ve a continuación.

```
hy = arbol.predict(G)
```

El error en el conjunto de prueba $\mathcal{G}$ es 0.0439, se puede comparar este error con otros algoritmos utilizados en este conjunto como clasificadores paramétricos basados en distribuciones Gaussianas (Sección 6.7.3). La siguiente instrucción muestra el cálculo del error.

```
error = (y_g != hy).mean()
```

Un dato interesante, considerando los parámetros con los que se inicializó el árbol, entonces este hizo que todas las hojas fueran puras, es decir, con entropía cero. Por lo tanto el error de clasificación en el conjunto de entrenamiento $\mathcal{T}$ es cero, como se puede verificar con el siguiente código.

```
(y_t != arbol.predict(T)).mean()
```

```
np.float64(0.0)
```

10.4. Regresión

Los árboles de decisión aplicados a problemas de regresión siguen una idea equivalente a los desarrollados en problemas de clasificación. Para ejemplificar las diferencias se utiliza el siguiente problema sintético; el cual corresponde a la suma de un seno y un coseno como se muestra a continuación.

```
X = np.linspace(-5, 5, 100)
y = np.sin(X) + 0.3 * np.cos(X * 3.)
```

Con este problema se genera un árbol de decisión utilizando la siguiente instrucción. El método `fit` espera recibir un arreglo en dos dimensiones por eso se usa la función `np.atleast_2d` y se calcula la transpuesta siguiendo el formato esperado. Se observa el uso del parámetro `max_depth` para limitar la profundidad del árbol de decisión.

```
arbol = tree.DecisionTreeRegressor(max_depth=3).fit(np.atleast_2d(X).T, y)
```

El árbol de decisión obtenido se muestra en la Figura 10.4. La información que se muestra en cada nodo interno es equivalente a la mostrada en los árboles de clasificación. La diferencia es que en los árboles de regresión se muestra el promedio (`value`) de las salidas que llegan a ese nodo y en regresión es la frecuencia de clases. Se observa que si la entrada es $x = -4.5$ entonces la respuesta la da el nodo #4 con un valor de 1.088.

10.4.1. Predicción

El árbol anterior se usa para predecir todos los puntos del conjunto de entrenamiento, el resultado se muestra en la Figura 10.5. Se observa que la predicción es discreta, son escalones y esto es porque las hojas predicen el promedio de los valores que llegaron hasta ahí, en este caso el árbol tiene 8 hojas entonces a lo más ese árbol puede predecir 8 valores distintos.

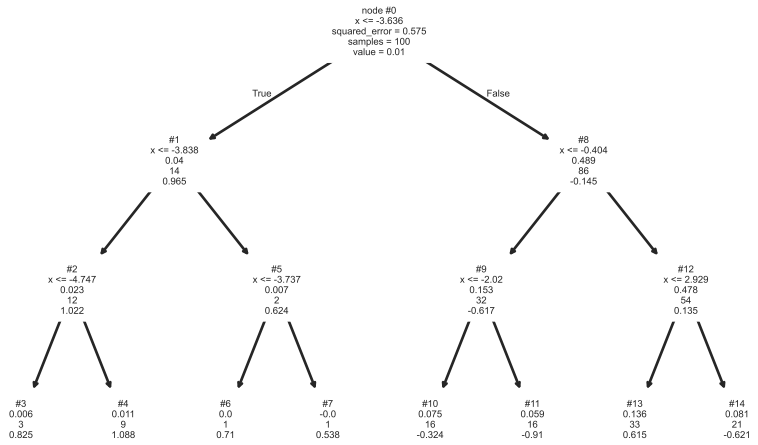


Figura 10.4: Árbol de Regresión

10.4.2. Entrenamiento

Con respecto al proceso de entrenamiento la diferencia entre clasificación y regresión se encuentra en la función de costo que guía el proceso de optimización. En el caso de clasificación la función de costo era la esperanza de la entropía. Por otro lado, en regresión una función de costo utilizada es la varianza que es el error cuadrático que se muestra en los nodos. Para ejemplificar el uso de esta función de costo se utilizan los datos de Diabetes tal y como se muestran en las siguientes instrucciones.

```
X, y = load_diabetes(return_X_y=True)
T, G, y_t, y_g = train_test_split(X, y, test_size=0.2)
```

Con los datos de entrenamiento se genera el siguiente árbol de decisión para regresión. Solamente se muestra la información de la raíz y sus dos hijos. En la raíz se observa los parámetros de la función de corte, se selecciona la variable con índice 8 y se envían 235 elementos al hijo izquierdo y el resto al hijo derecho.

```
arbol = tree.DecisionTreeRegressor().fit(T, y_t)
_ = tree.plot_tree(arbol, max_depth=1)
```

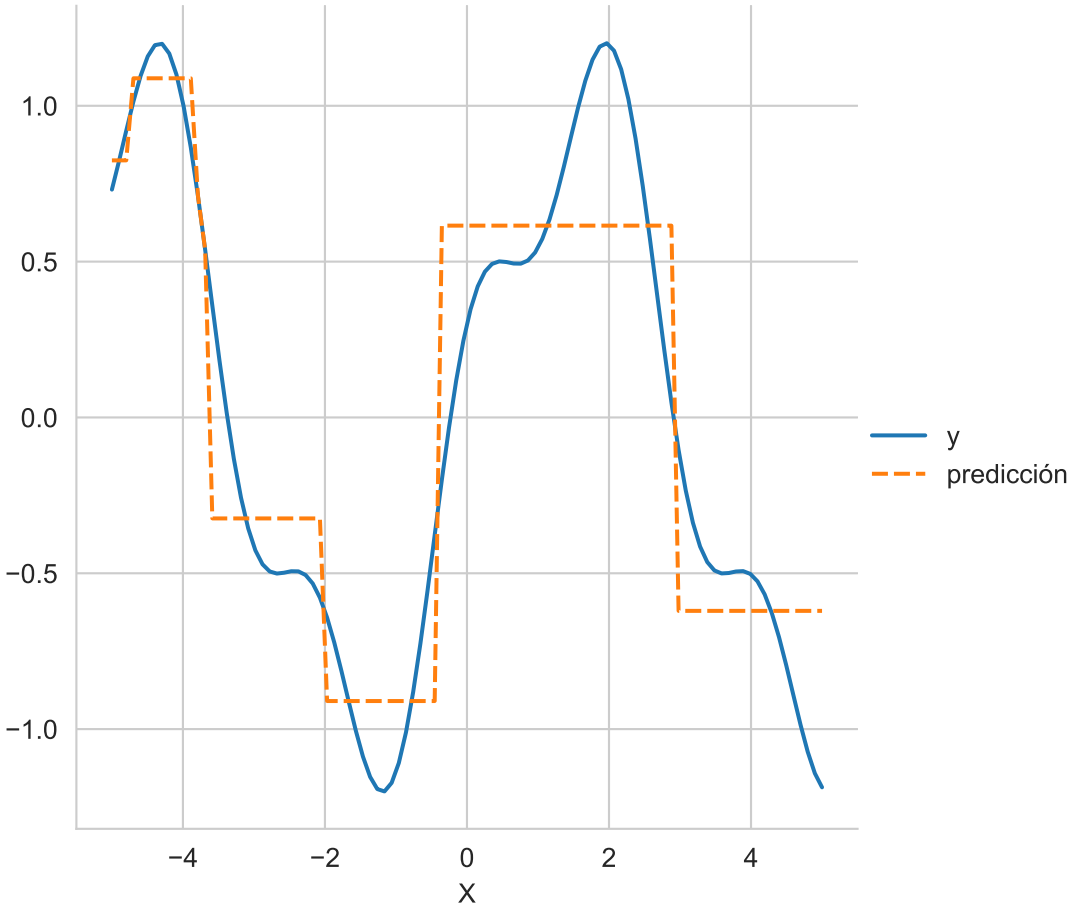
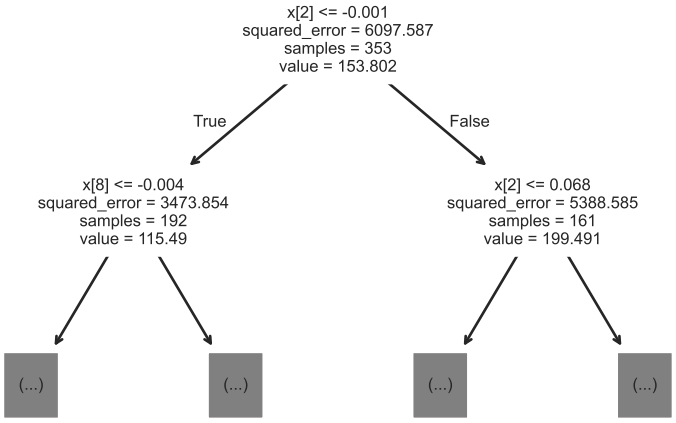


Figura 10.5: Problema de regresión



El siguiente método implementa la función de corte para regresión se puede observar que la única diferencia con la función `corte_var` definida en clasificación (Sección 10.3) es que la entropía `H` se cambia por la varianza `np.var`.

```
def corte_var(response):
    mejor = (np.inf, None)
    D_m = response.shape[0]
    corte = np.where(np.diff(response))[0] + 1
    for j in corte:
        izq = response[:j]
        der = response[j:]
        a = (izq.shape[0] / D_m) * np.var(izq)
        b = (der.shape[0] / D_m) * np.var(der)
        perf = a + b
        if perf < mejor[0]:
          mejor = (perf, j)
    return mejor
```

La función `corte_var` de regresión se utiliza para encontrar el punto de corte en los datos del conjunto de entrenamiento de la siguiente manera. En la primera línea se ordenan las variables independientes y en la segunda línea se itera por todas las variables independientes para calcular el corte con costo mínimo.

```
orden = T.argsort(axis=0)
res = [corte_var(y_t[orden[:, x]]) for x in range(10)]
res
```

```
[(np.float64(5823.658448143391), np.int64(192)),
 (np.float64(5975.894408036269), np.int64(331)),
 (np.float64(4347.145085528361), np.int64(192)),
 (np.float64(5009.672116063563), np.int64(247)),
 (np.float64(5773.8429320345895), np.int64(203)),
 (np.float64(5824.366368032179), np.int64(211)),
 (np.float64(5147.381774586123), np.int64(147)),
 (np.float64(4814.701015053039), np.int64(139)),
 (np.float64(4469.167976329612), np.int64(181)),
 (np.float64(5192.68561605473), np.int64(272))]
```

El resultado de ejecutar el código anterior se muestra a continuación; donde se observa que el costo mínimo corresponde a la variable con índice np.int64(2) tal y como se muestra en la figura anterior nodo derecho de la raíz.

10.5. Resumen

Un árbol de decisión divide el espacio de las variables mediante particiones recursivas y asigna una predicción a cada región. En clasificación (Sección 10.3) cada partición se elige para reducir una medida de impureza como la entropía o Gini (Sección 10.3.2), y la predicción se obtiene recorriendo el árbol desde la raíz (Sección 10.3.1). En regresión la idea es la misma, pero cada región predice un valor numérico (Figura 10.4). La profundidad máxima controla la complejidad del modelo, de modo que un árbol muy profundo se ajusta a los datos de entrenamiento y generaliza mal, mientras que uno muy somero no captura la estructura del problema.

Para la política pública la ventaja de un árbol es que sus reglas se pueden leer y explicar, y se parecen a los criterios de elegibilidad de un programa. Su desventaja es que son inestables, pues un cambio pequeño en los datos puede producir un árbol distinto. Por eso conviene verificar que una regla no depende de una sola muestra antes de proponerla como criterio.

Esa inestabilidad es un problema, pero también se puede aprovechar. Combinar muchos árboles reduce la varianza de la predicción, y es la idea de los ensambles que se presentan en Capítulo 11.

11 Ensambles

El **objetivo** de la unidad es conocer y aplicar diferentes técnicas para realizar un ensamble de clasificadores o regresores.

11.1. Paquetes usados

```
from scipy.stats import binom
from sklearn.datasets import load_diabetes, load_digits
from sklearn.model_selection import train_test_split
from sklearn.svm import LinearSVC, LinearSVR, SVR
from sklearn.tree import DecisionTreeClassifier, DecisionTreeRegressor
from sklearn.ensemble import BaggingRegressor
from sklearn.ensemble import RandomForestRegressor
from sklearn.ensemble import RandomForestClassifier
from sklearn.neighbors import KNeighborsRegressor
from sklearn.ensemble import StackingRegressor
from sklearn.metrics import recall_score, mean_absolute_percentage_error
from collections import Counter
from matplotlib import pylab as plt
import numpy as np
import pandas as pd
import seaborn as sns
```

11.2. Introducción

Como se ha visto hasta el momento, cada algoritmo de clasificación y regresión tiene un sesgo, este puede provenir de los supuestos que se asumieron cuando se entrenó o diseñó; por ejemplo, asumir que los datos provienen de una distribución gaussiana multivariada o que se pueden separar los ejemplos mediante un hiperplano, entre otros. Dado un problema se desea seleccionar aquel algoritmo que tiene el mejor rendimiento, visto de otra manera, se selecciona el algoritmo cuyo sesgo esté mejor alineado al problema. Una manera complementaria sería utilizar varios algoritmos y tratar de predecir basados en las predicciones individuales de cada algoritmo.

En esta unidad se explicarán diferentes metodologías que permiten combinar predicciones de algoritmos de clasificación y regresión.

11.3. Fundamentos

La descripción de ensambles se empieza observando el siguiente comportamiento. Suponiendo que se cuenta con M algoritmos de clasificación binaria cada uno tiene una exactitud de $p = 0.51$ y estos son completamente independientes. El proceso de clasificar un elemento corresponde a preguntar la clase a los M clasificadores y la clase que recibe más votos es la clase seleccionada, esta votación se comporta como una variable aleatoria que tiene una distribución Binomial. Suponiendo que la clase del elemento es 1, en esta condición la función acumulada de distribución (cdf) con parámetros $k = \lfloor \frac{M}{2} \rfloor$, $n = M$ y $p = 0.51$ indica seleccionar la clase 0 y $1 - \text{cdf}$ corresponde a la probabilidad de seleccionar la clase 1.

La Figura 11.1 muestra cómo cambia la exactitud, cuando el número de clasificadores se incrementa, cada uno de esos clasificadores son independientes y tiene una exactitud de $p = 0.51$, se puede observar que cuando $M = 501$ el rendimiento es 0.673 y con $9,999$ clasificadores se tiene un valor de 0.977.

En el caso de regresión, en particular cuando se usa como función de error el cuadrado del error, i.e., $(\hat{y} - y)^2$ se tiene el intercambio entre varianza y sesgo, el cual se deriva de la siguiente manera.

$$
\begin{aligned}
\mathbb{E}[(\hat{y} - y)^2] = & \\
& = \mathbb{E}[(\hat{y} - \mathbb{E}[\hat{y}] + \mathbb{E}[\hat{y}] - y)^2] \\
& = \underbrace{\mathbb{E}[(\hat{y} - \mathbb{E}[\hat{y}])^2]}_{\mathbb{V}(\hat{y})} + \mathbb{E}[(\mathbb{E}[\hat{y}] - y)^2] \\
& + 2\mathbb{E}[(\hat{y} - \mathbb{E}[\hat{y}])(\mathbb{E}[\hat{y}] - y)] \\
& = \mathbb{V}(\hat{y}) + (\underbrace{\mathbb{E}[\hat{y}] - y}_{\text{sesgo}})^2 + 2\underbrace{\mathbb{E}[(\hat{y} - \mathbb{E}[\hat{y}])]}_{\mathbb{E}[\hat{y}] - \mathbb{E}[\hat{y}] = 0}(\mathbb{E}[\hat{y}] - y) \\
& = \mathbb{V}(\hat{y}) + (\mathbb{E}[\hat{y}] - y)^2
\end{aligned}
$$

Se observa que el cuadrado del error está definido por la varianza de $\hat{y}$ (i.e., $\mathbb{V}(\hat{y})$), la cual es independiente de la salida y y el sesgo al cuadrado del algoritmo (i.e., $(\mathbb{E}[\hat{y}] - y)^2$).

En el contexto de ensamble, asumiendo que se tienen M regresores independientes donde la predicción está dada por $\bar{y} = \frac{1}{M}\sum_{i=1}^{M} \hat{y}^i$, se tiene que el sesgo de cada predictor individual es igual al sesgo de su promedio (i.e., $(\mathbb{E}[\bar{y}] - y) = (\mathbb{E}[\hat{y}^i] - y)$) como se puede observar a continuación.

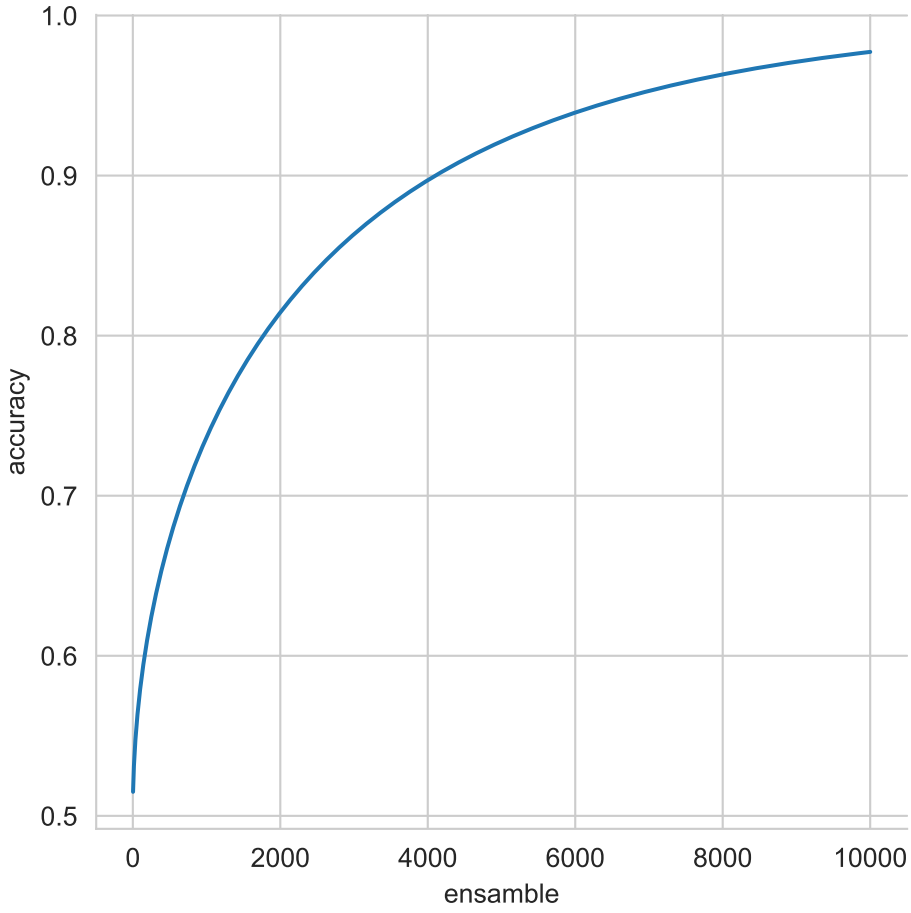


Figura 11.1: Rendimiento cuando el número de clasificadores se incrementa

$$\mathbb{E}[\bar{y}] = \mathbb{E}[\frac{1}{M}\sum_{i=1}^{M}\hat{y}^i]$$
$$= \frac{1}{M}\sum_{i=1}^{M}\underbrace{\mathbb{E}[\hat{y}^i]}_{\mathbb{E}[\hat{y}]} = \frac{1}{M}M\mathbb{E}[\hat{y}] = \mathbb{E}[\hat{y}]$$

Por otro lado la varianza del promedio (i.e., $\mathbb{V}(\bar{y})$) está dada por $\mathbb{V}(\bar{y}) = \frac{1}{M}\mathbb{V}(\hat{y})$, que se deriva siguiendo los pasos del error estándar de la media (Sección A.1.1).

Esto quiere decir que si se tienen M regresores independientes, entonces el error cuadrado de su promedio es menor que el error de cada regresor individual, esto es porque su varianza se reduce tal y como se mostró.

Tanto en el caso de clasificación como en el caso del error cuadrado, es poco probable contar con clasificadores y regresores que sean completamente independientes, entonces sus predicciones van a estar relacionadas en algún grado y no se podrá llegar a las reducciones obtenidas en el procedimiento presentado.

11.4. Bagging

Siguiendo con la idea de combinar M instancias independientes de un tipo de algoritmo, en esta sección se presenta el algoritmo Bagging (Bootstrap Aggregation) el cual como su nombre lo indica se basa en la técnica de Bootstrap (Sección A.2) para generar M instancias del algoritmo y la combinación es mediante votación o el promedio en caso de regresión o que se cuente con la probabilidad de cada clase.

11.4.1. Ejemplo: Dígitos

Para ejemplificar el uso del algoritmo de Bagging se utilizará el conjunto de datos de Dígitos. Estos datos se pueden obtener y generar el conjunto de entrenamiento ($\mathcal{T}$) y prueba ($\mathcal{G}$) con las siguientes instrucciones.

```
X, y = load_digits(return_X_y=True)
T, G, y_t, y_g = train_test_split(X, y,
                                  test_size=0.2,
                                  random_state=0)
```

Los algoritmos que se utilizarán de base son Máquinas de Soporte Vectorial Lineal (Sección 8.4) y Árboles de Decisión (Capítulo 10). Lo primero que se realizará es entrenar una instancia

de estos algoritmos para poder comparar su rendimiento en el conjunto de prueba contra Bagging.

Las siguientes instrucciones entrenan una máquina de soporte vectorial, calculando en la segunda línea el macro-recall (Sección 2.3.6). El rendimiento se presenta en una tabla para facilitar la comparación.

```
svc = LinearSVC(dual=False).fit(T, y_t)
svc_recall = recall_score(y_g, svc.predict(G),
                          average="macro")
```

Complementando las instrucciones anteriores, en el siguiente código se entrena un Árbol de Decisión.

```
tree = DecisionTreeClassifier(criterion='entropy',
                              min_samples_split=9).fit(T, y_t)
tree_recall = recall_score(y_g, tree.predict(G),
                           average="macro")
```

El algoritmo de Bootstrap inicia generando las muestras tal y como se realizó en el ejemplo del error estándar de la mediana del apéndice de Estadística (Sección A.2.1). El siguiente código genera las muestras, en particular el ensamble sería de $M = 11$ elementos.

```
B = np.random.randint(T.shape[0],
                      size=(11, T.shape[0]))
```

Empezando con Bagging usando como clasificador base la Máquina de Soporte Vectorial Lineal. La primera línea de las siguientes instrucciones, entrena las máquinas de soporte, después se realizan las predicciones. En la tercera línea se calcula la clase que tuvo la mayor cantidad de votos y finalmente se calcula el error en términos de macro-recall.

```
svc_ins = [LinearSVC(dual=False).fit(T[b], y_t[b])
           for b in B]
hys = np.array([m.predict(G) for m in svc_ins])
hy = np.array([Counter(x).most_common(n=1)[0][0]
               for x in hys.T])
bsvc_recall = recall_score(y_g, hy, average="macro")
```

El siguiente algoritmo son los Árboles de Decisión; la única diferencia con respecto a las instrucciones anteriores es la primera línea donde se entrenan los árboles.

```
tree_ins = [DecisionTreeClassifier(criterion='entropy',
                                   min_samples_split=9).fit(T[b], y_t[b])
            for b in B]
hys = np.array([m.predict(G) for m in tree_ins])
hy = np.array([Counter(x).most_common(n=1)[0][0]
               for x in hys.T])
btree_recall = recall_score(y_g, hy,
                            average="macro")
```

Como se mencionó, la predicción final se puede realizar de dos maneras en clasificación una es usando votación, como se vio en los códigos anteriores y la segunda es utilizando el promedio de las probabilidades. En el caso de las Máquinas de Soporte Vectorial, estas no calculan las probabilidades de cada clase, pero se cuenta con el valor de la función de decisión, en el siguiente código se usa esta información, la segunda y tercera línea normaliza los valores para que ningún valor sea mayor que 1 y menor que -1 y finalmente se calcula la suma para después seleccionar la clase que corresponde al argumento máximo.

```
hys = np.array([m.decision_function(G) for m in svc_ins])
hys = np.where(hys > 1, 1, hys)
hys = np.where(hys < -1, -1, hys)
hys = hys.sum(axis=0)
csvc_recall = recall_score(y_g, hys.argmax(axis=1),
                           average="macro")
```

El procedimiento anterior se puede adaptar a los Árboles de Decisión utilizando el siguiente código.

```
hys = np.array([m.predict_proba(G)
                for m in tree_ins])
ctree_recall = recall_score(y_g,
                            hys.sum(axis=0).argmax(axis=1),
                            average="macro")
```

Finalmente, la Tabla 11.1 muestra el rendimiento de las diferentes combinaciones, se puede observar el valor tanto de las Máquinas de Soporte Vectorial (M.S.V) Lineal y de los Árboles de decisión cuando se utilizaron fuera del ensamble; en el segundo renglón se muestra el rendimiento cuando la predicción del ensamble se hizo mediante votación y el último renglón presenta el rendimiento cuando se hace la suma.

Comparando los diferentes rendimientos, se puede observar que no existe mucha diferencia en rendimiento en las M.S.V Lineal y que la mayor mejora se presentó en los Árboles de Decisión.

Este comportamiento es esperado dado que para que Bagging funcione adecuadamente requiere algoritmos inestables, es decir, algoritmos cuyo comportamiento cambia considerablemente con un cambio pequeño en el conjunto de entrenamiento, este es el caso de los Árboles. Por otro lado las M.S.V son algoritmos estables y un cambio pequeño en su conjunto de entrenamiento no tendrá una repercusión considerable en el comportamiento del algoritmo.

Tabla 11.1: Rendimiento (macro-recall) de bagging y estimadores base.

	M.S.V. Lineal	Árboles de Decisión
Único	0.9450	0.8344
Votación ($M = 11$)	0.9421	0.9536
Suma ($M = 11$)	0.9504	0.9524

11.4.2. Ejemplo: Diabetes

Ahora toca el turno de atacar un problema de regresión mediante Bagging, el problema que se utilizará es el de Diabetes. Las instrucciones para obtener el problema y generar los conjuntos de entrenamiento ($\mathcal{T}$) y prueba ($\mathcal{G}$) se muestran a continuación.

```
X, y = load_diabetes(return_X_y=True)
T, G, y_t, y_g = train_test_split(X, y,
                                  random_state=0,
                                  test_size=0.2)
```

Tomando el caso de Dígitos como base, el primer algoritmo a entrenar es la M.S.V. Lineal y se usa como medida de rendimiento el porcentaje del error absoluto (Ecuación 2.6); tal y como se muestran en las siguientes instrucciones.

```
svr = LinearSVR(dual='auto').fit(T, y_t)
svr_mape = mean_absolute_percentage_error(y_g,
                                          svr.predict(G))
```

El árbol de decisión y su rendimiento se implementa con el siguiente código.

```
tree = DecisionTreeRegressor(min_samples_split=9).fit(T,
                                                      y_t)
tree_mape = mean_absolute_percentage_error(y_g,
                                           tree.predict(G))
```

Al igual que en el caso de clasificación, la siguiente instrucción genera los índices para generar las muestras. Se hace un ensamble de $M = 11$ elementos.

```
B = np.random.randint(T.shape[0], size=(11, T.shape[0]))
```

En el caso de regresión, la predicción final corresponde al promedio de las predicciones individuales, la primera línea de las siguientes instrucciones se entrenan las M.S.V Lineal, en la segunda instrucción se hacen las predicciones y en la tercera se realiza el promedio y se mide el rendimiento.

```
svr_ins = [LinearSVR(dual='auto').fit(T[b], y_t[b])
           for b in B]
hys = np.array([m.predict(G) for m in svr_ins])
bsvr_mape = mean_absolute_percentage_error(y_g,
                                           hys.mean(axis=0))
```

De manera equivalente se entrenan los Árboles de Decisión, como se muestra a continuación.

```
tree_ins = [DecisionTreeRegressor(min_samples_split=9).fit(T[b], y_t[b])
            for b in B]
hys = np.array([m.predict(G) for m in tree_ins])
btree_mape = mean_absolute_percentage_error(y_g,
                                            hys.mean(axis=0))
```

La Tabla 11.2 muestra el rendimiento de los algoritmos de regresión utilizados, al igual que en el caso de clasificación, la M.S.V. no se ve beneficiada con el uso de Bagging. Por otro lado los Árboles de Decisión tienen un incremento en rendimiento considerable al usar Bagging.

Tabla 11.2: Rendimiento (MAPE) de bagging y estimadores base.

	M.S.V. Lineal	Árboles de Decisión
Único	0.4128	0.5381
Promedio ($M = 11$)	0.4143	0.3874

Hasta este momento los ensambles han sido de $M = 11$ elementos, queda la duda cómo varía el rendimiento con respecto al tamaño del ensamble. La Figura 11.2 muestra el rendimiento de Bagging utilizando Árboles de Decisión, cuando el ensamble cambia $M = 2, \ldots, 500$. Se observa que hay un decremento importante cuando el ensamble es pequeño, después el error se incrementa y vuelve a bajar alrededor de $M = 100$. Finalmente se ve que el rendimiento es estable cuando $M > 200$.

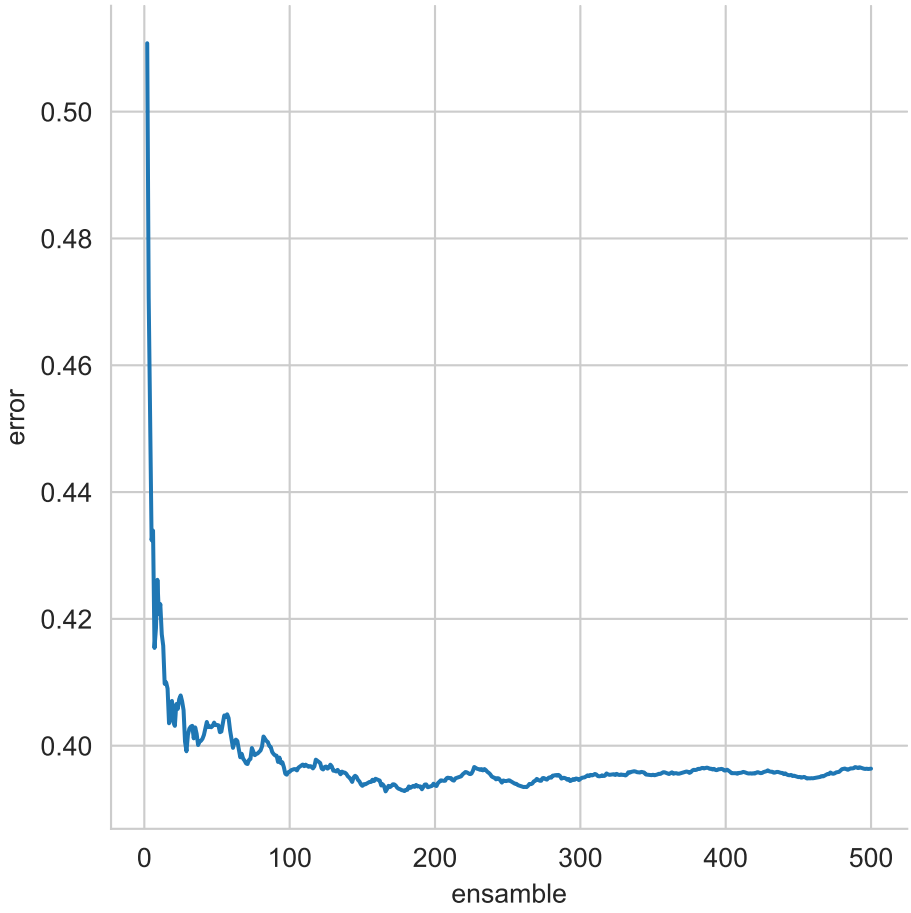


Figura 11.2: Variación del rendimiento con respecto al tamaño del ensamble (M).

Nota

Las clases `BaggingClassifier` y `BaggingRegressor` implementan el ensamble de Bagging. Estas clases tienen parámetros que permiten ejecutar variaciones de la idea original. El uso de la clase `BaggingRegressor` se ilustra con el siguiente código,

```
tree_ins = DecisionTreeRegressor(min_samples_split=9)
ens = BaggingRegressor(tree_ins).fit(T, y_t)
hy = ens.predict(G)
```

donde el promedio del error absoluto es 0.4046.

11.5. Bosques Aleatorios (Random Forest)

En la sección anterior se vio cómo se puede utilizar Bagging y Árboles de Decisión para generar un ensamble, en general Bagging (Sección 11.4) creado con árboles de decisión se les conoce como bosques aleatorios. Breiman (2001a) propone los árboles aleatorios y muestra de manera teórica su comportamiento en la predicción así como de manera experimental su rendimiento en problemas de clasificación.

El uso de árboles aleatorios es directo mediante las clases `RandomForestClassifier` y `RandomForestRegressor` tal y como se muestra en el siguiente código:

```
ens = RandomForestRegressor(min_samples_split=9)
ens.fit(T, y_t)
hy = ens.predict(G)
```

donde el promedio del error absoluto es 0.3962.

Actividad

Visualizar el efecto que tiene el parámetro `min_samples_split` en el algoritmo `RandomForestClassifier` cuando este varía como se muestra en Figura 11.3. El problema utilizado es el de dígitos (Sección B.2.2.3) con una partición de 80 % para entrenamiento y 20 % para validación.

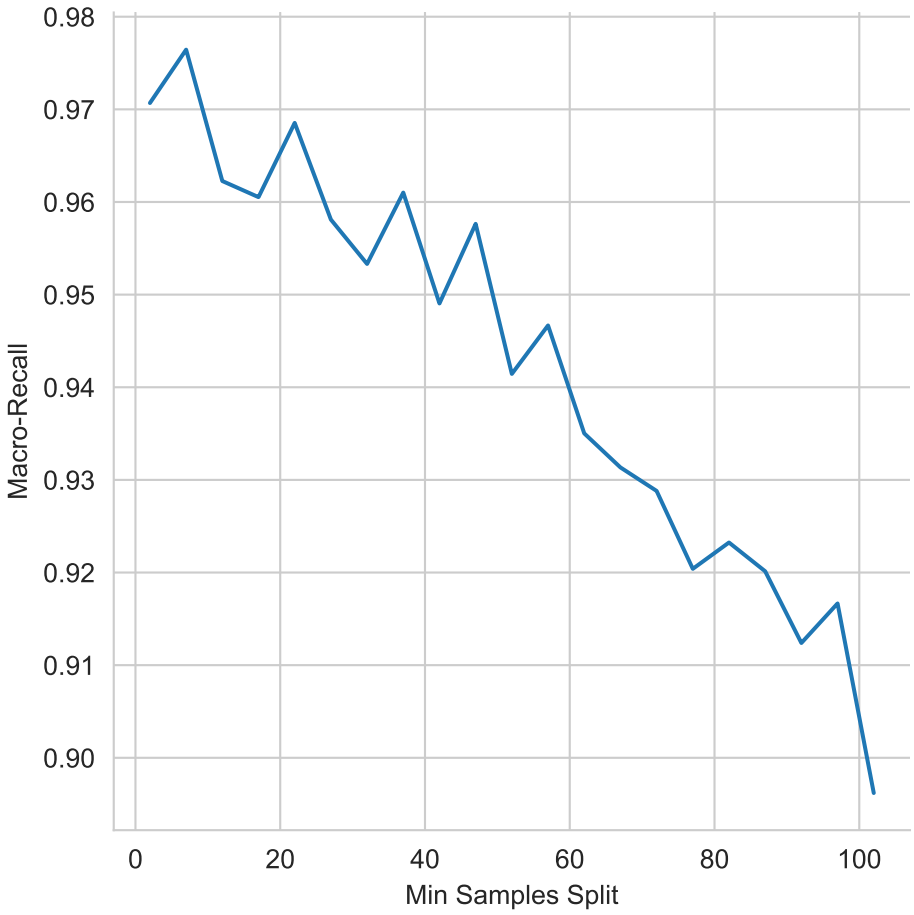


Figura 11.3: Cambio del rendimiento cuando el parámetro que controla el número de muestras para realizar la partición (i.e., min_samples_split) varía.

11.6. Stack Generalization

Continuando con la descripción de ensambles, se puede observar que Bagging en el caso de la media se puede representar como $\sum_i^M \frac{1}{M}\hat{y}^i$, donde el factor $\frac{1}{M}$ se puede observar como un parámetro a identificar. Entonces la idea siguiente sería cómo se podría estimar parámetros para cada uno de los estimadores bases, e.g., $\sum_i^M w_i\hat{y}^i$ donde w_i para bagging corresponde a $\frac{1}{M}$. Se podría ir más allá y pensar que las predicciones $\mathbf{y} = (\hat{y}^1, \ldots, \hat{y}^M)$ podrían ser la entrada a otro estimador.

Esa es la idea detrás de Stack Generalization, Wolpert (1992) propone utilizar las predicciones de los estimadores bases como las entradas de otro estimador. Para poder llevar este proceso es

necesario contar con un conjunto independiente del conjunto de entrenamiento para encontrar los parámetros del estimador que combina las predicciones.

11.6.1. Ejemplo: Diabetes

Para ejemplificar el uso de Stack Generalization, se usa el conjunto de datos de Diabetes. Como se acaba de describir es necesario contar con un conjunto independiente para estimar los parámetros del estimador del stack. Entonces el primer paso es dividir el conjunto de entrenamiento en un conjunto de entrenamiento y validación ($\mathcal{V}$,) tal y como se muestra en la siguiente instrucción.

```
T1, V, y_t1, y_v = train_test_split(T, y_t,
                                    test_size=0.3)
```

Para este ejemplo se usará como regresores bases el algoritmo de Vecinos Cercanos (Sección 7.7) con diferentes parámetros (primera línea), después se usan los modelos para predecir el conjunto de validación ($\mathcal{V}$) y prueba ($\mathcal{G}$), esto se observa en la segunda y tercera línea del siguiente código.

```
models = [KNeighborsRegressor(n_neighbors=n).fit(T1, y_t1)
          for n in [7, 9]]
V_stack = np.array([m.predict(V) for m in models]).T
G_stack = np.array([m.predict(G) for m in models]).T
```

El porcentaje del error absoluto (Ecuación 2.6) de los estimadores bases en el conjunto de prueba se puede calcular con el siguiente código

```
mape_test = []
for hy in G_stack.T:
  mape = mean_absolute_percentage_error(y_g, hy)
  mape_test.append(mape)
```

teniendo los siguientes valores 0.3650 y 0.3655, respectivamente.

Finalmente, es momento de entrenar el regresor que combinará las salidas de los estimadores bases, i.e., Vecinos Cercanos. Se decidió utilizar una Máquina de Soporte Vectorial (Sección 8.4) con kernel polinomial de grado 2. Los parámetros de la máquina se estiman en la primera línea, y después se predicen los datos del conjunto de prueba.

```
stacking = SVR(kernel='poly', degree=2).fit(V_stack, y_v)
hy = stacking.predict(np.vstack(G_stack))
```

El error (Ecuación 2.6) obtenido por este procedimiento es de 0.3584; cabe mencionar que no en todos los casos el procedimiento de stacking consigue un mejor rendimiento que los estimadores bases. En las siguientes instrucciones se entrena un Bagging con Árboles de Decisión para ser utilizado en lugar de la Máquina de Soporte Vectorial.

```
st_trees = BaggingRegressor(estimator=DecisionTreeRegressor(min_samples_split=9),
                            n_estimators=200).fit(V_stack, y_v)
hy = st_trees.predict(np.vstack(G_stack))
mape = mean_absolute_percentage_error(y_g, hy)
```

El rendimiento de este cambio es 0.4408.

> **Nota**
>
> Las clases `StackingClassifier` y `StackingRegressor` implementan la idea de Stack Generalization. El siguiente código muestra su uso en el ejemplo de diabetes, utilizando los algoritmos de vecinos cercanos y máquinas de soporte vectorial.
>
> ```
> models = [(f'KNN-{n}', KNeighborsRegressor(n_neighbors=n))
>           for n in [7, 9]]
> final_estimator = SVR(kernel='poly', degree=2)
> stack = StackingRegressor(models, final_estimator=final_estimator).fit(T, y_t)
> hy = stack.predict(G)
> ```
>
> El promedio del error absoluto es 0.3751.

11.7. Resumen

Un ensamble combina las predicciones de varios algoritmos para obtener una mejor que la de cada uno por separado. El fundamento es que promediar predicciones reduce la varianza (Sección 11.3), y de ahí viene Bagging (Sección 11.4), que entrena cada algoritmo con una muestra bootstrap de los datos. Los bosques aleatorios agregan aleatoriedad en las variables que cada árbol puede usar, y Stack Generalization aprende cómo combinar las predicciones con otro algoritmo en lugar de promediarlas con el mismo peso. En datos tabulares estos métodos suelen estar entre los de mejor rendimiento (Tabla 11.1 y Tabla 11.2).

El costo de ese rendimiento es la interpretabilidad. Un bosque de cientos de árboles ya no se lee como un criterio de elegibilidad, y es el dilema de Occam entre exactitud y simplicidad que

describe Breiman (2001b). Quien trabaja en política pública debe decidir cuánto de lo uno está dispuesto a perder por lo otro. Los bosques reaparecen más adelante en el contexto de la inferencia causal, pero ese tema queda fuera de este capítulo.

Los árboles y los ensambles son una familia flexible que se construye con reglas. Otra familia igualmente flexible se ajusta con descenso por gradiente, y se presenta en Capítulo 12.

12 Redes Neuronales

El **objetivo** de la unidad es conocer, diseñar y aplicar redes neuronales artificiales para problemas de regresión y clasificación.

12.1. Paquetes usados

```
import jax
import jax.lax as lax
import jax.numpy as jnp
import optax
from CompStats.metrics import r2_score
from sklearn.datasets import load_iris, load_digits, load_diabetes
from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split
import numpy as np
import pandas as pd
import seaborn as sns
```

12.2. Introducción

Las redes neuronales son sin duda uno de los algoritmos de aprendizaje supervisado que más han tomado auge en los últimos tiempos. Para iniciar la descripción de redes neuronales se toma de base el algoritmo de Regresión Logística (Sección 9.5) pero en el caso de múltiples clases, es decir, Regresión Logística Multinomial. Al final del capítulo se presentan un ejemplo de clasificación (Dígitos) y uno de regresión (Sección 12.7).

12.3. Regresión Logística Multinomial

La idea de regresión logística es modelar $\mathbb{P}(\mathcal{Y} = y \mid \mathcal{X} = \mathbf{x}) = \mathsf{Ber}(y \mid \mathsf{sigmoid}(\mathbf{w} \cdot \mathbf{x} + w_0))$, es decir, que la clase y está modelada como una distribución Bernoulli con parámetro $\mathsf{sigmoid}(\mathbf{w} \cdot \mathbf{x} + w_0)$.

Siguiendo esta definición que es equivalente a la mostrada anteriormente, se puede modelar a un problema de múltiples clases como $\mathbb{P}(\mathcal{Y} = y \mid \mathcal{X} = \mathbf{x}) = \mathsf{Cat}(y \mid \mathsf{softmax}(W\mathbf{x} + \mathbf{w}_0))$, es decir, que la clase proviene de una distribución Categórica con parámetros $\mathsf{softmax}(W\mathbf{x} + \mathbf{w}_0)$, donde $W \in \mathbb{R}^{K \times d}$, $\mathbf{x} \in \mathbb{R}^d$ y $\mathbf{w}_0 \in \mathbb{R}^d$.

La función $\mathsf{softmax}(\mathbf{v})$, donde $\mathbf{v} = W\mathbf{x} + \mathbf{w}_0$ está definida como:

$$\mathbf{v}_i = \frac{\exp \mathbf{v}_i}{\sum_{j=1}^{K} \exp \mathbf{v}_j}. \tag{12.1}$$

La función `jax.nn.softmax` implementa softmax; en el siguiente ejemplo se calcula para el vector `[2, 1, 3]`

```
jax.nn.softmax(np.array([2, 1, 3]))
```

```
Array([0.24472848, 0.09003057, 0.66524094], dtype=float32)
```

Se puede observar que softmax transforma los valores del vector $\mathbf{v}$ en probabilidades.

Para seguir explicando este tipo de regresión logística se utilizará el problema del Iris, el cual se obtiene de la siguiente manera, es importante notar que las entradas están normalizadas para tener media cero y desviación estándar uno.

```
D, y = load_iris(return_X_y=True)
normalize = StandardScaler().fit(D)
D = normalize.transform(D)
```

El siguiente paso es generar el modelo de la Regresión Logística Multinomial, el cual depende de una matriz de coeficientes $W \in \mathbb{R}^{K \times d}$ y $\mathbf{w}_0 \in \mathbb{R}^d$. Los parámetros iniciales se pueden generar con la función `parametros_iniciales` tal y como se muestra a continuación.

```
n_labels = np.unique(y).shape[0]
def parametros_iniciales(key=0):
    key = jax.random.PRNGKey(key)
    d = D.shape[1]
    params = []
    normal = jax.random.normal
    sqrt = jnp.sqrt
    for _ in range(n_labels):
        key, subkey = jax.random.split(key)
        _ = dict(w=normal(subkey, (d, )) * sqrt(2 / d),
                 w0=jnp.ones(1))
```

```
        params.append(_)
    return params
```

Utilizando los parámetros en el formato anterior, hace que el modelo se pueda implementar con las siguientes instrucciones. Donde el ciclo es por cada uno de los parámetros de las K clases y la última línea calcula el softmax.

```
@jax.jit
def modelo(params, X):
    o = []
    for p in params:
        o.append(X @ p['w'] + p['w0'])
    return jax.nn.softmax(jnp.array(o), axis=0).T
```

Una característica importante es que la función de pérdida, en este caso, a la Entropía Cruzada (Sección 2.3.7), requiere codificada la probabilidad de cada clase en un vector, donde el índice con probabilidad 1 corresponde a la clase, esto se puede realizar con el siguiente código.

```
y_oh = jax.nn.one_hot(y, n_labels)
```

Ahora se cuenta con todos los elementos para implementar la función de Entropía Cruzada para múltiples clases, la cual se muestra en el siguiente fragmento.

```
@jax.jit
def media_entropia_cruzada(params, X, y_oh):
    hy = modelo(params, X)
    return - (y_oh * jnp.log(hy)).sum(axis=1).mean()
```

12.3.1. Optimización

El siguiente paso es encontrar los parámetros del modelo, para esto se utiliza el método de optimización visto en Regresión Logística (Sección 9.5) con algunos ajustes. Lo primero es que se desarrolla todo en una función `fit` que recibe el parámetro η, los parámetros a identificar y el número de épocas, es decir, el número de iteraciones que se va a realizar el procedimiento.

Dentro de la función `fit`se observa la función `update` que calcula los nuevos parámetros, también regresa el valor del error, esto para poder visualizar cómo va aprendiendo el modelo. La primera línea después de la función `update` genera la función que calculará el valor y el gradiente de la función `media_entropia_cruzada`. Finalmente viene el ciclo donde se realizan las actualizaciones de los parámetros y se guarda el error calculado en cada época.

```
def fit(eta, params, epocas=500):
    @jax.jit
    def update(params, eta, X, y_oh):
        _ , gs = error_grad(params, X, y_oh)
        return _, jax.tree.map(lambda p, g: p - eta * g,
                               params, gs)

    error_grad  = jax.value_and_grad(media_entropia_cruzada)
    error = []
    for i in range(epocas):
        _, params = update(params, eta, D, y_oh)
        error.append(_)
    return params, error
```

12.3.2. Optimización Método Adam

Como se había visto en la Sección 9.6 existen diferentes métodos para encontrar los parámetros, en particular en esta sección se utilizará el método Adam (implementado en la librería optax) para encontrar los parámetros de la Regresión Logística Multinomial. Se decide utilizar este método dado que su uso es frecuente en la identificación de parámetros de redes neuronales.

Siguiendo la misma estructura que la función `fit`, la función `adam` recibe tres parámetros el primero es la instancia de optimizador, la segunda son los parámetros y finalmente el número de épocas que se va a ejecutar. La primera línea de la función `update` (que se encuentra en `adam`) calcula el valor de la función de error y su gradiente, estos son utilizados por `optimizer.update` para calcular la actualización de parámetros así como el nuevo estado del optimizador, los nuevos parámetros son calculados en la tercera línea y la función regresa los nuevos parámetros, el estado del optimizador y el error en esa iteración. La primera línea después de `update` inicializa el optimizador, después se genera la función que calculará el valor y gradiente de la función `media_entropia_cruzada`. El ciclo llama la función `update` y guarda el error encontrado en cada época.

```
def adam(optimizer, params, epocas=500):
    @jax.jit
    def update(params, opt_state, X, y_oh):
        loss_value, grads = error_grad(params,
                                       X,
                                       y_oh)
        updates, opt_state = optimizer.update(grads,
                                              opt_state,
                                              params)
        params = optax.apply_updates(params, updates)
```

```
        return params, opt_state, loss_value

    opt_state = optimizer.init(params)
    error_grad  = jax.value_and_grad(media_entropia_cruzada)
    error = []
    for i in range(epocas):
        params, opt_state, loss_value = update(params,
                                               opt_state,
                                               D,
                                               y_oh)
        error.append(loss_value)
    return params, error
```

12.3.3. Comparación entre Optimizadores

Los optimizadores descritos anteriormente se pueden utilizar con el siguiente código, donde la primera línea calcula los parámetros iniciales, después se llama a la función `fit` para encontrar los parámetros con el primer método. La tercera línea genera una instancia del optimizador Adam; el cual se pasa a la función `adam` para encontrar los parámetros con este método.

```
params = parametros_iniciales()
p1, error1 = fit(1e-2, params)
optimizer = optax.adam(learning_rate=1e-2)
p2, error2 = adam(optimizer, params)
```

La Figura 12.1 muestra cómo la media de la Entropía Cruzada se minimiza con respecto a las épocas para los dos métodos. Se puede observar cómo el método `adam` converge más rápido y llega a un valor menor de Entropía Cruzada.

Finalmente la exactitud (Sección 2.3.2) en el conjunto de entrenamiento del modelo estimado con `fit` es 0.8867 (i.e., `(y == modelo(p1, D).argmax(axis=1)).mean()`) y del estimado con `adam` es 0.9667.

12.4. Perceptrón

La unidad básica de procesamiento en una red neuronal es el perceptrón, el cual es un viejo conocido de Discriminantes Lineales (Capítulo 8), es decir, $g(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} + \mathbf{w}_0$. En problemas de clasificación binaria se encuentran los parámetros de $g(\mathbf{x})$ de tal manera que genera un hiperplano y se clasifican los elementos de acuerdo al lado positivo o negativo del hiperplano.

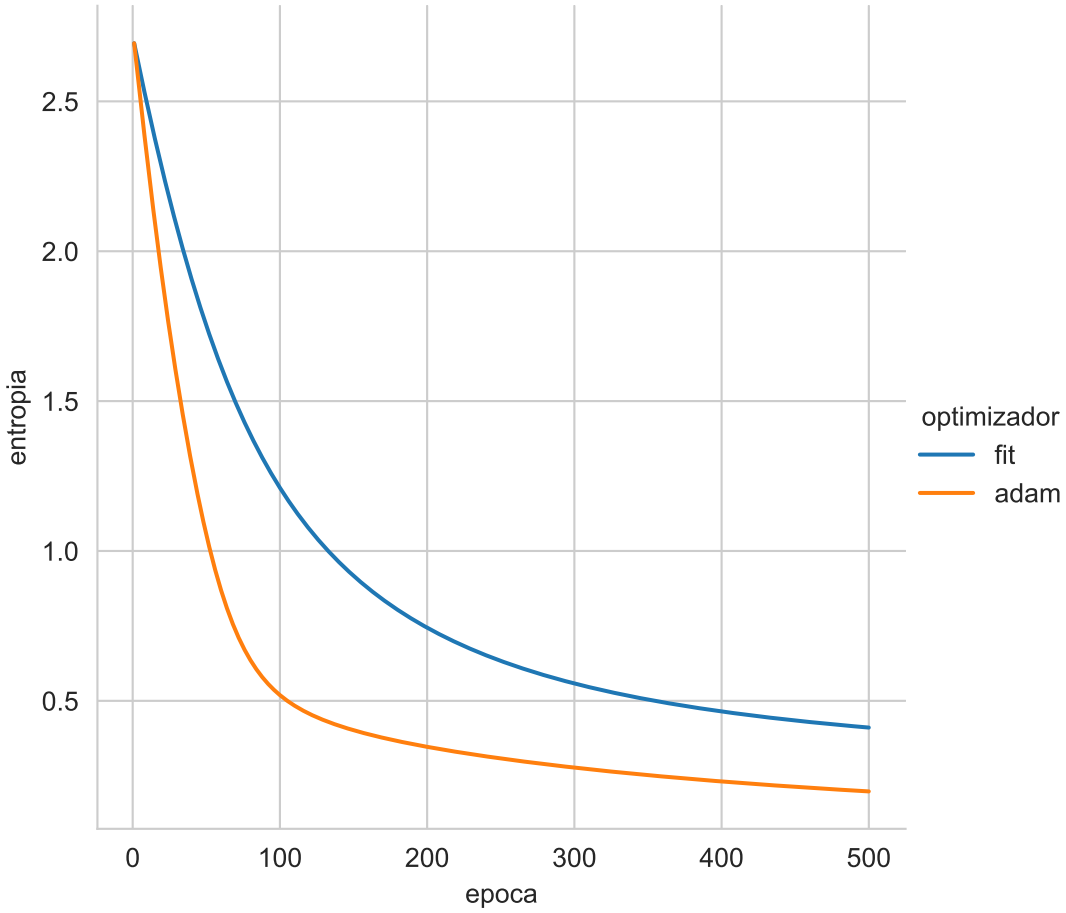


Figura 12.1: Comparación de diferentes optimizadores.

En problemas de Regresión (Sección 3.3) los parámetros de $g(\mathbf{x})$ se encuentran utilizando mínimos cuadrados.

En el caso de tener $K > 2$ clases entonces el problema se puede afrontar entrenando $g_k(\mathbf{x})$ perceptrones $(k = 1, \dots, K)$ tal y como se realizó Discriminantes Lineales (Sección 8.3.3). De manera concisa se puede definir a $g : \mathbb{R}^d \to \mathbb{R}^K$, es decir, $g(\mathbf{x}) = W\mathbf{x} + \mathbf{w}_0$ tal y como se realizó en Regresión Logística Multinomial (Sección 12.3). En el caso de desear conocer la probabilidad de pertenencia a una clase, en el caso binario se utilizó $g(\mathbf{x}) = \mathsf{sigmoid}(\mathbf{w} \cdot \mathbf{x} + \mathbf{w}_0)$ y en el caso multiclase $g(\mathbf{x}) = \mathsf{softmax}(W\mathbf{x} + \mathbf{w}_0)$.

12.4.1. Composición de Perceptrones Lineales

Se puede realizar una composición de perceptrones de la siguiente manera, sea $g_1 : \mathbb{R}^d \to \mathbb{R}^{d'}$ y $g_2 : \mathbb{R}^{d'} \to \mathbb{R}^K$, es decir $g = g_2 \circ g_1$. Realizando esta composición en las ecuaciones descritas anteriormente se tiene

$$\begin{aligned} \hat{\mathbf{y}}_1 &= g_1(\mathbf{x}) \\ \hat{\mathbf{y}} &= g_2(\hat{\mathbf{y}}_1) \end{aligned}$$

Expandiendo las ecuaciones anteriores se tiene

$$\begin{aligned} \hat{\mathbf{y}}_1 &= W_1\mathbf{x} + \mathbf{w}_{1_0} \\ \hat{\mathbf{y}} &= W_2\hat{\mathbf{y}}_1 + \mathbf{w}_{2_0} \\ &= W_2(W_1\mathbf{x} + \mathbf{w}_{1_0}) + \mathbf{w}_{2_0} \\ &= W_2W_1\mathbf{x} + W_2\mathbf{w}_{1_0} + \mathbf{w}_{2_0} \\ &= W\mathbf{x} + \mathbf{w}_0 \end{aligned}$$

como se puede observar la composición realizada da como resultado una red donde se tienen que identificar $W \in \mathbb{R}^{K \times d}$ y $\mathbf{w}_0 \in \mathbb{R}^d$, es decir, son K perceptrones equivalentes al modelado de Regresión Logística Multinomial. Esto es porque la composición fue con funciones lineales.

12.5. Perceptrón Multicapa

Para evitar que la composición de perceptrones colapse a una función equivalente, es necesario incluir una función no lineal, sea ϕ esta función no lineal, (a esta función se le conoce como **función de activación**) entonces se puede observar que la composición $g = g_2 \circ g_1$ donde $g_1 = \phi(W_1\mathbf{x} + \mathbf{w}_{1_0})$ resulta en

$$\begin{aligned}\hat{\mathbf{y}}_1 &= \phi(W_1\mathbf{x} + \mathbf{w}_{1_0}) \\ \hat{\mathbf{y}} &= W_2\hat{\mathbf{y}}_1 + \mathbf{w}_{2_0}\end{aligned}.$$

A la estructura anterior se le conoce como una red neuronal de una capa oculta, la salida de la capa oculta está en $\hat{\mathbf{y}}_1$ y la salida de la red es $\hat{\mathbf{y}}$. Siguiendo la notación anterior se puede definir una red neuronal con dos capas ocultas de la siguiente manera

$$\begin{aligned}\hat{\mathbf{y}}_1 &= \phi(W_1\mathbf{x} + \mathbf{w}_{1_0}) \\ \hat{\mathbf{y}}_2 &= \phi_2(W_2\hat{\mathbf{y}}_1 + \mathbf{w}_{2_0}), \\ \hat{\mathbf{y}} &= (W_3\hat{\mathbf{y}}_2 + \mathbf{w}_{3_0})\end{aligned}$$

donde la salida de la primera capa oculta ($\hat{\mathbf{y}}_1$) es la entrada de la segunda capa oculta y su salida ($\hat{\mathbf{y}}_2$) se convierte en la entrada de la capa de salida.

12.5.1. Desvanecimiento del Gradiente

Por lo expuesto hasta el momento se podría pensar que una candidata para ser la función ϕ es la función sigmoid, aunque esto es factible, esta presenta el problema de desvanecimiento del gradiente. Para ejemplificar este problema, se utilizan dos funciones $g_1(x) = w_1x + 1.0$ y $g_1(x) = w_2x + 1.0$; haciéndose la composición de estas dos funciones $g = g_2 \circ g_1$.

Las siguientes instrucciones implementan las funciones anteriores utilizando la librería JAX.

```
@jax.jit
def g_1(params, x):
    return jax.nn.sigmoid(params['w1'] * x + 1.0)

@jax.jit
def g_2(params, x):
    return jax.nn.sigmoid(params['w2'] * x + 1.0)

@jax.jit
def g(params, x):
    return g_2(params, g_1(params, x))
```

Utilizando unos parámetros aleatorios generados con el siguiente código

```
key = jax.random.PRNGKey(0)
key, subkey1, subkey2 = jax.random.split(key, num=3)
params = dict(w1=jax.random.normal(subkey1),
              w2=jax.random.normal(subkey2))
```

se tiene que la derivada de g_1 con respecto a w_1 (i.e., `jax.grad(g_1)(params, 1.0)`) y g_2 con respecto a w_2 (i.e., `jax.grad(g_2)(params, 1.0)`) es 0.1418 y 0.1171, respectivamente. El problema viene cuando se calcula $\frac{\partial g}{\partial w_1}$ en este caso se observa que el gradiente es pequeño comparado con el gradiente obtenido en $\frac{dg}{dw_1}$, i.e., `jax.grad(g)(params, 1.0)`, donde se observa que el gradiente para w_1 corresponde a 0.0157, el gradiente de w_2 sigue en la misma magnitud teniendo un valor de 0.1077.

El problema de desvanecimiento de gradiente, hace que el gradiente disminuya de manera exponencial, entonces los pesos asociados a las capas alejadas de la capa de salida reciben un gradiente equivalente a cero y no se cuenta con información para actualizar sus pesos. Por este motivo es recomendable utilizar funciones de activación que no presenten esta característica, una muy utilizada es $\mathsf{ReLU}(x) = \max(0, x)$.

12.6. Ejemplo: Dígitos

Para ejemplificar el uso de una red neuronal en un problema de clasificación se utilizarán los datos de Dígitos, los cuales se pueden obtener con las siguientes instrucciones.

```
X, y = load_digits(return_X_y=True)
T, G, y_t, y_g = train_test_split(X, y, test_size=0.2)
```

Un procedimiento necesario en redes neuronales es que los datos estén normalizados, tradicionalmente esto se realiza haciendo que los datos tengan media cero y desviación estándar uno. En las siguientes líneas se normalizan los datos usando la clase `StandardScaler` se puede observar que los parámetros para la normalización son encontrados en el conjunto de entrenamiento (`T`) y aplicados tanto al conjunto de entrenamiento como el conjunto de prueba `G`.

```
normalize = StandardScaler().fit(T)
T = normalize.transform(T)
G = normalize.transform(G)
```

Como se realizó previamente es necesario convertir las clases de salida para que cada ejemplo sea un vector unitario donde el índice con el valor 1 representa la clase, esto se realiza con las siguientes instrucciones.

```
n_labels = np.unique(y).shape[0]
yt_oh = jax.nn.one_hot(y_t, n_labels)
```

Es momento de decidir la estructura de la red neuronal, las únicas dos restricciones es que la primera capa tiene que tener la dimensión del vector de entrada, en este caso corresponde a 64 (`T.shape[1]`) y la última capa tiene que tener de salida el número de clases, en este caso 10 (`n_labels`), el resto de las capas ocultas pueden tener cualquier valor solamente es necesario que las dimensiones sean coherentes con la operación que se va a realizar.

La red que se va a implementar es la siguiente, como super-índice se encuentran las dimensiones para que sea más fácil seguir la estructura de la red.

$$\begin{aligned}
\hat{\mathbf{y}}_1^{32} &= \phi(W^{32\times 64}\mathbf{x}^{64} + \mathbf{w}_{1_0}^{32}) \\
\hat{\mathbf{y}}_2^{16} &= \phi(W^{16\times 32}\hat{\mathbf{y}}_1^{32} + \mathbf{w}_{2_0}^{16}) \\
\hat{\mathbf{y}}^{10} &= W^{10\times 16}\hat{\mathbf{y}}_2^{16} + \mathbf{w}_{3_0}^{10}
\end{aligned}$$

Considerando que las entradas se encuentran en una matriz $X^{N\times 64}$, entonces se puede definir esta estructura en términos de multiplicación de matrices, lo cual queda como

$$\begin{aligned}
\hat{Y}_1^{N\times 32} &= \phi(X^{N\times 64}W^{64\times 32} + \mathbf{w}_{1_0}^{32}) \\
\hat{Y}_2^{N\times 16} &= \phi(\hat{Y}_1^{N\times 32}W^{32\times 16} + \mathbf{w}_{2_0}^{16}), \\
\hat{Y}^{N\times 10} &= \hat{Y}_2^{N\times 16}W^{16\times 10} + \mathbf{w}_{3_0}^{10}
\end{aligned}$$

donde la suma con el término $\mathbf{w}_0$ se realiza en la dimensión que corresponde y se replica tantas veces para cumplir con la otra dimensión. Esta configuración se puede expresar en una lista como la que se muestra a continuación.

```
d = [64, 32, 16, 10]
```

Utilizando esta notación los parámetros iniciales de la red se pueden generar con la siguiente función, se puede observar cómo el ciclo está iterando por los elementos de `d` creando pares, para generar las dimensiones adecuadas para las matrices W.

```
def parametros_iniciales(d, key=0):
    key = jax.random.PRNGKey(key)
    params = []
    for init, end in zip(d, d[1:]):
```

```
        key, subkey1, subkey2 = jax.random.split(key, num=3)
        _ = dict(w=jax.random.normal(subkey1, (init, end)) * jnp.sqrt(2 / (init * end)),
                 w0=jax.random.normal(subkey2, (end, )) * jnp.sqrt(2 / end))
        params.append(_)
    return params
```

Habiendo generado los parámetros iniciales de la red, es momento para implementar la red, la siguiente función implementa la red, se puede observar cómo se realizan las operaciones matriciales tal y como se mostraron en las ecuaciones anteriores. La función de activación ϕ seleccionada fue ReLU que está implementada en la función `jax.nn.relu`.

```
@jax.jit
def ann(params, D):
    y1 = jax.nn.relu(D @ params[0]['w'] + params[0]['w0'])
    y2 = jax.nn.relu(y1 @ params[1]['w'] + params[1]['w0'])
    return y2 @ params[2]['w'] + params[2]['w0']
```

Como medida de error se usa la Entropía Cruzada (Sección 2.3.7) tal y como se implementa a continuación. El caso $0 \log 0$ corresponde a un valor no definido lo cual genera que el valor de la función tampoco esté definido, para proteger la función en ese caso se usa `jnp.nansum` que trata los valores no definidos como ceros.

```
@jax.jit
def media_entropia_cruzada(params, D, y_oh):
    hy = jax.nn.softmax(ann(params, D), axis=1)
    return - jnp.nansum(y_oh * jnp.log(hy), axis=1).mean()
```

En esta ocasión se utiliza el optimizador Adam, tal y como se muestra en la siguiente función. La única diferencia con respecto al visto previamente es la función `update_finite` que actualiza los parámetros siempre y cuando el nuevo valor sea un valor numérico, de lo contrario se queda con el valor anterior.

```
def adam(optimizer, params, epocas=500):
    @jax.jit
    def update_finite(a, b):
        m = jnp.isfinite(b)
        return jnp.where(m, b, a)

    @jax.jit
    def update(params, opt_state, X, y_oh):
        loss_value, grads = error_grad(params, X, y_oh)
```

```
        updates, opt_state = optimizer.update(grads, opt_state, params)
        params = optax.apply_updates(params, updates)
        return params, opt_state, loss_value

    opt_state = optimizer.init(params)
    error_grad  = jax.value_and_grad(media_entropia_cruzada)
    error = []
    for i in range(epocas):
        p, opt_state, loss_value = update(params, opt_state, T, yt_oh)
        params = jax.tree.map(update_finite, params, p)
        error.append(loss_value)
    return params, error
```

Finalmente, la red creada se entrena utilizando las siguientes instrucciones, donde la primera línea genera los parámetros iniciales, después se inicializa el optimizador y en la línea final se llama al optimizador con los parámetros y número de épocas.

```
params = parametros_iniciales(d)
optimizer = optax.adam(learning_rate=1e-2)
p, error = adam(optimizer, params, epocas=500)
```

El resultado de esta red, es que el error en el conjunto de prueba es 0.0361 calculado con la siguiente instrucción `(ann(p, G).argmax(axis=1) != y_g).mean()`.

12.7. Ejemplo: Diabetes

Para ejemplificar el uso de una red neuronal en un problema de regresión se utilizan los datos de Diabetes (Sección B.2.3.2), donde se desea predecir una medida cuantitativa de la progresión de la enfermedad a partir de 10 variables de cada paciente. Los datos se obtienen y se parten en los conjuntos de entrenamiento y prueba con las siguientes instrucciones; se fija la semilla (`random_state=0`) para que la partición sea la misma en cada ejecución.

```
X, y = load_diabetes(return_X_y=True)
T, G, y_t, y_g = train_test_split(X, y, test_size=0.2, random_state=0)
```

Al igual que en el ejemplo anterior, las entradas se normalizan para que tengan media cero y desviación estándar uno; los parámetros de la normalización se encuentran únicamente en el conjunto de entrenamiento (`T`) y se aplican tanto a `T` como a `G`.

```
normalize = StandardScaler().fit(T)
T = normalize.transform(T)
G = normalize.transform(G)
```

En regresión también conviene normalizar la variable dependiente. Los valores de y se encuentran en una escala muy distinta a la de las entradas, mientras que la red se inicializa para producir salidas cercanas a cero. Por este motivo, la red se entrena para predecir la variable dependiente normalizada con la media y la desviación estándar del conjunto de entrenamiento, y sus predicciones se regresan a la escala original antes de medir el rendimiento. Las siguientes instrucciones calculan estos dos valores y la variable dependiente normalizada de entrenamiento.

```
mu, sigma = y_t.mean(), y_t.std()
yt_n = (y_t - mu) / sigma
```

La estructura de la red es la misma que en el ejemplo de Dígitos, con dos capas ocultas y función de activación ReLU. La diferencia está en la capa de salida: en clasificación tenía una neurona por clase y las salidas pasaban por softmax para interpretarse como probabilidades, en regresión se predice un único número, por lo que la última capa tiene una sola neurona y su salida se utiliza tal cual, es decir, no se le aplica ninguna función. La estructura $\mathbb{R}^{10} \to \mathbb{R}^{32} \to \mathbb{R}^{16} \to \mathbb{R}$ queda representada en la siguiente lista.

```
d = [T.shape[1], 32, 16, 1]
```

Se observa que la única restricción para la primera capa es que tenga la dimensión del vector de entrada, que en este caso es 10 (`T.shape[1]`), y que la última capa tiene dimensión 1 porque se predice un único valor.

Los parámetros iniciales (`parametros_iniciales`) y la red (`ann`) son los mismos que se definieron en el ejemplo de Dígitos; la función `ann` regresa una matriz con una sola columna, por lo que en la función de pérdida se aplica `flatten` para obtener un vector. Como medida de error se utiliza el error cuadrático medio (Ecuación 2.4), que es la función que se minimiza en regresión (Sección 3.3).

```
@jax.jit
def media_error_cuadratico(params, D, y):
    return ((ann(params, D).flatten() - y) ** 2).mean()
```

El optimizador es Adam, igual que en el ejemplo anterior. La función `adam_regresion` sigue la misma estructura que `adam`; las diferencias son que la función de error es `media_error_cuadratico` y que los datos de entrenamiento se reciben como parámetros (`X` y `y`) en lugar de estar fijos en la función.

```
def adam_regresion(optimizer, params, X, y, epocas=500):
    @jax.jit
    def update_finite(a, b):
        m = jnp.isfinite(b)
        return jnp.where(m, b, a)

    @jax.jit
    def update(params, opt_state, X, y):
        loss_value, grads = error_grad(params, X, y)
        updates, opt_state = optimizer.update(grads, opt_state, params)
        params = optax.apply_updates(params, updates)
        return params, opt_state, loss_value

    opt_state = optimizer.init(params)
    error_grad  = jax.value_and_grad(media_error_cuadratico)
    error = []
    for i in range(epocas):
        p, opt_state, loss_value = update(params, opt_state, X, y)
        params = jax.tree.map(update_finite, params, p)
        error.append(loss_value)
    return params, error
```

La red se entrena con las siguientes instrucciones, que primero generan los parámetros iniciales, después inicializan el optimizador y finalmente llaman a `adam_regresion` con los datos de entrenamiento normalizados. Es importante notar que el conjunto de entrenamiento es pequeño comparado con el número de parámetros de la red, por lo que entrenar durante demasiadas épocas hace que la red se ajuste al ruido del conjunto de entrenamiento (sobreajuste); en este ejemplo se utiliza una tasa de aprendizaje pequeña y un número moderado de épocas. El número de épocas es un hiperparámetro que se puede seleccionar con un conjunto de validación (Sección 2.5).

```
params = parametros_iniciales(d)
optimizer = optax.adam(learning_rate=1e-3)
p, error = adam_regresion(optimizer, params, T, yt_n, epocas=200)
```

La Figura 12.2 muestra cómo el error cuadrático medio (calculado sobre la variable dependiente normalizada) disminuye conforme avanzan las épocas.

Para medir el rendimiento en el conjunto de prueba, las predicciones de la red se regresan a la escala original, es decir, se multiplican por la desviación estándar `sigma` y se suma la media `mu`. Como referencia se ajusta una regresión lineal (Sección 3.3) con los mismos datos de entrenamiento y se obtienen sus predicciones en el conjunto de prueba.

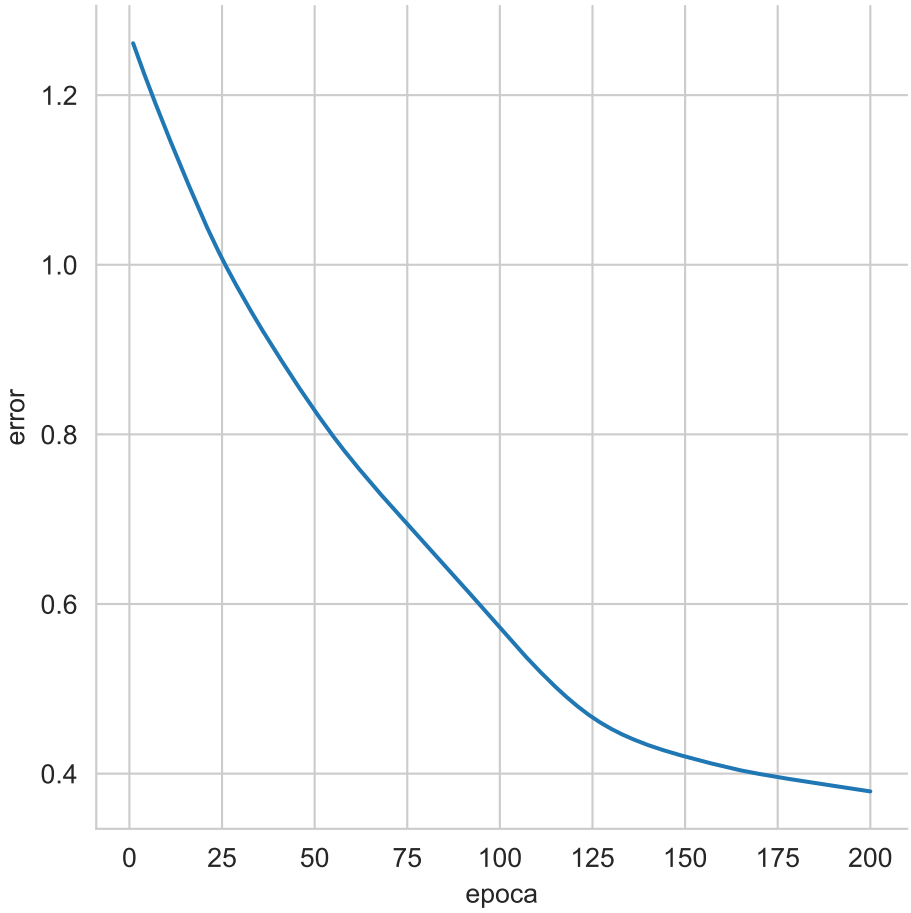


Figura 12.2: Error cuadrático medio en el conjunto de entrenamiento en cada época.

```
hy_ann = np.array(ann(p, G).flatten()) * sigma + mu
hy_lr = LinearRegression().fit(T, y_t).predict(G)
```

El rendimiento se mide con el coeficiente de determinación R^2 (Ecuación 2.7) implementado en `CompStats`, tal y como se hizo en Sección 2.4. La siguiente instrucción calcula el R^2 de la red neuronal en el conjunto de prueba; el parámetro `name` es el nombre con el que aparecerá la red en las comparaciones.

```
r2 = r2_score(y_g, hy_ann, name='Red Neuronal', use_tqdm=False)
```

El R^2 de la red neuronal es 0.3024 con un error estándar de 0.1137. Para compararla con la regresión lineal se agregan sus predicciones al mismo objeto y se grafican, el resultado se muestra en la Figura 12.3.

```
r2(hy_lr, name='Regresión Lineal')
r2.plot(comp_legend='Comparación',
        winner_legend='Mejor',
        tie_legend='Equivalente',
        loser_legend='Diferente',
        alg_legend='Algoritmo',
        var_name='Rendimiento')
```

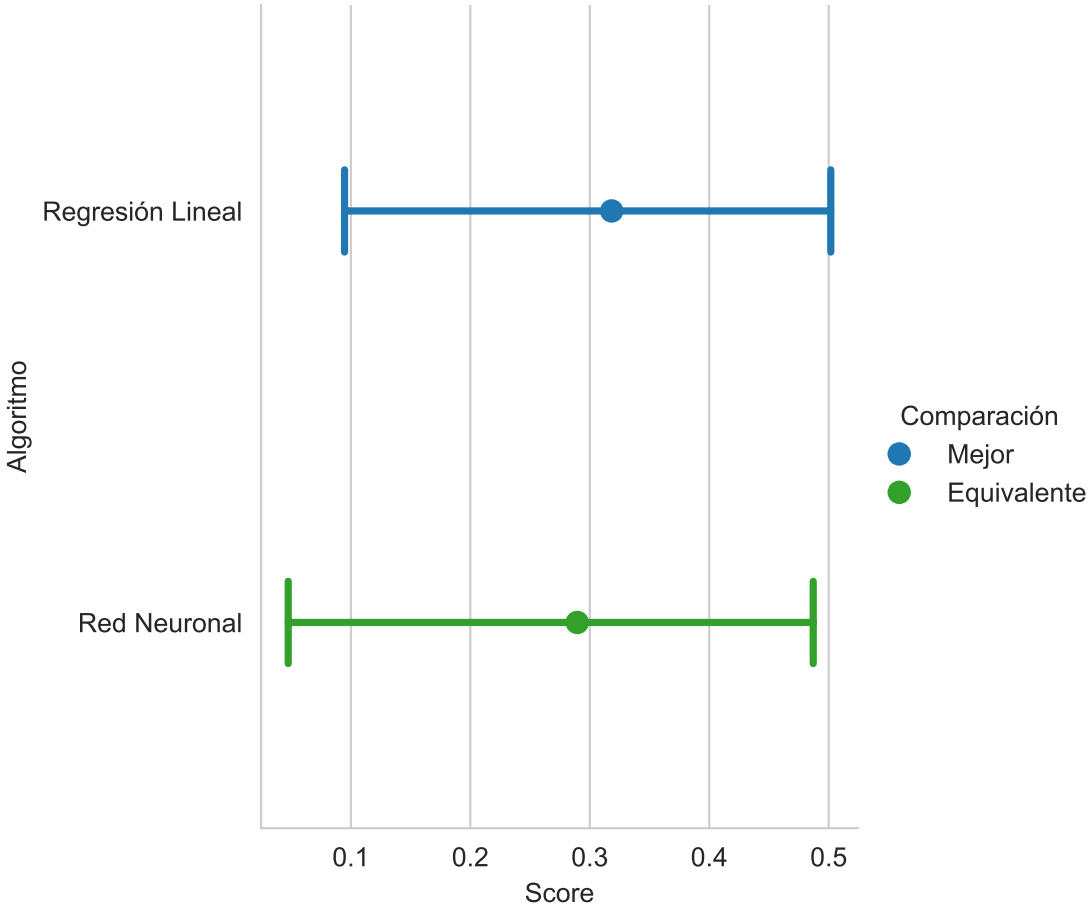


Figura 12.3: Rendimiento (R^2) de la red neuronal y de la regresión lineal en el conjunto de prueba.

En la figura se observa el R^2 de cada algoritmo con su intervalo de confianza, estimado mediante bootstrap. La figura también indica cuál es el algoritmo con el mejor rendimiento (`Mejor`) y, para el otro algoritmo, si su rendimiento es estadísticamente equivalente (`Equivalente`) o diferente (`Diferente`) con respecto al mejor. El R^2 de la regresión lineal es 0.3322 con un error estándar de 0.1045.

Finalmente, la Figura 12.4 muestra el valor real contra el valor predicho por la red neuronal en el conjunto de prueba, la línea punteada es la identidad, es decir, las predicciones perfectas.

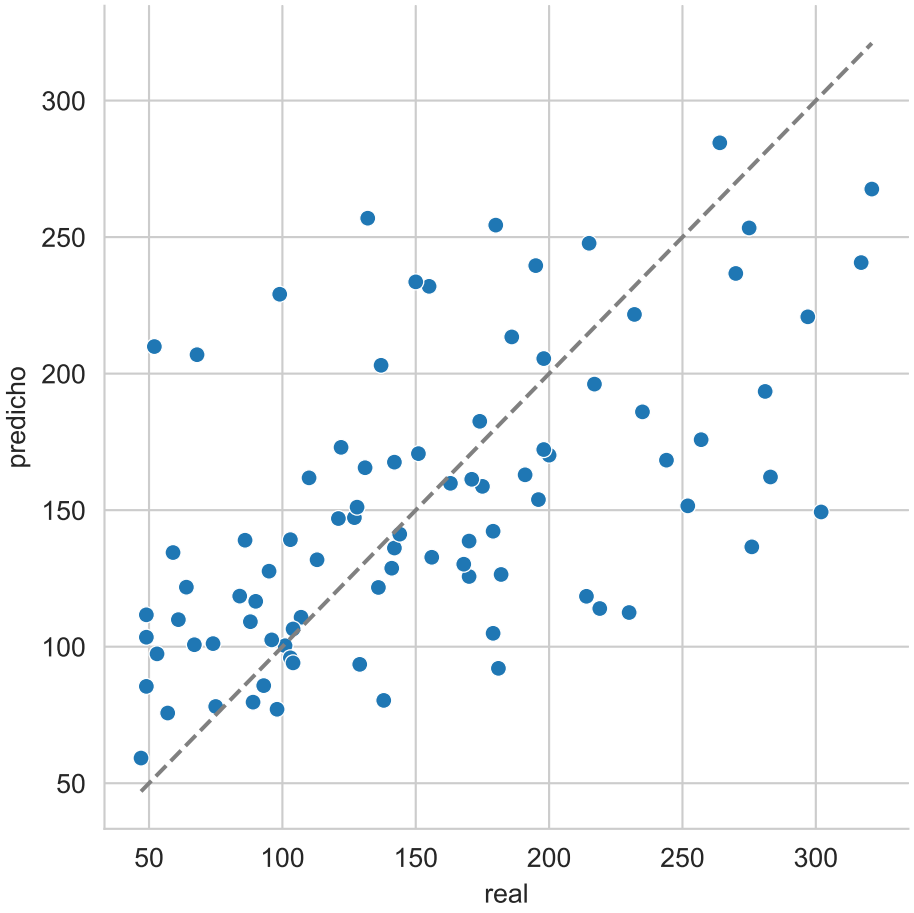


Figura 12.4: Valor real contra valor predicho por la red neuronal en el conjunto de prueba.

Actividad

Comparar el rendimiento (R^2) en el conjunto de prueba de redes neuronales con diferente número de neuronas en las capas ocultas, i.e., modificando los valores 32 y 16 de la lista `d`, tal y como se muestra en la Figura 12.5. Utilizar los mismos datos de Diabetes, la misma partición y el mismo procedimiento de entrenamiento descrito en esta sección; el rendimiento se compara con `CompStats`.

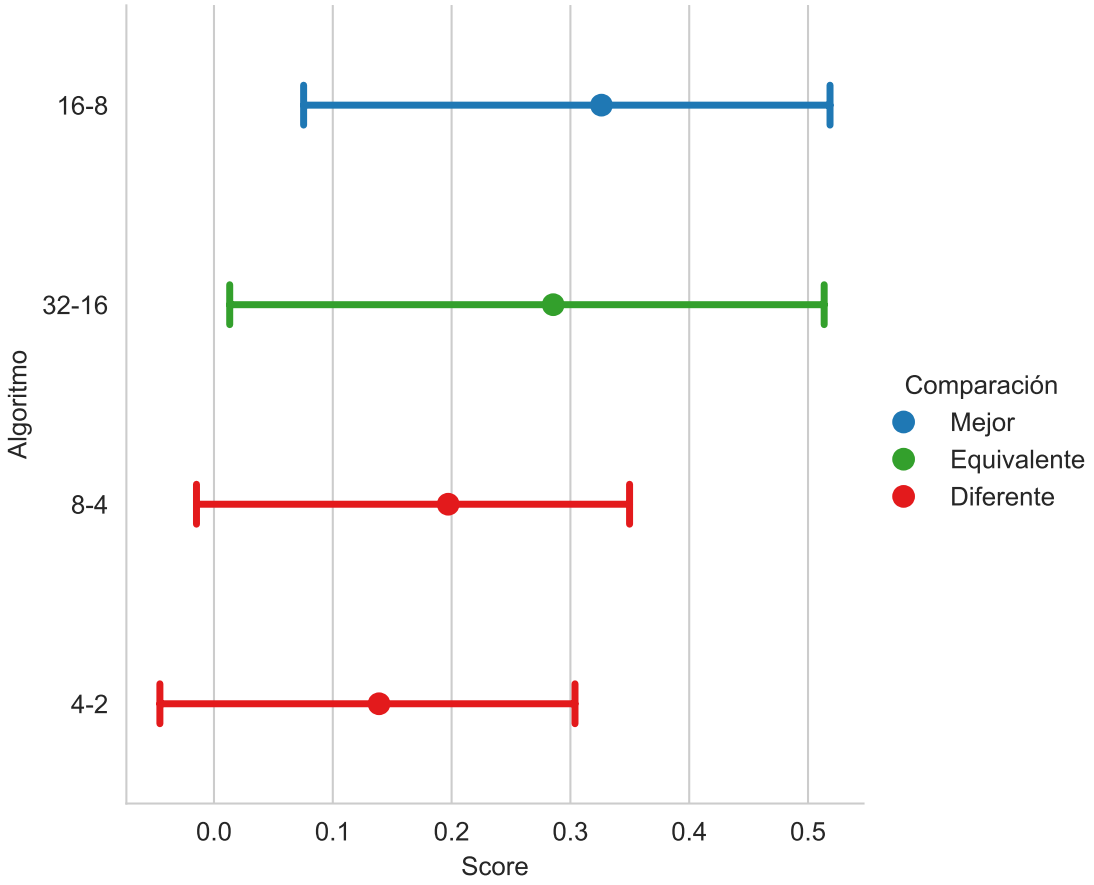


Figura 12.5: Rendimiento (R^2) de redes neuronales con diferente número de neuronas en las capas ocultas.

12.8. Resumen

Una red neuronal se construye componiendo funciones simples. La regresión logística multinomial (Sección 12.3) es el punto de partida, y el perceptrón (Sección 12.4) es una unidad que calcula

una combinación lineal de las entradas. Componer perceptrones lineales no agrega capacidad, y por eso el perceptrón multicapa incluye una función de activación no lineal. La elección de esa función importa, pues algunas provocan el desvanecimiento del gradiente que impide entrenar redes profundas. Los parámetros se ajustan con las herramientas de Capítulo 9, y el método Adam (Sección 12.3.2) es un ejemplo de regla de actualización que suele converger más rápido que el descenso por gradiente simple. El mismo marco sirve para clasificación y para regresión (Sección 12.7).

La flexibilidad de las redes exige disciplina en la evaluación. La arquitectura y los hiperparámetros se deben validar fuera de muestra con los procedimientos de Capítulo 2, porque una red con suficientes parámetros puede ajustar casi cualquier conjunto de entrenamiento. En política pública esto significa que un buen ajuste en los datos disponibles no basta para confiar en la predicción sobre casos nuevos.

Con este capítulo termina el aprendizaje supervisado. Queda la pregunta de qué hacer cuando no se tiene una variable respuesta y solo se quiere entender la estructura de los datos, lo que empieza con la reducción de dimensión en Capítulo 13.

13 Reducción de Dimensión

El **objetivo** de la unidad es aplicar técnicas de reducción de dimensionalidad, para mejorar el aprendizaje y para visualizar los datos

Paquetes usados

```
from sklearn.datasets import load_iris,\
                             load_digits
from sklearn.preprocessing import StandardScaler
from sklearn import decomposition
import umap
import numpy as np
import pandas as pd
import matplotlib as mpl
import seaborn as sns
```

13.1. Introducción

Existen ocasiones donde las variables que describen al problema no contribuyen dentro de la solución, o su aporte está dado por otras componentes de la descripción. Esto trae como consecuencia, en el mejor de los casos, que el algoritmo tenga un mayor costo computacional o, en un caso menos afortunado, que tenga un rendimiento menor al que se hubiera obtenido con una mejor representación. Es pertinente mencionar que el caso contrario, el incremento del número de variables, es también un escenario factible y se abordará en otra ocasión.

Reducir la dimensión de un problema es transformar la representación original $x \in \mathbb{R}^d$ a una representación $\hat{x} \in \mathbb{R}^m$ donde $m < d$. Tiene dos usos: mejorar el aprendizaje, pues el objetivo es que la nueva representación $\hat{x}$ contenga la información necesaria para realizar la tarea de clasificación o regresión; y visualizar los datos, reduciendo a $\mathbb{R}^2$ o $\mathbb{R}^3$, donde el objetivo es que se mantengan en la reducción las características de los datos en $\mathbb{R}^d$.

La **selección** de variables, que escoge un subconjunto de las variables originales sin transformarlas, se trató en la Capítulo 4. Este capítulo trata las **proyecciones**, que construyen variables nuevas a partir de las originales: Análisis de Componentes Principales (PCA) y UMAP.

13.2. Análisis de Componentes Principales

Los métodos de selección de variables (Capítulo 4) requieren un conjunto de entrenamiento de aprendizaje supervisado, por lo que no podrían ser utilizados en problemas de aprendizaje no-supervisado. En esta sección se revisará el uso de Análisis de Componentes Principales (Principal Components Analysis - PCA) para la reducción de dimensión. PCA tiene la firma: $f : \mathbb{R}^d \to \mathbb{R}^m$ donde $m < d$

La idea de PCA es buscar una matriz de proyección $W^\top \in \mathbb{R}^{m \times d}$ tal que los elementos de $\mathcal{D} = \{x_i\}$ sean transformados utilizando $z = W^\top x$ donde $z \in \mathbb{R}^m$. El objetivo es que la muestra z_1 tenga la mayor variación posible. Es decir, se quiere observar en la primera característica de los elementos transformados la mayor variación; esto se puede lograr de la siguiente manera.

Si suponemos que $\mathbf{x} \sim \mathcal{N}_d(\mu, \Sigma)$ y $\mathbf{w} \in \mathbb{R}^d$ entonces $\mathbf{w} \cdot \mathbf{x} \sim \mathcal{N}(\mathbf{w} \cdot \mu, \mathbf{w}^\top \Sigma \mathbf{w})$ y por lo tanto $\mathsf{Var}(\mathbf{w} \cdot \mathbf{x}) = \mathbf{w}^\top \Sigma \mathbf{w}$.

Utilizando esta información se puede describir el problema como encontrar $\mathbf{w}_1$ tal que $\mathsf{Var}(\mathbf{z}_1)$ sea máxima, donde $\mathsf{Var}(\mathbf{z}_1) = \mathbf{w}_1^\top \Sigma \mathbf{w}_1$. Dado que en este problema de optimización tiene múltiples soluciones, se busca además maximizar bajo la restricción de $|| \mathbf{w}_1 ||= 1$. Escribiéndolo como un problema de Lagrange quedaría como: $\max_{\mathbf{w}_1} \mathbf{w}_1^\top \Sigma \mathbf{w}_1 - \alpha(\mathbf{w}_1 \cdot \mathbf{w}_1 - 1)$. Derivando con respecto a $\mathbf{w}_1$ se tiene que la solución es: $\Sigma \mathbf{w}_i = \alpha \mathbf{w}_i$ donde esto se cumple solo si $\mathbf{w}_1$ es un vector propio de Σ y α es el valor propio correspondiente. Para encontrar $\mathbf{w}_2$ se requiere $|| \mathbf{w}_2 ||= 1$ y que los vectores sean ortogonales, es decir, $\mathbf{w}_2 \cdot \mathbf{w}_1 = 0$. Realizando las operaciones necesarias se encuentra que $\mathbf{w}_2$ corresponde al segundo vector propio y así sucesivamente.

13.2.1. Ejemplo - Visualización

Supongamos que deseamos visualizar los ejemplos del problema del iris. Los ejemplos se encuentran en $\mathbb{R}^4$ entonces para poderlos graficar en $\mathbb{R}^2$ se requiere realizar una transformación como podría ser Análisis de Componentes Principales.

Empezamos por cargar los datos del problema tal y como se muestra en la siguiente instrucción, en la segunda línea se normalizan los datos para tener una media 0 y desviación estándar 1, este procedimiento es necesario cuando los valores de las características se encuentran en diferentes escalas.

```
D, y = load_iris(return_X_y=True)
D = StandardScaler().fit_transform(D)
```

Habiendo importado los datos el siguiente paso es inicializar la clase de PCA, para esto requerimos especificar el parámetro que indica el número de componentes deseado, dado que el objetivo es representar en $\mathbb{R}^2$ los datos, entonces ocupamos dos componentes. La primera línea inicializa la clase de PCA, después, en la segunda línea se hace la proyección.

```
pca = decomposition.PCA(n_components=2).fit(D)
Xn = pca.transform(D)
```

El siguiente código se utiliza para visualizar los datos. El resultado se muestra en la Figura 13.1, donde se observa en diferente color cada una de las clases.

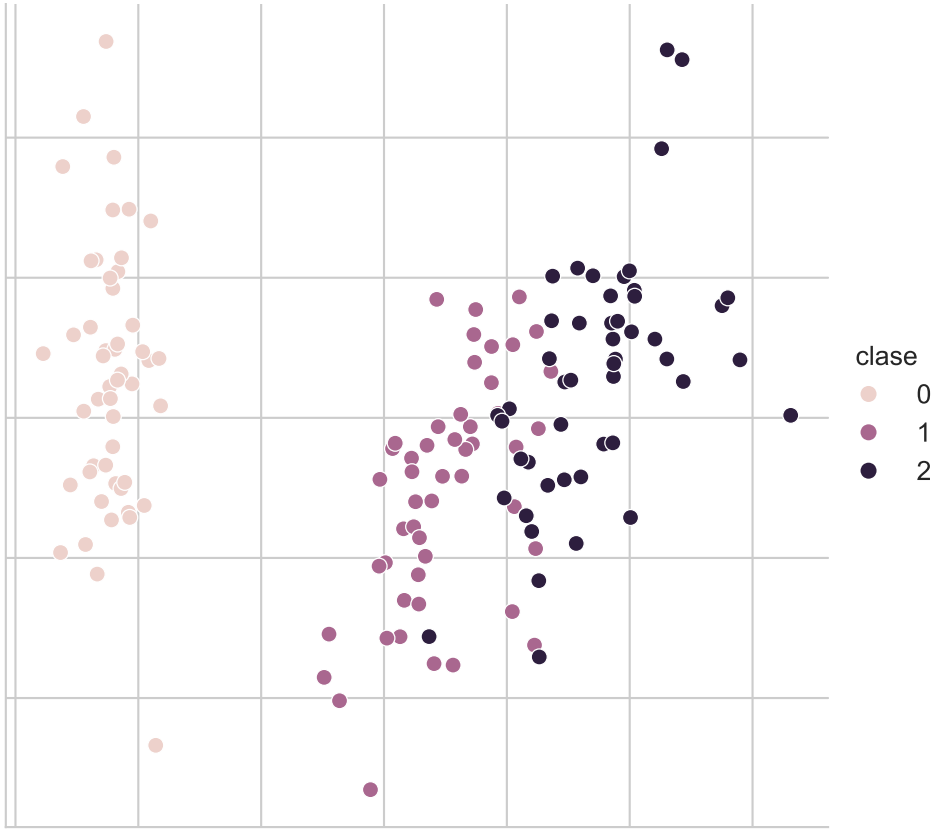


Figura 13.1: Proyección mediante PCA del problema del Iris

13.3. UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction

En esta sección se presenta el uso de UMAP propuesto por McInnes et al. (2020). UMAP es una técnica no lineal para reducir la dimensión y que con dimensiones bajas ($d = 2$) permite tener una visualización de los datos. El ejemplo que se realizará es visualizar mediante UMAP los datos del problema de Dígitos, estos datos se pueden obtener con la siguiente instrucción; en estas instrucciones también se normalizan los datos para tener una media 0 y desviación estándar 1.

```
D, y = load_digits(return_X_y=True)
D = StandardScaler().fit_transform(D)
```

Con el objetivo de ilustrar la diferencia entre una técnica de proyección lineal como PCA con respecto a una técnica no lineal, la Figura 13.2 presenta la proyección del conjunto de Dígitos utilizando PCA. Como se puede observar en la figura, esta proyección no da una separación clara entre grupos, aunque sí se puede identificar una estructura, donde algunos números se encuentran en la periferia de la figura.

UMAP genera una proyección que intuitivamente trata de preservar la distancia que existe entre los K vecinos cercanos en la dimensión original como en la dimensión destino. Por este motivo un parámetro importante de UMAP es la cantidad de vecinos, que tiene el efecto de priorizar la estructura global o local de los datos. En el siguiente código se realiza una exploración de este parámetro generando una visualización para $K = [2, 4, 8, 16]$. El código que realiza esta exploración se muestra en las siguientes instrucciones.

```
df = pd.DataFrame()
for K in [2, 4, 8, 16]:
    reducer = umap.UMAP(n_neighbors=K)
    low_dim = reducer.fit_transform(D)
    _ = pd.DataFrame(low_dim, columns=['x', 'y'])
    _['Clase'] = y
    _['K'] = K
    df = pd.concat((df, _))
```

La Figura 13.3 muestra las diferentes visualizaciones cuando el número de vecinos cambia en UMAP, se puede observar cómo para $K = 2$ la visualización no muestra ninguna estructura, pero partiendo de $K = 4$ se puede visualizar grupos que corresponden a los diferentes dígitos.

Con el objetivo de mostrar con mayor detalle los grupos encontrados, la Figura 13.4 muestra la visualización de $K = 8$ en ella se puede observar cómo los ejemplos se agrupan de acuerdo al dígito que representan, también se puede ver la similitud entre los diferentes dígitos y cómo algunos ejemplos están muy cerca a un grupo al cual no pertenecen.

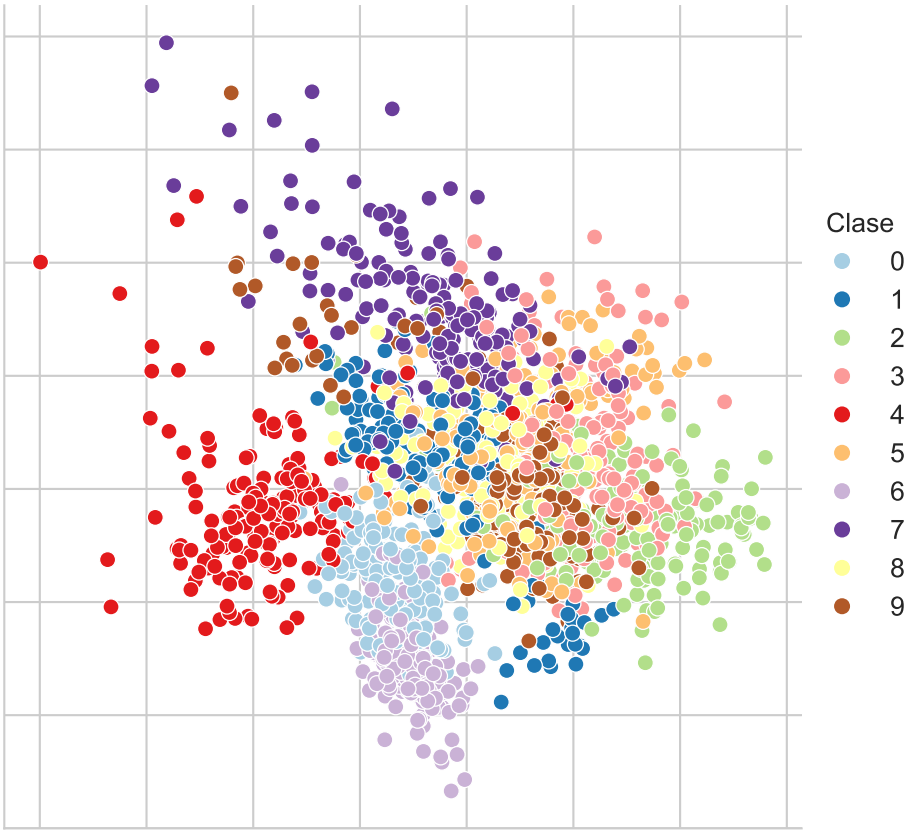


Figura 13.2: Proyección mediante PCA del problema de Dígitos

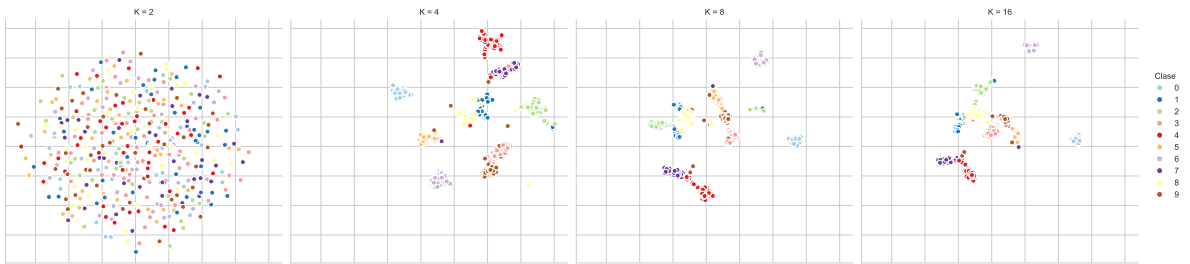


Figura 13.3: Proyección mediante UMAP del problema de Dígitos variando el número de vecinos

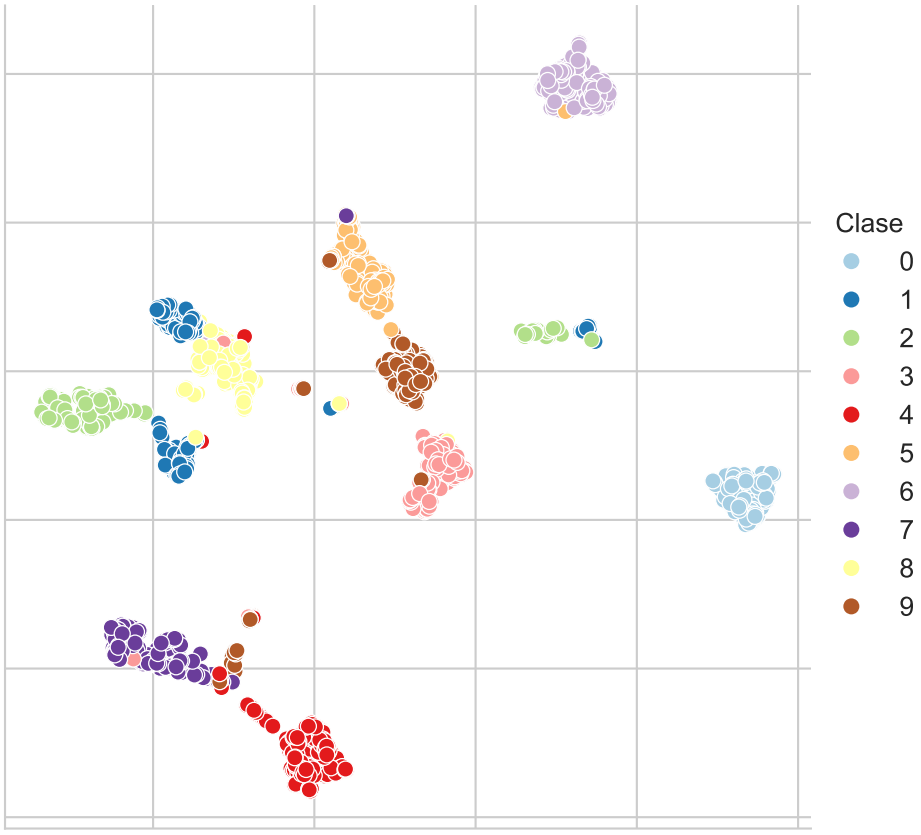


Figura 13.4: Proyección mediante UMAP del problema de dígitos con ocho vecinos

13.4. Resumen

Reducir la dimensión es transformar la representación original en una con menos variables, ya sea para mejorar el aprendizaje o para visualizar los datos. A diferencia de la selección de variables (Capítulo 4), que escoge un subconjunto de las variables originales, las proyecciones construyen variables nuevas a partir de ellas. El Análisis de Componentes Principales (Sección 13.2) encuentra las direcciones de mayor varianza y produce una proyección lineal, mientras que UMAP (Sección 13.3) busca preservar la vecindad de los datos y puede revelar estructuras que una proyección lineal no muestra. La Figura 13.3 muestra además que el resultado de UMAP depende de sus hiperparámetros, por lo que debe leerse con cautela.

En política pública la reducción de dimensión sirve para construir índices que resumen muchas variables en una sola, como un índice de marginación, y para visualizar poblaciones o territorios descritos por decenas de indicadores. Un índice construido con componentes principales tiene la ventaja de que sus pesos salen de los datos, pero también significa que lo que se mide es la dirección de mayor variación y no necesariamente lo que la política considera importante.

Cuando una visualización sugiere que los datos forman grupos, el paso siguiente es encontrarlos de manera formal, lo que se hace con los métodos de agrupamiento de Capítulo 14.

14 Agrupamiento

El **objetivo** de la unidad es conocer y aplicar el algoritmo de agrupamiento k-medias

14.1. Paquetes usados

```
from sklearn.cluster import KMeans
from sklearn.datasets import load_iris
from sklearn import decomposition
from sklearn import metrics
from scipy import linalg
from itertools import permutations
from matplotlib import pylab as plt
import numpy as np
import pandas as pd
import seaborn as sns
```

14.2. Introducción

Esta unidad trata el problema de agrupamiento, el cual es un problema de aprendizaje no supervisado (Sección 1.5), en el cual se cuenta con un conjunto $\mathcal{D} = \{x_i \mid i = 1, \dots, N\}$ donde $x_i \in \mathbb{R}^d$. El objetivo de agrupamiento es separar los elementos de $\mathcal{D}$ en K grupos. Es decir asociar a $x_i \in \mathcal{D}$ a un grupo $x_i \in G_j$ donde $\cup_j^K G_j = \mathcal{D}$ y $G_j \cap G_i = \emptyset$ para todo $i \neq j$.

Por supuesto existen diferentes algoritmos que se han desarrollado para generar esta partición, en particular, todos ellos encuentran la partición optimizando una función objetivo que se considera adecuada para el problema que se está analizando. En particular, esta unidad se enfoca a describir uno de los algoritmos de agrupamiento más utilizados que es K-medias.

14.3. K-medias

De manera formal el objetivo de K-medias es encontrar la partición $G = \{G_1, G_2, \ldots, G_K\}$ que corresponda al mín $\sum_{i=1}^{K} \sum_{x \in G_i} || x - \mu_i ||$, donde μ_i es la media de todos los elementos que pertenecen a G_i.

Para comprender la función objetivo (mín $\sum_{i=1}^{K} \sum_{x \in G_i} || x - \mu_i ||$) de k-medias se explican los dos componentes principales que son las medias μ_i y los grupos G_i.

Para ilustrar tanto a μ_i como a G_i se utiliza el problema del iris (Sección 13.2.1) cuyos datos se pueden obtener de la siguiente manera.

```
D, y = load_iris(return_X_y=True)
```

14.3.1. μ_i

Como se describió, μ_i es la media de los elementos que corresponden al grupo G_i. Asumiendo que el grupo 1 (G_1) tiene 10 elementos seleccionados de manera aleatoria de $\mathcal{D}$ como se muestra a continuación.

```
index = np.arange(len(D))
np.random.shuffle(index)
sel = index[:10]
G_1 = D[sel]
```

La variable `G_1` tiene los 10 elementos considerados como miembros de G_1 entonces μ_1 se calcula como la media de cada componente, lo cual se puede calcular con el siguiente código.

```
mu_1 = G_1.mean(axis=0)
```

La Figura 14.1 muestra los elementos seleccionados ($x \in G_1$) y la media (μ_1) del grupo. Los elementos se encuentran en $\mathbb{R}^4$ y para visualizarlos se transformaron usando PCA descrito en la Sección 13.2.1.

14.3.2. G_i

El complemento del procedimiento anterior es encontrar los elementos de G_i dada la μ_i. El ejemplo consiste en generar dos medias, es decir, $K = 2$ y encontrar los elementos que corresponden a las medias generadas. Se puede utilizar cualquier procedimiento para generar dos vectores de manera aleatoria, pero en este ejemplo se asume que estos vectores corresponden

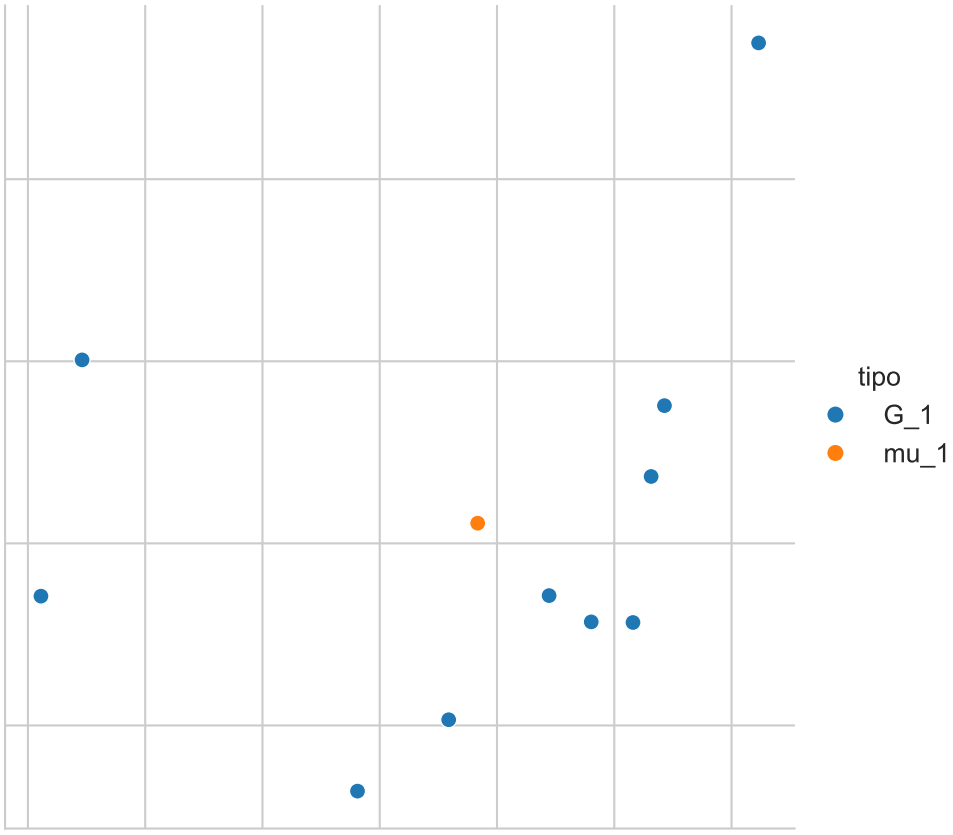


Figura 14.1: Elementos del primer grupo y su centro

a dos elementos de $\mathcal{D}$. Estos elementos son los que se encuentran en los índices 50 y 100 tal y como se muestra en las siguientes instrucciones.

```
mu_1 = D[50]
mu_2 = D[100]
```

El elemento x pertenece al grupo G_i si el valor $|| x - \mu_i ||$ corresponde al $\text{mín}_j || x - \mu_j ||$. Entonces se requiere calcular $|| x - \mu_i ||$ para cada elemento $x \in \mathcal{D}$ y para cada una de las medias μ_i. Esto se puede realizar con la siguiente instrucción

```
dis = np.array([linalg.norm((D - np.atleast_2d(mu)),
                            axis=1)
                for mu in [mu_1, mu_2]]).T
```

donde se puede observar que el ciclo itera por cada una de las medias, i.e., `mu_1` y `mu_2`. Después se calcula la norma utilizando la función `linalg.norm` y finalmente se regresa la transpuesta para tener una matriz de 150 renglones y dos columnas que corresponden al número de ejemplos en $\mathcal{D}$ y a las dos medias. Los valores de `dis[50]` y `dis[100]` son array([0. , 1.8439]) y array([1.8439, 0.]) respectivamente. Tal y como se espera porque μ_1 corresponde al índice 50 y μ_2 es el índice 100. Estos dos ejemplos, array([0. , 1.8439]) y array([1.8439, 0.]), permiten observar que el argumento mínimo de `dis` identifica al grupo del elemento, haciendo la consideración que el índice 0 representa G_1 y el índice 1 es G_2. La siguiente instrucción muestra cómo se realiza esta asignación.

```
G = dis.argmin(axis=1)
```

La Figura 14.2 muestra los grupos formados, el primer grupo `G_1` se encuentra en azul y el segundo en naranja, también muestra los elementos que fueron usados como medias de cada grupo; estos elementos se observan en color verde.

14.3.3. Algoritmo

Habiendo explicado μ_i y G_i se procede a describir el procedimiento para calcular los grupos utilizado por k-medias. Este es un procedimiento iterativo que consta de los siguientes pasos.

1. Se generan K medias de manera aleatoria, donde μ_i corresponde a G_i.
2. Para cada media, μ_i, se seleccionan los elementos más cercanos, esto es, $x \in G_i$ si $|| x - \mu_i ||$ corresponde al $\text{mín}_j || x - \mu_j ||$.
3. Se actualizan las μ_i con los elementos de G_i.
4. Se regresa al paso 2.

El procedimiento termina cuando se llega a un número máximo de iteraciones o que la variación de los μ_i es mínima, es decir, que los grupos no cambian.

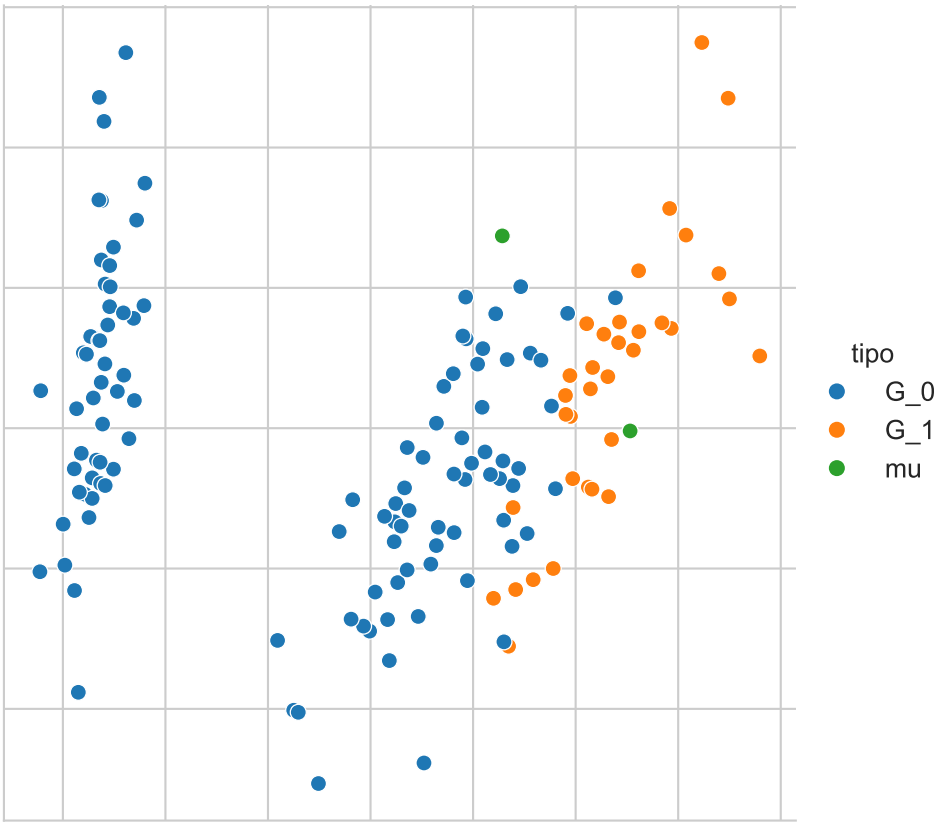


Figura 14.2: Proyección de los elementos del conjunto y sus centros

14.4. Maximización de la Expectativa

K-medias (Sección 14.3) es un caso particular de un algoritmo más general conocido como **Expectation-Maximization** (EM), el cual se utiliza para estimar por máxima verosimilitud (Sección 6.3.1) los parámetros de un modelo cuando este depende de una variable que no se observa, es decir, una variable latente.

En el problema de agrupamiento la variable que no se observa es el grupo al que pertenece cada elemento $x \in \mathcal{D}$. Sea z la variable aleatoria correspondiente, donde $z = i$ indica que $x \in G_i$. Se asume que x proviene de una mezcla de K distribuciones, donde la distribución i-ésima está definida por la función de densidad f_{θ_i} y tiene una probabilidad a priori $\pi_i = \mathbb{P}(z = i)$ tal que $\sum_{i=1}^{K} \pi_i = 1$. Bajo este modelo, la función de densidad de x corresponde a $f(x) = \sum_{i=1}^{K} \pi_i f_{\theta_i}(x)$.

Los parámetros de este modelo son $\Theta = \{\pi_1, \theta_1, \ldots, \pi_K, \theta_K\}$, entonces siguiendo la misma notación de la Sección 6.3.1, la verosimilitud de $\mathcal{D}$ es

$$\mathcal{L}(\Theta) = \prod_{x \in \mathcal{D}} \sum_{i=1}^{K} \pi_i f_{\theta_i}(x), \tag{14.1}$$

cuyo logaritmo es

$$\ell(\Theta) = \sum_{x \in \mathcal{D}} \log \left(\sum_{i=1}^{K} \pi_i f_{\theta_i}(x) \right). \tag{14.2}$$

La dificultad para maximizar $\ell(\Theta)$ (Ecuación 14.2) de manera directa es que, al no observarse z, el logaritmo no puede aplicarse a cada término de la suma en i. EM resuelve este problema con un procedimiento iterativo de dos pasos, Expectativa (E) y Maximización (M), que en la iteración t se definen de la siguiente manera.

Para entender por qué el primer paso se llama Expectativa conviene considerar qué pasaría si z se observara. En ese caso, para un elemento x con grupo verdadero z, se podría usar el indicador $\mathbb{1}(z = i)$, que vale 1 si $z = i$ y 0 en otro caso, para escribir el logaritmo de su verosimilitud completa (la que incluye a z) como $\sum_{i=1}^{K} \mathbb{1}(z = i) \log(\pi_i f_{\theta_i}(x))$, ya que únicamente el término correspondiente al grupo verdadero de x contribuye a la suma, al ser cero el resto de los indicadores. Sumando sobre $\mathcal{D}$ se obtiene la log-verosimilitud completa

$$\ell_c(\Theta) = \sum_{x \in \mathcal{D}} \sum_{i=1}^{K} \mathbb{1}(z = i) \log(\pi_i f_{\theta_i}(x)). \tag{14.3}$$

Maximizar la Ecuación 14.3 sería sencillo, sin embargo no se puede calcular porque z, y por lo tanto $\mathbb{1}(z = i)$, no se observa. La idea de EM es sustituir el indicador $\mathbb{1}(z = i)$ por su

valor esperado dado lo que sí se observa, es decir, dado x y los parámetros actuales $\Theta^{(t)}$; esta esperanza es

$$\mathbb{E}[\mathbb{1}(z = i) \mid x, \Theta^{(t)}] = \mathbb{P}(z = i \mid x, \Theta^{(t)}) = \gamma_i(x), \tag{14.4}$$

donde la primera igualdad se debe a que la esperanza de una variable indicadora corresponde a la probabilidad del evento que indica. Sustituyendo la Ecuación 14.4 en la Ecuación 14.3, en lugar de $\ell_c(\Theta)$ se obtiene su valor esperado

$$Q(\Theta, \Theta^{(t)}) = \mathbb{E}_{z|x,\Theta^{(t)}}[\ell_c(\Theta)] = \sum_{x \in \mathcal{D}} \sum_{i=1}^{K} \gamma_i(x) \log(\pi_i f_{\theta_i}(x)). \tag{14.5}$$

En la Ecuación 14.5 se puede notar que Q tiene dos argumentos, Θ y $\Theta^{(t)}$, con roles distintos. $\Theta^{(t)}$ son los parámetros de la iteración anterior, que ya se conocen; mientras que Θ es la variable sobre la que se maximiza. Dado que $\gamma_i(x)$ (Ecuación 14.4) depende únicamente de x y $\Theta^{(t)}$, y no de Θ, al resolver $\arg\max_\Theta Q(\Theta, \Theta^{(t)})$ cada $\gamma_i(x)$ se comporta como una constante, es decir, un peso fijo que ya no cambia durante la maximización; los únicos términos de la Ecuación 14.5 que dependen de Θ son π_i y $f_{\theta_i}(x)$, dentro del logaritmo.

Calcular $\gamma_i(x)$ (Ecuación 14.4), es necesario para resolver $\arg\max_\Theta Q(\Theta, \Theta^{(t)})$; y este se calcula en el **Paso E**, de ahí su nombre, Expectativa. El **Paso M** completa el procedimiento encontrando $\Theta^{(t+1)} = \arg\max_\Theta Q(\Theta, \Theta^{(t)})$, es decir, maximizando la esperanza; de ahí que se llame Maximización. A continuación se presentan ambos pasos de manera explícita.

Paso E. Dados los parámetros actuales $\Theta^{(t)} = \{\pi_i^{(t)}, \theta_i^{(t)}\}$, se calcula $\gamma_i(x)$ (Ecuación 14.4) para cada $x \in \mathcal{D}$ y cada grupo i, lo cual, sustituyendo $\mathbb{P}(z = i \mid x, \Theta^{(t)})$ con el Teorema de Bayes, corresponde a

$$\gamma_i(x) = \mathbb{P}(z = i \mid x, \Theta^{(t)}) = \frac{\pi_i^{(t)} f_{\theta_i^{(t)}}(x)}{\sum_{j=1}^{K} \pi_j^{(t)} f_{\theta_j^{(t)}}(x)}. \tag{14.6}$$

$\gamma_i(x)$ es la responsabilidad de G_i en el elemento x; a diferencia del paso 2 de K-medias (Sección 14.3) donde x se asigna completamente a un grupo, en EM x se asigna de manera fraccionaria a los K grupos, dado que $\gamma_i(x) \in [0, 1]$ y $\sum_{i=1}^{K} \gamma_i(x) = 1$.

Paso M. Con las responsabilidades del paso anterior se actualizan los parámetros $\Theta^{(t+1)} = \arg\max_\Theta Q(\Theta, \Theta^{(t)})$ (Ecuación 14.5). La probabilidad a priori se actualiza con

$$\pi_i^{(t+1)} = \frac{1}{N} \sum_{x \in \mathcal{D}} \gamma_i(x), \tag{14.7}$$

y $\theta_i^{(t+1)}$ se obtiene con la estimación de máxima verosimilitud de f_{θ_i} ponderando cada x con $\gamma_i(x)$. Por ejemplo, cuando f_{θ_i} corresponde a $\mathcal{N}(\mu_i, \Sigma_i)$ (Sección 6.3.3) las actualizaciones son

$$\mu_i^{(t+1)} = \frac{\sum_{x \in \mathcal{D}} \gamma_i(x)\, x}{\sum_{x \in \mathcal{D}} \gamma_i(x)}, \tag{14.8}$$

$$\Sigma_i^{(t+1)} = \frac{\sum_{x \in \mathcal{D}} \gamma_i(x)\, (x - \mu_i^{(t+1)})(x - \mu_i^{(t+1)})^\top}{\sum_{x \in \mathcal{D}} \gamma_i(x)}. \tag{14.9}$$

Los pasos E (Ecuación 14.6) y M (Ecuación 14.7, Ecuación 14.8 y Ecuación 14.9) se repiten hasta que $\ell(\Theta)$ converge o se llega a un número máximo de iteraciones, de manera análoga al criterio de paro de K-medias.

14.4.1. K-medias como caso particular de EM

K-medias corresponde a EM cuando se hacen dos suposiciones sobre el modelo. La primera es que las K distribuciones son Gaussianas con la misma matriz de covarianza y esta es proporcional a la identidad, es decir, $f_{\theta_i} = \mathcal{N}(\mu_i, \sigma^2 I)$ para todo i, con σ^2 fija y compartida por los K grupos; la segunda es que todos los grupos son igualmente probables a priori, i.e., $\pi_i = \frac{1}{K}$ para todo i.

Para observar el efecto de estas suposiciones en el **Paso E** (Ecuación 14.6) se requiere la función de densidad de una Gaussiana multivariada con media μ_i y matriz de covarianza esférica $\sigma^2 I$; para $x \in \mathbb{R}^d$ esta densidad es

$$f_{\theta_i}(x) = \mathcal{N}(x \mid \mu_i, \sigma^2 I) = \frac{1}{(2\pi\sigma^2)^{d/2}} \exp\left(-\frac{1}{2\sigma^2} \mid\mid x - \mu_i \mid\mid^2\right), \tag{14.10}$$

donde $(2\pi\sigma^2)^{-d/2}$ es la constante de normalización de la Gaussiana. Se puede observar en la Ecuación 14.10 que esta constante depende únicamente de σ^2 y de d, no de μ_i, entonces tiene el mismo valor para las K Gaussianas al ser σ^2 compartida. Sustituyendo la Ecuación 14.10 y $\pi_i = \pi_j = \frac{1}{K}$ en la definición general del **Paso E** (Ecuación 14.6) se obtiene

$$\gamma_i(x) = \frac{\frac{1}{K} \cdot \frac{1}{(2\pi\sigma^2)^{d/2}} \exp\left(-\frac{1}{2\sigma^2} \mid\mid x - \mu_i \mid\mid^2\right)}{\sum_{j=1}^{K} \frac{1}{K} \cdot \frac{1}{(2\pi\sigma^2)^{d/2}} \exp\left(-\frac{1}{2\sigma^2} \mid\mid x - \mu_j \mid\mid^2\right)}. \tag{14.11}$$

En la Ecuación 14.11 el factor $c = \frac{1}{K} \cdot \frac{1}{(2\pi\sigma^2)^{d/2}}$ es el mismo en el numerador y en cada uno de los K términos de la suma del denominador, dado que no depende ni del grupo i del numerador ni del índice j de la suma. Al ser un factor común se puede sacar de la suma, quedando

$$\gamma_i(x) = \frac{c \cdot \exp\left(-\frac{1}{2\sigma^2} \mid\mid x - \mu_i \mid\mid^2\right)}{c \cdot \sum_{j=1}^{K} \exp\left(-\frac{1}{2\sigma^2} \mid\mid x - \mu_j \mid\mid^2\right)}, \tag{14.12}$$

y como $c > 0$, se cancela entre el numerador y el denominador de la Ecuación 14.12, es decir, las responsabilidades no dependen ni de π_i ni de la constante de normalización de la Gaussiana, sino únicamente de la distancia de x a cada media. Esto se resume en

$$\gamma_i(x) = \frac{\exp\left(-\frac{1}{2\sigma^2} \mid\mid x - \mu_i \mid\mid^2\right)}{\sum_{j=1}^{K} \exp\left(-\frac{1}{2\sigma^2} \mid\mid x - \mu_j \mid\mid^2\right)}. \tag{14.13}$$

Para tomar el límite $\sigma^2 \to 0$ en la Ecuación 14.13 conviene denotar $d_j = \mid\mid x - \mu_j \mid\mid^2$ y, asumiendo que la media más cercana a x es única, sea i^* el grupo tal que $d_{i^*} = \min_j d_j$. Multiplicando el numerador y el denominador de la Ecuación 14.13 por $\exp\left(\frac{1}{2\sigma^2} d_{i^*}\right)$, es decir, sacando de la suma del denominador el factor común $\exp\left(-\frac{1}{2\sigma^2} d_{i^*}\right)$ tal como se hizo con c en la Ecuación 14.12, se obtiene

$$\gamma_i(x) = \frac{\exp\left(-\frac{1}{2\sigma^2}(d_i - d_{i^*})\right)}{\sum_{j=1}^{K} \exp\left(-\frac{1}{2\sigma^2}(d_j - d_{i^*})\right)}. \tag{14.14}$$

En la Ecuación 14.14 cada exponente está escrito en términos de $d_j - d_{i^*} \geq 0$, dado que d_{i^*} es el mínimo; en particular, para $j = i^*$ el exponente es 0 y por lo tanto ese término de la suma es $\exp(0) = 1$, sin importar el valor de σ^2. Para cualquier otro grupo $j \neq i^*$ se tiene $d_j - d_{i^*} > 0$, entonces al tomar el límite $\sigma^2 \to 0$ el exponente $-\frac{1}{2\sigma^2}(d_j - d_{i^*}) \to -\infty$ y en consecuencia ese término tiende a $\exp(-\infty) = 0$. Esto significa que en el límite la suma del denominador de la Ecuación 14.14 se reduce únicamente al término $j = i^*$, es decir, $\sum_{j=1}^{K} \exp\left(-\frac{1}{2\sigma^2}(d_j - d_{i^*})\right) \to 1$, de donde se dice que este término domina la suma: todos los demás términos se desprecian frente a él conforme $\sigma^2 \to 0$.

Con esta asignación completa, i.e., $\gamma_i(x) \in \{0, 1\}$, la actualización de μ_i del **Paso M** (Ecuación 14.8) se reduce a la media de los elementos de G_i, que corresponde al paso 3 de K-medias. Por lo tanto, K-medias es el algoritmo EM aplicado a una mezcla de Gaussianas con matriz de covarianza esférica compartida, en el límite en que $\sigma^2 \to 0$ y sustituyendo la responsabilidad $\gamma_i(x)$ por la asignación completa al grupo más cercano.

14.5. Ejemplo: Iris

En el siguiente ejemplo se usará K-medias para encontrar 2 y 3 grupos en el conjunto del iris. La clase se inicializa primero con 2 grupos (primera línea). En la segunda instrucción se predice los grupos para todo el conjunto de datos. Las medias para cada grupo se encuentran en el atributo `cluster_centers_`.

```
m = KMeans(n_clusters=2, n_init='auto').fit(D)
cl = m.predict(D)
```

La Figura 14.3 muestra el resultado del algoritmo k-medias en el conjunto del Iris, se muestran los dos grupos G_1 y G_2 y en color verde μ_1 y μ_2.

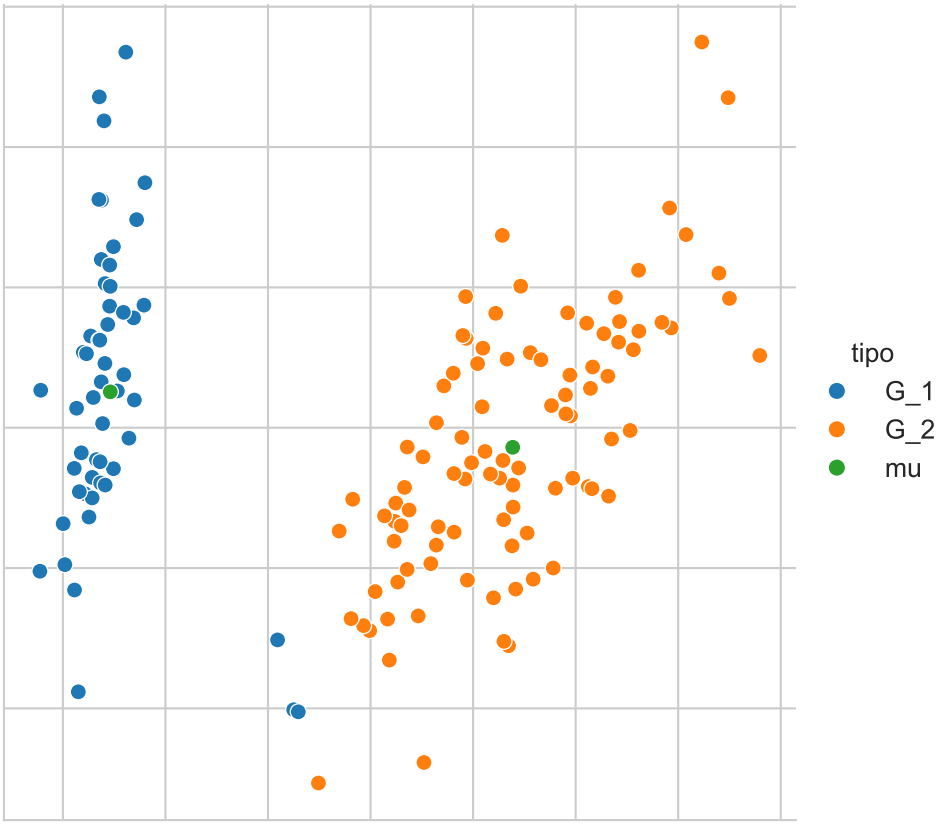


Figura 14.3: Proyección de k-means usando dos grupos

Un procedimiento equivalente se puede realizar para generar tres grupos, el único cambio es el parámetro `n_clusters` en la clase `KMeans` de la siguiente manera.

```
m = KMeans(n_clusters=3, n_init='auto').fit(D)
cl = m.predict(D)
```

La Figura 14.4 muestra los tres grupos y con sus tres respectivas medias en color rojo.

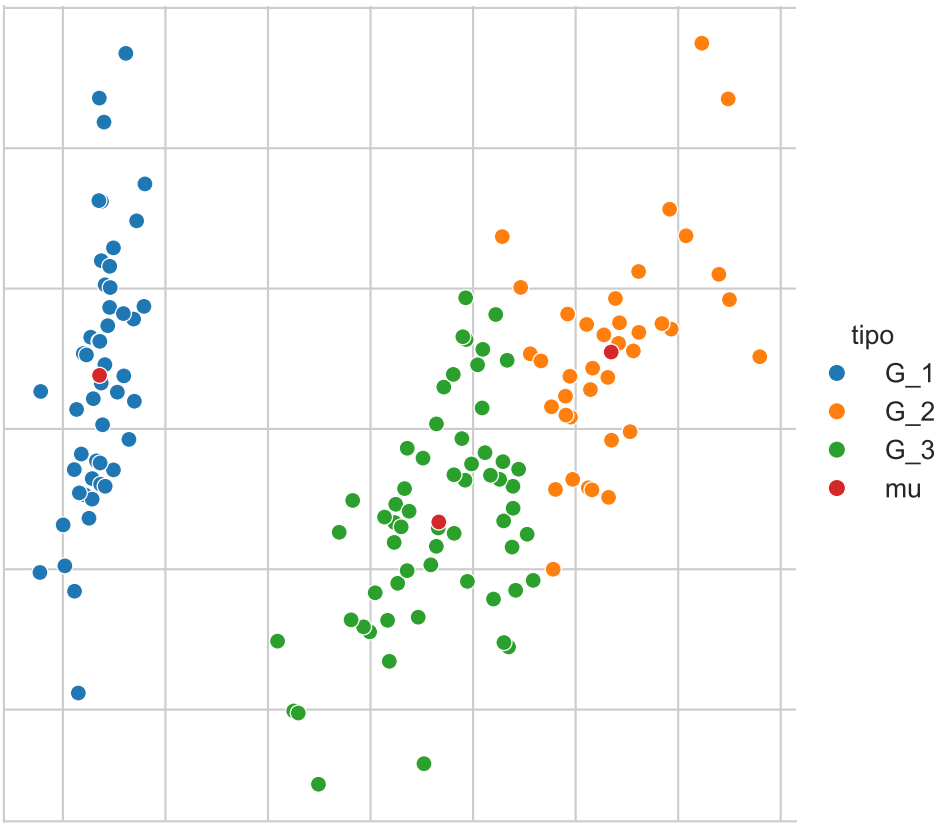


Figura 14.4: Proyección de k-means usando tres grupos

14.6. Rendimiento

Recordando que en aprendizaje no supervisado no se tiene una variable dependiente que predecir. En este caso particular se utilizó un problema de clasificación para ilustrar el procedimiento de k-medias, entonces se cuenta con una clase para cada elemento $x \in \mathcal{D}$. Además se sabe que el problema del iris tiene tres clases, entonces utilizando los tres grupos obtenidos previamente podemos medir qué tanto se parecen estos tres grupos a las clases del iris. Es decir, se puede saber si el algoritmo de k-medias agrupa los elementos de tal manera que cada grupo corresponda a una clase del iris.

Los grupos generados se encuentran en la lista `cl` y las clases se encuentran en `y`. La lista `y` tiene organizada las clases de la siguiente manera: los primeros 50 elementos son la clase 0, los siguientes 50 son clase 1 y los últimos son la clase 2. Dado que K-medias no conoce las clases y genera los grupos empezando de manera aleatoria, entonces es probable que los grupos sigan una numeración diferente al problema del iris. Los grupos en `cl` están organizados de la siguiente manera aproximadamente los 50 primeros elementos son del grupo 1, los siguientes son grupo 0 y finalmente los últimos son grupo 2. Entonces se puede hacer una transformación que asigne a cada grupo una clase. La siguiente instrucción prueba todas las permutaciones de las tres clases y se queda con la que obtiene la mayor exactitud, la cual se guarda en la variable `perm`.

```
perms = list(permutations([0, 1, 2]))
perfs = [(metrics.accuracy_score(y, np.array(x)[cl]), x)
         for x in perms]
perm = np.r_[sorted(perfs, key=lambda x: x[0])[-1][1]]
```

La variable `perm` contiene array([0, 2, 1]).

Utilizando `perm` se calcula la exactitud (Sección 2.3.2) utilizando la siguiente instrucción. Se obtiene una exactitud de 0.8867 que significa que la mayoría de los datos se agrupan en un conjunto que corresponde a la clase del conjunto del iris.

```
acc = metrics.accuracy_score(y, perm[cl])
```

En general en agrupamiento no se cuenta con la composición de los grupos, es más, se desconocen cuántos grupos modela el problema. Para estas ocasiones es imposible medir la exactitud o cualquier otra medida de agrupamiento que requiera la composición real de los grupos.

Una medida que no requiere conocer los grupos es el **Silhouette Coefficient**; el cual mide la calidad de los grupos, mientras mayor sea el valor significa una mejor calidad en los grupos. Este coeficiente se basa en la siguiente función:

$$s = \frac{b - a}{\text{máx}(a, b)},$$

donde a corresponde a la distancia media entre un elemento y todos los objetos del mismo grupo; y b es la distancia media entre la muestra y todos los elementos del grupo más cercano.

Por ejemplo, en el problema del Iris s tiene un valor de 0.5512 calculado con la siguiente instrucción.

```
sil = metrics.silhouette_score(D, cl, metric='euclidean')
```

Otra medida de la calidad de los grupos es el índice de **Calinski-Harabasz** que mide la dispersión entre grupos y dentro del grupo, al igual que Silhouette, mientras mayor sea la estadística mejor es el agrupamiento. Para el problema del Iris el índice de Calinski-Harabasz tiene un valor de 561.5937 obtenido con la siguiente instrucción.

```
cal_har = metrics.calinski_harabasz_score(D, cl)
```

14.7. Número de Grupos

Utilizando una medida de rendimiento de agrupamiento se analiza cuál sería el número adecuado de grupos para un problema dado. El procedimiento es variar el número de grupos y medir el rendimiento para cada grupo y quedarse con aquel que da el mejor rendimiento considerando también el número de grupos.

Por ejemplo, la siguiente instrucción calcula el coeficiente de Silhouette y el índice de Calinski-Harabasz en el problema del Iris.

```
S1 = []
S2 = []
for k in range(2, 11):
    m = KMeans(n_clusters=k, n_init='auto').fit(D)
    cl = m.predict(D)
    _ = metrics.silhouette_score(D, cl, metric='euclidean')
    S1.append(_)
    _ = metrics.calinski_harabasz_score(D, cl)
    S2.append(_)
```

Estas dos estadísticas se pueden observar en la Figura 14.5. En color azul se observa el coeficiente de Silhouette; donde el mejor resultado es cuando $K = 2$. En color naranja se muestra el índice Calinski-Harabasz donde el mejor resultado se tiene cuando $K = 3$. Considerando que se está trabajando con el problema del Iris se conoce que la mejor agrupación es para $K = 3$ dado que son tres clases.

14.8. Resumen

El agrupamiento busca estructura en datos sin variable respuesta. El algoritmo k-medias (Sección 14.3) alterna entre asignar cada observación al centro más cercano y recalcular los centros, y la maximización de la expectativa (Sección 14.4) generaliza esa idea a mezclas de distribuciones, con k-medias como un caso particular. Como no hay respuesta que predecir, el rendimiento se mide con índices propios del agrupamiento, y esos mismos índices sirven para

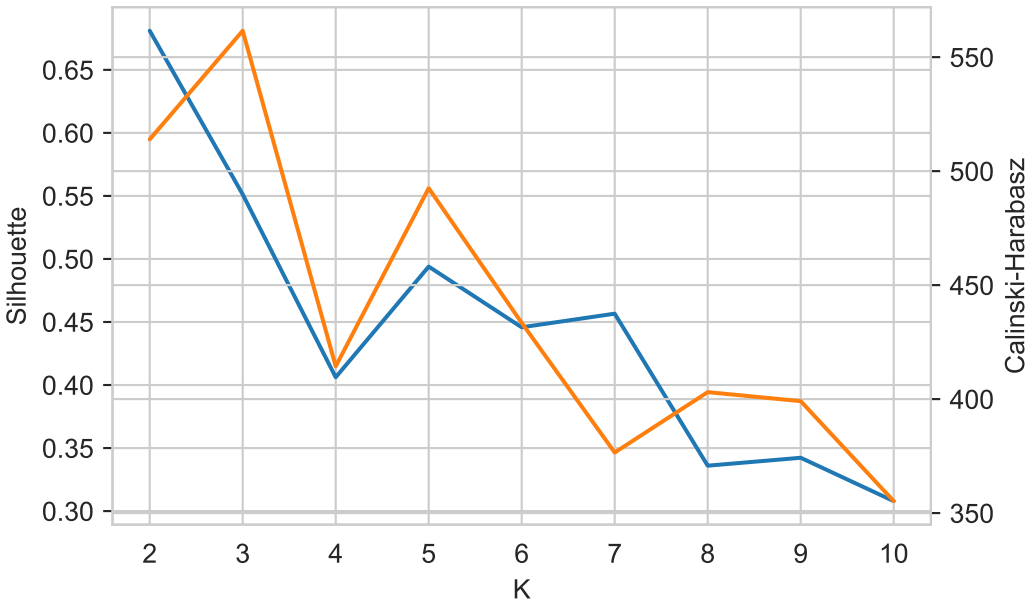


Figura 14.5: Rendimiento variando el número de grupos

elegir el número de grupos, como se muestra en la Figura 14.5. Ese número no es un dato del problema sino una decisión que se apoya en un criterio.

En política pública agrupar sirve para segmentar territorios, poblaciones o programas con características parecidas y para diseñar intervenciones diferenciadas. Es una tarea descriptiva y no predictiva, así que un grupo no es una causa ni una categoría con significado propio. Además, los grupos dependen de las variables elegidas, de su escala y del número de grupos, por lo que conviene revisar si son estables y si tienen una lectura sustantiva.

A lo largo del libro se han presentado muchos algoritmos, y para decidir cuál es mejor en un problema hace falta una comparación que tome en cuenta la incertidumbre de las medidas. Ese es el tema de Capítulo 15.

15 Comparación de Algoritmos

El **objetivo** de la unidad es conocer y aplicar diferentes procedimientos estadísticos para comparar y analizar el rendimiento de algoritmos.

15.1. Paquetes usados

```
from CompStats import StatisticSamples, CI
from CompStats import performance, plot_performance
from CompStats import difference, plot_difference
from scipy.stats import norm, wilcoxon
from sklearn.datasets import load_iris, load_breast_cancer
from sklearn.naive_bayes import GaussianNB
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import train_test_split, StratifiedKFold
from sklearn.metrics import recall_score
import numpy as np
import seaborn as sns
import pandas as pd
```

15.2. Introducción

Hasta el momento se han descrito diferentes algoritmos de clasificación y regresión. Se han presentado diferentes medidas para conocer su rendimiento, pero solo se ha tocado de manera práctica (con el error estándar, Bootstrap y las comparaciones de CompStats de las unidades anteriores) el conocer la distribución de estas medidas, la cual permite tener mayor información sobre el rendimiento del algoritmo y también poder comparar y seleccionar el algoritmo que tenga las mejores prestaciones ya sea en rendimiento o en complejidad.

15.3. Intervalos de confianza

El análisis del rendimiento se inicia partiendo de que el rendimiento se puede estimar a partir del conjunto de prueba, $\mathcal{G}$; el valor obtenido estima el rendimiento real, θ, el cual se considera una constante. Una manera de conocer el rango de valores donde se puede encontrar θ es generando su intervalo de confianza. El intervalo de confianza de θ está dado por $C = (a(\mathcal{G}), b(\mathcal{G}))$, de tal manera que $P_\theta(\theta \in C) \geq 1 - \alpha$. Es importante mencionar que el intervalo no mide la probabilidad de θ dado que θ es una constante, en su lugar mide que el valor estimado esté dentro de esos límites con esa probabilidad. Por otro lado se utiliza la notación $a(\mathcal{G})$ y $b(\mathcal{G})$ para hacer explícito que en este caso los límites del intervalo son obtenidos utilizando el conjunto de prueba. Una manera de entender el intervalo de confianza de cualquier parámetro es suponer que si el parámetro se estima 100 veces con el mismo procedimiento, en diferentes muestras, un intervalo del 95 % de confianza dice que 95 de las veces la estimación del parámetro estará en el intervalo calculado.

15.3.1. Método: Distribución Normal

Existen diferentes procedimientos para generar intervalos de confianza, uno de ellos es asumir que la estimación de θ, i.e., $\hat{\theta}$ se distribuye como una normal, i.e., $\hat{\theta} \sim \mathcal{N}(\mu, \sigma^2)$, donde $\sigma = \mathsf{se} = \sqrt{\mathbb{V}(\hat{\theta})}$ corresponde al error estándar (Sección A.1) de la estimación $\hat{\theta}$. En estas condiciones el intervalo está dado por:

$$C = (\hat{\theta} - z_{\frac{\alpha}{2}}\mathsf{se}, \hat{\theta} + z_{\frac{\alpha}{2}}\mathsf{se}),$$

donde $z_{\frac{\alpha}{2}} = \Phi^{-1}(1 - \frac{\alpha}{2})$ y Φ es la función de distribución acumulada de una normal.

15.3.2. Ejemplo: Exactitud

Recordando que dada una entrada el clasificador puede acertar la clase a la que pertenece esa entrada, entonces el resultado se puede representar como 1 si la respuesta es correcta y 0 de lo contrario. En este caso la respuesta es una variable aleatoria con una distribución de Bernoulli. Recordando que la distribución Bernoulli está definida por un parámetro p, estimado como $\hat{p} = \frac{1}{N}\sum_{i=1}^{N} \mathcal{X}_i$ donde $\mathcal{X}_i$ corresponde al resultado del algoritmo en el i-ésimo ejemplo. La varianza de una distribución Bernoulli es $p(1-p)$ por lo que el error estándar es: $se = \sqrt{\frac{p(1-p)}{N}}$ dando como resultado el siguiente intervalo:

$$C = (\hat{p}_N - z_{\frac{\alpha}{2}}\sqrt{\frac{p(1-p)}{N}}, \hat{p}_N + z_{\frac{\alpha}{2}}\sqrt{\frac{p(1-p)}{N}}).$$

Suponiendo $N = 100$ y $p = 0.85$ el siguiente código calcula el intervalo usando $\alpha = 0.05$

```
alpha = 0.05
z = norm().ppf(1 - alpha / 2)
p = 0.85
N = 100
Cn = (p - z * np.sqrt(p * (1 - p) / N),
      p + z * np.sqrt(p * (1 - p) / N))
```

dando como resultado el siguiente intervalo, $C = (0.78, 0.92)$.

En el caso anterior se supuso que se contaba con los resultados de un algoritmo de clasificación, con el objetivo de completar este ejemplo a continuación se presenta el análisis con un Naive Bayes en el problema del Iris.

Lo primero que se realiza es cargar los datos y dividir en el conjunto de entrenamiento ($\mathcal{T}$) y prueba ($\mathcal{G}$) como se muestra a continuación.

```
X, y = load_iris(return_X_y=True)
T, G, y_t, y_g = train_test_split(X, y,
                                  random_state=1,
                                  test_size=0.3)
```

El siguiente paso es entrenar el algoritmo y realizar las predicciones en el conjunto de prueba ($\mathcal{G}$) tal y como se muestra en las siguientes instrucciones.

```
model = GaussianNB().fit(T, y_t)
hy = model.predict(G)
```

Con las predicciones se estima la exactitud y se siguen los pasos para calcular el intervalo de confianza como se ilustra en el siguiente código.

```
_ = np.where(y_g == hy, 1, 0)
p = _.mean()
N = _.shape[0]
C = (p - z * np.sqrt(p * (1 - p) / N), p + z * np.sqrt(p * (1 - p) / N))
```

El intervalo de confianza obtenido es $C = (0.86, 1.01)$. Se puede observar que el límite superior es mayor que 1 lo cual no es posible dado que el máximo valor del accuracy es 1, esto es resultado de generar el intervalo de confianza asumiendo una distribución normal.

Cuando se cuenta con conjuntos de datos pequeños y además no se ha definido un conjunto de prueba, se puede obtener las predicciones del algoritmo de clasificación mediante el uso de validación cruzada usando K-fold. En el siguiente código se muestra su uso, el cambio solamente es en el procedimiento para obtener las predicciones.

```
kf = StratifiedKFold(n_splits=10,
                     random_state=0,
                     shuffle=True)
hy = np.empty_like(y)
for tr, ts in kf.split(X, y):
    model = GaussianNB().fit(X[tr], y[tr])
    hy[ts] = model.predict(X[ts])
```

El resto del código es equivalente al usado previamente obteniendo el siguiente intervalo de confianza $C = (0.92, 0.99)$.

15.3.3. Método: Bootstrap del error estándar

Existen ocasiones donde no es sencillo identificar el error estándar (se) y por lo mismo no se puede calcular el intervalo de confianza. En estos casos se emplea la técnica de Bootstrap (Sección A.2) para estimar $\mathbb{V}(\hat{\theta})$. Un ejemplo donde no es sencillo encontrar analíticamente el error estándar es en el *recall* (Sección 2.3.3).

Es más sencillo entender este método mediante un ejemplo. Usando el ejercicio de $N = 100$ y $p = 0.85$ y $\alpha = 0.05$ descrito previamente, el siguiente código primero construye las variables aleatorias de tal manera que den $p = 0.85$

```
alpha = 0.05
N = 100
z = norm().ppf(1 - alpha / 2)
X = np.zeros(N)
X[:85] = 1
```

`X` es un arreglo que podría provenir de la evaluación de un clasificador usando alguna medida de similitud entre predicción y valor medido. El siguiente paso es seleccionar con remplazo y obtener $\hat{\theta}$ para cada muestra, en este caso $\hat{\theta}$ corresponde a la media. El resultado se guarda en una lista B y se repite el experimento 500 veces.

```
S = np.random.randint(X.shape[0],
                      size=(500, X.shape[0]))
B = [X[s].mean() for s in S]
```

El error estándar es y el intervalo de confianza se calcula con las siguientes instrucciones

```
se = np.sqrt(np.var(B))
C = (p - z * se, p + z * se)
```

el intervalo de confianza corresponde a $C = (0.88, 1.03)$.

Continuando con el mismo ejemplo pero ahora analizando Naive Bayes en el problema del Iris. El primer paso es obtener las predicciones que se pueden observar en el siguiente código (previamente descrito.)

```
X, y = load_iris(return_X_y=True)
kf = StratifiedKFold(n_splits=10,
                     random_state=0,
                     shuffle=True)

hy = np.empty_like(y)
for tr, ts in kf.split(X, y):
    model = GaussianNB().fit(X[tr], y[tr])
    hy[ts] = model.predict(X[ts])
X = np.where(y == hy, 1, 0)
```

Realizando la selección con remplazo se obtiene el intervalo con las siguientes instrucciones

```
B = [X[s].mean() for s in S]
se = np.sqrt(np.var(B))
C = (p - z * se, p + z * se)
```

teniendo un valor de $C = (0.92, 0.98)$.

15.3.4. Método: Percentil

Existe otra manera de calcular los intervalos de confianza y es mediante el uso del percentil, utilizando directamente las estimaciones realizadas a $\hat{\theta}$ en la selección. El siguiente código muestra este método usando el ejemplo anterior,

```
alpha = 0.05 / 2
C = (np.percentile(B, alpha * 100),
     np.percentile(B, (1 - alpha) * 100))
```

obteniendo un intervalo de $C = (0.92, 0.98)$.

15.3.5. Ejemplo: macro-recall

Hasta el momento se ha usado una medida de rendimiento para la cual se puede conocer su varianza de manera analítica. Existen problemas donde esta medida no es recomendada, en el siguiente ejemplo utilizaremos macro-recall para medir el rendimiento de Naive Bayes en el problema del Iris. El primer paso es realizar las predicciones del algoritmo usando validación cruzada y hacer la muestra con reemplazo B.

```
alpha = 0.05
z = norm().ppf(1 - alpha / 2)

X, y = load_iris(return_X_y=True)
kf = StratifiedKFold(n_splits=10,
                     random_state=0,
                     shuffle=True)

hy = np.empty_like(y)
for tr, ts in kf.split(X, y):
    model = GaussianNB().fit(X[tr], y[tr])
    hy[ts] = model.predict(X[ts])

S = np.random.randint(hy.shape[0],
                      size=(500, hy.shape[0]))
B = [recall_score(y[s], hy[s], average="macro")
     for s in S]
```

El siguiente paso es calcular el intervalo asumiendo que este se comporta como una normal tal y como se muestra en las siguientes instrucciones;

```
p = np.mean(B)
se = np.sqrt(np.var(B))
C = (p - z * se, p + z * se)
```

obteniendo un intervalo de $C = (0.92, 0.99)$ Completando el ejercicio, el intervalo se puede calcular directamente usando el percentil, estimando un intervalo de $C = (0.92, 0.98)$

> **Nota**
>
> El método de bootstrap para calcular el error estándar y el método de percentil para calcular el intervalo de confianza se pueden estimar utilizando la clase `StatisticSamples`. Las siguientes instrucciones se pueden utilizar para calcular el error estándar.

```
recall = lambda y, hy: recall_score(y, hy,
                                    average="macro")

statistic = StatisticSamples(statistic=recall)
samples = statistic(y, hy)
np.std(samples)
```

```
np.float64(0.01724910236267657)
```

Complementando el intervalo de confianza con el método de percentil se implementa en el siguiente código.

```
CI(samples)
```

```
(np.float64(0.9190105702740112), np.float64(0.9856691335183472))
```

15.4. Comparación de Algoritmos

Se han descrito varios procedimientos para conocer los intervalos de confianza de un algoritmo de aprendizaje. Es momento para describir la metodología para conocer si dos algoritmos se comportan similar en un problema dado.

15.4.1. Método: Distribución t de Student

Suponiendo que se tienen las medidas de rendimiento de dos algoritmos mediante validación cruzada de K-fold, es decir, se tiene el rendimiento del primer algoritmo como p_i^1 y del segundo como p_i^2 en la i-ésima instancia. Suponiendo que el rendimiento es una normal, entonces la resta, i.e., $p_i = p_i^1 - p_i^2$ también sería normal. Dado que se está comparando los algoritmos en los mismos datos, se puede utilizar la prueba t de Student de muestras dependientes. La estadística de la prueba está dada por $\frac{\sqrt{K}m}{S} \sim t_{K-1}$, donde m y S^2 es la media varianza estimada.

En el siguiente ejemplo se compara el rendimiento de Árboles Aleatorios y Naive Bayes en el problema de Breast Cancer. El primer paso es cargar las librerías así como obtener las predicciones de los algoritmos.

```
K = 30
kf = StratifiedKFold(n_splits=K,
                     random_state=0,
                     shuffle=True)
```

```
X, y = load_breast_cancer(return_X_y=True)

P = []
for tr, ts in kf.split(X, y):
    forest = RandomForestClassifier().fit(X[tr], y[tr]).predict(X[ts])
    naive = GaussianNB().fit(X[tr], y[tr]).predict(X[ts])
    P.append([recall_score(y[ts], hy, average="macro") for hy in [forest, naive]])
P = np.array(P)
```

Como se puede observar la medida de rendimiento es macro-recall. Continuando con el procedimiento para obtener la estadística t_{K-1}

```
p = P[:, 0] - P[:, 1]
t = np.sqrt(K) * np.mean(p) / np.std(p)
```

donde el valor de la estadística es 2.6682, si el valor está fuera del siguiente intervalo $(-2.045, 2.045)$ se rechaza la hipótesis nula de que los dos algoritmos se comportan similar.

En caso de que la medida de rendimiento no esté normalmente distribuida, la prueba no paramétrica equivalente corresponde a Wilcoxon. La instrucción `wilcoxon(P[:, 0], P[:, 1])` se puede utilizar para calcularla, dando un p_{value} de 0.0254. En ambos casos podemos concluir que los algoritmos Árboles Aleatorios y Naive Bayes son estadísticamente diferentes con una confianza del 95 % en el problema de Breast Cancer.

15.4.2. Método: Bootstrap en diferencias

Un método para comparar el rendimiento de dos algoritmos que no asume ningún tipo de distribución se puede realizar mediante la técnica de Bootstrap. Nava-Muñoz et al. (2024) utilizan esta idea para comparar diferentes algoritmos en el esquema de una competencia de aprendizaje supervisado. La idea es calcular las predicciones de los algoritmos y realizar la muestra calculando en cada una la diferencia del rendimiento. Este procedimiento se explicará mediante un ejemplo.

El primer paso es calcular las predicciones de los algoritmos, en este caso se realiza una validación cruzada, tal y como se muestra a continuación.

```
forest = np.empty_like(y)
naive = np.empty_like(y)
for tr, ts in kf.split(X, y):
    forest[ts] = RandomForestClassifier().fit(X[tr], y[tr]).predict(X[ts])
    naive[ts] = GaussianNB().fit(X[tr], y[tr]).predict(X[ts])
```

El macro-recall para los Bosques Aleatorios es 0.96 y para el Naive Bayes es 0.93. Lo que se observa es que los bosques tienen un mejor rendimiento, entonces la distribución de la diferencia del rendimiento entre bosques y Naive Bayes no debería de incluir al cero, si lo incluye la masa que está al lado izquierdo del cero debe de ser menor, esa masa corresponde al valor p.

Las muestras de la diferencia de rendimiento se pueden calcular de las siguientes instrucciones.

```
S = np.random.randint(y.shape[0],
                      size=(500, y.shape[0]))
r = recall_score
diff = lambda y, hy1, hy2: r(y, hy1, average="macro") -\
                           r(y, hy2, average="macro")
B = [diff(y[s], forest[s], naive[s])
     for s in S]
```

Finalmente, el p_{value} corresponde a la proporción de elementos que son menores que cero, i.e., `(np.array(B) < 0).mean()`, es decir, aquellas muestras donde Naive Bayes tiene un mejor desempeño que los bosques. En este caso el p_{value} tiene un valor de 0.0040. Dado que el valor es menor que 0.05 se puede rechazar la hipótesis nula con una confianza superior al 95 % y concluir que existe una diferencia estadísticamente significativa en el rendimiento entre los dos algoritmos. La Figura 15.1 muestra la distribución de la diferencia de rendimiento, en esta se puede observar cómo la mayor parte de la masa se encuentra del lado positivo y que muy poca masa es menor que cero.

15.5. CompStats

La librería CompStats (Nava-Muñoz et al. (2024)) permite realizar de manera sencilla la comparación entre el rendimiento de varios algoritmos, además de presentar gráficas sobre su comportamiento. Esta librería usa la técnica de Bootstrap tal y como se ha mostrado en este capítulo.

Lo primero que se realiza es calcular las muestras del rendimiento entre los dos algoritmos analizados, los cuales tienen sus predicciones en las variables `naive` y `forest`. En la primera línea se inicializa la variable `macro_recall` que calcula el promedio de la cobertura. La segunda línea crea un cuadro de datos (`DataFrame`) que contiene tanto la variable medida como las predicciones. La tercera línea calcula el rendimiento de los dos algoritmos.

```
macro_recall = lambda y, hy: recall_score(y, hy,
                                          average='macro')
df = pd.DataFrame(dict(y=y,
                       naive=naive,
```

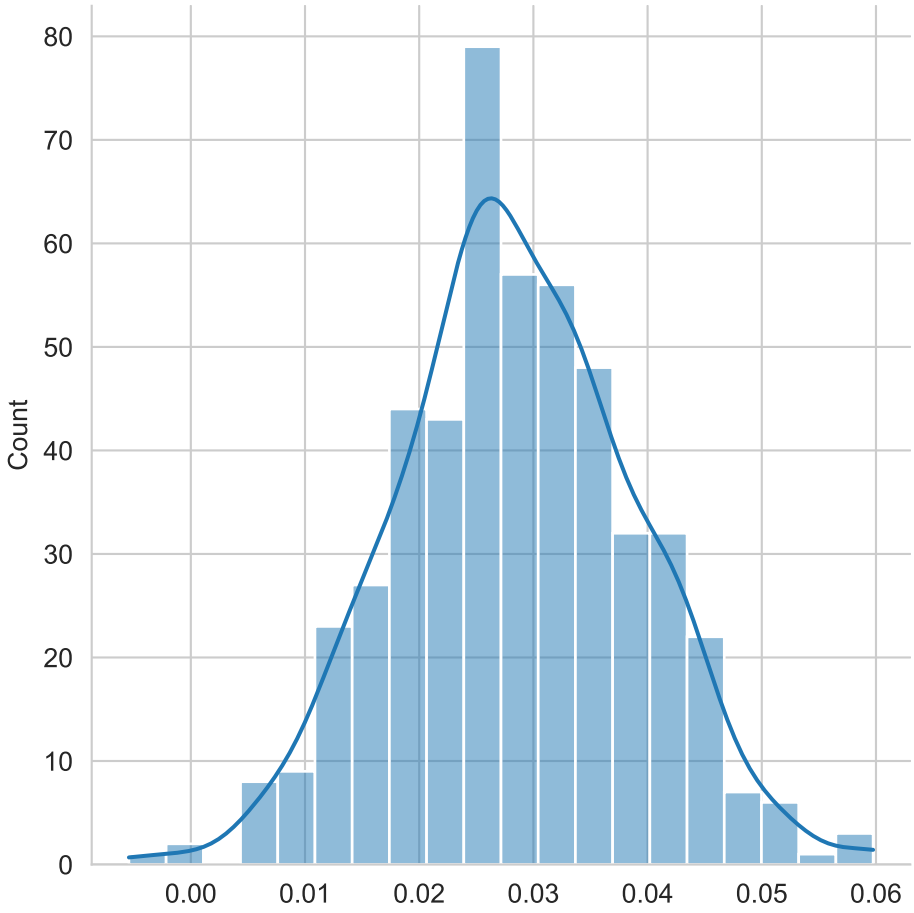


Figura 15.1: Distribución de la diferencia de rendimiento

```
                        forest=forest))
perf = performance(df, score=macro_recall)
```

La variable `perf` contiene las muestras del rendimiento de cada algoritmo. Por ejemplo, la siguiente línea calcula el intervalo de confianza de cada algoritmo.

```
CI(perf)
```

```
{'naive': (np.float64(0.907789704716059), np.float64(0.950913495968842)),
 'forest': (np.float64(0.9391325709794905), np.float64(0.9738480481426753))}
```

Los intervalos de confianza se pueden visualizar en la Figura 15.2.

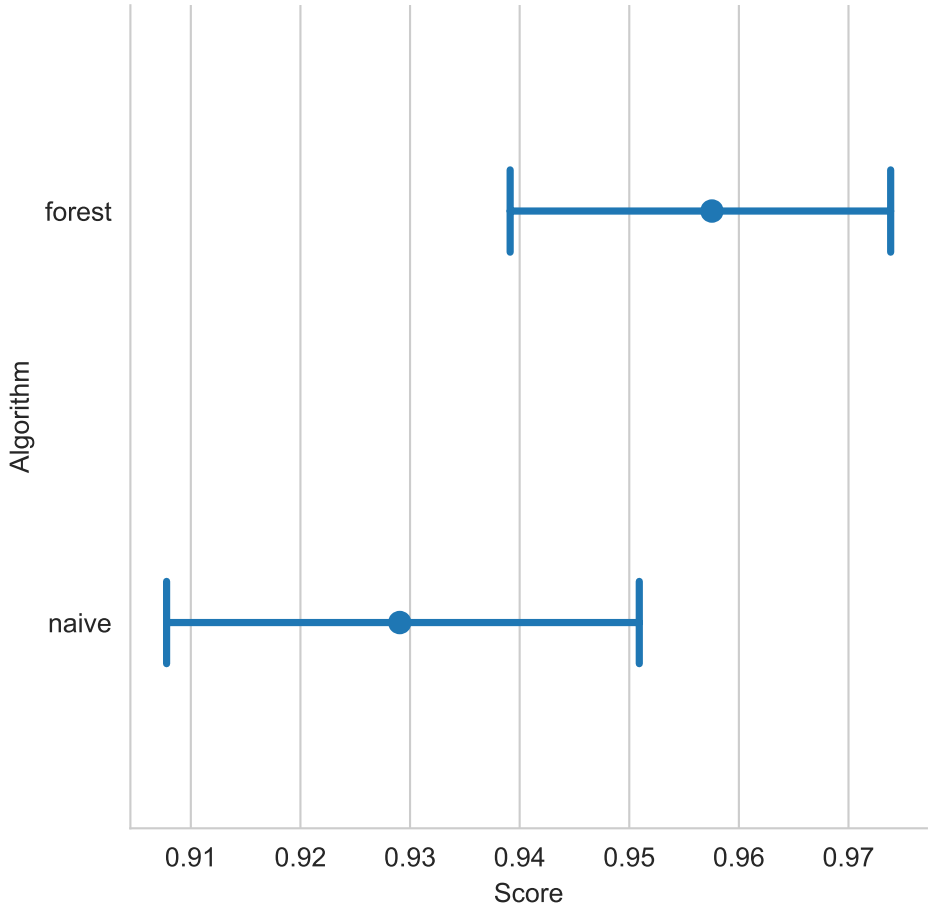


Figura 15.2: Intervalos de confianza

El segundo paso es conocer si la diferencia en rendimiento es significativa, en la Figura 15.3 se observa la comparación entre el mejor algoritmo (i.e., `forest`) y los otros algoritmos (`naive`) incluidos en la comparación. Se observa, en la figura, una línea puntuada que se encuentra en cero para facilitar la comparación, si el intervalo de confianza intersecta con la línea se puede concluir que los algoritmos comparados no son estadísticamente diferentes. En el ejemplo mostrado se ve que el intervalo no intersecta entonces se puede concluir que la hipótesis nula se puede descartar con una cierta confianza.

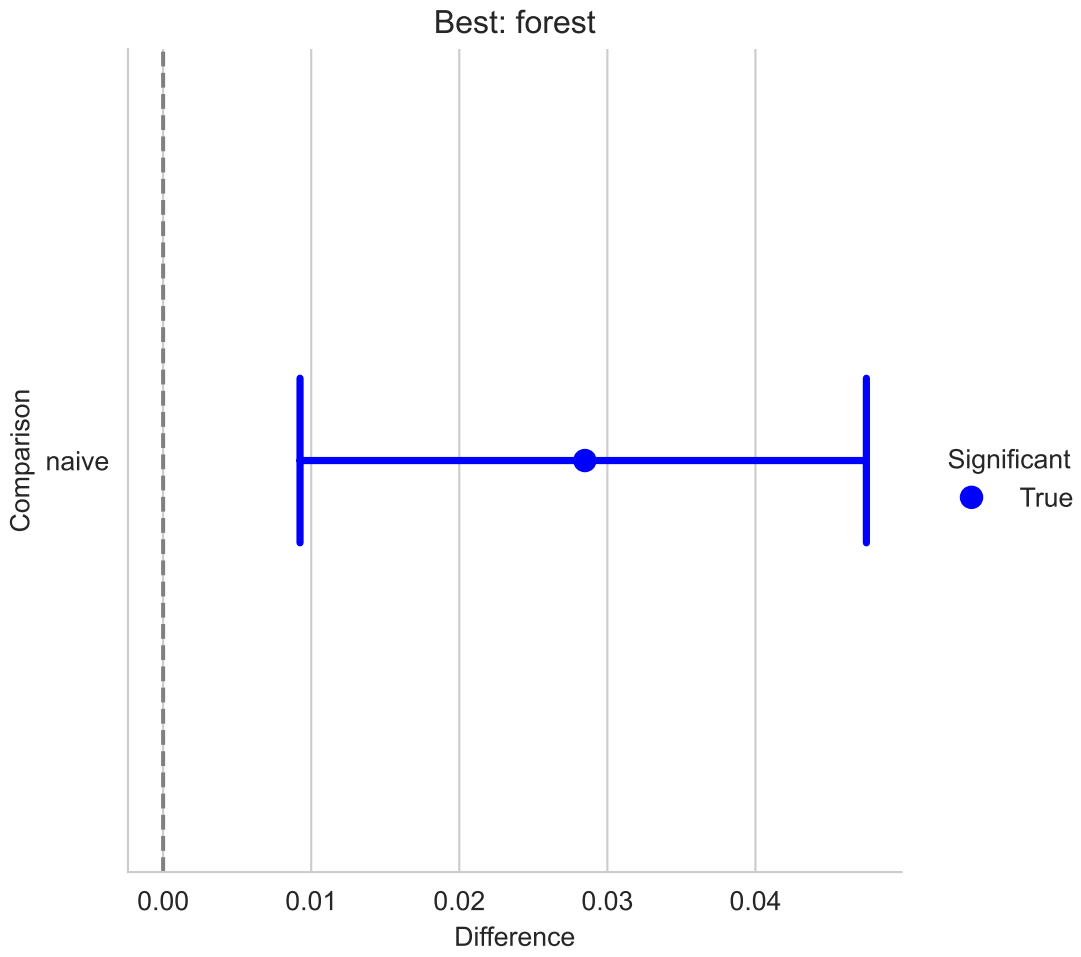


Figura 15.3: Comparación contra el mejor

15.6. Resumen

Una medida de rendimiento calculada en un conjunto de prueba es una estimación, y por lo tanto tiene incertidumbre. Los intervalos de confianza (Sección 15.3) cuantifican esa incertidumbre, ya sea con la distribución normal o con el bootstrap (Sección 15.3.3). Para comparar dos algoritmos no basta con que uno tenga un número mayor, sino que la diferencia debe ser estadísticamente distinta de cero, lo que se puede verificar con la distribución t de Student o con el bootstrap de las diferencias. La librería `CompStats` reúne estos procedimientos y los presenta de manera gráfica (Figura 15.3). En este contexto «mejor» significa distinto con evidencia estadística y no solo mayor.

Este es el último capítulo de esta versión del libro, y retoma el hilo de la Tabla 1.1. Se empezó con la diferencia entre predecir e inferir, se estudiaron modelos de regresión y de clasificación cada vez más flexibles, se vio cómo reducir la dimensión y agrupar, y se terminó con la forma de decidir entre algoritmos. Quedan en preparación los capítulos *Interpretabilidad y Equidad*, *Aprendizaje Computacional e Inferencia Causal* y *Texto como Datos*, que tratan el uso responsable de los modelos, la pregunta de qué pasa cuando se interviene y los datos en forma de texto.

Para el *policy paper* de METPOL, esto se traduce en una práctica concreta. Plantear primero el problema como predicción o como inferencia, medir siempre fuera de muestra con la medida que refleje los costos de cada error, comparar contra un modelo de referencia sencillo con su intervalo de confianza y reportar la elección de manera que otra persona pueda reproducirla.

Referencias

Athey, Susan. 2019. «The Impact of Machine Learning on Economics». En *The Economics of Artificial Intelligence: An Agenda*, editado por Ajay Agrawal, Joshua Gans, y Avi Goldfarb. University of Chicago Press. https://www.nber.org/books-and-chapters/economics-artificial-intelligence-agenda/impact-machine-learning-economics.

Athey, Susan, y Guido W. Imbens. 2019. «Machine Learning Methods That Economists Should Know About». *Annual Review of Economics* 11: 685-725. https://doi.org/10.1146/annurev-economics-080217-053433.

Belloni, Alexandre, Victor Chernozhukov, y Christian Hansen. 2014. «High-Dimensional Methods and Inference on Structural and Treatment Effects». *Journal of Economic Perspectives* 28 (2): 29-50. https://doi.org/10.1257/jep.28.2.29.

Breiman, Leo. 2001a. «Random Forests». *Machine Learning* 45: 5-32. https://doi.org/10.1214/ss/1009213726.

Breiman, Leo. 2001b. «Statistical modeling: The two cultures». *Statistical science* 16 (3): 199-231. https://doi.org/10.1214/ss/1009213726.

Consejo Nacional de Evaluación de la Política de Desarrollo Social. 2025. *Líneas de Pobreza por Ingresos*. https://www.coneval.org.mx/Medicion/MP/Paginas/Lineas-de-Pobreza-por-Ingresos.aspx.

Cortes, Corinna, y Vladimir Vapnik. 1995. «Support vector machine». *Machine learning* 20 (3): 273-97. https://link.springer.com/article/10.1007/BF00994018.

Diamond, Steven, y Stephen Boyd. 2016. «CVXPY: A Python-Embedded Modeling Language for Convex Optimization». *Journal of Machine Learning Research*. https://stanford.edu/~boyd/papers/pdf/cvxpy_paper.pdf.

Esteva, Andre, Brett Kuprel, Roberto A. Novoa, et al. 2017. «Dermatologist-level classification of skin cancer with deep neural networks». *Nature* 542 (7639): 115-18. https://doi.org/10.1038/nature21056.

Fisher, Ronald Aylmer. 1936. «The use of multiple measurements in taxonomic problems».

Annals of Eugenics 7 (2): 179-88. https://doi.org/https://doi.org/10.1111/j.1469-1809.1936.tb02137.x.

Fix, Evelyn, y Joseph Lawson Hodges. 1951. *Discriminatory analysis, nonparametric discrimination: consistency properties*. https://collections.uakron.edu/digital/collection/p15960coll1/id/17162/.

Goutte, Cyril, y Eric Gaussier. 2005. «A Probabilistic Interpretation of Precision, Recall and F-Score, with Implication for Evaluation». En *Advances in Information Retrieval*, editado por David E. Losada y Juan M. Fernández-Luna. Springer Berlin Heidelberg. https://link.springer.com/chapter/10.1007/978-3-540-31865-1_25.

Guyon, Isabelle, y André Elisseeff. 2003. «An Introduction to Variable and Feature Selection». *Journal of Machine Learning Research* 3: 1157-82. https://jmlr.org/papers/v3/guyon03a.html.

Hannun, Awni Y., Pranav Rajpurkar, Masoumeh Haghpanahi, et al. 2019. «Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network». *Nature Medicine* 25 (1): 65-69. https://doi.org/10.1038/s41591-018-0268-3.

Hastie, Trevor, Robert Tibshirani, y Jerome Friedman. 2009. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2.ª ed. Springer. https://doi.org/10.1007/978-0-387-84858-7.

Hoerl, Arthur E., y Robert W. Kennard. 1970. «Ridge Regression: Biased Estimation for Nonorthogonal Problems». *Technometrics* 12 (1): 55-67. https://doi.org/10.1080/00401706.1970.10488634.

Instituto Nacional de Estadística y Geografía. 2021. *Censo de Población y Vivienda 2020. Resultados por AGEB y manzana urbana*. https://www.inegi.org.mx/programas/ccpv/2020/.

Instituto Nacional de Estadística y Geografía. 2023. *Encuesta Nacional de Ingresos y Gastos de los Hogares (ENIGH) 2022, Nueva Serie. Datos abiertos*. https://www.inegi.org.mx/programas/enigh/nc/2022/.

Instituto Nacional de Estadística y Geografía. 2026a. *Directorio Estadístico Nacional de Unidades Económicas (DENUE) 05_2026*. https://www.inegi.org.mx/app/descarga/?ti=6.

Instituto Nacional de Estadística y Geografía. 2026b. *Encuesta Nacional de Victimización y Percepción sobre Seguridad Pública (ENVIPE) 2026. Datos abiertos*. https://www.inegi.org.mx/programas/envipe/2026/.

Instituto Nacional de Salud Pública. 2023. *Encuesta Nacional de Salud y Nutrición Continua*

2022. Bases de datos. https://ensanut.insp.mx/encuestas/ensanutcontinua2022/index.php.

Kleinberg, Jon, Jens Ludwig, Sendhil Mullainathan, y Ziad Obermeyer. 2015. «Prediction Policy Problems». *American Economic Review: Papers & Proceedings* 105 (5): 491-95. https://doi.org/10.1257/aer.p20151023.

Langley, Pat. 1986. «Machine learning: An editorial». *Maching Learning* 1: 5-10. https://doi.org/10.1023/A:1022687019898.

McInnes, Leland, John Healy, y James Melville. 2020. *UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction*. https://arxiv.org/abs/1802.03426.

Mullainathan, Sendhil, y Jann Spiess. 2017. «Machine Learning: An Applied Econometric Approach». *Journal of Economic Perspectives* 31 (2): 87-106. https://doi.org/10.1257/jep.31.2.87.

Nava-Muñoz, Sergio, Mario Graff, y Hugo Jair Escalante. 2024. «Analysis of systems' performance in natural language processing competitions». *Pattern Recognition Letters*, advance online publication, marzo. https://doi.org/10.1016/J.PATREC.2024.03.010.

Quinlan, J. R. 1986. «Induction of decision trees». *Machine Learning 1986 1:1* 1 (marzo): 81-106. https://doi.org/10.1007/BF00116251.

Sarewitz, Daniel, y Roger A. Pielke Jr. 1999. «Prediction in science and policy». *Technology in Society* 21 (2): 121-33. https://doi.org/10.1016/S0160-791X(99)00002-0.

Sebastiani, Fabrizio. 2015. «An Axiomatically Derived Measure for the Evaluation of Classification Algorithms». *Proceedings of the 2015 International Conference on The Theory of Information Retrieval* (New York, NY, USA), ICTIR '15, 11-20. https://doi.org/10.1145/2808194.2809449.

Secretaría de Educación Pública. 2024. *Registro del alumnado y personal docente de educación básica, media superior y superior (formato 911)*. https://www.datos.gob.mx/dataset/registro_alumnado_personal_docente_educacion_basica_media_superior_formato_911.

Silver, David, Aja Huang, Chris J. Maddison, et al. 2016. «Mastering the game of Go with deep neural networks and tree search». *Nature* 529 (7587): 484-89. https://doi.org/10.1038/nature16961.

Silver, David, Julian Schrittwieser, Karen Simonyan, et al. 2017. «Mastering the game of Go without human knowledge». *Nature* 550 (7676): 354-59. https://doi.org/10.1038/nature24270.

Street, William Nick, William H. Wolberg, y Olvi L. Mangasarian. 1993. «Nuclear feature extraction for breast tumor diagnosis». *Electronic imaging*. https://api.semanticscholar.org/CorpusID:14922543.

Tibshirani, Robert. 1996. «Regression Shrinkage and Selection via the Lasso». *Journal of the Royal Statistical Society: Series B (Methodological)* 58 (1): 267-88. https://doi.org/10.1111/j.2517-6161.1996.tb02080.x.

Varian, Hal R. 2014. «Big Data: New Tricks for Econometrics». *Journal of Economic Perspectives* 28 (2): 3-28. https://doi.org/10.1257/jep.28.2.3.

Wasserman, Larry. 2004. *All of Statistics : A Concise Course in Statistical Inference*. Springer. https://doi.org/10.1007/978-0-387-21736-9.

Wolpert, David H. 1992. «Stacked generalization». *Neural Networks* 5 (2): 241-59. https://doi.org/https://doi.org/10.1016/S0893-6080(05)80023-1.

Xu, L., A. Krzyzak, y C. Y. Suen. 1992. «Methods of combining multiple classifiers and their applications to handwriting recognition». *IEEE Transactions on Systems, Man, and Cybernetics* 22 (3): 418-35. https://doi.org/10.1109/21.155943.

Zou, Hui, y Trevor Hastie. 2005. «Regularization and Variable Selection via the Elastic Net». *Journal of the Royal Statistical Society: Series B (Statistical Methodology)* 67 (2): 301-20. https://doi.org/10.1111/j.1467-9868.2005.00503.x.

A Estadística

El **objetivo** de este apéndice es complementar la información de algunos procedimientos estadísticos usados en el curso.

Paquetes usados

```
from scipy.stats import norm
from matplotlib import pylab as plt
import numpy as np
import pandas as pd
import seaborn as sns
```

A.1. Error estándar

El **error estándar** está definido como $\sqrt{\mathbb{V}(\hat{\theta})}$ donde $\hat{\theta}$ es el valor estimado. No para todas las estadísticas es posible tener una ecuación analítica para calcular $\sqrt{\mathbb{V}(\hat{\theta})}$ y en los casos donde el valor analítico no se puede calcular se puede usar la técnica de Bootstrap.

A.1.1. Media

Una de las estadísticas donde sí se puede calcular analíticamente $\sqrt{\mathbb{V}(\hat{\theta})}$ es la media, es decir, se tiene una muestra $\mathcal{D}$ con N elementos independientes y idénticamente distribuidos, entonces la media corresponde a

$$\bar{x} = \frac{1}{N} \sum_{x \in \mathcal{D}} x.$$

El error estándar de $\bar{x}$ es $\sqrt{\mathbb{V}(\bar{x})}$. Para derivar el valor analítico de este error estándar es necesario utilizar la siguiente propiedad de la varianza:

$$\mathbb{V}(\sum_i a_i \mathcal{X}_i) = \sum_i a_i^2 \mathbb{V}(\mathcal{X}_i),$$

donde a_i representa una constante y las variables aleatorias $\mathcal{X}$ son independientes. En lugar de utilizar la definición asumiendo la realización de las variables aleatorias, esto es, cuando $\mathcal{D}$ tiene valores, se define la media con respecto a N variables aleatorias, i.e., $\bar{\mathcal{X}} = \frac{1}{N}\sum_i^N \mathcal{X}_i$. En estas condiciones se observa que para el caso del error estándar de la media la constante es $\frac{1}{N}$ y las variables son independientes entonces

$$\begin{aligned}
\sqrt{\mathbb{V}(\bar{\mathcal{X}})} &= \sqrt{\mathbb{V}(\frac{1}{N}\sum_i^N \mathcal{X}_i)} \\
&= \sqrt{\sum_i^N \frac{1}{N^2}\mathbb{V}(\mathcal{X}_i)} \\
&= \sqrt{\frac{1}{N^2}\sum_i^N \sigma^2} \\
&= \sqrt{\frac{N}{N^2}\sigma^2} \\
&= \sqrt{\frac{\sigma^2}{N}} = \frac{\sigma}{\sqrt{N}},
\end{aligned}$$

donde σ^2 es la varianza de la distribución. Es importante notar que $\mathbb{V}(X_i)$ es independiente de i dado $\mathcal{X}_i \sim F$ para cualquier i, donde la distribución F tiene una varianza σ^2 por lo tanto $\mathbb{V}(X_i) = \sigma^2$.

A.1.2. Ejemplo: Media

El siguiente ejemplo complementa la información al presentar el error estándar de la media cuando los datos vienen de una distribución Gaussiana. Suponiendo que se tienen 1000 muestras de una distribución Gaussiana $\mathcal{N}(1, 4)$, i.e., $\mu = 1$ y $\sigma = 2$. El error estándar de estimar la media con esos datos está dado por $\mathbb{V}(\widehat{\mu}) = \frac{\sigma}{\sqrt{N}} = \frac{2}{\sqrt{1000}} = 0.0632$.

Continuando con el ejemplo, se simula la generación de esta población de 1000 elementos. El primer paso es iniciar la clase `norm` (que implementa una distribución Gaussiana) para que se simule $\mathcal{N}(1, 4)$. Es importante notar que el parámetro `scale` de `norm` corresponde a la desviación estándar σ.

```
p1 = norm(loc=1, scale=2)
```

Usando `p1` se simulan 500 poblaciones de 1000 elementos cada una, y para cada una de esas poblaciones se calcula su media. La primera línea crea la muestra $\mathcal{D}$ y a continuación se calcula la media por cada población, renglón de `D`.

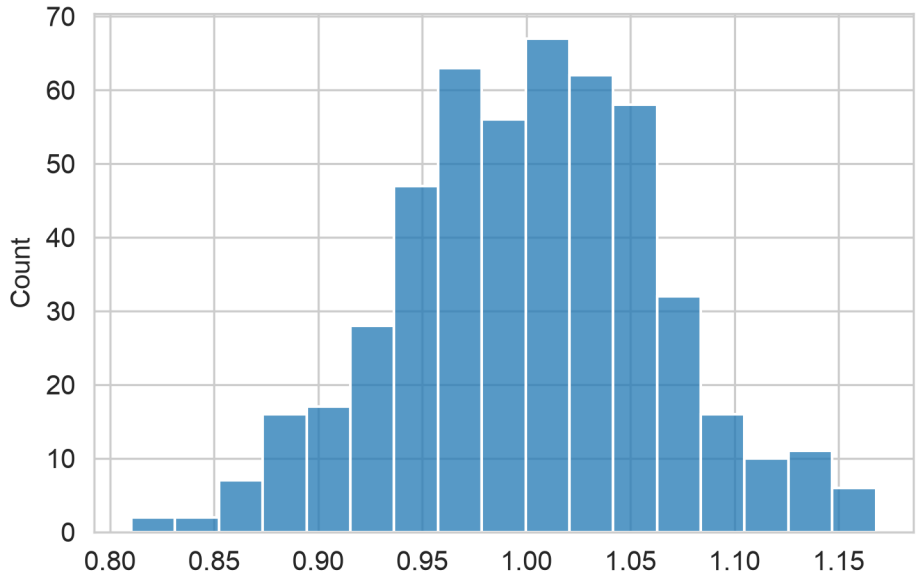
```
D = p1.rvs(size=(500, 1000))
mu = [x.mean() for x in D]
```

El error estándar es la desviación estándar de `mu`, el cual se puede calcular con la siguiente instrucción. `se` tiene un valor de 0.0632, que es similar al obtenido mediante $\mathbb{V}(\hat{\mu})$.

```
se = np.std(mu)
```

Para complementar la información se presenta el histograma de `mu` donde se puede observar la distribución de estimar la media de una población.

```
fig = sns.histplot(mu)
```



A.1.3. Ejemplo: Coeficientes OLS

El error estándar de los coeficientes estimados con mínimos cuadrados se puede calcular de la siguiente forma. El primer paso es utilizar la siguiente identidad

$$\mathbb{V}(A\mathcal{Y}) = A\Sigma A^\top,$$

donde A es una matriz y $\mathcal{Y}$ es un vector de variables aleatorias. La matriz A en OLS es

$$A = (X^\top X)^{-1} X^\top.$$

quedando la varianza como

$$\mathbb{V}(\mathbf{w}) = A\Sigma A^\top,$$

donde Σ es la covarianza de $\mathcal{Y}$. Dado que $\mathcal{Y}$ tiene una varianza constante entonces $\Sigma = \sigma^2 I$. Usando esta información se puede derivar la varianza de $\mathbf{w}$ de la siguiente manera

$$\begin{aligned}
\mathbb{V}(\mathbf{w}) &= A\sigma^2 I A^\top \\
&= \sigma^2 A A^\top \\
&= \sigma^2 (X^\top X)^{-1} X^\top ((X^\top X)^{-1} X^\top)^\top \\
&= \sigma^2 (X^\top X)^{-1} X^\top X (X^\top X)^{-1} \\
&= \sigma^2 (X^\top X)^{-1}
\end{aligned}$$

Por lo tanto el error estándar es: $\mathsf{se}(\mathbf{w}) = \sigma\sqrt{(X^\top X)^{-1}}$.

A.2. Bootstrap

Existen ocasiones donde no se cuenta con una ecuación cerrada para $\mathbb{V}(\hat{\theta})$, un ejemplo sería la mediana. En aquellas estadísticas donde no se tenga el error estándar no se pueda calcular analíticamente se puede utilizar Bootstrap.

Bootstrap es un procedimiento que permite calcular el error estándar. Suponiendo que la estadística se calcula mediante la realización de N variables aleatorias, $\mathcal{X} \sim F$, es decir, $\theta = g(\mathcal{X}_1, \mathcal{X}_2, \ldots, \mathcal{X}_N)$. Por ejemplo, la media es $g(\mathcal{X}_1, \mathcal{X}_2, \ldots, \mathcal{X}_N) = \frac{1}{N}\sum_i^N \mathcal{X}_i$.

El Bootstrap simula la distribución θ mediante la selección con remplazo de N elementos del conjunto de la muestra $\mathcal{D} = (x_1, x_2, \ldots, x_n)$ donde $x_i \sim F$. Es decir, se genera un nuevo conjunto $\mathcal{D}_j = (x_{j_1}, x_{j_2}, \ldots, x_{j_n})$ donde x_{j_1} podría ser x_4 de $\mathcal{D}$ y dado que se selecciona con

reemplazo entonces x_4 podría aparecer otra vez en $\mathcal{D}_j$. Utilizando $\mathcal{D}_j$ se puede estimar la estadística $\hat{\theta}_j = g(x_{j_1}, x_{j_2}, \ldots, x_{j_n})$. Bootstrap repite el proceso anterior B veces donde en cada iteración se selecciona con reemplazo N veces $\mathcal{D}$. Utilizando las θ_j calculadas se estima $\mathbb{V}(\theta)$ con la siguiente ecuación

$$\mathbb{V}(\hat{\theta}) = \frac{1}{B}\sum_{j=1}^{B}(\hat{\theta}_j - \frac{1}{B}\sum_{k}^{B}\hat{\theta}_k)^2.$$

A.2.1. Ejemplo

Utilizando los datos generados en la Sección A.1.2 se puede calcular el error estándar de la mediana. El primer paso es tener el conjunto $\mathcal{D}$ el cual puede ser cualquier renglón de los 500 de la variable `D`, por simplicidad se toma el primero como se muestra a continuación.

```
D_mediana = D[0]
```

La variable `D_mediana` tiene la muestra $\mathcal{D}$ con la que se trabajará para estimar el error estándar de la mediana. Se tienen que generar B repeticiones de muestrear $\mathcal{D}$ N veces con reemplazo. Esto se puede implementar usando índices y números aleatorios de $[0, N)$ considerando que en Python el primer índice es 0. Este procedimiento se muestra en la primera línea del siguiente código. El arreglo `S` contiene los índices para realizar las B muestras, en la segunda línea se itera por los renglones de `S` y en cada operación se calcula la mediana. Es decir, en cada iteración se está calculando un $\hat{\theta}_i$ que corresponde a la mediana. Finalmente, se calcula la desviación estándar de la lista `B` y ese valor corresponde al error estándar de la mediana.

```
S = np.random.randint(D_mediana.shape[0],
                      size=(500, D_mediana.shape[0]))
B = [np.median(D_mediana[s]) for s in S]
se = np.std(B)
```

`se` tiene un valor de 0.0902.

Considerando que se generaron 500 poblaciones de 1000 elementos que se encuentran en la variable `D` se puede visualizar el histograma de las medianas calculadas con `D` y aquellas obtenidas con Bootstrap. Se guardan estos dos valores en un `DataFrame` para posteriormente graficar el histograma, como se muestra en el siguiente código y en la Figura A.1.

```
df = pd.DataFrame(dict(Bootstrap=B,
                       Muestra=[np.median(x) for x in D]))
fig = sns.histplot(df)
```

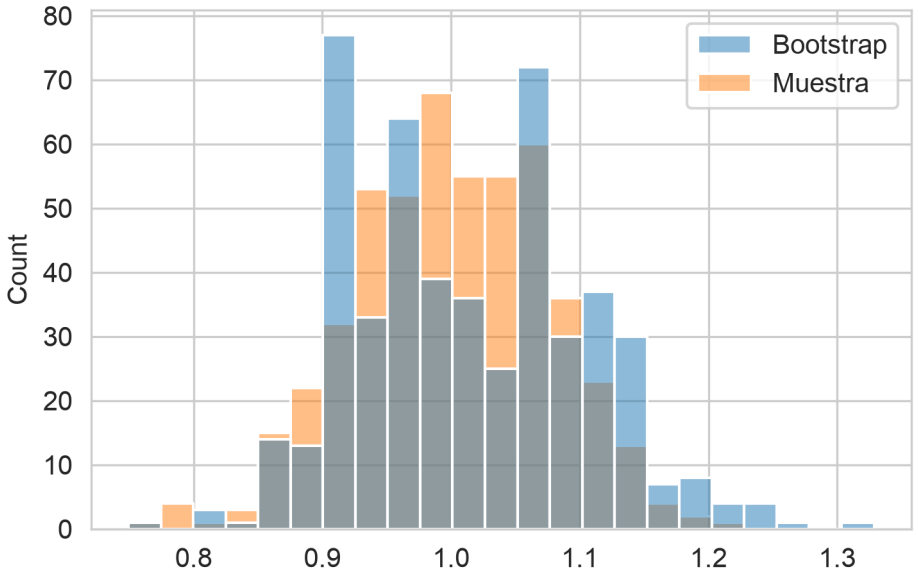


Figura A.1: Histograma de la mediana

B Conjunto de Datos

El **objetivo** de este apéndice es listar los conjuntos de datos utilizados en el curso. Primero se presentan los conjuntos de política pública mexicanos, cada uno con su ficha (fuente, licencia, unidad de observación, variables) y la tarea de aprendizaje que lo motiva; al final se conservan, como problemas sintéticos y clásicos, los conjuntos que se usan para ilustrar los algoritmos.

Paquetes usados

```
from sklearn.datasets import load_breast_cancer,\
                             load_diabetes,\
                             load_digits, load_iris,\
                             load_wine
from sklearn.preprocessing import StandardScaler
from sklearn import decomposition
from scipy.stats import multivariate_normal
import umap
from matplotlib import pylab as plt
import matplotlib as mpl
import numpy as np
import pandas as pd
import seaborn as sns
PALETTE = mpl.cm.Paired
```

B.1. Problemas de Política Pública

Los conjuntos de esta sección provienen de encuestas y registros administrativos oficiales de México y cada uno responde a una decisión pública concreta, como a quién dirigir un programa social, dónde reforzar la prevención del delito, a quién ofrecer un tamizaje de salud, qué planteles apoyar para que sus estudiantes no abandonen la escuela o cómo aproximar las condiciones de un barrio cuando el censo ya no es reciente. Los archivos procesados están en el release `datos-v1` del repositorio del libro y el código de cada subsección los lee directamente de ahí. La Tabla B.1 resume los cinco conjuntos. En ella, el tamaño N es el número de observaciones y

la dimensión d es el número de variables predictoras, es decir, no cuenta la variable objetivo ni las columnas que son factores de expansión o identificadores.

Tabla B.1: Problemas de política pública

Nombre	Unidad	Tamaño (N)	Dimensión (d)	Tarea	Año	Fuente
Pobreza	Hogar	89988	42	Clasificación (binaria)	2022	ENIGH, INEGI
Seguridad	Persona	91797	49	Clasificación (binaria)	2025	ENVIPE, INEGI
Salud	Adulto	6143	16	Clasificación (binaria)	2022	ENSANUT, INSP
Educación	Secundaria	26689	17	Regresión	2023-2025	Formato 911, SEP
Territorio	AGEB urbana	464	30	Regresión	2020 y 2026	Censo y DENUE, INEGI

B.1.1. Pobreza

Los programas de transferencias necesitan decidir qué hogares son elegibles, pero medir el ingreso de un hogar es costoso, poco confiable y, en el caso de la informalidad, casi imposible de verificar. Una alternativa es la *prueba de medios sustituta* (*proxy means test*), que consiste en predecir si un hogar es pobre a partir de características fáciles de observar de su vivienda y de su composición, y usar esa predicción para focalizar. La tarea de este conjunto es precisamente esa, clasificar si un hogar se encuentra por debajo de la línea de pobreza por ingresos sin usar ninguna variable de ingreso ni de gasto.

Ficha

- **Fuente:** Encuesta Nacional de Ingresos y Gastos de los Hogares (ENIGH) 2022, Nueva Serie, del INEGI (Instituto Nacional de Estadística y Geografía (2023)), datos abiertos. La línea de pobreza por ingresos de agosto de 2022 (canasta alimentaria más no alimentaria, valor mensual por persona) es la que publica el CONEVAL (Consejo Nacional de Evaluación de la Política de Desarrollo Social (2025)) y vale \$2,970.19 en el ámbito rural y \$4,157.63 en el urbano.

- **Licencia:** Términos de libre uso de la información del INEGI.
- **Unidad de observación:** hogar.
- **Tamaño:** $N = 89988$ hogares, que son todos los de la encuesta con información completa en las variables usadas.
- **Variables:** $d = 42$ predictoras observables de la vivienda y el hogar, entre ellas la entidad federativa, el tamaño de localidad, el tipo de hogar, el número y las edades de los integrantes, el sexo, la edad y la escolaridad de la jefatura, los materiales de la vivienda (paredes, techo, piso), los cuartos y dormitorios, los servicios (agua, drenaje, electricidad, combustible para cocinar, basura), la tenencia, y los bienes y el equipamiento (vehículos, computadoras, refrigeradores, lavadoras, internet, etc.). No hay ninguna variable de ingreso ni de gasto. La columna `factor` es el factor de expansión de la encuesta y no es predictora.
- **Objetivo y tarea:** `pobre_ingresos` vale 1 cuando el ingreso corriente per cápita mensual del hogar (el ingreso corriente trimestral entre tres y entre el número de integrantes) es menor que la línea de pobreza de su ámbito (rural si la localidad tiene menos de 2500 habitantes). Es una tarea de clasificación binaria; es una aproximación a la medición oficial, no la replica.

El siguiente código lee el archivo.

```
pobreza = pd.read_csv('https://github.com/INGEOTEC/AprendizajeComputacional/releases/downloa
```

En el conjunto, la proporción de hogares bajo la línea de pobreza es 32.7 %; si se ponderan los hogares con el factor de expansión es 34.5 %. Por ámbito, es 35.6 % en los hogares rurales y 30.9 % en los urbanos. La Figura B.1 muestra cómo cambia esta proporción con la escolaridad de la jefatura del hogar.

B.1.2. Seguridad

La prevención del delito y el despliegue policial se planean con estadísticas oficiales, pero las denuncias sólo registran una parte de los delitos. Las encuestas de victimización permiten estudiar quién es víctima y qué relación tiene con las condiciones del entorno y la percepción de inseguridad. La tarea de este conjunto es clasificar si una persona fue víctima de algún delito durante el año de referencia. Como las víctimas son una minoría, el problema es de clases desbalanceadas, y equivocarse al no identificar a una víctima y equivocarse al marcar a quien no lo es no cuestan lo mismo, lo que será relevante al hablar de decisiones y costos.

Ficha

- **Fuente:** Encuesta Nacional de Victimización y Percepción sobre Seguridad Pública (ENVIPE) 2026 del INEGI (Instituto Nacional de Estadística y Geografía (2026b)), datos abiertos. Es la edición más reciente publicada al preparar los datos; el periodo de referencia es el año 2025.

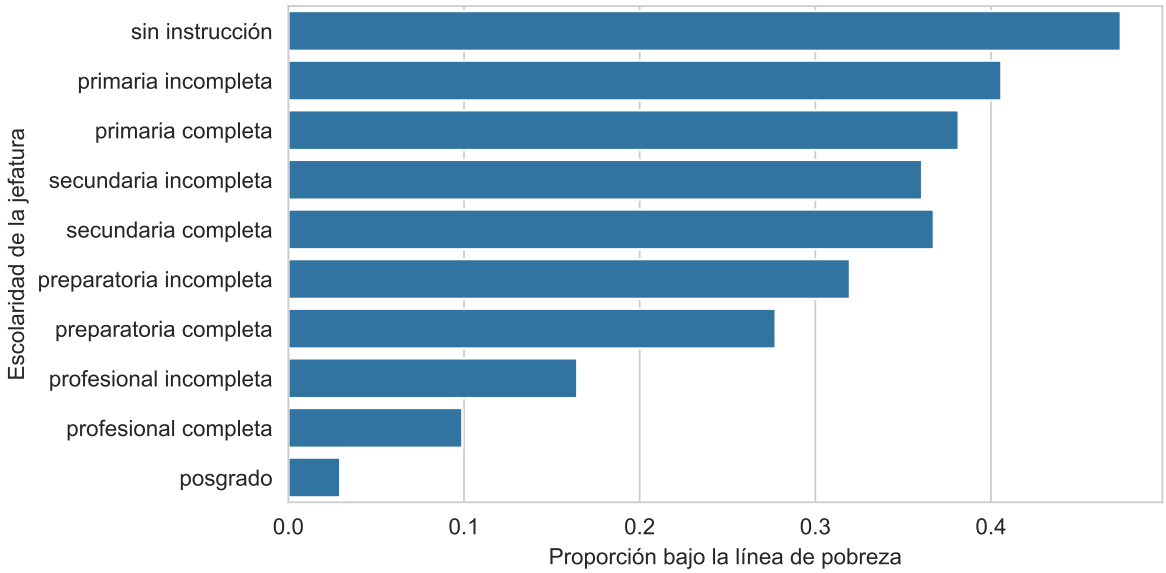


Figura B.1: Proporción de hogares bajo la línea de pobreza por ingresos según la escolaridad de la jefatura del hogar.

- **Licencia:** Términos de libre uso de la información del INEGI.
- **Unidad de observación:** persona de 18 años o más seleccionada como informante.
- **Tamaño:** $N = 91797$ personas, que son todas las seleccionadas como informantes en la encuesta que respondieron si fueron víctimas de algún delito personal.
- **Variables:** $d = 49$ predictoras, entre ellas la entidad, el dominio (urbano, complemento urbano o rural), el sexo, la edad, el nivel de instrucción, la condición de actividad, el tamaño del hogar, el tiempo en la vivienda y las preguntas de percepción de la encuesta (temas que preocupan, percepción de seguridad en la colonia, el municipio, el estado y en lugares específicos, problemas e incivilidades en la colonia, temor a ser víctima y expectativas). No se incluyen variables que sean consecuencia de la victimización, como las medidas de protección, los cambios de conducta por temor, el contacto con autoridades o la denuncia. La columna `factor` es el factor de expansión y no es predictora.
- **Objetivo y tarea:** `victima_delito` vale 1 cuando la persona declara haber sido víctima, durante 2025, de algún delito personal (robo o asalto, otro tipo de robo, fraude, extorsión, amenazas, lesiones, secuestro, delitos sexuales u otros). Los delitos que afectan al hogar, como el robo de vehículo o a casa habitación, no forman parte del objetivo. Es una tarea de clasificación binaria con clases desbalanceadas.

El siguiente código lee el archivo.

```
seguridad = pd.read_csv('https://github.com/INGEOTEC/AprendizajeComputacional/releases/downl
```

En el conjunto hay 5034 víctimas, es decir, 5.5 % de las personas (5.7 % al ponderar con el factor de expansión). La Figura B.2 muestra la proporción de víctimas por grupo de edad y sexo.

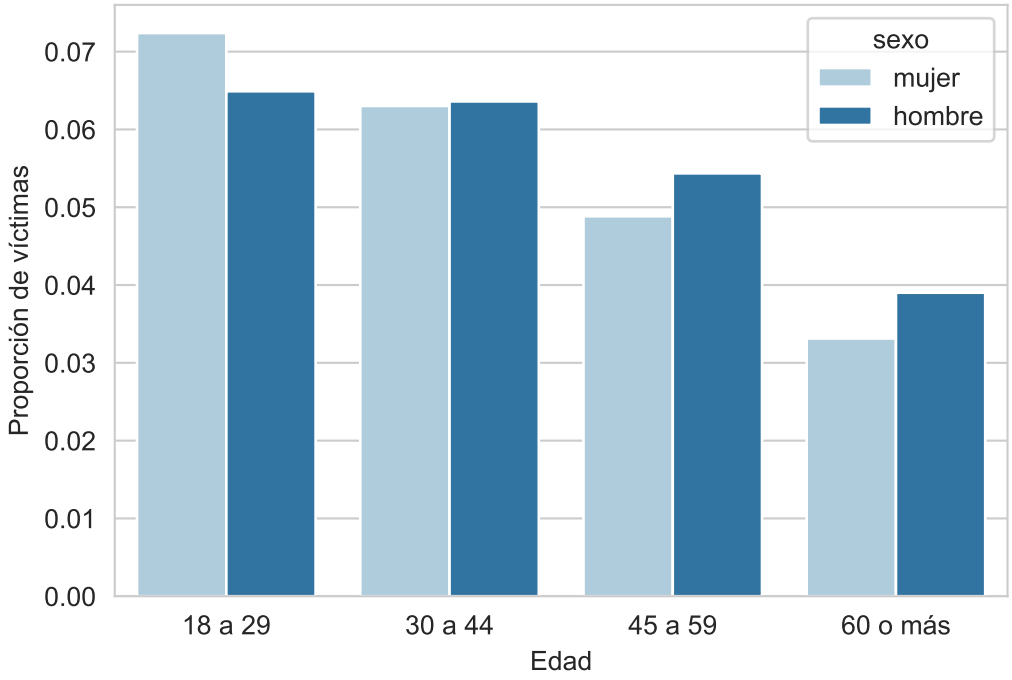


Figura B.2: Proporción de personas que fueron víctimas de algún delito personal por grupo de edad y sexo.

B.1.3. Salud

Los sistemas de salud no pueden hacer pruebas de glucosa a toda la población adulta con la misma frecuencia, por lo que el tamizaje se dirige a las personas con más riesgo. Saber qué características permiten anticipar el diagnóstico de diabetes, y cuántos casos se perderían con cada regla de focalización, es una decisión de política de salud pública. La tarea de este conjunto es clasificar si una persona adulta tiene un diagnóstico médico previo de diabetes. Hay que tener presente que un diagnóstico previo no es lo mismo que la presencia de la enfermedad, pues las personas sin acceso a servicios de salud pueden tener diabetes sin saberlo.

Ficha

- **Fuente:** Encuesta Nacional de Salud y Nutrición Continua (ENSANUT) 2022 del Instituto Nacional de Salud Pública (INSP) (Instituto Nacional de Salud Pública (2023)), bases de

datos. Se combinan el cuestionario de salud de adultos, el de antropometría y tensión arterial y el índice de bienestar del hogar.
- **Licencia:** acceso libre para investigación y docencia, citando al INSP como fuente.
- **Unidad de observación:** persona adulta con mediciones de peso, talla y tensión arterial; las edades van de 20 a 69 años. Se excluyen las mujeres embarazadas o en lactancia y las personas con diabetes sólo durante el embarazo.
- **Tamaño:** $N = 6143$ personas.
- **Variables:** $d = 16$ predictoras, entre ellas la entidad, el tamaño de localidad, el quintil del índice de bienestar del hogar, el sexo, la edad, el peso, la talla, el índice de masa corporal y la tensión arterial medidos, diagnóstico previo de hipertensión, antecedentes familiares de diabetes (padre, madre y hermanos), tabaquismo y consumo de alcohol. No se incluye ninguna pregunta sobre el tratamiento ni las complicaciones de la diabetes. La columna `factor` es el ponderador de la encuesta y no es predictora.
- **Objetivo y tarea:** `diabetes` vale 1 cuando un médico le dijo a la persona que tiene diabetes (o azúcar alta en la sangre). Se eligió diabetes y no hipertensión porque hay suficientes casos, y es una tarea de clasificación binaria.

El siguiente código lee el archivo.

```
salud = pd.read_csv('https://github.com/INGEOTEC/AprendizajeComputacional/releases/download/
```

En el conjunto hay 558 personas con diagnóstico de diabetes, es decir, 9.1 %. La Figura B.3 muestra que la proporción aumenta con la edad y con el índice de masa corporal.

B.1.4. Educación

El abandono escolar es uno de los principales obstáculos para que la educación cumpla su papel como mecanismo de movilidad social, y la transición de la primaria a la secundaria y de la secundaria a la educación media superior es un momento crítico. Los programas de becas, de tutoría y de reinserción tienen recursos limitados y deben decidir qué planteles apoyar primero. La tarea de este conjunto es predecir, para cada secundaria, la tasa de abandono escolar a partir de las características del plantel; como la variable objetivo es numérica, se trata de un problema de regresión.

Ficha

- **Fuente:** Estadística del Formato 911 de la Secretaría de Educación Pública (SEP), registro del alumnado y personal docente de educación básica, media superior y superior (Secretaría de Educación Pública (2024)), publicada en datos.gob.mx. Se usan los archivos de educación básica, nivel secundaria, de los ciclos escolares 2023-2024 y 2024-2025 (este último es el más reciente disponible al preparar los datos).
- **Licencia:** Creative Commons Atribución 4.0 (CC-BY-4.0).

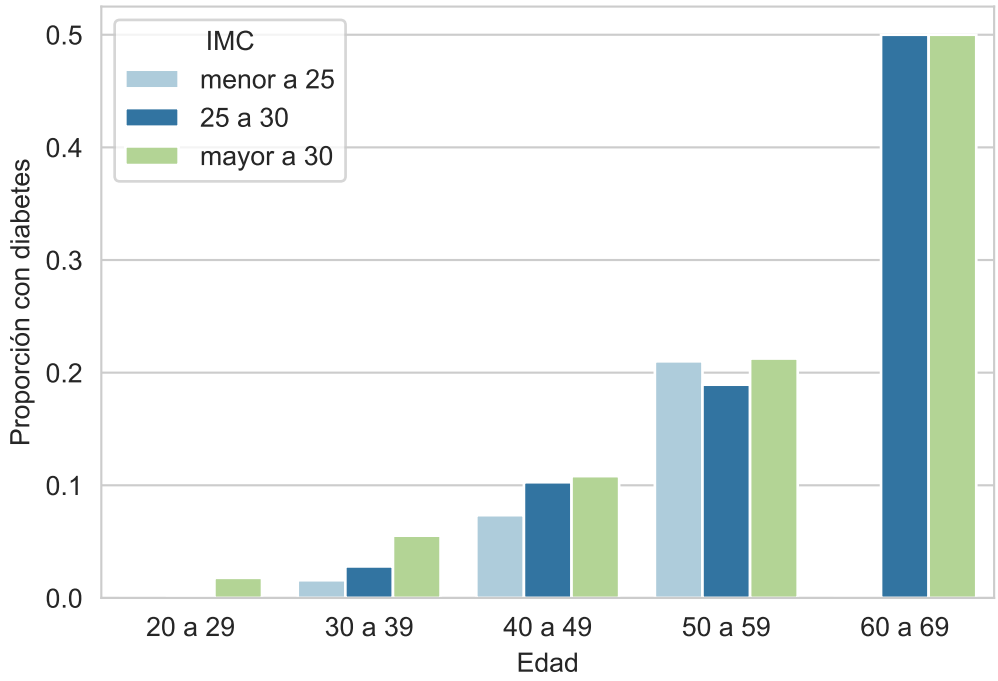


Figura B.3: Proporción de personas con diagnóstico previo de diabetes por grupo de edad y categoría del índice de masa corporal.

- **Unidad de observación:** secundaria-turno, identificada por su clave de centro de trabajo (`clave_cct`) y su turno. Sólo se incluyen los planteles que aparecen en los dos ciclos y que al inicio del ciclo 2023-2024, descontando a los egresados, tenían al menos 30 alumnos, porque las tasas de planteles más pequeños son muy inestables; también se descartan los que no reportan docentes o grupos.
- **Tamaño:** $N = 26689$ planteles.
- **Variables:** $d = 17$ predictoras, todas del ciclo 2023-2024, entre ellas la entidad, el sostenimiento (público o privado y su tipo), el tipo de servicio (general, técnica, telesecundaria o Conafe), el turno, la organización de los docentes, el número de alumnos, de grupos y de docentes, los alumnos por docente y por grupo, los porcentajes de mujeres, de alumnos de primer grado y de repetidores, las aulas en uso, los laboratorios y los talleres. La columna `clave_cct` identifica al plantel y no es predictora. No se usa ninguna cifra del ciclo 2024-2025 como predictora, pues forma parte del objetivo.
- **Objetivo y tarea:** `tasa_abandono` es la tasa de abandono escolar del ciclo 2023-2024 con la definición de la SEP, que compara las matrículas de dos ciclos consecutivos y es igual a $100\left(1 - \frac{M_{t+1} - NI_{t+1}}{M_t - E_t}\right)$, donde M_t es la matrícula al inicio del ciclo t (2023-2024), M_{t+1} la del ciclo siguiente, NI_{t+1} el nuevo ingreso a primer grado del ciclo siguiente y E_t los egresados del ciclo t. Entre planteles hay traslados, por lo que en un plantel individual la tasa puede ser negativa (recibe más alumnos de los que pierde); en esos casos se acota a cero. Es una tarea de regresión.

El siguiente código lee el archivo.

```
educacion = pd.read_csv('https://github.com/INGEOTEC/AprendizajeComputacional/releases/downl
```

La tasa de abandono tiene media 6.9 % y mediana 4.8 %; el 10 % de los planteles con más abandono tiene al menos 16.2 %, y 26.2 % de los planteles tienen una tasa de cero (incluye los casos acotados). La Figura B.4 muestra la distribución de la tasa de abandono.

B.1.5. Territorio

Los censos son la mejor fuente de condiciones sociales a escala de barrio, pero se levantan cada diez años; entre un censo y otro, la planeación urbana y la focalización territorial de programas necesitan aproximaciones con información más reciente. El Directorio Estadístico Nacional de Unidades Económicas (DENUE) se actualiza con frecuencia y dice qué negocios hay en cada zona. La tarea de este conjunto es predecir un indicador censal, el grado promedio de escolaridad, a partir de la composición de establecimientos del DENUE de cada AGEB urbana (área geoestadística básica) del estado de Aguascalientes.

Ficha

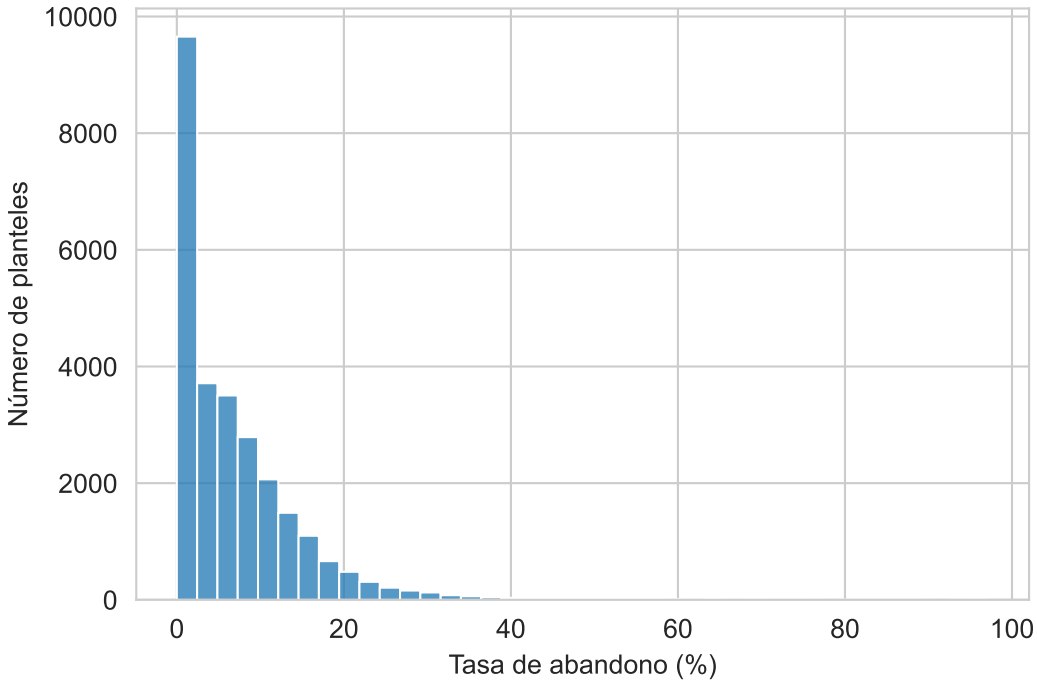


Figura B.4: Distribución de la tasa de abandono escolar de las secundarias.

- **Fuente:** Censo de Población y Vivienda 2020, resultados por AGEB y manzana urbana de Aguascalientes (Instituto Nacional de Estadística y Geografía (2021)), datos abiertos, y DENUE de Aguascalientes, edición 05_2026 (Instituto Nacional de Estadística y Geografía (2026a)), descarga. Ambos son del INEGI.
- **Licencia:** Términos de libre uso de la información del INEGI.
- **Unidad de observación:** AGEB urbana. Se usan los renglones de total por AGEB del censo y se descartan los AGEB con menos de 100 habitantes, donde el grado promedio de escolaridad es muy inestable, y aquellos cuyo valor está suprimido.
- **Tamaño:** $N = 464$ AGEB, con 68905 establecimientos del DENUE en total; 1 AGEB no tienen ningún establecimiento y su conteo es cero.
- **Variables:** $d = 30$ predictoras, que son el número de establecimientos por sector SCIAN (agropecuario, minería, manufactura, comercio al por mayor y al por menor, servicios profesionales, educación, salud, alojamiento y alimentos, entre otros) y por estrato de personal ocupado, el total de establecimientos y dos columnas de tamaño del AGEB (`pob_total` y `viviendas_habitadas`). Los tres indicadores censales adicionales (`pct_viv_internet`, `pct_sin_servicio_salud` y `pct_jefatura_femenina`) sirven como objetivos alternativos y no deben usarse como predictoras cuando el objetivo es la escolaridad. Las columnas `clave_ageb` y `municipio` identifican el AGEB y no son predictoras.
- **Objetivo y tarea:** `grado_promedio_escolaridad` es el grado promedio de escolaridad de la población de 15 años o más en 2020. Es una tarea de regresión.
- **Valores suprimidos:** el censo oculta algunos valores por confidencialidad (`*`) o los reporta como no disponibles (`N/D`). Aquí se tratan explícitamente, pues se descartan los AGEB cuyo objetivo está suprimido y los porcentajes de los indicadores adicionales quedan vacíos cuando su numerador o su denominador está suprimido; hay 1, 1 y 0 valores vacíos en `pct_viv_internet`, `pct_sin_servicio_salud` y `pct_jefatura_femenina`, respectivamente.
- **Desfase temporal:** el censo es de 2020 y el DENUE de 2026, por lo que los establecimientos son más recientes que la población que se describe.

El siguiente código lee el archivo.

```
territorio = pd.read_csv('https://github.com/INGEOTEC/AprendizajeComputacional/releases/downl
```

El grado promedio de escolaridad tiene media 10.80, con un mínimo de 6.92 y un máximo de 15.45 años. La Figura B.5 muestra el grado promedio de escolaridad contra el número de establecimientos por cada mil habitantes de cada AGEB.

B.2. Problemas Sintéticos y Clásicos

En esta sección se conservan los problemas sintéticos y los conjuntos clásicos de clasificación y regresión que se usan, en el resto del libro, para ilustrar el funcionamiento de los algoritmos.

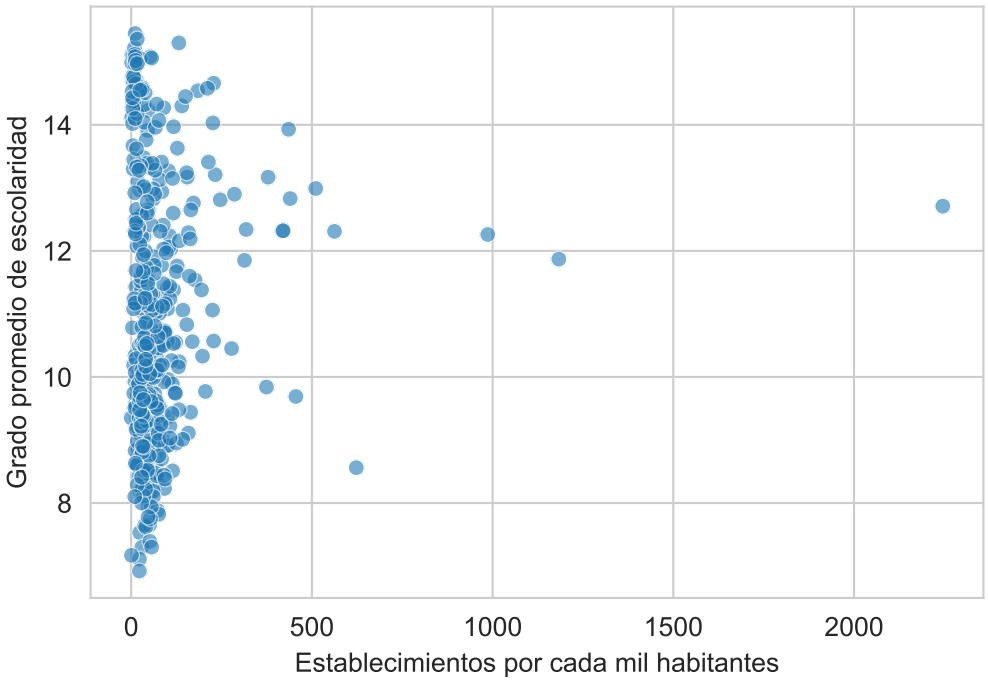


Figura B.5: Grado promedio de escolaridad y establecimientos del DENUE por cada mil habitantes en las AGEB urbanas de Aguascalientes.

B.2.1. Problemas Sintéticos

En esta sección se presentan los problemas sintéticos que corresponden aquellos problemas en los que se conocen todos los parámetros y se usan para mostrar algunas características de los algoritmos.

B.2.1.1. Mezcla de Clases

```
p1 = multivariate_normal(mean=[5, 5],
                         cov=[[4, 0], [0, 2]])
X_1 = p1.rvs(size=1000)
p2 = multivariate_normal(mean=[1.5, -1.5],
                         cov=[[2, 1], [1, 3]])
X_2 = p2.rvs(size=1000)
p3 = multivariate_normal(mean=[12.5, -3.5],
                         cov=[[2, 3], [3, 7]])
X_3 = p3.rvs(size=1000)
```

Figura B.6 muestra estas tres distribuciones.

B.2.1.2. Clases Separadas

```
X_1 = multivariate_normal(mean=[5, 5],
                          cov=[[4, 0], [0, 2]]).rvs(1000)
X_2 = multivariate_normal(mean=[-5, -10],
                          cov=[[2, 1], [1, 3]]).rvs(1000)
X_3 = multivariate_normal(mean=[15, -6],
                          cov=[[2, 3], [3, 7]]).rvs(1000)
```

Este problema se muestra en la Figura B.7.

B.2.2. Problemas de Clasificación

En esta sección se listan los problemas de clasificación utilizados durante el curso. La Tabla B.2 resume las principales características de los problemas utilizados. Se incluye la entropía como una medida que está relacionada al desbalance de clases, la entropía está normalizada para que su rango se encuentre entre $[0, 1]$.

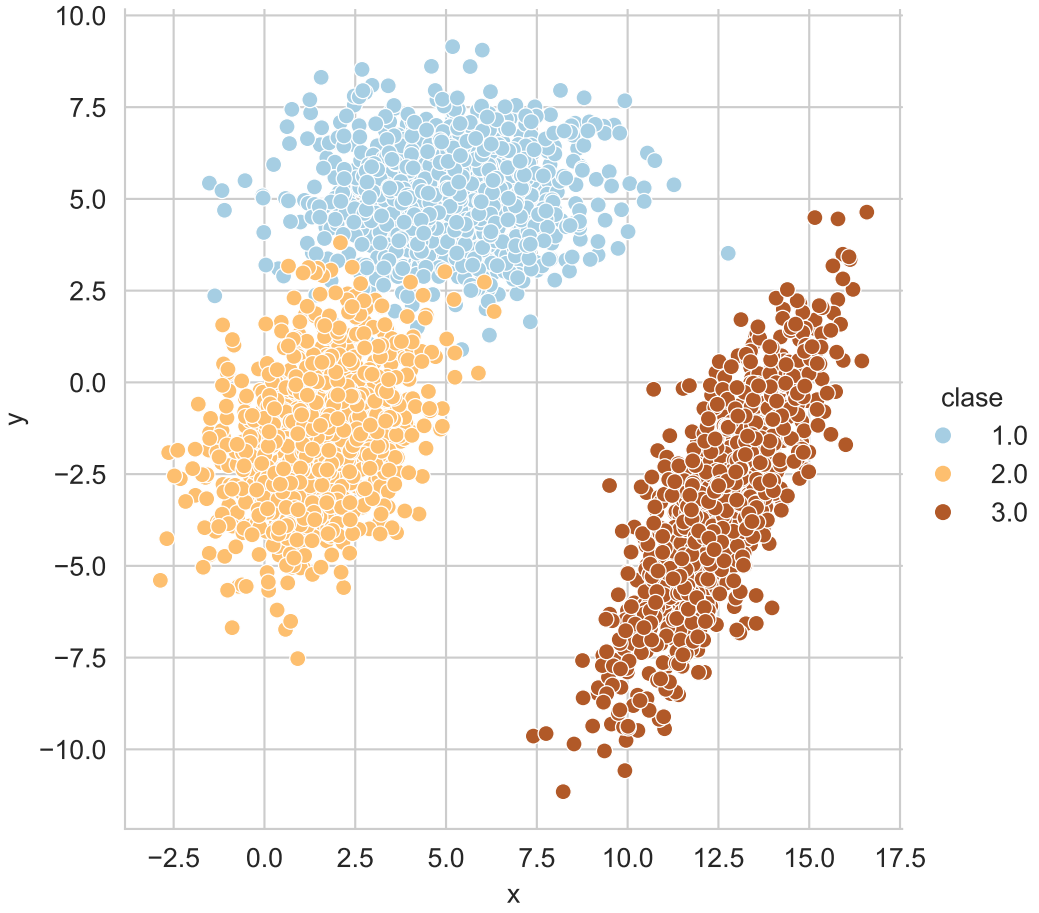


Figura B.6: Muestras de 3 distribuciones gaussianas

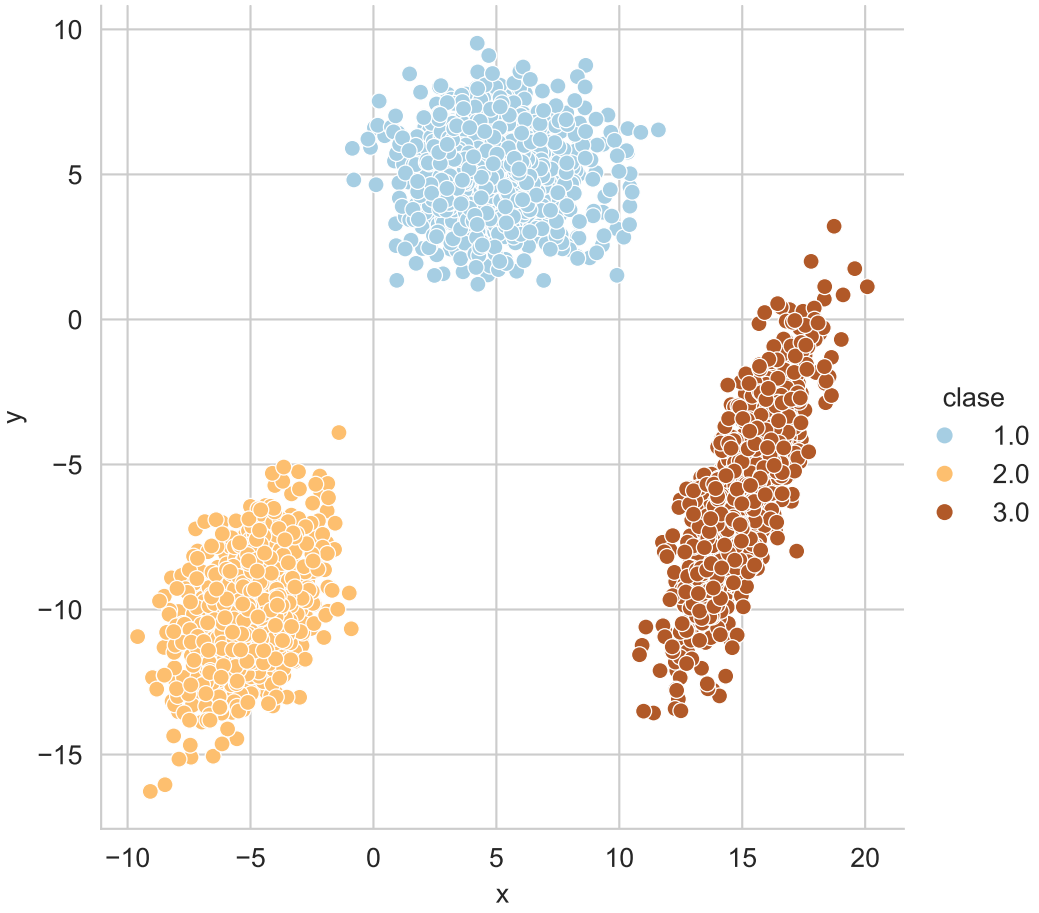


Figura B.7: Muestras de 3 distribuciones gaussianas

Tabla B.2: Problemas de clasificación

Nombre	Tamaño (N)	Dimensión (d)	Número de clases (K)	Entropía
Breast Cancer	569	30	2	0.95
Iris	150	4	3	1.00
Dígitos	1797	64	10	1.00
Vino	178	13	3	0.99

B.2.2.1. Breast Cancer Wisconsin

El conjunto de datos de Breast Cancer Wisconsin (ver Street et al. (1993)) se obtiene con el siguiente código. La Figura B.8 muestra una proyección utilizando PCA de este conjunto de datos.

```
D, y = load_breast_cancer(return_X_y=True)
```

B.2.2.2. Iris

Un conjunto clásico en problemas de clasificación es el problema del Iris descrito por Fisher (1936); este problema se descarga con la siguiente instrucción. La Figura B.9 muestra una visualización de estos datos mediante PCA.

```
D, y = load_iris(return_X_y=True)
```

B.2.2.3. Dígitos

El conjunto de Dígitos (ver Xu et al. (1992)) es un conjunto de clasificación donde se trata de identificar el número escrito en una imagen; este conjunto de datos se descarga utilizando la siguiente instrucción. La Figura B.10 muestra una proyección de estos datos utilizando UMAP con ocho vecinos.

```
D, y = load_digits(return_X_y=True)
```

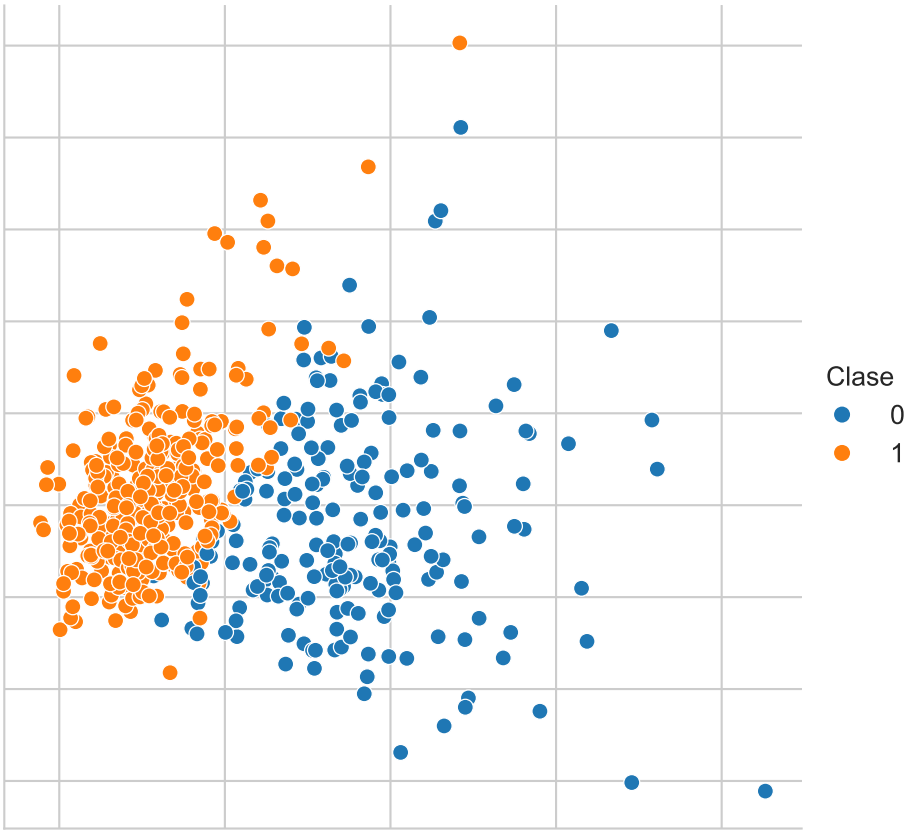


Figura B.8: Proyección mediante PCA del problema de Breast Cancer Wisconsin.

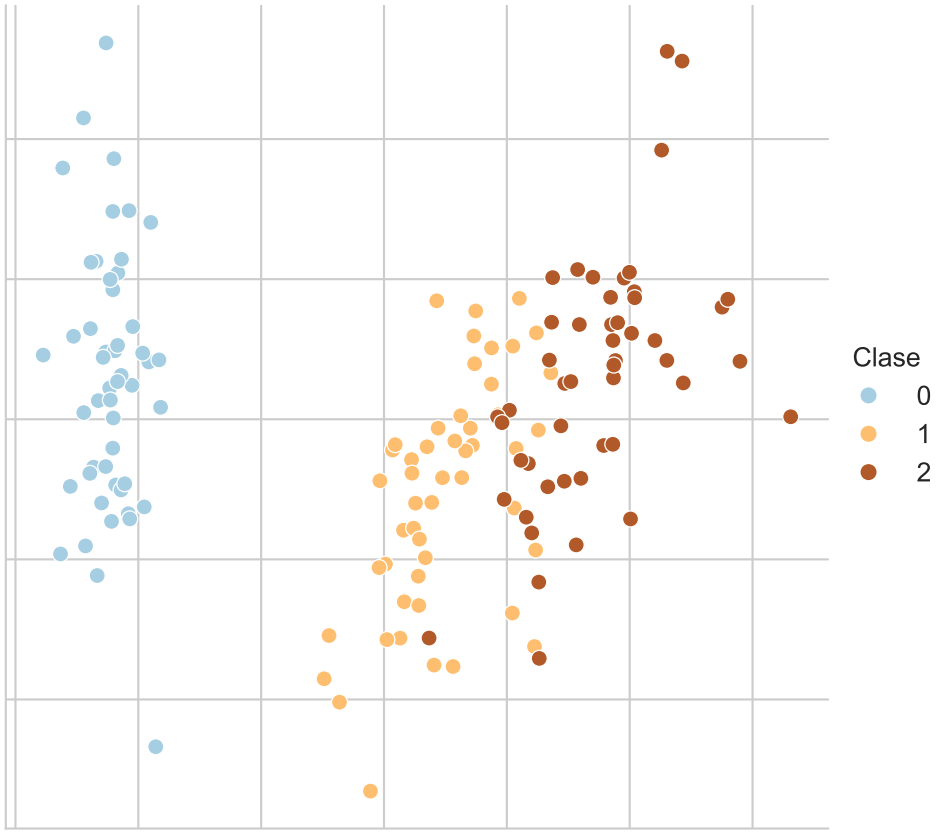


Figura B.9: Proyección mediante PCA del problema del Iris.

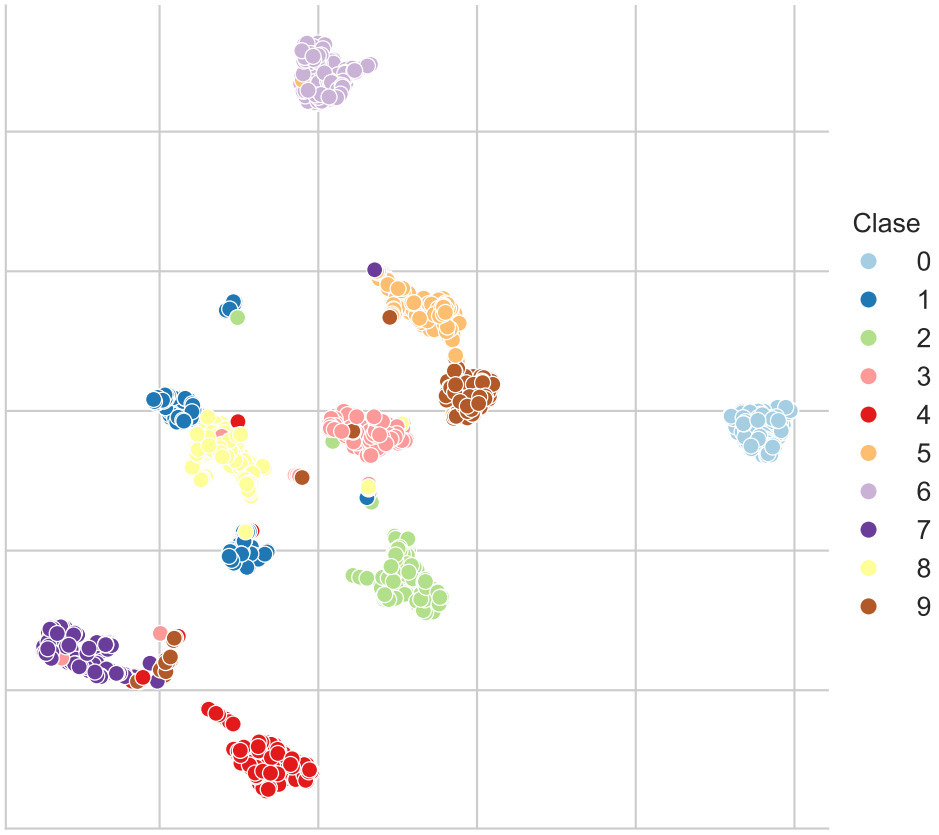


Figura B.10: Proyección mediante UMAP del problema de Dígitos con ocho vecinos.

B.2.2.4. Vino

El conjunto de Vino se obtiene con la siguiente instrucción. La Figura B.11 muestra una proyección de estos datos utilizando PCA.

```
D, y = load_wine(return_X_y=True)
```

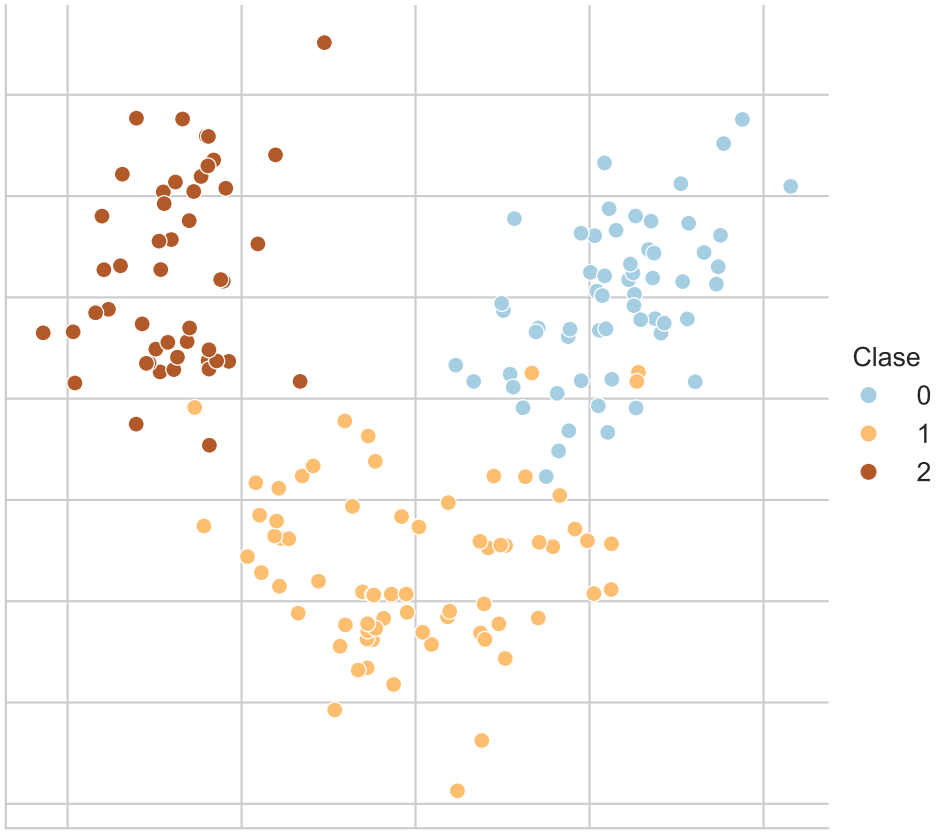


Figura B.11: Proyección mediante PCA del problema del Vino.

B.2.3. Problemas de Regresión

En esta sección se listan los problemas de regresión utilizados para ejemplificar los algoritmos y su rendimiento.

B.2.3.1. Problema Sintético

El siguiente ejemplo es un problema de regresión sintético que se forma de la suma de dos funciones trascendentales como se muestra en el siguiente código.

```
X = np.linspace(-5, 5, 100)
y = np.sin(X) + 0.3 * np.cos(X * 3.)
```

La Figura B.12 muestra este problema sintético.

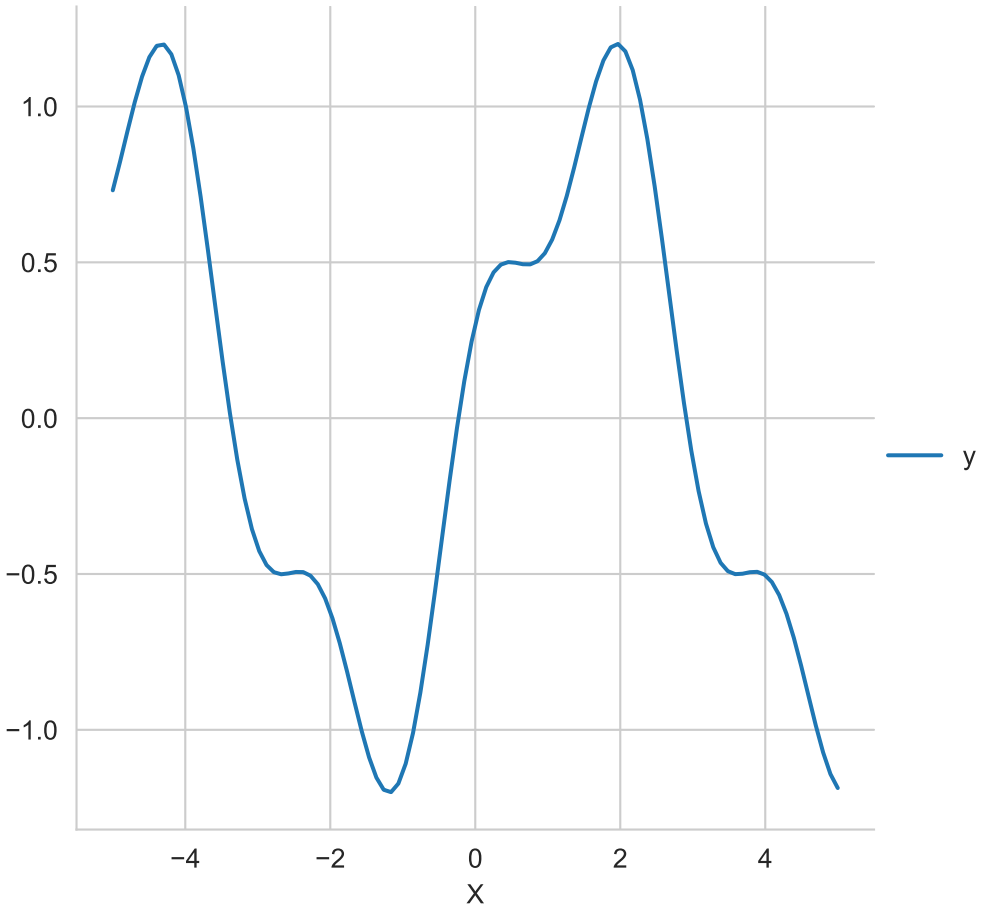


Figura B.12: Problema de Regresión

B.2.3.2. Diabetes

El conjunto de datos Diabetes es un problema que se puede recuperar usando el siguiente código.

```
D, y = load_diabetes(return_X_y=True)
```